

Grundlagen der Testtheorie

BSc Psychologie WiSe 2026/27

Prof. Dr. Dirk Ostwald

(1) Psychologische Tests

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Definition

Test (engl.) *Probe, Prüfung, Kontrolle*

Der Begriff bezeichnet unterschiedliche Dinge

- Ein Verfahren zur Untersuchung psychologischer Merkmale
- Den Vorgang einer solchen Untersuchung
- Die Materialien, mit denen eine Untersuchung durchgeführt wird

In dieser Veranstaltung

- Psychologische Tests als planmäßig entwickelte Untersuchungsverfahren
- Aufgaben, Fragen oder andere Reize lösen beobachtbare Reaktionen aus
- Festgelegte Regeln ermöglichen Aussagen über psychologische Merkmale

Lienert and Raatz (1998); Streiner et al. (2024)

Test (engl.) *Probe, Prüfung, Kontrolle*

test = 1. (*logic*) any criterion or procedure used to determine the truth or falsity of a hypothesis, either by empirical evidence or by reasoning; 2. (*psychol.*) a routine examination administered to individuals belonging to the same group, in order to determine the relative position of a given individual in the group with respect to one or more mental traits, motor abilities, etc. or in order to compare one group with another in these characteristics. [In practice a series or battery of psychological tests (2) is generally used, and the scores are arranged or plotted on a definite scale; cf. **mental test**, **scale** (1).] **tester**^{np} (contr. rarely w. **testee**, the individual tested). — Fr. (1) *épreuve*, (2) *test*; Ger. (1) *Prüfung*, (2) *Test*, *Probe*.

Warren (1934)

Definition

Vom beobachtbaren Verhalten zum psychologischen Merkmal

Konstrukt

Ein theoretisch bestimmtes Merkmal, das sich nicht unmittelbar beobachten lässt, zum Beispiel Konzentrationsfähigkeit oder depressive Symptomatik.

Indikator

Eine beobachtbare Reaktion, die Hinweise auf das Konstrukt geben soll, zum Beispiel eine Aufgabenbearbeitung oder eine Antwort im Fragebogen.

Interpretation

Der Schluss vom beobachteten Verhalten auf das Konstrukt braucht eine Begründung. Eine Antwort kann auch durch Sprache, Situation oder Antwortbereitschaft entstehen.

Vgl. Streiner et al. (2024), Kap. 1 und 2

Reichweite des Testbegriffs

Psychologische Tests können unterschiedliche Merkmale erfassen

- Relativ überdauernde Eigenschaften, etwa eine typische Verhaltenstendenz (*trait*)
- Veränderliche Zustände, etwa die gegenwärtige Symptomatik (*state*)
- Fähigkeiten, Kenntnisse oder Interessen

Tests im weiteren Sinn umfassen auch Fragebögen, standardisierte Interviews und standardisierte Beobachtungen.

Bei Leistungstests steht typischerweise das bestmögliche Verhalten im Vordergrund. Selbstberichte fragen häufig nach typischem Verhalten oder subjektivem Erleben.

Die Bezeichnung eines Verfahrens allein sagt noch nichts über seine Qualität aus.

Rost (2004); Streiner et al. (2024)

Testbestandteile

Materialbestandteile

- Testmanual
- Testmaterial (Items)
- Auswertungshilfen

Durchführungsbestandteile

- Testanweisung
- Testdurchführung
- Testauswertung

Lienert and Raatz (1998)

Definition

Item

Ein Item ist eine einzelne Aufgabe, Frage oder Aussage eines Tests.

Itemstamm

Der Reiz, auf den eine Reaktion erwartet wird, etwa eine Frage, ein Bild oder eine Aufgabe.

Antwortformat

Die vorgesehene Form der Antwort, etwa freier Text, eine Auswahl oder eine Beurteilung.

Beispiel

„Wie häufig schweiften Ihre Gedanken beim Lernen in der vergangenen Woche ab?“

☐ nie ☐ selten ☐ manchmal ☐ häufig ☐ sehr häufig

Mehrere Items können einen Untertest oder eine Skala bilden. Auch Verfahren mit einem einzelnen Item benötigen eine begründete Interpretation.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 1 und 4

Psychologischer Test und Experiment

Psychologischer Test

- Erfasst Merkmale anhand ausgewählter Verhaltensweisen oder Selbstberichte
- Vereinheitlicht Aufgabenstellung, Durchführung und Auswertung

Experiment

- Verändert Bedingungen gezielt, um Wirkungen zu untersuchen
- Benötigt eine geeignete Kontrolle alternativer Erklärungen

Tests können innerhalb eines Experiments eingesetzt werden. Eine standardisierte Testdurchführung allein erlaubt noch keine Aussage über Ursachen.

Rost (2004); Streiner et al. (2024)

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Testarten

Klassifikation

Psychometrische Persönlichkeitstests

- Klinische Tests
- Einstellungstests
- Persönlichkeitsstrukturtests
- Interessentests

Leistungstests

- Entwicklungstests
- Intelligenztests
- Allgemeine Leistungstests
- Schultests
- Spezielle Funktionsprüfungs- und Eignungstests

Persönlichkeitsentfaltungsverfahren

- Formdeuteverfahren
- Verbal-thematische Verfahren
- Zeichnerische und Gestaltungsverfahren

Charakteristika

Psychometrische Persönlichkeitstests

- Erfassen unter anderem Symptome, Eigenschaften, Einstellungen und Interessen
- Bei Selbstberichten meist keine sachlich richtigen oder falschen Antworten
- Antworten setzen Verständnis, Selbsteinschätzung und Auskunftsbereitschaft voraus

Leistungstests

- Vorgegebene Aufgaben mit Kriterien für die Qualität der Bearbeitung
- Je nach Test stehen Genauigkeit, Schwierigkeit oder Bearbeitungstempo im Vordergrund
- Sprachverständnis und Motivation können das beobachtete Verhalten mitbestimmen

Persönlichkeitsentfaltungsverfahren

- Reaktionen auf mehrdeutige oder wenig strukturierte Materialien
- Die Deutung und ihr wissenschaftlicher Nachweis sind gesondert zu prüfen

Moosbrugger and Kelava (2012); Streiner et al. (2024)

Klinische Tests

Klinische Tests unterstützen die Beschreibung psychischer Beschwerden und die Diagnostik.

Beispiel: Beck-Depressionsinventar (BDI-II)

- Selbstbeurteilungsinstrument zur Schwere depressiver Symptomatik
- Entwicklung durch Beck und Mitarbeitende als Überarbeitung des BDI
- Deutschsprachige Fassung nach Hautzinger und Mitarbeitenden
- Erfasst unterschiedliche Beschwerden mit 21 Items
- Bezugszeitraum: die vergangenen zwei Wochen einschließlich des heutigen Tages
- Auswahl unter abgestuften Beschreibungen des eigenen Erlebens

Die Antworten ergänzen die klinische Beurteilung. Ein Fragebogenergebnis allein begründet noch keine Diagnose einer depressiven Störung.

Beck (1961); Beck et al. (1996); Hautzinger et al. (2006)

Klinische Tests

Beispiel: Beck-Depressionsinventar (BDI-II)

Beispielitem Traurigkeit

(0) Ich bin nicht traurig

(1) Ich bin oft traurig

(2) Ich bin ständig traurig

(3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte

Klinische Tests

Beispiel: Beck-Depressionsinventar (BDI-II)

Items

1. Traurigkeit
2. Pessimismus
3. Versagensgefühle
4. Verlust an Freude
5. Schuldgefühle
6. Bestrafungsgefühle
7. Selbstablehnung
8. Selbstkritik
9. Suizidgedanken
10. Weinen
11. Unruhe
12. Interessensverlust
13. Entschlussunfähigkeit
14. Wertlosigkeit
15. Energieverlust
16. Veränderungen der Schlafgewohnheiten
17. Reizbarkeit
18. Appetitveränderung
19. Konzentrationsschwierigkeiten
20. Müdigkeit
21. Verlust an sexuellem Interesse

Einstellungstests

Einstellungen sind Bewertungen von Objekten, Personen oder Sachverhalten. Sie können sich im Denken, Erleben und Handeln ausdrücken.

Beispiel: General Ecological Behavior (GEB) Scale

- Erfragt selbstberichtetes umweltschützendes Verhalten
- Deutet Verhaltensweisen im Rahmen des Campbell-Paradigmas als Ausdruck einer Umwelteinstellung
- Berücksichtigt, dass Verhalten unterschiedlichen Aufwand erfordert

Beispiel aus dem Verfahren

„Ich kaufe Lebensmittel aus kontrolliert biologischem Anbau."

☐ nie ☐ selten ☐ gelegentlich ☐ oft ☐ sehr oft ☐ keine Angabe

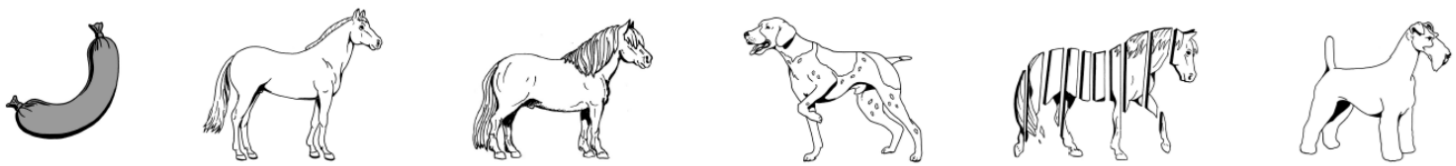
Die Verbindung zwischen berichteter Handlung und Einstellung ist eine theoretische Annahme.

Kaiser (1998); Kaiser et al. (2010)

Leistungstests

Beispiel: Konzentrationstest für Kinder (KoKi)

- Kinder markieren Hunde, die in Richtung einer Wurst blicken
- Andere Bilder dienen als Ablenkreize (Distraktoren)
- Auffällige „verzauberte“ Pferde erschweren das Übergehen von Ablenkreizen
- Die Bearbeitung gibt Hinweise auf Konzentration, Tempo und Genauigkeit



Schmidt-Atzert and Funsch (2023)

Projektive Verfahren

Rorschach Test



Thematischer Apperzeptionstest



Rorschach (1921), Revers and Taeber (1968)

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Verwendungszweck und Zielgruppe

Vor dem Schreiben von Items stehen Entscheidungen über das Verfahren.

- **Was** soll erfasst werden?
- **Bei wem** soll das Verfahren eingesetzt werden?
- **In welcher Situation** sollen die Antworten entstehen?
- **Wozu** sollen die Ergebnisse verwendet werden?

Durchgehendes Lehrbeispiel: Konzentration beim Lernen

Selbstbericht von Studierenden über Schwierigkeiten, ihre Aufmerksamkeit beim selbstständigen Lernen in der vergangenen Woche aufrechtzuerhalten.

Die folgenden selbst entworfenen Items illustrieren Entwicklungsentscheidungen. Sie bilden kein geprüftes Testverfahren.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 1 bis 3

Vorhandene Verfahren prüfen

Eine Neuentwicklung beginnt mit der Suche nach vorhandenen Instrumenten.

- Passt die Konstruktdefinition zur eigenen Fragestellung?
- Stimmen Zielgruppe, Sprache und Anwendungssituation überein?
- Eignen sich Inhalt und Bezugszeitraum für den vorgesehenen Zweck?
- Sind Manual, Anwendungsvoraussetzungen und Nutzungsbedingungen zugänglich?
- Welche Belege stützen die beabsichtigte Interpretation?

Ein bekannter Testname genügt als Begründung nicht. Auch bei gleichem Namen können Verfahren unterschiedliche Aspekte eines Merkmals erfassen.

Die Entscheidung für Übernahme, Anpassung oder Neuentwicklung wird dokumentiert.

Vgl. Streiner et al. (2024), Kap. 1 und 2

Ein Konstrukt inhaltlich abgrenzen

Arbeitsdefinition

Was gehört zu „Konzentration beim Lernen“, was gehört zu benachbarten Merkmalen?

Einbeziehen	Bei einer Lernaufgabe bleiben, Abschweifen bemerken, zur Aufgabe zurückfinden
Abgrenzen	Lernmotivation, Interesse am Fach, Vorwissen, Müdigkeit
Kontext festlegen	Selbstständiges Lernen in der vergangenen Woche

Benachbarte Merkmale können zusammenwirken, ohne dass sie dasselbe bedeuten. Eine breite Definition deckt mehr Aspekte ab, verlangt aber auch breitere Inhalte.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 1 und 3

Inhaltsbereiche vor einzelnen Formulierungen

Ein Inhaltsplan hält fest, welche Aspekte durch Items vertreten sein sollen.

Inhaltsbereich	**Mögliche Beobachtung oder Itemidee**
Aufmerksamkeit halten	Gedanken schweifen während einer Lernaufgabe ab
Ablenkungen widerstehen	Umgebungsgeräusche lenken von der Lernaufgabe ab
Zur Aufgabe zurückfinden	Nach einer Unterbrechung fällt die Wiederaufnahme schwer

Der Plan hilft, Lücken und einseitige Schwerpunkte zu erkennen. Er bleibt während der Entwicklung überprüfbar und veränderbar.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 3

Quellen für einen ersten Itempool

Theorie und vorhandene Forschung

Definitionen, Modelle und bestehende Verfahren zeigen mögliche Inhaltsbereiche.

Beobachtung und fachliche Erfahrung

Konkrete Situationen machen typische Schwierigkeiten und Verhaltensweisen sichtbar.

Gespräche mit der Zielgruppe

Interviews oder Gruppengespräche erschließen deren Sprache, Erfahrungen und Prioritäten.

Zunächst mehrere Formulierungen und unterschiedliche Aspekte sammeln. Anschließend prüfen Fachpersonen und Angehörige der Zielgruppe Relevanz, Verständlichkeit und Lücken.

Vgl. Streiner et al. (2024), Kap. 3

Verständliche Items formulieren

Problematische Formulierung

„Ich bin beim Lernen konzentriert und motiviert.“

Die Aussage verbindet unterschiedliche Merkmale. Eine Person kann motiviert sein und sich trotzdem schlecht konzentrieren.

Gezieltere Formulierung

„Wie häufig schweiften Ihre Gedanken beim Lernen in der vergangenen Woche ab?“

- Pro Item möglichst eine Frage stellen
- Geläufige Wörter und einen passenden Bezugszeitraum verwenden
- Mehrdeutigkeit, doppelte Verneinungen und wertende Vorgaben vermeiden
- Die Antwortmöglichkeiten zusammen mit dem Itemstamm entwickeln

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 5

Übersetzung und kulturelle Anpassung

Eine wörtlich ähnliche Formulierung kann in einer anderen Sprache etwas anderes auslösen.

- Bedeutet das Konstrukt im Anwendungskontext dasselbe?
- Sind die beschriebenen Situationen in der Zielgruppe vertraut und relevant?
- Haben Wörter und Antwortkategorien eine vergleichbare Bedeutung?
- Verändert eine Anpassung den Inhalt des Items?

Übersetzungen vergleichen, Abweichungen gemeinsam klären und die Fassung mit der Zielgruppe erproben. Eine Rückübersetzung kann Unterschiede sichtbar machen, ersetzt aber keine Prüfung des tatsächlichen Verständnisses.

Alle Anpassungen und ihre Begründungen werden dokumentiert.

Vgl. Streiner et al. (2024), Kap. 3

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Freie und gebundene Antworten

Freie Antwortformate

Die Person formuliert oder gestaltet ihre Antwort selbst.

- Kurze Ergänzung, ausführliche Antwort, Zeichnung oder Handlung

Gebundene Antwortformate

Die Person reagiert innerhalb vorgegebener Möglichkeiten.

- **Ordnen:** Elemente zuordnen oder in eine Reihenfolge bringen
- **Auswählen:** Eine oder mehrere Alternativen ankreuzen
- **Beurteilen:** Die Ausprägung eines Merkmals einschätzen

Itemstamm, Antwortformat und Instruktion bestimmen gemeinsam die Aufgabe.

Pospeschill (2022); Streiner et al. (2024)

Freie Antworten

Lehrbeispiel: Wissen über Tests

„Erläutern Sie an einem Beispiel, wodurch eine Testanweisung missverständlich werden kann.“

Antwort: .....

.....

- Eigene Formulierungen machen Gedankengänge sichtbar
- Sprachliche Ausdrucksfähigkeit beeinflusst die Antwort
- Die Auswertung braucht vorab festgelegte Kriterien und Beispielantworten

Mögliches Auswertungskriterium: Die Antwort nennt eine Mehrdeutigkeit und erklärt, wie sie zu unterschiedlichen Bearbeitungen führt.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Ordnungsaufgaben

Zuordnen

Ordnen Sie jedem Beispiel das passende Verfahren zu:

Bericht über die eigene Stimmung	Selbstbeurteilung
Markieren bestimmter Bilder	Leistungstest
Beurteilung durch eine Lehrperson	Fremdbeurteilung

Hier bereits mit den zugehörigen Lösungen dargestellt.

Rangordnen

„Ordnen Sie Ruhe, Interesse und Zeitdruck danach, wie stark sie Ihr Lernen beeinflussen.“

Eine Rangfolge zeigt relative Prioritäten innerhalb dieser Auswahl. Sie verrät nicht, wie stark ein einzelner Einfluss insgesamt erlebt wird.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Auswahlaufgaben

Einfachauswahl im Leistungstest

Welche Aussage beschreibt einen standardisierten Test am besten? Kreuzen Sie eine Antwort an.

☐ Jede Person erhält eine frei gewählte Instruktion.

☐ Durchführung und Auswertung folgen festgelegten Regeln.

☐ Jede Antwort wird ausschließlich intuitiv beurteilt.

Die zweite Alternative ist hier die richtige Antwort. Die übrigen Alternativen sind **Distraktoren** und sollen plausible Fehlvorstellungen aufgreifen.

Bei einer Mehrfachauswahl muss die Instruktion ausdrücklich erklären, dass mehrere Alternativen zutreffen können.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Eindeutige und vollständige Antwortkategorien

Lehrbeispiel: Ort des Lernens

„Wo haben Sie gestern zuletzt gelernt?“

☐ zu Hause ☐ Bibliothek ☐ Universität

Probleme: Eine Universitätsbibliothek passt zu zwei Kategorien. Andere Lernorte und Tage ohne Lernen sind nicht berücksichtigt.

Überarbeitete Möglichkeiten

☐ zu Hause ☐ in einer Bibliothek

☐ an einem anderen Ort ☐ ich habe gestern nicht gelernt

Disjunkt: Die Kategorien überschneiden sich nicht.

Exhaustiv: Die Kategorien decken die relevanten Antwortmöglichkeiten ab.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4 und 5

Forced Choice bei Auswahlaufgaben

Lehrbeispiel: Relative Präferenz

„Welche Aussage beschreibt Sie eher? Bitte wählen Sie eine der beiden Aussagen.“

☐ Beim Lernen suche ich gern den Austausch mit anderen.

☐ Beim Lernen arbeite ich gern für mich allein.

- Die Person muss zwischen vorgegebenen Alternativen wählen
- Die Auswahl beschreibt eine relative Präferenz innerhalb dieses Paares
- Beide Aussagen könnten auch zutreffen oder beide wenig passen

Forced Choice ist kein allgemeiner Schutz vor absichtlicher Verfälschung. Ein Rating ohne Mittelkategorie ist eine andere Gestaltungsentscheidung.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Beurteilungsaufgaben: Was wird beurteilt?

Häufigkeit

„Wie häufig schweiften Ihre Gedanken beim Lernen in der vergangenen Woche ab?“

☐ nie ☐ selten ☐ manchmal ☐ häufig ☐ sehr häufig

Intensität

„Wie stark beeinträchtigten Umgebungsgeräusche heute Ihre Konzentration beim Lernen?“

☐ gar nicht ☐ wenig ☐ mäßig ☐ stark ☐ sehr stark

Häufigkeit und Intensität sind unterschiedliche Fragen. Die Beschriftung muss zur beabsichtigten Beurteilung passen.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Ratings mit und ohne Mittelkategorie

„Wie beurteilen Sie gemeinsames Lernen?“

Mit inhaltlicher Mittelkategorie

☐	☐	☐	☐	☐
sehr negativ	eher negativ	weder negativ noch positiv	eher positiv	sehr positiv

Ohne inhaltliche Mittelkategorie

☐ sehr negativ ☐ eher negativ ☐ eher positiv ☐ sehr positiv

Ohne Mitte wird eine Richtung verlangt („forciertes Rating“). Mit Mitte kann eine inhaltlich neutrale Position angegeben werden („unforciertes Rating“).

Ob eine Mitte sinnvoll ist, hängt vom Inhalt ab. „Manchmal“ auf einer Häufigkeitsskala bezeichnet beispielsweise keine neutrale Einstellung.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Neutrale Antwort, Unwissen und Nichtanwendbarkeit

Unterschiedliche Gründe für eine Antwort brauchen unterscheidbare Möglichkeiten.

Inhaltliche Mitte	„Ich beurteile gemeinsames Lernen weder negativ noch positiv.“
Weiß nicht	„Ich kann gemeinsames Lernen noch nicht beurteilen.“
Nicht anwendbar	„Ich habe im erfragten Zeitraum nicht gelernt.“
Keine Angabe	„Ich möchte diese Frage nicht beantworten.“

Zusätzliche Kategorien werden außerhalb der inhaltlichen Abstufung angeboten, wenn sie für die Frage benötigt werden. Ihre Bedeutung muss eindeutig sein.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4 und 7

Polarität

Unipolare Antwortskala

Abstufungen von der Abwesenheit bis zur starken Ausprägung eines Merkmals.

„Wie stark waren Sie beim Lernen angespannt?“

☐ gar nicht ☐ wenig ☐ mäßig ☐ stark ☐ sehr stark

Bipolare Antwortskala

Abstufungen zwischen zwei inhaltlich entgegengesetzten Polen.

„Wie beurteilen Sie die heutige Lernsitzung?“

☐ sehr negativ ☐ eher negativ ☐ neutral ☐ eher positiv ☐ sehr positiv

Die Abwesenheit eines Merkmals ist nicht automatisch die Ausprägung seines Gegenteils.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Balance

„Wie beurteilen Sie die Lernbedingungen in der Bibliothek?“

Einseitig abgestufte Bewertung

☐ schlecht ☐ gut ☐ sehr gut ☐ ausgezeichnet

Positive Urteile lassen sich stärker differenzieren als negative Urteile.

Symmetrisch abgestufte Bewertung

☐ sehr schlecht ☐ eher schlecht ☐ eher gut ☐ sehr gut

Die angebotenen Abstufungen beeinflussen, welche Unterschiede ausgedrückt werden können. Eine symmetrische Gestaltung passt zu einer beidseitigen Bewertung.

Eine unipolare Intensitätsskala braucht dagegen keinen negativen Gegenpol.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Verankerung der Antwortkategorien

Verbale Verankerung

Beschriftungen erklären, welche Bedeutung die einzelnen Kategorien haben.

☐ nie ☐ selten ☐ manchmal ☐ häufig ☐ sehr häufig

- Alle Kategorien beschriften, wenn dies ihre Unterscheidung erleichtert
- Begriffe wie „häufig“ können zwischen Personen unterschiedlich verstanden werden
- Der Itemstamm muss deutlich machen, auf welche Situationen sich die Antwort bezieht
- Kategorien müssen zur Sprache und Erfahrung der Zielgruppe passen

Im BDI-II tragen ausformulierte Aussagen die Abstufung. Die Wahl der Anker gehört zur inhaltlichen Entwicklung des Instruments.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Visuelle Analogskala

„Wie schwer fiel es Ihnen heute, beim Lernen aufmerksam zu bleiben?“

Markieren Sie die Stelle auf der Linie, die Ihre Einschätzung am besten beschreibt.

überhaupt nicht schwer — äußerst schwer

- Die Antwort erfolgt als Markierung zwischen beschrifteten Endpunkten
- Die Bedeutung der Endpunkte muss verständlich sein
- Bedienbarkeit und Darstellung sind auf Papier und am Bildschirm zu prüfen

Auch Bildsymbole benötigen eine Verständnisprüfung. Ein Gesichtsausdruck kann etwa Stimmung ausdrücken, obwohl nach Schmerzen oder Anstrengung gefragt wird.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Ein passendes Antwortformat auswählen

Die Entscheidung richtet sich nach Inhalt, Zielgruppe und Anwendungssituation.

- Können Personen die geforderte Abstufung sinnvoll unterscheiden?
- Hilft eine freie Antwort dabei, unerwartete Erfahrungen sichtbar zu machen?
- Erleichtern vorgegebene Möglichkeiten die Bearbeitung oder engen sie den Inhalt ein?
- Können alle Personen die Darstellung sehen, lesen und bedienen?
- Bleibt die Aufgabe bei einer mündlichen Durchführung verständlich?

Mehr Antwortmöglichkeiten liefern nicht automatisch bessere Auskünfte. Wiederkehrende Formate erleichtern die Bearbeitung, sofern sie zum jeweiligen Inhalt passen.

Vgl. Streiner et al. (2024), Kap. 4

Antwortformate im Überblick

Format	**Reaktion**	**Wichtige Entscheidung**
Freie Antwort	Selbst formulieren	Welche Auswertungskriterien gelten?
Zuordnung	Elemente verbinden	Ist die Zuordnung eindeutig?
Rangordnung	Reihenfolge bilden	Welche relative Priorität ist gefragt?
Auswahl	Alternativen wählen	Sind Einfach- oder Mehrfachantworten erlaubt?
Beurteilung	Ausprägung einschätzen	Sind Anker und Kategorien passend?

Die Qualität eines Formats zeigt sich auch daran, wie die Zielgruppe es tatsächlich verwendet.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 4

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Von der Frage zur angekreuzten Antwort

Eine einfache Frage kann eine anspruchsvolle Aufgabe auslösen.

1. **Verstehen:** Was meint die Frage mit „beim Lernen“?
2. **Erinnern:** Welche Situationen aus der vergangenen Woche fallen mir ein?
3. **Urteilen:** Wie fasse ich diese unterschiedlichen Situationen zusammen?
4. **Zuordnen:** Passt meine Einschätzung eher zu „manchmal“ oder „häufig“?
5. **Antwort bearbeiten:** Möchte ich diese Einschätzung tatsächlich mitteilen?

Bei jedem Schritt kann die Antwort vom Verständnis der Testentwickelnden abweichen. Die sichtbare Antwort verrät den zugrunde liegenden Gedankengang zunächst nicht.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 6

Erinnern und Bezugszeiträume

Selbstberichte beruhen häufig auf einer Rekonstruktion vergangener Erfahrungen.

- Auffällige und kürzlich erlebte Situationen fallen leichter ein
- Ähnliche Ereignisse können zu einem allgemeinen Eindruck verschmelzen
- Ereignisse außerhalb des Zeitraums können irrtümlich einbezogen werden
- Ein zu kurzer Zeitraum kann wichtige, seltene Erfahrungen verfehlen

Folgerung für die Entwicklung

Den Zeitraum passend zum Inhalt wählen, eindeutig benennen und im Pretest prüfen, welche Erlebnisse die Befragten tatsächlich heranziehen.

Beim BDI-II bildet der festgelegte Zeitraum einen Teil der standardisierten Instruktion. Eine Änderung verändert die Aufgabe.

Vgl. Streiner et al. (2024), Kap. 6

Soziale Erwünschtheit und absichtliche Darstellung

Menschen können ihre Antworten daran ausrichten, wie sie wahrgenommen werden möchten.

- Sozial erwünschte Antworten können bewusst oder ohne bewusste Täuschungsabsicht entstehen
- Je nach Situation kann eine besonders günstige oder ungünstige Darstellung erwünscht sein
- Bewertungsangst und befürchtete Folgen beeinflussen die Auskunftsbereitschaft

Gestaltungsmöglichkeiten

Wertende Formulierungen vermeiden, Zweck und Verwendung der Angaben erklären und einen angemessenen Rahmen für vertrauliche Antworten schaffen.

Eine Zusicherung von Vertraulichkeit muss den tatsächlichen Bedingungen entsprechen. Auch verständliche und sachlich formulierte Items bleiben kontextabhängig.

Vgl. Streiner et al. (2024), Kap. 6

Antworttendenzen

Zustimmungstendenz (Akquieszenz)

Zustimmen, obwohl der Inhalt der Aussage dafür nicht ausschlaggebend ist.

Tendenz zur Mitte oder zu extremen Kategorien

Bestimmte Positionen bevorzugen, teilweise unabhängig vom jeweiligen Inhalt.

Solche Muster können Antworten mitprägen. Eine einzelne mittlere oder extreme Antwort belegt aber noch keinen Antwortstil.

Problem vermeintlich einfacher Lösungen

Verneinte oder gegensinnig formulierte Items können zusätzliche Verständnisprobleme schaffen. Ihr Einsatz muss inhaltlich begründet und erprobt werden.

Vgl. Streiner et al. (2024), Kap. 5 und 6

Nachlassende Sorgfalt und Satisficing

Satisficing bezeichnet eine vereinfachte Bearbeitung, bei der eine gerade noch hinreichend erscheinende Antwort gewählt wird.

- Fragen nur oberflächlich lesen
- Die erste plausibel erscheinende Alternative wählen
- Dieselbe Position wiederholt ankreuzen
- Erinnerung und Abwägung abkürzen

Lange, unübersichtliche oder schwierige Fragebögen begünstigen solche Strategien.

Kurze verständliche Aufgaben, ein übersichtliches Layout und ein angemessener Umfang erleichtern eine sorgfältige Bearbeitung. Auffällige Muster sind zunächst Anlass zur Prüfung und kein sicherer Beleg für Unaufmerksamkeit.

Vgl. Streiner et al. (2024), Kap. 6

Kontext, Reihenfolge und Erhebungssituation

Lehrbeispiel

Eine Frage zu Schwierigkeiten beim Lernen kann anders verstanden werden, wenn direkt zuvor Prüfungsangst oder direkt zuvor störende Umgebungsgeräusche angesprochen wurden.

- Vorherige Fragen können Erinnerungen und Vergleichsmaßstäbe aktivieren
- Reihenfolge und Formulierung der Antwortmöglichkeiten lenken die Aufmerksamkeit
- Die Anwesenheit anderer Personen kann die Antwortbereitschaft verändern
- Papier, Bildschirm und Interview stellen unterschiedliche Anforderungen

Deshalb wird der Fragebogen im Zusammenhang erprobt. Eine gut verständliche Einzelfrage kann sich in einer ungünstigen Reihenfolge anders verhalten.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 6

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Die Zielgruppe in die Entwicklung einbeziehen

Ein Pretest prüft, wie die vorgesehenen Befragten die Items tatsächlich bearbeiten.

- Personen mit unterschiedlichen relevanten Erfahrungen und Sprachvoraussetzungen einbeziehen
- Verständlichkeit, Relevanz und mögliche Belastungen erfragen
- Schwierigkeiten mit Instruktion, Layout und Antwortformat beobachten
- Unterschiedliche Deutungen und fehlende Antwortmöglichkeiten dokumentieren

Fachkolleginnen und Fachkollegen allein ersetzen die Zielgruppe nicht.

Überarbeiten und erneut erproben, bis wesentliche bekannte Probleme behoben sind und weitere Gespräche keine neuen wichtigen Schwierigkeiten erkennen lassen.

Vgl. Streiner et al. (2024), Kap. 3 und 6

Kognitive Interviews

Paraphrasieren

„Können Sie die Frage mit eigenen Worten wiedergeben?“

Lautes Denken

„Beschreiben Sie bitte, woran Sie beim Beantworten gerade denken.“

Gezieltes Nachfragen (Probing)

„Was bedeutet für Sie hier ‚häufig‘?“

„An welche Situationen haben Sie bei Ihrer Antwort gedacht?“

Die Fragen sollen das Verständnis sichtbar machen, ohne die beabsichtigte Antwort vorzugeben. Nachfragen können selbst die Bearbeitung verändern.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 6

Vom beobachteten Problem zur Revision

Ausgangsitem

„Ich lerne regelmäßig und ohne Ablenkung.“

Fiktive Rückmeldung im Pretest

„Ich lerne fast jeden Tag, werde aber dauernd unterbrochen. Was soll ich ankreuzen?“

Entwicklungsentscheidung

Die Aussage verbindet Regelmäßigkeit und Ablenkung. Für unser Konstrukt wird gezielt das Abschweifen während des Lernens erfragt. Regelmäßigkeit gehört nicht zum Inhaltsplan.

Erneute Erprobung

„Wie häufig schweiften Ihre Gedanken beim Lernen in der vergangenen Woche ab?“

Prüfen, ob „Abschweifen“ verstanden wird und welche Situationen als Lernen gelten.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 5 und 6

Items qualitativ auswählen

Prüffrage	**Mögliche Konsequenz**
Inhaltlich relevant?	Unpassende Inhalte streichen oder die Definition überprüfen
Verständlich?	Mehrdeutige Wörter ersetzen und erneut erproben
Beantwortbar?	Zeitraum, Voraussetzungen oder Antwortmöglichkeiten anpassen
Unverzichtbarer Aspekt?	Lücken im Inhaltsplan durch neue Items schließen
Nur Wiederholung?	Redundanz verringern, ohne wichtige Unterschiede zu verlieren

Entscheidungen mit Rückmeldungen und Inhaltsplan begründen. Qualitative Erprobung ist ein Entwicklungsschritt und noch kein vollständiger Gütenachweis.

Vgl. Streiner et al. (2024), Kap. 5 und 6

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Von einzelnen Items zu einer Skala

Eine Skala fasst mehrere aufeinander bezogene Items zur Beschreibung eines Merkmals zusammen.

- Jedes Item soll einen begründeten Beitrag zum vorgesehenen Inhalt leisten
- Verschiedene Formulierungen können unterschiedliche Aspekte erschließen
- Sehr ähnliche Items verengen den erfassten Inhalt möglicherweise auf einen Ausschnitt
- Inhaltlich unterscheidbare Bereiche können getrennte Subskalen erfordern

Beim BDI-II beziehen sich die Items auf unterschiedliche depressive Beschwerden. Ihre gemeinsame Interpretation benötigt eine inhaltliche und empirische Begründung.

Eine Sammlung passend klingender Fragen bildet noch nicht automatisch eine sinnvolle Skala.

Vgl. Streiner et al. (2024), Kap. 5 und 7

Skala und Index: unterschiedliche inhaltliche Logik

Anzeichen eines gemeinsamen Merkmals

Mehrere Items sollen verschiedene Ausdrucksformen eines zugrunde liegenden Merkmals erfassen, etwa unterschiedliche Hinweise auf Konzentrationsprobleme.

Zusammenstellung unterschiedlicher Einflüsse

Ein Index belastender Lebensereignisse sammelt beispielsweise Arbeitsplatzverlust, Trennung oder Umzug. Die Ereignisse können unabhängig voneinander auftreten und jeweils zur Belastung beitragen.

Die Auswahlregeln richten sich nach dieser inhaltlichen Logik. Ein eigenständiger, wichtiger Einfluss darf nicht allein deshalb fehlen, weil er anders ist als die übrigen Inhalte.

Vgl. Streiner et al. (2024), Kap. 5 und 7

Instruktion, Reihenfolge und Bearbeitungsaufwand

Instruktion

Zweck, Bezugszeitraum und Vorgehen erklären. Angeben, ob eine oder mehrere Antworten zulässig sind und wie nicht anwendbare Fragen behandelt werden.

Reihenfolge und Gestaltung

Verwandte Inhalte nachvollziehbar anordnen. Veränderungen des Antwortformats deutlich markieren und unbeabsichtigte Hinweise durch benachbarte Fragen prüfen.

Belastung

Lesbarkeit, Länge, Wiederholungen und sensible Inhalte aus Sicht der Zielgruppe beurteilen.

Die endgültige Fassung einschließlich Instruktion und Layout nochmals als Ganzes erproben.

Vgl. Streiner et al. (2024), Kap. 6 und 7

Inhaltliche Gewichtung durch die Itemauswahl

Lehrbeispiel

Ein Fragebogen enthält viele Varianten zum Abschweifen der Gedanken, aber nur eine Frage zur Wiederaufnahme nach einer Unterbrechung.

Der erste Bereich prägt die Gesamtbeschreibung stärker, wenn alle Antworten in gleicher Weise berücksichtigt werden.

- Schon die Zusammenstellung legt inhaltliche Schwerpunkte fest
- Ähnliche Items sind deshalb nicht beliebig austauschbare Ergänzungen
- Die Verteilung der Inhalte sollte zum Konstrukt und zum Verwendungszweck passen
- Entscheidungen über Subskalen und Auswertung müssen dazu stimmig sein

Der Inhaltsplan hilft, unbeabsichtigte Schwerpunktsetzungen zu erkennen.

Eigene Lehrbeispiele. Vgl. Streiner et al. (2024), Kap. 7

Fehlende Angaben und Grenzen der Interpretation

Eine unbeantwortete Frage kann unterschiedliche Gründe haben.

- Übersehen oder nicht verstanden
- Für die Person oder den Zeitraum nicht anwendbar
- Nicht erinnerbar oder zu schwierig einzuschätzen
- Bewusst nicht beantwortet

Fehlende Angaben dürfen nicht stillschweigend als Abwesenheit eines Merkmals gedeutet werden. Der Umgang damit wird vorab festgelegt und im Manual beschrieben.

Für etablierte Verfahren wie den BDI-II gelten die Vorgaben des jeweiligen Manuals. Eigenmächtige Änderungen an Items, Antwortformaten oder Auswertungsregeln erfordern eine erneute Prüfung der Interpretation.

Vgl. Streiner et al. (2024), Kap. 7

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Qualität für eine bestimmte Anwendung

Gütekriterien begründen, ob die vorgesehenen Aussagen und Anwendungen tragfähig sind.

Hauptgütekriterien

- **Objektivität:** Wie unabhängig ist das Ergebnis von den Untersuchenden?
- **Reliabilität:** Wie zuverlässig wird das Merkmal erfasst?
- **Validität:** Wie gut ist die beabsichtigte Interpretation begründet?

Weitere Anforderungen

Normierung, Skalierung, Testökonomie, Nützlichkeit, Zumutbarkeit, Unverfälschbarkeit und Fairness.

Die Anforderungen beziehen sich auf eine Zielgruppe, einen Verwendungszweck und bestimmte Bedingungen. Ein Testname allein garantiert keine Qualität.

Moosbrugger and Kelava (2012); Streiner et al. (2024)

Objektivität

Objektivität betrifft die Unabhängigkeit von durchführenden, auswertenden und interpretierenden Personen.

Durchführungsobjektivität

Gleiche Instruktionen und festgelegte Rahmenbedingungen begrenzen den Einfluss der Testleitung.

Auswertungsobjektivität

Eindeutige Regeln sollen bei derselben Bearbeitung zur selben Auswertung führen. Auch freie Antworten benötigen nachvollziehbare Beurteilungskriterien.

Interpretationsobjektivität

Dokumentierte Interpretationsregeln begrenzen willkürliche Schlussfolgerungen. Sie müssen zum Anwendungsfall passen.

Moosbrugger and Kelava (2012); Streiner et al. (2024)

Objektivität am Beispiel des BDI-II

Durchführung

Die standardisierte Instruktion einschließlich des Bezugszeitraums verwenden. Die Bedeutung der Aussagen nicht durch spontane Umformulierungen verändern.

Auswertung

Die gewählten Antworten und Sonderfälle nach den Regeln des Manuals behandeln. Unklare Markierungen und fehlende Antworten nicht frei deuten.

Interpretation

Die vorgesehenen Anwendungsmöglichkeiten und Grenzen berücksichtigen. Den Befund zusammen mit weiteren klinischen Informationen beurteilen.

Festgelegte Regeln erleichtern ein einheitliches Vorgehen. Sie ersetzen keine fachlich begründete Interpretation.

Hautzinger et al. (2006); Moosbrugger and Kelava (2012)

Reliabilität

Reliabilität bezeichnet die Zuverlässigkeit einer Messung unter bestimmten Bedingungen.

Leitfrage

Wie beständig ist die Erfassung, wenn das Merkmal und die relevanten Bedingungen gleich bleiben?

- Unklare Instruktionen können uneinheitliche Bearbeitungen hervorrufen
- Zufällige Störungen können die Aufgabenleistung beeinflussen
- Uneindeutige Auswertungsregeln können Unterschiede zwischen Beurteilenden erzeugen

Zuverlässigkeit ist graduell und situationsbezogen. Ein zuverlässig erfasstes Merkmal kann trotzdem am beabsichtigten Konstrukt vorbeigehen.

Vgl. Streiner et al. (2024), Kap. 2

Zuverlässigkeit und tatsächliche Veränderung

Beispiel: Wiederholte Anwendung des BDI-II

Eine Person berichtet zu zwei Zeitpunkten unterschiedliche Beschwerden.

- Ihre Symptomatik kann sich tatsächlich verändert haben
- Sie kann den Bezugszeitraum unterschiedlich verstanden haben
- Die Erhebungssituation kann ihre Auskunftsbereitschaft beeinflusst haben

Eine veränderte Antwort ist deshalb nicht automatisch ein Zeichen unzuverlässiger Messung.

Bei der Beurteilung der Zuverlässigkeit muss klar sein, welche Merkmale und Bedingungen als stabil vorausgesetzt werden dürfen. Bei aktuellen Zuständen kann echte Veränderung gerade der Gegenstand der Untersuchung sein.

Hautzinger et al. (2006); Streiner et al. (2024)

Validität

Validität betrifft die Begründung einer bestimmten Interpretation der Testergebnisse für eine vorgesehene Verwendung.

Leitfragen

- Welche Aussage über eine Person soll aus den Antworten folgen?
- Welche theoretischen Annahmen und Befunde stützen diese Aussage?
- Welche alternativen Erklärungen der Antworten müssen berücksichtigt werden?
- Für welche Zielgruppen und Situationen liegen passende Belege vor?

Validierung ist eine fortlaufende Prüfung. Die Übertragung auf einen neuen Zweck, eine andere Sprache oder eine neue Zielgruppe braucht eine eigene Begründung.

Vgl. Streiner et al. (2024), Kap. 2

Inhalt und Antwortprozesse als Evidenz

Inhaltliche Angemessenheit (Inhaltsvalidität)

Passen die Items zur Definition? Sind wichtige Bereiche vertreten? Enthält der Test inhaltlich fremde oder für die Zielgruppe irrelevante Aufgaben?

Tatsächliche Antwortprozesse

Verstehen die Personen die Fragen wie beabsichtigt? Ziehen sie passende Erfahrungen heran? Können sie ihre Einschätzung mit den Kategorien ausdrücken?

Inhaltspläne, fachliche Beurteilungen und kognitive Interviews liefern dafür wichtige Hinweise.

Dass ein Test auf den ersten Blick passend wirkt (**Augenschein**), ersetzt diese Prüfungen und weitere Validitätsbelege nicht.

Vgl. Streiner et al. (2024), Kap. 2, 3 und 6

Bezüge zu anderen Beobachtungen

Theoriebezogene Erwartungen (Konstruktvalidität)

Die Konstruktdefinition legt nahe, mit welchen anderen Beobachtungen ein Ergebnis inhaltlich zusammenpassen sollte und von welchen Merkmalen es unterscheidbar sein muss.

Außenkriterien (Kriteriumsvalidität)

Bei einer konkreten Anwendung wird zusätzlich geprüft, ob die Ergebnisse zu einem relevanten Außenkriterium passen, etwa einer unabhängig vorgenommenen fachlichen Beurteilung.

Auch das Außenkriterium kann unvollständig oder fehlerhaft sein. Es ist nicht automatisch ein unfehlbarer Maßstab.

Verschiedene Belege tragen gemeinsam zur Validitätsargumentation bei.

Vgl. Streiner et al. (2024), Kap. 2

Validitätsargumentation am Beispiel des BDI-II

Beabsichtigte Aussage

Die Antworten geben Hinweise auf die Schwere depressiver Symptomatik im festgelegten Zeitraum.

Zu prüfende Begründungen

- Bilden die Items die relevanten Beschwerden angemessen ab?
- Versteht die Zielgruppe die Aussagen und den Bezugszeitraum?
- Passen die Antworten zu weiteren Informationen über die depressive Symptomatik?
- Lassen sich depressive Beschwerden von anderen möglichen Ursachen einzelner Symptome abgrenzen?

Schlafprobleme und Müdigkeit können unterschiedliche Ursachen haben. Eine einzelne Antwort begründet daher noch keine Diagnose.

Hautzinger et al. (2006); Streiner et al. (2024)

Zusammenspiel der Hauptgütekriterien

Standardisiert, aber am Ziel vorbei

Ein sehr einheitlich durchgeführter Wissenstest kann vor allem Fachsprache verlangen, obwohl eigentlich fachliches Verständnis erfasst werden soll.

Zuverlässig, aber inhaltlich zu eng

Viele sehr ähnliche Fragen zu Müdigkeit können einen stabilen Eindruck liefern, ohne das gesamte Spektrum depressiver Beschwerden abzudecken.

Objektivität unterstützt eine verlässliche Untersuchung. Sie garantiert weder Reliabilität noch Validität.

Zuverlässigkeit unterstützt begründete Aussagen. Welche Aussage zulässig ist, muss zusätzlich inhaltlich und empirisch geprüft werden.

Eigene Lehrbeispiele. Moosbrugger and Kelava (2012); Streiner et al. (2024)

Weitere Anforderungen: Vergleich und praktischer Nutzen

Normierung

Geeignete Vergleichsdaten helfen, ein Ergebnis einzuordnen. Die Bezugsgruppe muss zur getesteten Person und zum Zweck der Einordnung passen.

Skalierung

Die Auswertungsregeln sollen die inhaltlich gemeinten Unterschiede angemessen abbilden.

Testökonomie

Der Erkenntnisgewinn soll in einem angemessenen Verhältnis zu Zeit, Aufwand und Kosten stehen.

Nützlichkeit

Die Informationen sollen für die vorgesehene Entscheidung relevant sein und eine Anwendung mit günstigem Verhältnis von Nutzen und Schaden ermöglichen.

Moosbrugger and Kelava (2012); Streiner et al. (2024)

Weitere Anforderungen: Die Perspektive der Testpersonen

Zumutbarkeit

Zeitliche, psychische und körperliche Belastungen sollen dem Zweck angemessen sein.

Unverfälschbarkeit

Gezielte Selbstdarstellung soll die beabsichtigte Aussage möglichst wenig beeinträchtigen. Vollständige Unverfälschbarkeit lässt sich bei Selbstberichten kaum voraussetzen.

Fairness

Sprachliche, kulturelle oder andere für das Zielmerkmal irrelevante Anforderungen sollen keine systematische Benachteiligung erzeugen.

Beispiel: Ein Konzentrationstest soll nicht vor allem das Verständnis einer unnötig komplizierten Instruktion erfassen. Gleiche Bedingungen allein gewährleisten noch keine Fairness.

Eigene Lehrbeispiele. Moosbrugger and Kelava (2012); Streiner et al. (2024)

Definition

Testarten

Antwortformate

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Testtheorien

- Probabilistische Modelle zum Zusammenhang von zu erfassendem Konstrukt und Testverhalten
- Grundlage der Fragebogendatenanalyse

Hauptrichtungen

- Klassische Testtheorie
- Faktoranalyse
- Item-Response-Theorien

Besonderheiten

- Klassische Testtheorie und Faktoranalyse sind Modelle mit latenten Zufallsvariablen
- Item-Response-Theorien können latente Zufallsvariablen enthalten

Standarddatenstruktur der Testtheorie und Fragebogendatenanalyse

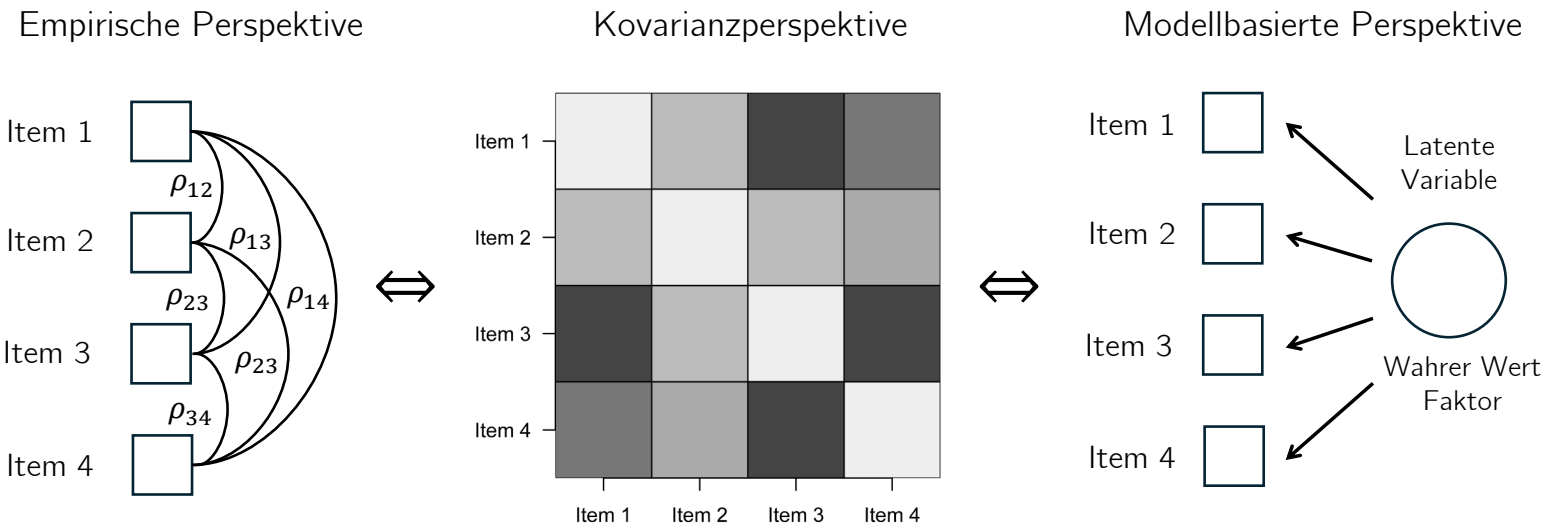
Beobachtung von Werten von m Items von n Testpersonen

Table 1: 20 Testpersonen $\times$ 10 Items (Antwortskala 1–5)

Testperson	Item 1	Item 2	Item 3	Item 4	Item 5	Item 6	Item 7	Item 8	Item 9	Item 10
1	1	5	3	4	2	1	1	4	3	2
2	4	2	2	4	2	3	4	2	4	5
3	1	2	2	1	5	3	1	2	5	5
4	2	1	5	5	2	3	4	4	4	4
5	5	4	2	5	5	3	2	5	1	4
6	3	1	1	1	4	4	5	1	1	1
7	2	4	3	1	5	1	2	5	5	2
8	3	3	3	3	4	1	2	5	5	4
9	3	2	4	2	1	4	2	5	1	1
10	1	2	3	2	3	2	3	4	5	1
11	5	4	1	3	2	1	1	4	4	3
12	5	4	4	2	3	2	2	4	2	1
13	2	4	5	4	3	3	3	2	2	1
14	2	2	1	3	1	4	3	1	1	4
15	1	4	1	5	5	1	3	3	5	3
16	5	1	4	2	4	3	3	1	5	5
17	5	1	5	2	4	5	5	1	2	3
18	1	4	5	1	1	3	3	4	5	5
19	1	1	4	3	5	4	1	5	2	1
20	5	2	5	3	5	2	2	1	4	1

Standardproblem der Testtheorie und Fragebogendatenanalyse

Erklärung der beobachteten Itemkorrelationsstruktur durch latente Variablen



Klassische Testtheorie

- Probabilistisches Modell von Item- und Summenwerten eines Tests
- Zentrale Beiträge von Gulliksen (1950) und Lord and Novick (1968)
- Latentes Variablenmodell der Form

$$\text{Beobachteter Wert} = \text{Wahrer Wert} + \text{Fehler} \tag{1}$$

- Meist als "Messfehlermodell" beschrieben
- Erklärung von Antwortmustern durch einen nicht direkt observierbaren True Score
- Modellierung von intra- und interindividueller Variabilität
- Grundlage der quantitativen Reliabilitätsbeurteilung

$\Rightarrow$ Paralleltest-Reliabilität, Cronbach's α, Spearman-Brown-Formel

Faktoranalysen

- Probabilistisches Modell der Kovarianzeigenschaften von Items eines Tests
- Zentrale Beiträge von Spearman (1904), Hotelling (1933), Lawley (1940)
- Latentes Variablenmodell der Form

$$\begin{aligned} \text{Latente Faktorwerte} &= \text{Latenter Fehler} \\ \text{Beobachtete Werte} &= \text{Ladungen} \cdot \text{Latente Faktorwerte} + \text{Fehler} \end{aligned} \tag{2}$$

- Erklärung von Antwortmustern durch wenige nicht direkt observierbare Faktoren
- Exploratorische und konfirmatorische Varianten

$\Rightarrow$ Bestimmung der faktoriellen Validität

Item-Response-Theorien

- Probabilistisches Modell von Itemantworten als Funktion latenter Zustände
- Zentrale Beiträge von Rasch (1960), Novick (1966), Lord (1980)
- Verschiedene mathematische Formen der logistischen Regression

$$\mathbb{P}\left(\text{Itemantwort}\right) = f\left(\text{Testparameter, Personenparameter}\right) \tag{3}$$

- Einsatz und Entwicklung insbesondere bei Leistungstests
- Zur Bedeutung im klinischen Kontext, siehe Reise and Waller (2009)

$\Rightarrow$ Anwendung insbesondere im Bereich des adaptiven Leistungstestens

Definition

Testarten

Konstrukt und Items

Antwortformate

Antwortprozesse

Qualitative Erprobung

Zusammenstellung einer Skala

Testgütekriterien

Testtheorien

Selbstkontrollfragen

Selbstkontrollfragen

Grundlagen, Testarten und Itementwicklung

1. Wie unterscheiden sich ein Konstrukt und ein beobachtbarer Indikator?
2. Nennen Sie die typischen Material- und Durchführungsbestandteile eines Tests.
3. Erläutern Sie die Begriffe Item, Itemstamm und Antwortformat.
4. Wie unterscheiden sich ein psychologischer Test und ein Experiment?
5. Vergleichen Sie Selbstbericht, Leistungstest und projektives Verfahren.
6. Was soll der BDI-II erfassen und auf welchen Zeitraum beziehen sich die Antworten?
7. Warum begründet ein BDI-II-Ergebnis allein noch keine klinische Diagnose?
8. Erläutern Sie am GEB den Unterschied zwischen beobachtetem Indikator und theoretischer Interpretation.
9. Welche Entscheidungen zu Zweck und Zielgruppe stehen vor der Itementwicklung?
10. Nach welchen Kriterien würden Sie ein vorhandenes Verfahren für eine Anwendung auswählen?
11. Wie grenzen Sie Konzentration beim Lernen von Motivation und Vorwissen ab?
12. Welche Funktion hat ein Inhaltsplan bei der Entwicklung eines Itempools?
13. Nennen Sie unterschiedliche Quellen für Items und den Beitrag der Zielgruppe.
14. Überarbeiten Sie ein Item, das zwei verschiedene Merkmale zugleich anspricht.
15. Warum reicht eine wörtliche Übersetzung für die Übertragung eines Tests nicht aus?

Antwortformate, Antwortprozesse und Erprobung

1. Vergleichen Sie freie Antworten, Zuordnungen, Rangordnungen, Auswahl- und Beurteilungsaufgaben.
2. Welche Regeln brauchen die Auswertung freier Antworten und die Gestaltung von Auswahlaufgaben?
3. Erläutern Sie Distraktoren, Disjunktheit und Exhaustivität an eigenen Beispielen.
4. Worin unterscheiden sich eine Forced-Choice-Auswahl und ein Rating ohne Mittelkategorie?
5. Unterscheiden Sie inhaltliche Mitte, „weiß nicht“, „nicht anwendbar“ und „keine Angabe“.
6. Erläutern Sie Polarität, Balance und Verankerung einer Antwortskala.
7. Welche Überlegungen bestimmen die Wahl eines Antwortformats?
8. Beschreiben Sie die Schritte von der gelesenen Frage bis zur mitgeteilten Antwort.
9. Wie können Erinnerungsprozesse und der Bezugszeitraum einen Selbstbericht beeinflussen?
10. Erläutern Sie soziale Erwünschtheit, Akquieszenz und Satisficing.
11. Warum lösen verneinte Items das Problem von Antworttendenzen nicht automatisch?
12. Wie können Reihenfolge und Erhebungssituation das Beantworten beeinflussen?
13. Erläutern Sie Paraphrasieren, lautes Denken und Probing.
14. Wie gelangen Sie von einer Rückmeldung im Pretest zu einer begründeten Revision?
15. Nach welchen inhaltlichen Kriterien behalten, überarbeiten oder streichen Sie ein Item?

Skalen, Gütekriterien und Testtheorien

1. Wie unterscheiden sich eine Skala mit Anzeichen eines Merkmals und ein Index verschiedener Einflüsse?
2. Wie kann die Itemauswahl unbeabsichtigt inhaltliche Schwerpunkte setzen?
3. Warum erproben Sie die vollständige Skala nochmals einschließlich Instruktion und Layout?
4. Welche Gründe können fehlende Antworten haben und warum brauchen sie vorab festgelegte Regeln?
5. Erläutern Sie Objektivität, Reliabilität und Validität anhand des BDI-II.
6. Warum ist tatsächliche Veränderung von unzuverlässiger Messung zu unterscheiden?
7. Welche Belege stützen eine Validitätsargumentation und warum genügt der Augenschein nicht?
8. Nennen und erläutern Sie die sieben weiteren Gütekriterien dieser Veranstaltung.
9. Nennen Sie die drei Hauptrichtungen der Testtheorie.
10. Erläutern Sie die Standarddatenstruktur der Testtheorie und Fragebogendatenanalyse.
11. Erläutern Sie das Standardproblem der Testtheorie und Fragebogendatenanalyse.
12. Erläutern Sie den Begriff der Klassischen Testtheorie.
13. Erläutern Sie den Begriff der Faktoranalyse.
14. Erläutern Sie den Begriff der Item-Response-Theorien.

Referenzen I

Beck, A. T. 1961. "An Inventory for Measuring Depression." *Archives of General Psychiatry* 4 (6): 561. https://doi.org/10.1001/archpsyc.1961.01710120031004.

Beck, Aaron T., Robert A. Steer, Roberta Ball, and William F. Ranieri. 1996. "Comparison of Beck Depression Inventories-IA and-II in Psychiatric Outpatients." *Journal of Personality Assessment* 67 (3): 588–97. https://doi.org/10.1207/s15327752jpa6703_13.

Gulliksen, Harold. 1950. *Theory of Mental Tests*. John Wiley & Sons Inc. https://doi.org/10.1037/13240-000.

Hautzinger, M, F. Keller, and C. Kühner. 2006. *BDI-II Beck Depressions-Inventar*. Pearson.

Hotelling, Harold. 1933. "Analysis of Complex Variables into Principal Components." *Journal of Educational Psychology* 24: 417-441 and 498-520.

Kaiser, F. G. 1998. "A General Measure of Ecological Behavior[1]." *Journal of Applied Social Psychology* 28 (5): 395–422. https://doi.org/10.1111/j.1559-1816.1998.tb01712.x.

Kaiser, Florian, Katarzyna Byrka, and Terry Hartig. 2010. "Reviving Campbell's Paradigm for Attitude Research." *Personality and Social Psychology Review* 14 (4): 351–67. https://doi.org/10.1177/1088868310366452.

Lawley, Derrick. 1940. "The Estimation of Factor Loadings by the Method of Maximum Likelihood." *Proceedings of the Royal Society of Edinburgh. Section B: Biological Sciences*.

Referenzen II

Lienert, Gustav A., and Ulrich Raatz. 1998. *Testaufbau und Testanalyse*. 6. Auflage. Beltz, Psychologie Verlags Union.

Lord, Frederic M. 1980. *Applications of Item Response Theory To Practical Testing Problems*. Routledge. https://doi.org/10.4324/9780203056615.

Lord, Frederic M., and Melvin R. Novick. 1968. *Statistical Theories of Mental Test Scores*. Nachdr. der Ausg. Reading, Mass. [u.a.], 1968. The Addison-Wesley Series in Behavioral Science: Quantitative Methods. Information Age Publ.

Moosbrugger, Helfried, and Augustin Kelava, eds. 2012. *Testtheorie und Fragebogenkonstruktion: mit 66 Abbildungen und 41 Tabellen*. 2., aktualisierte und überarbeitete Auflage. Springer-Lehrbuch. Springer.

Novick, Melvin R. 1966. "The Axioms and Principal Results of Classical Test Theory." *Journal of Mathematical Psychology* 3 (1): 1–18. https://doi.org/10.1016/0022-2496(66)90002-2.

Pospeschill, Markus. 2022. *Testtheorie, Testkonstruktion, Testevaluation*. 2nd ed. Ernst Reihnhardt Verlag.

Rasch, G. 1960. *Probabilistic Models for Some Intelligence and Attainment Tests*. Expanded ed. University of Chicago Press.

Reise, Steven P., and Niels G. Waller. 2009. "Item Response Theory and Clinical Measurement." *Annual Review of Clinical Psychology* 5 (1): 27–48. https://doi.org/10.1146/annurev.clinpsy.032408.153553.

Referenzen III

Revers, W. J, and K Taeber. 1968. *Der Thematische Apperzeptionstest*. Bern: Huber.

Rorschach, Hermann. 1921. *Psychodiagnostik: Methodik und Ergebnisse eines wahrnehmungsdiagnostischen Experiments*. Arbeiten zur angewandten Psychiatrie. Bircher.

Rost, Jürgen. 2004. *Lehrbuch Testtheorie, Testkonstruktion*. 2., vollständig überarbeitete und erweiterte Aufl. Aus dem Programm Huber. H. Huber.

Schmidt-Atzert, Lothar, and Karin Funsch. 2023. *KoKi - Konzentrationstest für Kinder*. 1st ed. Hogrefe Verlag.

Spearman, C. 1904. ""General Intelligence," Objectively Determined and Measured." *The American Journal of Psychology* 15 (2): 201. https://doi.org/10.2307/1412107.

Streiner, David L., Geoffrey R. Norman, and John Cairney. 2024. *Health Measurement Scales: A Practical Guide to Their Development and Use*. 6th ed. Oxford University Press. https://doi.org/10.1093/med/9780192869487.001.0001.

Warren, Howard C. 1934. *Dictionary of Psychology*. Routledge Revivals Ser. Routledge.