

Grundlagen der Testtheorie

BSc Psychologie WiSe 2026/27

Prof. Dr. Dirk Ostwald

(1) Psychologische Tests

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Definitionsversuche

Test (engl.) *Probe, Prüfung, Kontrolle*

Bedeutungen

- Ein Verfahren zur Untersuchung eines Persönlichkeitsmerkmals
- Der Vorgang der Durchführung einer Untersuchung
- Die Gesamtheit der zur Durchführung einer Untersuchung nötigen Materialien
- Ein statistisches Prüfverfahren (Hypothesentests)
- Kurze, außerplanmäßige "Zettelarbeiten" im Schulunterricht
- u.v.a.m.

Lienert and Raatz (1998)

Definitionsversuche

Test (engl.) *Probe, Prüfung, Kontrolle*

test = 1. (*logic*) any criterion or procedure used to determine the truth or falsity of a hypothesis, either by empirical evidence or by reasoning; 2. (*psychol.*) a routine examination administered to individuals belonging to the same group, in order to determine the relative position of a given individual in the group with respect to one or more mental traits, motor abilities, etc. or in order to compare one group with another in these characteristics. [In practice a series or battery of psychological tests (2) is generally used, and the scores are arranged or plotted on a definite scale; cf. **mental test**, **scale** (1).] **tester**^{np} (contr. rarely w. **testee**, the individual tested). — Fr. (1) *épreuve*, (2) *test*; Ger. (1) *Prüfung*, (2) *Test, Probe*.

Warren (1934)

Definitionsversuche

Definition eines **Tests** nach Moosbrugger and Kelava (2012)

"Ein *Test* ist ein wissenschaftliches Routineverfahren zu Erfassung eines oder mehrerer empirisch abgrenzbarer psychologischer Merkmale mit dem Ziel einer möglichst genauen quantitativen Aussage über den Grad der individuellen Merkmalsausprägung"

Definition eines **psychometrischen Tests** nach Bühner (2010)

"Ein *psychometrischer Test* ist ein wissenschaftliches Routineverfahren zur Untersuchung eines oder mehrerer empirisch abgrenzbarer Persönlichkeitsmerkmale (vgl. Lienert and Raatz (1998), S.1). Das Ziel eines psychometrischen Tests besteht darin, die absolute oder relative Ausprägung einer Eigenschaft, einer Fähigkeit oder eines Zustands bei einer oder mehreren Personen zu messen oder eine qualitative Aussage zu treffen, welcher Personenklasse Personen zugeordnet werden können (vgl. Rost (2004)). Psychometrische Tests sind nach der Klassischen oder probabilistischen Testtheorie entwickelt, sind theoretisch fundiert und genügen genau definierten Gütekriterien (Haupt- und Nebengütekriterien)."

Definition eines **Psychologischen Tests** nach Krauth (1995)

"Ein *psychologischer Test* besteht aus eine Menge von Reizen mit den zugehörigen zugelassenen Reaktionen, d.h. aus einer Menge von manifesten Variablen, und einer Vorschrift (Skala), die den Reaktionsmustern der manifesten Variablen Ausprägungen einer oder mehrerer latenter Variablen zuordnet. Anders ausgedrückt ist ein Test ein Messinstrument zur Messung von nicht direkt beobachtbaren (latenten) Variablen, deren Existenz man bei Personen (gelegentlich auch bei Tieren) postuliert."

Definitionsversuche

Definition eines **Psychologischen Tests** nach Lienert (1968) kommentiert von Rost (2004)

"Ein Test ist ein wissenschaftliches Routineverfahren zur Untersuchung eines oder mehrerer empirisch abgrenzbarer Persönlichkeitsmerkmale mit dem Ziel einer möglichst quantitativen Aussage über den relativen Grad der individuellen Merkmalsausprägung."

Wissenschaftlich

- Existenz einer Testtheorie zur Inferenz von manifesten auf latente Variablen

Routineverfahren

- Durchführung und Auswertung sind an einer Normstichprobe erprobt und dokumentiert

Persönlichkeitsmerkmale

- Erfassung stabiler Merkmale der Testperson, die für das im Test gezeigte Verhalten verantwortlich sind

Quantitativ

- Relativer Grad der Merkmalsausprägung, es können aber auch qualitative Aussagen von Interesse sein

Tests im engeren und weiteren Sinn nach Rost (2004)

Tests im engeren Sinn

- Testverfahren, die die Testpersonen nicht willentlich in eine gewünsche Richtung verfälschen kann

Tests im weiteren Sinn

- Fragebögen, standardisierte Interviews und standardisierte Beobachtungen

Testbestandteile

Materialbestandteile

- Testmanual
- Testmaterial (Items)
- Auswertungshilfen

Durchführungsbestandteile

- Testanweisung
- Testdurchführung
- Testauswertung

Lienert and Raatz (1998)

Definitionsversuche

Item

Kleinste Beobachtungseinheit und damit Grundbausteine eines psychologischen Tests

Item = Itemstamm + Antwortformat

Itemstamm

- Reiz, auf den eine Reaktion erwartet wird
- Beispiele: Frage, Aussage, Bild, Geschichte, Rechenaufgabe, ...

Antwortformat

- Art und Weise der Reaktionsregistrierung
- Beispiele: Kreuz auf einer Skala, leere Zeile, Zeichenpapier

Oft besteht ein Test aus mehreren Untertests, die aus mehreren Items bestehen

Prinzipiell können Untertests und Tests aus nur einem Item bestehen

Jedes Item kann also auch als ein Test angesehen werden

Lord and Novick (1968), Rost (2004)

Definitionsversuche

Tests und Studiendesign

Psychologische Tests sind spezielle Experimente

Unabhängige Variable

- Test mit den Leveln “Items”

Abhängige Variable

- Itemantworten oder Summenscore

Experimentelle Einheiten

- Testpersonen mit Messwiederholung

Konzeptualisierung als Einstichprobendesigns oder Testpersonen $\times$ Items Designs

Rost (2004)

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Testarten

Klassifikation

Psychometrische Persönlichkeitstests

- Klinische Tests
- Einstellungstests
- Persönlichkeitsstrukturtests
- Interessentests

Leistungstests

- Entwicklungstests
- Intelligenztests
- Allgemeine Leistungstests
- Schultests
- Spezielle Funktionsprüfungs- und Eignungstests

Persönlichkeitsentfaltungsverfahren

- Formdeuteverfahren
- Verbal-thematische Verfahren
- Zeichnerische- und Gestaltungsverfahren

Testarten

Charakteristika

Psychometrische Persönlichkeitstests

- Messen einer akuten Symptomatik (state) oder stabilen Eigenschaft (trait)
- Selbstauskunftsfragebögen ohne richtige oder falsche Antworten
- Voraussetzungen: Metakognition und Offenbarungsbereitschaft
- Verfälschung und Durchschaubarkeit in der Regel leicht

Leistungstests

- Messen einer Leistung
- Leistung kann als richtig oder falsch klassifiziert werden
- Schnelligkeitstest (Speedtests) und Niveautests (Powertests)
- Verfälschung nach unten möglich

Persönlichkeitsentfaltungsverfahren

- Projektive Verfahren
- Projektion als psychoanalytischer Abwehrmechanismus
- ICH projiziert ÜBER-ICH-konfliktträchtige Triebregungen nach außen
- Üblicherweise unstrukturiert und qualitativ

Testarten

Klinische Tests

Fragebogenverfahren zur ICD/DSM-basierten Diagnose psychischer Störungen

Störungsübergreifende und störungsspezifische Verfahren

Beispiel: Beck-Depressionsinventar (BDI-II)

- Selbstbeurteilungsinstrument zur Erfassung der Schwere einer depressiven Symptomatik
- Entwicklung von Beck et al. (1996)
- Nachfolger des Beck Depressionsinventar Beck (1961)
- Deutschsprachige Version nach Hautzinger et al. (2006)
- Sprachliche Überarbeitung und Anpassung an aktuelle Diagnosemanuale
- 21 Items zur Erfassung des Schweregrads von 0 bis 3 und summative Gesamtauswertung
- Grenzwerte der Nationalen Versorgungsleitlinie Unipolare Depression

0–13	keine Depression bzw. klinisch unauffällig oder remittiert
14–19	leichtes depressives Syndrom
20–28	mittelgradiges depressives Syndrom
$\geq$ 29	schweres depressives Syndrom

Klinische Tests

Beispiel: Beck-Depressionsinventar (BDI-II)

Beispielitem Traurigkeit

(0) Ich bin nicht traurig

(1) Ich bin oft traurig

(2) Ich bin ständig traurig

(3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte

Klinische Tests

Beispiel: Beck-Depressionsinventar (BDI-II)

Items

1. Traurigkeit
2. Pessimismus
3. Versagensgefühle
4. Verlust an Freude
5. Schuldgefühle
6. Bestrafungsgefühle
7. Selbstablehnung
8. Selbstkritik
9. Suizidgedanken
10. Weinen
11. Unruhe
12. Interessensverlust
13. Entschlussunfähigkeit
14. Wertlosigkeit
15. Energieverlust
16. Veränderungen der Schlafgewohnheiten
17. Reizbarkeit
18. Appetitveränderung
19. Konzentrationsschwierigkeiten
20. Müdigkeit
21. Verlust an sexuellem Interesse

Einstellungstests

Psychologische Einstellung

- Relativ stabile, aber veränderbare innere Haltung einer Person
- Haltung gegenüber Objekten, Personen, Gruppen, Ideen oder Situationen
- Kognitive, affektive und konative (handlungsbereitschaftsorientierte) Komponenten

Einstellungstest

- Psychologisches Messinstrument zur systematischen Erfassung von Einstellungen
- Meist durch Fragebögen oder Skalen realisiert
- Testperson bewertet Aussagen in unterschiedlichem Maß

Ziele eines Einstellungstests

- Erhebung von Wertorientierungen, Vorurteilen oder politischen/religiösen Überzeugungen
- Messung von arbeits- oder organisationsbezogenen Einstellungen
- Forschung zu sozialen Einstellungen (z. B. Minderheiten, Umweltschutz, Gesundheit)

Einstellungstests

Beispiel: General Ecological Behavior (GEB) Scale

Ursprünglich: Messinstrument für umweltschützendes Verhalten (Kaiser (1998))

Später: Messinstrument für individuelle Umwelteinstellung (Kaiser et al. (2010))

Theoretische Grundlage: Campbell-Paradigma (Campbell (1963))

- Grundidee: Stärke der Einstellung über erbrachte *Verhaltenskosten* messbar
- Einstellung: Ziel (z. B. “Umwelt schützen”)
- Verhaltenskosten: Eingesetzte Mittel zur Zielerreichung

Verhaltenskosten

- Unterschiedliche Kosten für unterschiedliche Verhaltensmittel
- Bsp. Recycling (gering) vs. Mitgliedschaft in Umweltschutzgruppe (hoch)
- Kostenarten: Aufwand, Zeit, Geld, soziale Normen, kulturelle Praktiken
- Je mehr und je höhere Kosten eine Person trägt, desto stärker ausgeprägte Umwelteinstellung

Einstellungstests

Beispiel: General Ecological Behavior (GEB) Scale

Testaufbau

- 50 Selbstberichte von Verhaltensweisen, mit deren Hilfe Menschen die Umwelt schützen
- 32 Selbstberichte erfordern Auskunft über die Häufigkeit ihres Auftretens
- Antwortmöglichkeiten: “nie”, “selten”, “gelegentlich,”oft” “sehr oft”
- 18 Selbstberichte erfordern eine Ja/Nein-Aussage.
- “keine Angabe” bei allen Selbstberichten möglich

Itembeispiele

“Ich kaufe Lebensmittel aus kontrolliert biologischem Anbau.”

☐ nie ☐ selten ☐ gelegentlich ☐ oft ☐ sehr oft ☐ keine Angabe

“Altglas bringe ich zum Sammelcontainer.”

☐ nie ☐ selten ☐ gelegentlich ☐ oft ☐ sehr oft ☐ keine Angabe

“Ich bin Mitglied in einer Umweltschutzorganisation.”

☐ ja ☐ nein ☐ keine Angabe

Testarten

Leistungstests

Beispiel: Konzentrationstest für Kinder (KoKi)

Objektive und kindgerechte Erfassung der Konzentrationsfähigkeit

Testaufbau und Aufgabenstellung

- 8 Testseiten mit je 100 Bildern, jede Seite mit 10 Zeilen $\times$ 10 Bilder (Hunde und Pferde)
- Kinder sollen Hunde durchstreichen, die in Richtung einer Wurst am Zeilenanfang/ende blicken
- Alle anderen Bilder = Distraktoren

Spezielle Distraktoren

- Auf der Hälfte der Testseiten: "verzauberte" Pferde (z. B. mit Flügeln, Geweih, 3 Beinen)
- Diese erregen besonders viel Aufmerksamkeit $\Rightarrow$ erschwerte Leistungskontrolle
- Erwartbar: geringere Testergebnisse auf Seiten mit "verzauberten" Pferden

Erhobene Kennwerte

- Konzentrationsfähigkeit, Arbeitstempo, Genauigkeit
- Unablenkbarkeit (Ablenkbarkeit durch "verzauberte" Pferde)

Diagnostische Relevanz

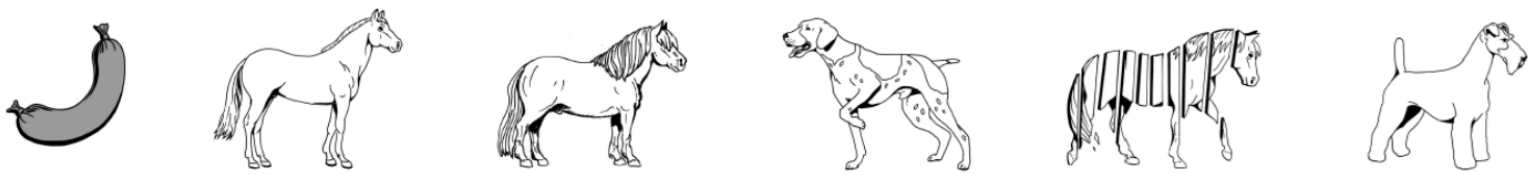
- Kombination der vier Kennwerte liefert Hinweise für ADHS-Diagnostik

Schmidt-Atzert and Funsch (2023)

Leistungstests

Beispiel: Konzentrationstest für Kinder (KoKi)

Beispielitem



Schmidt-Atzert and Funsch (2023)

Projektive Verfahren

Rorschach Test



Thematischer Apperzeptionstest



- Deutung mehrdeutige Tintenklecksbilder zur Ableitung von Hinweisen auf Persönlichkeitsmerkmale
- Geschichten zu mehrdeutigen Bildern zur Ableitung persönlicher Motive, Bedürfnisse und Konflikte
- Kein Gegenstand quantitativer Testtheorien $\rightarrow$ Verfahren qualitative Datenanalyse

Rorschach (1921), Revers and Taeber (1968)

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Antwortformat eines psychologischen Tests

Die Art und Weise, wie Testpersonen auf die gestellten Aufgaben reagieren sollen

Wahl des Antwortformates ist abhängig von Testart und Testaufgabe

Freies/offenes Antwortformat

- Kurzaufsatzaufgaben
- Ergänzungsaufgaben

Gebundenes/geschlossenes Antwortformat

- Ordnungsaufgaben
- Auswahlaufgaben
- Beurteilungsaufgaben

Wir folgen Pospeschill (2022), Kapitel 2

Offene Antwortformate

- Die Testperson formuliert die Antwort auf Grundlage einer strukturellen Vorgabe eigenständig
- Einsatz bei projektiven Verfahren und Abfragen komplexer Wissensinhalte
- Man unterscheidet Kurzaufsatzaufgaben und Ergänzungsaufgaben

Kurzaufsatzaufgaben

- Kurze schriftliche Abhandlung von einem Wort bis zu mehreren Sätzen
- Begrenzung der Wortzahl kann sinnvoll sein

Ergänzungsaufgaben

- Offene Fragen mit einem Schlüsselwort am Satzende
- Lückentext mit zu ergänzenden Schlüsselwörtern im laufenden Text

Vorteile offener Antwortformate

- Bei Leistungstests: Eigenständige Leistung, keine Zufallstreffer möglich
- Testen von Sprachverständnis, Motivation, Interesse, Kreativität, Reproduktion, Transfer

Nachteile offener Antwortformate

- Hoher Bearbeitungsaufwand und kognitive Belastung für Testpersonen
- Hoher Auswertungsaufwand und erschwerte Auswertungsobjektivität für Testende

Pospeschill (2022)

Kurzaufsatzaufgabe

Beispiel: Wissen über psychologische Tests

Erläutern Sie an einem Beispiel, wodurch eine Testanweisung missverständlich werden kann. Beschränken Sie Ihre Antwort auf zwei bis drei Sätze.

Antwort: .....

.....

.....

Auswertung: Die Antwort nennt eine missverständliche Testanweisung und erläutert anhand zweier möglicher Interpretationen, wie diese zu unterschiedlichen Antworten führen kann.

Ergänzungsaufgaben

Offene Fragen mit Schlüsselwort

(Einfachantwort) Wie bezeichnet man die kleinste Einheit eines psychologischen Tests? .....

(Reihenantwort) Wie heißen die drei klassischen Testgütekriterien? .....

(Analogieantwort) Länge verhält sich zu Meter wie Masse zu .....

(Folgenantwort) Welche Zahl setzt die Zahlenfolge fort? $2, 4, 8, 16,$ .....

Lückentext

Ergänzen Sie die fehlenden Fachbegriffe.

Die kleinste Einheit eines psychologischen Tests heißt _____. Bei _____ Antwortformaten formuliert die Testperson ihre Antwort selbst. Bei _____ Antwortformaten stehen Antwortmöglichkeiten zur Verfügung.

Ordnungsaufgaben

Umordnungsaufgaben und Zuordnungsaufgaben

Umordnungsaufgaben

- Testen schlussfolgernden Denkens oder des Ursache-Wirkungs-Verständnisses
- Nicht-verbale Aufgaben schließen Beeinträchtigung durch Lesefähigkeit aus
- Bildliche Aufgaben haben einen hohen Materialentwicklungsaufwand

Zuordnungsaufgaben

- Wissensprüfung durch Wiedererkennung
- Einfache Konstruktion, hohe Ökonomie und Auswertungsobjektivität
- Keine Reproduktion, Wiedererkennung reicht aus
- Zufallstreffer sind bei Fehlen von nicht-zuordbaren Antworten möglich

Pospeschill (2022)

Umordnungsaufgabe

Beispiel: Ablauf einer psychologischen Untersuchung

Bringen Sie die folgenden Schritte in eine sinnvolle zeitliche Reihenfolge. Tragen Sie dazu die Buchstaben in die Antwortzeile ein.

A. Die erhobenen Daten statistisch auswerten

B. Eine überprüfbare Hypothese formulieren

C. Die Ergebnisse im Hinblick auf die Hypothese interpretieren

D. Die Untersuchung planen und die Messinstrumente auswählen

E. Die Untersuchung durchführen und Daten erheben

Reihenfolge: _____ → _____ → _____ → _____ → _____

Zuordnungsaufgabe

Beispiel: Psychologische Erhebungsverfahren

Ordnen Sie jedem Beispiel das passende Verfahren zu. Tragen Sie den zugehörigen Buchstaben ein. Jedes Verfahren wird genau einmal verwendet.

A. Fremdbeurteilung B. Leistungstest C. Selbstbeurteilung

Beispiel	Antwort
Eine Person berichtet in einem Fragebogen über ihre eigene Stimmung.	_____
Eine Person markiert unter Zeitdruck vorgegebene Zielbilder. Die Anzahl korrekt markierter Bilder wird ausgewertet.	_____
Eine Lehrperson beurteilt die Konzentrationsfähigkeit eines Kindes.	_____

Auswahlaufgaben

- Auswahl zutreffender Antworten bei Vorgabe mehrerer Alternativen
- Dichotom = Zwei mögliche Antworten, Multiple Choice = Mehrere mögliche Antworten
- *Distraktoren* (Ablenkungsantworten) dienen der Schwierigkeit bei Leistungstests
- *Disjunktion* (Trennung) zwischen richtigen und falschen Aussagen wichtig bei Leistungstests
- *Exhaustivität* (Vollständigkeit) wichtig bei Persönlichkeitstests
- Fehlende Exhaustivität führt zu *Forced-Choice-Antworten*

Vorteile von Auswahlaufgaben

- Einfach, ökonomisch, objektiv

Nachteile von Auswahlaufgaben

- Hohe Ratewahrscheinlichkeit
- Reine Rekognitionsleistung, keine Problemlösefähigkeits- oder Kreativitätsleistung
- Distraktionsentwicklung kann komplex sein

Pospeschill (2022)

Einfachwahl- und Mehrfachwahlaufgaben

Beispiel: Einfachwahlaufgabe

Welche Aussage beschreibt einen standardisierten Test am besten?

Kreuzen Sie genau **eine** Antwort an.

☐ Jede Person erhält eine frei gewählte Instruktion.

☐ Durchführung und Auswertung folgen festgelegten Regeln.

☐ Jede Antwort wird ausschließlich intuitiv beurteilt.

Beispiel: Mehrfachwahlaufgabe

Welche der folgenden Aufgaben haben ein offenes Antwortformat?

Kreuzen Sie **alle** zutreffenden Antworten an.

☐ Einen Begriff in eigenen Worten erklären

☐ Eine Aussage als richtig oder falsch markieren

☐ Ein fehlendes Wort in einem Lückentext ergänzen

☐ Eine Aussage auf einer Ratingskala beurteilen

Disjunkte und exhaustive Antwortalternativen

Beispiel: Nicht disjunkte Antwortalternativen

Wo haben Sie gestern zuletzt gelernt? Wählen Sie eine Antwort.

☐ Zu Hause ☐ In einer Bibliothek ☐ An der Universität

- Eine Universitätsbibliothek passt zu zwei Kategorien.
- Die Antwortalternativen überschneiden sich und sind daher nicht disjunkt.

Beispiel: Nicht exhaustive Antwortalternativen

Wo haben Sie gestern zuletzt gelernt? Wählen Sie eine Antwort.

☐ Zu Hause ☐ In einer Bibliothek

- Andere Lernorte und der Fall, dass die Person gestern nicht gelernt hat, fehlen.
- Die Antwortalternativen sind daher nicht exhaustiv.

Forced-Choice-Antwortalternativen

Beispiel: Relative Präferenz

Welche Aussage beschreibt Sie eher? Bitte wählen Sie **eine** der beiden Aussagen.

☐ Beim Lernen suche ich gern den Austausch mit anderen.

☐ Beim Lernen arbeite ich gern für mich allein.

- Die Testperson muss sich zwischen den vorgegebenen Aussagen entscheiden
- Die Antwort beschreibt nur eine relative Präferenz innerhalb des Aussagenpaares.

Beurteilungsaufgaben

- Eine *Beurteilung* wird auch als *Rating* bezeichnet.
- Anwendung vorzugsweise im Rahmen von klinischen Fragebögen und Persönlichkeitstests
- Einschätzung eines *Statements* mit *diskreter Ratingskala* oder *kontinuierlicher Analogskala*
- Aus den (gewichteten) Punktwerten wird meist ein Gesamtpunktwert (*score*) errechnet

Wichtige Aspekte von Beurteilungsaufgaben

1. Anzahl der Skalenstufen
2. Forciertheit des Ratings
3. Ausweichkategorien
4. Polarität der Antwortskala
5. Balance der Antwortskala
6. Verankerung der Antwortskala
7. Symbole und Marker
8. Kombinierte Antwortskalen
9. Skalenniveau im Sinne der Repräsentationstheorie des Messens

Pospeschill (2022)

Beurteilungsaufgaben

Anzahl von Skalenstufen

- Abhängig von und determinierend für die Urteilsdifferenzierbarkeit
- Meist 9 ± 1 Skaleneinheiten bei einzelner Ratingskala (Test mit einem Item)
- Meist 5 $\pm$ 2 Skaleneinheiten bei Itembatterien (Test mit vielen Items)
- Entfällt für grafische Analogskalen

Unforciertes und forciertes Rating

- Ungerade Anzahl an Kategorien enthalten Mittelpunkt als mittleres Rating/Ausweichoption
- Mittelpunkt kann uneindeutig interpretiert werden = unforciertes Rating
- Gerade Anzahl an Kategorien enthalten keinen Mittelpunkt
- Testperson ist zu einem Urteil gezwungen = forciertes Rating

Ausweichkategorie

- "Weiß nicht", "nicht anwendbar", "keine Meinung"
- Valide Information über Nichtbearbeitung bzw. Nichtbeantwortung der Frage

Pospeschill (2022)

Verbale, unforcierte Ratingskalen

Beispiel: Lernen im Studium

Wählen Sie für jede Frage eine Antwort.

(Häufigkeit) Wie häufig lernen Sie gemeinsam mit anderen?

☐ Nie ☐ Selten ☐ Manchmal ☐ Oft ☐ Immer

(Intensität) Wie stark fühlen Sie sich beim Lernen unter Zeitdruck?

☐ Gar nicht ☐ Wenig ☐ Mittelmäßig ☐ Stark ☐ Sehr stark

(Wahrscheinlichkeit) Wie wahrscheinlich ist es, dass Sie morgen lernen?

☐ Sehr unwahrscheinlich ☐ Eher unwahrscheinlich ☐ Weder wahrscheinlich noch unwahrscheinlich ☐ Eher wahrscheinlich ☐ Sehr wahrscheinlich

(Bewertung) Wie beurteilen Sie die Lernbedingungen an Ihrer Universität?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

(Einstellung) „Gemeinsames Lernen ist sinnvoll.“

☐ Stimme überhaupt nicht zu ☐ Stimme eher nicht zu ☐ Stimme weder zu noch lehne ab ☐ Stimme eher zu ☐ Stimme völlig zu

Verbale, forcierte Ratingskalen

Beispiel: Lernen im Studium

Wählen Sie für jede Frage eine Antwort.

(Häufigkeit) Wie häufig lernen Sie gemeinsam mit anderen?

☐ Nie ☐ Selten ☐ Oft ☐ Immer

(Intensität) Wie stark fühlen Sie sich beim Lernen unter Zeitdruck?

☐ Gar nicht ☐ Wenig ☐ Stark ☐ Sehr stark

(Wahrscheinlichkeit) Wie wahrscheinlich ist es, dass Sie morgen lernen?

☐ Sehr unwahrscheinlich ☐ Eher unwahrscheinlich ☐ Eher wahrscheinlich ☐ Sehr wahrscheinlich

(Bewertung) Wie beurteilen Sie die Lernbedingungen an Ihrer Universität?

☐ Sehr schlecht ☐ Eher schlecht ☐ Eher gut ☐ Sehr gut

(Einstellung) „Gemeinsames Lernen ist sinnvoll.“

☐ Stimme überhaupt nicht zu ☐ Stimme eher nicht zu ☐ Stimme eher zu ☐ Stimme völlig zu

Beurteilungsaufgaben

Polarität der Antwortskala

Unipolare Skalen: Von geringster bis größter Intensität eines Merkmals

Bipolare Skalen: Zwischen zwei entgegengesetzten Polen

Die Wahl hängt vom Gegenstandsbereich und vom Inhalt des Items ab.

Beispiel: Unipolare Ratingskala

Wie stark sind Ihre Schmerzen momentan?

☐ Keine ☐ Leichte ☐ Mittlere ☐ Starke ☐ Sehr starke

Beispiel: Bipolare Ratingskala

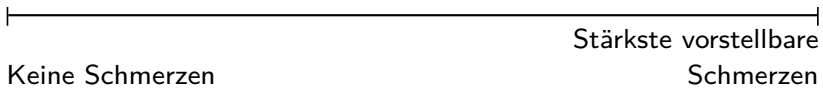
Wie bewerten Sie die Lehrveranstaltung?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

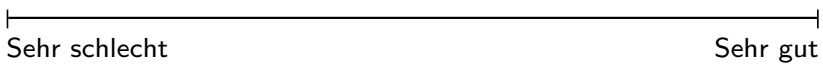
Beispiele: Analogskalen

Markieren Sie Ihre Einschätzung jeweils durch einen Strich auf der Linie.

Unipolar: Wie stark sind Ihre Schmerzen momentan?



Bipolar: Wie bewerten Sie die Lehrveranstaltung?



Beurteilungsaufgaben

Balance der Antwortskala

Balancierte Skalen: Gleiche Anzahl positiver und negativer Kategorien

Unbalancierte Skalen: Ungleiche Anzahl positiver und negativer Kategorien

- Im Allgemeinen werden balancierte Skalen vorgezogen.
- Unbalancierte Skalen können bei begründeten Annahmen über den vorwiegenden Antwortbereich sinnvoll sein.

Beispiel: Balancierte Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

Zwei negative und zwei positive Kategorien sowie eine neutrale Kategorie.

Beispiel: Unbalancierte Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Gut ☐ Sehr gut

- Eine negative und drei positive Kategorien sowie eine neutrale Kategorie.
- Der positive Bewertungsbereich wird feiner unterteilt.

Beurteilungsaufgaben

Verankerung der Antwortskala

- Definition der Skalenendpunkte sowie der einzelnen Skalenstufen
- *Numerische Verankerung*: Bezeichnung der Kategorien mit Zahlen
- *Verbale Verankerung*: Bezeichnung der Kategorien mit Worten oder Sätzen
- Allgemein kann Äquidistanz der Kategorienurteile nicht impliziert werden

Symbole und Marker

- Verwendbarkeit bei mit Zahlen oder semantischen Kategorien ungeübten Testpersonen

Kombinierte Skalen

- Multiple Skalierung durch sowohl numerische, verbale oder symbolische Verankerung

Pospeschill (2022)

Beurteilungsaufgaben

Wie zufrieden sind Sie mit der Lehrveranstaltung?

Numerisch verankerte Ratingskalen

Unforciert ☐ -2 ☐ -1 ☐ 0 ☐ $+1$ ☐ $+2$

Forciert ☐ -2 ☐ -1 ☐ $+1$ ☐ $+2$

Kombiniert numerisch und verbal verankerte Ratingskalen

Unforciert

☐ -2 Sehr unzufrieden

☐ -1 Eher unzufrieden

☐ 0 Weder zufrieden noch unzufrieden

☐ $+1$ Eher zufrieden

☐ $+2$ Sehr zufrieden

Forciert

☐ -2 Sehr unzufrieden

☐ -1 Eher unzufrieden

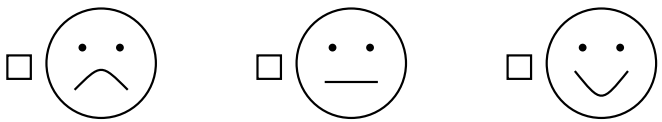
☐ $+1$ Eher zufrieden

☐ $+2$ Sehr zufrieden

Symbolische Marker

Plus-/Minuszeichen: ☐ $--$ ☐ $-$ ☐ $\pm$ ☐ $+$ ☐ $++$

Gesichter:



Beispiel: Wie stark sind Ihre Schmerzen momentan?

Optische Skala

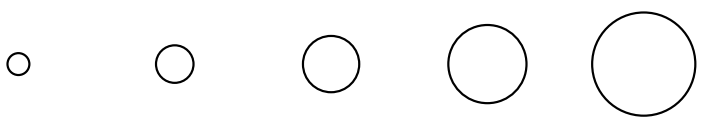
Markieren Sie eine Stelle auf dem Keil.



Keine Schmerzen — Stärkste vorstellbare Schmerzen

Kreisgrößen

Kreuzen Sie den passenden Kreis an.



Keine Schmerzen — Sehr starke Schmerzen

Beurteilungsaufgaben

Skalenniveau im Sinne der Repräsentationstheorie des Messens

- Aus Äquidistanz der Ratingkategorien kann nicht auf Äquidistanz der Urteile geschlossen werden
- Ratingtechnik ist eine Einzelreizmethode, kein Additive Conjoint Measurement
- Das repräsentationstheoretische Skalenniveau einer Ratingskala ist i. Allg. unbestimmt
- Bei jeder Messung interagieren das zu messende Merkmal, das Messinstrument, die Testperson

Vorteile von Beurteilungsaufgaben

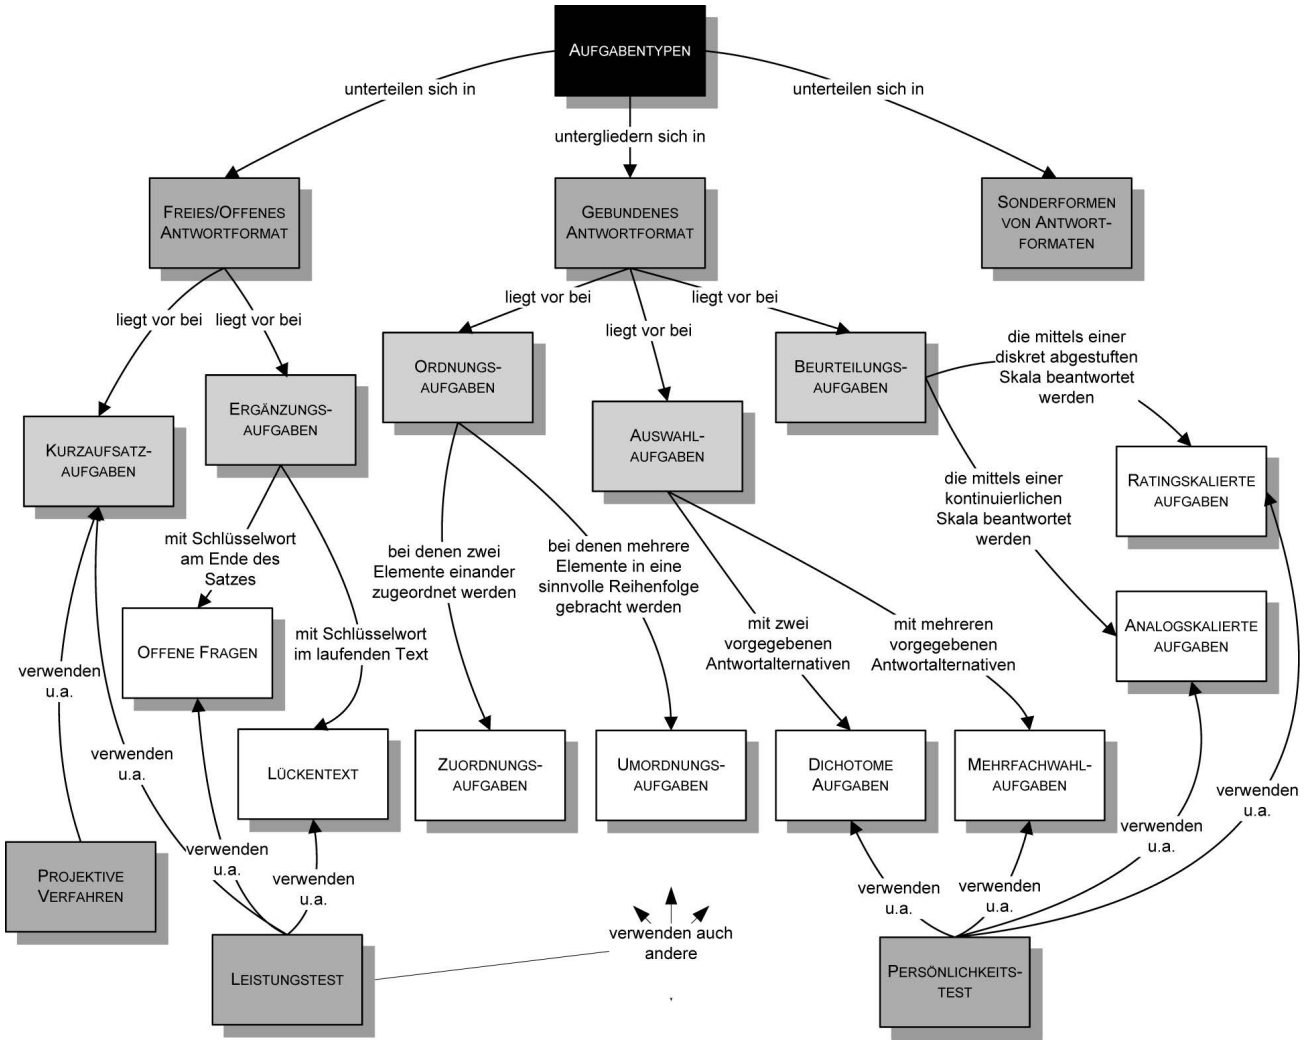
- Leichte Handhabung, Ökonomie, allgemeine Akzeptanz durch Testpersonen

Nachteile von Beurteilungsaufgaben

- Eher Ordinal- denn Intervallskalencharakter
- Subjektive Interpretation der Antwortkategorien (z.B. “selten”, “manchmal”, “oft”)

Pospeschill (2022)

Antwortformate



Pospeschill (2022)

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Testgütekriterien

Qualitätseigenschaften von psychologischen Tests

Grundlage der Argumentation für die Wissenschaftlichkeit eines Testverfahrens

Qualitative Konzepte, die (nur) zum Teil quantitativ erfasst werden können

Hauptgütekriterien

1. Objektivität
2. Reliabilität
3. Validität

Nebengütekriterien

1. Normierung
2. Skalierung
3. Testökonomie
4. Nützlichkeit
5. Zumutbarkeit
6. Unverfälschbarkeit
7. Fairness

Wir folgen Kapitel 2 in Moosbrugger and Kelava (2012)

Objektivität

"Ein Test ist dann *objektiv*, wenn er dasjenige Merkmal, das er misst, unabhängig von Testleitenden und Testauswertenden misst. Außerdem müssen klare und anwenderunabhängige Regeln für die Ergebnisinterpretation vorliegen."

Durchführungsobjektivität

- Unabhängigkeit der Testpersonantwort von den Testleitenden und der Testsituation
- Standardisierte Testausführung anhand des Testmanuals
- Höchstmögliche Kontrolle der Testsituation

Auswertungsobjektivität

- Unabhängigkeit der Testauswertung von den Testauswertenden
- Bei gebundenem Antwortformat und automatisierter Auswertung üblicherweise gegeben
- Bei offenen Antwortformaten aufwändiger herzustellen

Interpretationsobjektivität

- Unabhängigkeit der Testergebnisschlussfolgerungen von Testanwendern
- Meist durch Normwertklassifikationen gegeben

Moosbrugger and Kelava (2012)

Beispiel BDI-II

Durchführungsobjektivität durch schriftliche Durchführungsinstruktion

Dieser Fragebogen enthält 21 Gruppen von Aussagen. Bitte lesen Sie jede dieser Gruppen von Aussagen sorgfältig durch und suchen Sie sich dann in jeder Gruppe eine Aussage heraus, die am besten beschreibt, wie Sie sich in den letzten zwei Wochen, einschließlich heute, gefühlt haben. Kreuzen Sie die Zahl neben der Aussage an, die Sie sich herausgesucht haben (0,1,2 oder 3). Falls in einer Gruppe mehrere Aussagen gleichermaßen auf Sie zutreffen, kreuzen Sie die Aussage mit der höheren Zahl an. Achten Sie bitte darauf, dass Sie in jeder Gruppe nicht mehr als eine Aussage ankreuzen, das gilt auch für Gruppe 16 (Veränderungen der Schlafgewohnheiten) oder Gruppe 18 (Veränderungen des Appetits).

Auswertungsobjektivität

Der Fragebogen wird durch die einfache Addition der angekreuzten Aussagen ausgewertet. Jedes Item wird auf einer 4-Punkt-Skala bewertet, die von 0 bis 3 reicht. Kreuzt ein Proband bei einem Item mehrere Aussagen an, so geht nur die Aussage mit der höchsten Ziffer in den Summenwert ein. Der Gesamtwert des BDI-II kann Werte zwischen 0 und 63 Punkten annehmen.

Interpretationsobjektivität

0 - 8 Keine, 9 - 13 minimale, 14 - 19 leichte, 20 - 28 mittelschwere, 29 - 63 schwere Depression

Hautzinger et al. (2006)

Reliabilität

"Ein Test ist dann *reliabel*, wenn er das Merkmal, das er misst, exakt, d.h. ohne Messfehler misst."

- Die klassische Testtheorie bettet diese Definition in ein probabilistisches Modell ein
- Die klassische Testtheorie ist in erster Linie eine quantitative Reliabilitätstheorie

Retest-Reliabilität

- Korrelation der Ergebnisse des identischen Tests zwischen zwei Testmessungen
- Abhängig von Zeitintervall-, Erinnerungs- und Lerneffekten

Paralleltest-Reliabilität

- Korrelation der Ergebnisse eines Tests mit dem Ergebnis eines Paralleltests
- Paralleltest als Test aus möglichst ähnlichen Items (Itemzwillinge)

Testhalbierungs-Reliabilität (Split-Half-Reliabilität)

- Unterteilung eines Tests in zwei möglichst parallele Testhälften
- Korrekturfaktor zur Hochrechnung auf ursprüngliche Itemanzahl (Spearman-Brown-Formel)

Interne Konsistenz

- Verallgemeinerung der Testhalbierungs-Reliabilität auf Einzelitemebene
- Cronbach's α der klassischen Testtheorie

Moosbrugger and Kelava (2012)

Testgütekriterien

Beispiel BDI-II

In der Studie von Beck et al. (1996) resultierte bei 26 Patienten, die im Abstand von einer Woche untersucht wurden, ein Retestkoeffizient von $r_{tt} = .93$. Aus Studentenstichproben werden für ein- bis zweiwöchige Zeiträume Koeffizienten von $r_{tt} = .74 - .96$ berichtet (Leigh & Antony-Tolbert, 2001; Al-Musawi, 2001; Sprinkle, Lurie, Insko et al., 2002; Ghassemzadeh, Mojtabai, Karamghadiri & Ebrahimkhani, 2005). In Tabelle 2 sind bisherige Ergebnisse zur internen Konsistenz (Cronbach's α) des BDI II aufgelistet. In psychiatrischen Stichproben lag die interne Konsistenz im Bereich von $.89 \leq \alpha \leq .94$, in nichtklinischen Stichproben im Bereich von $.84 \leq \alpha \leq .91$.

Hautzinger et al. (2006)

Beispiel GEB

Die gefundene Test-Retest-Reliabilität liegt bei $r_{tt} = .76$ (Kaiser & Wilson, 2000) und $r_{tt} = .83$ (Kaiser, Frick & Stoll-Kleemann, 2001) und sogar bei $r_{tt} = .96$ (Kaiser & Byrka, 2011) und $r_{tt} = .99$ (Kaiser, Brügger, Hartig, Bogner & Gutscher, 2014), wenn korrigiert um die Messfehlerausdünnung.

Kaiser (2020)

Beispiel KoKi

Interne Konsistenz (Cronbachs Alpha) für Konzentrationsleistung = .96, Arbeitstempo = .94 und Genauigkeit = .83. Retestreliabilität (Intervall von 6 bis 12 Wochen) für Konzentrationsleistung = .84, Arbeitstempo = .85, Genauigkeit = .53 sowie Unablenkbarkeit = .47.

Schmidt-Atzert and Funsch (2023)

Validität

"Ein Test gilt dann als valide, wenn er das Merkmal, das er messen soll, auch wirklich misst und nicht irgendein anderes."

- Es existiert keine allgemeine quantitative Validitätstheorie
- Je nach Testart werden unterschiedliche Maße zur Validitätsargumentation genutzt

Augenscheinvalidität

- Validitätseinschätzung durch Laien
- Qualitativer Grad der intuitiv-repräsentativen Erfassung des Merkmals

Inhaltsvalidität

- Validitätseinschätzung durch Testexpert:innen
- Qualitativer Grad der fachlich-repräsentativen Erfassung des Merkmals

Kriteriumsvalidität

- Quantitativer Grad des Zusammenhangs eines Testergebnisses mit einem externen Kriterium
- Beispiel: Varianzaufklärung von Psychologiestudienleistungen durch Studieneingangstest

Validität

Konstruktvalidität

Grad der wissenschaftlichen Fundierung des Schlusses von Testwerten auf Merkmale

Zur Erinnerung: Validität in Einführung in die psychologischen Forschungsmethoden

Struktursuchendes Vorgehen

- Exploratorische Faktoranalyse zur Inspiration einer Faktorentdeckung
- Konvergente Validität (Übereinstimmung mit Messung ähnlicher Merkmale)
- Diskriminatorische Validität (Abgrenzung zur Messung anderer Merkmale)

Strukturprüfendes Vorgehen

- Faktorielle Validität mithilfe konfirmatorischer Faktoranalysen
- Homogenitätsprüfungen mithilfe von Item-Response-Theorie-Modellen
- Strukturgleichungsmodellevaluation

Moosbrugger and Kelava (2012)

Beispiel BDI-II

Konvergente und diskriminante Validität

In Tabelle 3 sind Studien zum Zusammenhang des BDI II mit anderen Selbst- und Fremdbeurteilungsskalen aufgeführt. Wie daraus hervorgeht, korreliert das Verfahren mit anderen Depressionsskalen zwischen r = .68 bis r = .89, etwas geringer mit selbst- und fremdbeurteilter Angst/Ängstlichkeit (.37 $\leq$ r $\leq$ .60) sowie im ähnlichen Bereich mit konstruktnahen kognitiven Skalen (.37 $\leq$ r $\leq$ .68). Die Differenzierungsfähigkeit bezüglich Depression und Angst anhand des BDI II ist eingeschränkt und abhängig von der Methode: fremdbeurteilte Angst anhand der HRSA korreliert niedriger mit dem BDI II als selbstbeurteilte Angst anhand des BAI (vgl. Tabelle 3). Bislang fehlen Studien, die Zusammenhänge zwischen BDI II und konstruktfernen Verfahren (z.B. symptomferne Persönlichkeitstraits) erfassen.

Faktorielle Validität

In der Untersuchung von Beck et al. (1996) legten Scree-Tests aus explorativen Faktorenanalysen sowohl für die Patientenstichprobe als auch für die Studentenstichprobe die Extraktion zweier Faktoren nahe. Nach parallel durchgeführten Hauptachsenanalysen mit anschließender obliquer (Promax-)Rotation resultierte für die Patientenstichprobe ein Faktor, den die Autoren als "somatisch-affektiven" Faktor bezeichneten, auf einem zweiten Faktor luden v.a. kognitive Items des BDI-II, er wurde demnach als "kognitiver" Faktor bezeichnet. Die beiden obliquen Faktoren korrelierten miteinander zu r = 0.66. In der Studentenstichprobe repräsentierte dagegen der erste Faktor die "kognitiv-affektive", der zweite Faktor die "somatische" Dimension. Hier betrug die Korrelation der beiden Faktoren r = 0.62.

Beispiel GEB

Validität

Obwohl sich das mehrdimensionale Rasch-Modell dem eindimensionalen Rasch-Modell bei der mittels GEB erfassten Neigung, sich umweltschützend zu verhalten, als formal überlegen erwies, ist der Informationsverlust des eindimensionalen Modells vernachlässigbar gering. So lagen die messfehlerkorrigierten Korrelationen zwischen den Verhaltensneigungen in den verschiedenen Verhaltensdomänen in der Regel jenseits von .50 und im Bereich der Reliabilitäten der einzelnen Skalen. Entsprechend erscheint es nicht nur machbar, sondern aus Sparsamkeitsgründen auch ratsam, Umweltschutzneigung, wie beabsichtigt, als eine mehr oder weniger konsistente, allgemeine Verhaltensneigung zu erfassen (Kaiser & Wilson, 2004).

Beispiel KoKi

Validität

Konvergente Konstruktvalidität: Korrelationen der "Konzentrationsleistung" im KoKi mit dem d2-R (.69), der Skala "Aufmerksamkeit-selektiv" der IDS (.58), der "Verarbeitungsgeschwindigkeit" der WISC-IV (.55), des "Wahrnehmungstempos" im CFT 1-R (.57). Korrelationen der "Genauigkeit" im KoKi mit Fehlerwerten im d2-R (.48) und der IDS (.40). Zusammenhänge des KoKi mit der Lehrerfremdbeurteilung ADHS-FBB im DISYPS II zwischen .22 und .33 (Korrelationsbeträge). Erwartungsgemäßer Leistungsunterschied im KoKi zwischen Kindern mit und ohne ADHS (Δ ca. 0.5 SD).

Beziehungen zwischen den drei Hauptgütekriterien

Objektivität $\Rightarrow$ Reliabilität $\Rightarrow$ Validität

- Ein Test, der in anderer Testsituation andere Resultate ergibt, kann nicht reliabel sein
- Ein Test, der ein Konstrukt zu unreliabel misst, kann nicht sehr valide sein

Reliabilitäts-Kriteriumsvaliditäts-Dilemma der klassischen Testtheorie

- Abnahme der Kriteriumsvalidität bei Erhöhung der Reliabilität
- Einstieg in Rost (2004), Kapitel 6.4.3

Rost (2004)

Nebengütekriterien

Nebengütekriterium	Definition
Normierung	Für einen Test liegen geeignete Vergleichswerte vor, mit deren Hilfe das Ergebnis einer Testperson im Verhältnis zu einer relevanten Bezugsgruppe eingeordnet und interpretiert werden kann.
Skalierung	Die nach den Auswertungsregeln gebildeten Testwerte geben die qualitativen Beziehungen zwischen den Merkmalsausprägungen angemessen wieder.
Testökonomie	Der finanzielle und zeitliche Aufwand eines Tests ist im Verhältnis zum diagnostischen Erkenntnisgewinn gering.
Nützlichkeit	Das erfasste Merkmal ist praktisch relevant, und die auf den Testergebnissen beruhenden Entscheidungen oder Maßnahmen lassen mehr Nutzen als Schaden erwarten.
Zumutbarkeit	Die zeitliche, psychische und physische Belastung der Testperson bleibt sowohl für sich genommen als auch im Verhältnis zum Nutzen der Testanwendung angemessen.
Unverfälschbarkeit	Der Test ist so gestaltet, dass die Testperson ihre Testwerte nicht durch gezieltes Antwort- oder Bearbeitungsverhalten steuern oder verzerren kann.
Fairness	Die Testwerte führen zu keiner systematischen Benachteiligung von Personen aufgrund ihrer Zugehörigkeit zu ethnischen, soziokulturellen oder geschlechtsspezifischen Gruppen.

In Anlehnung an Moosbrugger and Kelava (2012)

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Testkonstruktion

Konstruktdefinition und Testplanung

- Merkmal definieren und seine inhaltlichen Teilbereiche bestimmen
- Zielgruppe und vorgesehenen Anwendungszweck festlegen

Itemkonstruktion und Antwortformate

- Geeignete Fragen oder Aufgaben aus der Konstruktdefinition ableiten
- Antwortformate, Instruktionen und Auswertungsregeln festlegen

Erprobung und Auswahl der Items

- Testentwurf erproben und Eigenschaften der Items untersuchen
- Items anhand statistischer und inhaltlicher Kriterien überarbeiten und auswählen

Validierung und Dokumentation

- Objektivität, Reliabilität und Validität des Tests untersuchen
- Entwicklung, Anwendung und Güte des Tests im Testmanual dokumentieren

Normierung

- Normierung ermöglicht die Einordnung eines Ergebnisses in eine Vergleichsgruppe
- Grundlage ist eine hinreichend große, möglichst repräsentative Normstichprobe
- Rohwerte beschreiben die Ergebnisse einzelner Items oder eines gesamten Tests
- Vergleichsgruppe und Normierungsverfahren werden im Testmanual dokumentiert
- Normwerte können nach relevanten Merkmalen wie Alter oder Diagnose differenziert werden
- Prozentränge geben an, welcher Anteil der Normstichprobe höchstens denselben Rohwert erzielt
- Normwerte müssen regelmäßig auf ihre Aktualität überprüft werden
- Neben Rohwertnormwerten sind auch Z-Scores, T-Scores und weitere Normwerte verbreitet.

Beispiel BDI-II

Normwerte

Prozentränge für eine Patientenstichprobe und für Gesunde sind in Tabelle 11 errechnet. Hieraus ist z. B. zu erkennen, dass 50% der depressiven Patienten in Behandlung einen BDI-II-Summenwert von 22 oder höher erzielen, während bei den Gesunden nur 5% diesen oder einen höheren Wert erreichen.

BDI-II-Summenwerte für ausgewählte Prozentränge

Prozentrang	10	20	25	30	35	40	45	50	55	60	65	70	75	80	85	90	95	99
Depressive	6	11	13	15	16	18	20	22	24	27	28	30	32	33	37	41	44	55
Gesunde	0	1	2	3	3	3	4	5	6	7	8	9	10	12	13	17	23	34

Hautzinger et al. (2006), S. 29, Tabelle 11

Die neuropsychologische Testbatterie CERAD-Plus verwendet Z-Scores zur Darstellung ihrer Normwerte.

Die SCL-90-S zur Erfassung psychischer Belastung verwendet T-Scores zur Darstellung ihrer Normwerte.

Weitere Beispiele für Normskalen sind die *Stanine-Werte* oder *Sten-Werte*.

Testrohwertdatenstruktur

y_{ij} bezeichnet den beobachteten Wert der i-ten Testperson im j-ten von m Items, y_i den Summenscore.

Beispiel: Simulierter BDI-II-Datensatz mit $n = 20$ Testpersonen, $m = 21$ Items und $y_{ij} \in \{0, 1, 2, 3\}$.

i	y_{i1}	y_{i2}	y_{i3}	y_{i4}	y_{i5}	y_{i6}	y_{i7}	y_{i8}	y_{i9}	y_{i10}	y_{i11}	y_{i12}	y_{i13}	y_{i14}	y_{i15}	y_{i16}	y_{i17}	y_{i18}	y_{i19}	y_{i20}	y_{i21}	y_i
1	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	1
2	0	0	0	0	0	0	0	0	1	0	0	0	0	1	0	1	0	0	0	0	0	3
3	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
5	0	0	0	0	1	0	0	0	1	0	1	1	1	1	1	0	0	0	0	0	1	8
6	0	1	0	1	0	0	1	1	1	1	0	1	2	2	1	1	1	1	2	1	2	20
7	1	0	0	0	1	1	0	1	0	0	1	0	0	0	1	0	0	0	0	0	0	6
8	1	1	0	0	1	0	0	2	0	0	0	0	1	1	1	0	1	0	2	1	0	12
9	0	0	0	1	1	1	0	0	1	0	0	1	1	1	0	1	0	0	0	0	0	8
10	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
11	0	0	0	0	1	0	2	2	1	2	1	0	1	0	2	2	0	0	0	1	0	15
12	0	0	0	0	0	0	0	0	0	0	1	0	1	0	0	0	0	0	0	0	0	2
13	0	0	1	0	0	1	0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	4
14	0	0	0	0	0	0	1	0	1	1	1	0	1	1	1	1	2	1	0	0	0	11
15	0	0	0	0	0	0	0	0	0	1	0	1	0	0	0	0	0	0	0	0	0	2
16	1	0	0	1	1	0	0	1	1	1	0	0	0	1	1	1	0	0	0	1	0	10
17	0	0	0	1	0	0	0	1	0	1	0	0	1	0	0	0	0	1	0	0	1	6
18	0	0	0	0	0	0	1	1	0	0	1	0	0	1	0	0	0	0	0	0	0	4
19	3	1	1	0	1	1	2	2	2	2	0	2	1	1	2	2	2	2	1	1	1	30
20	0	0	0	0	0	0	0	0	0	0	0	0	1	1	1	0	0	0	0	0	0	3

Standarddeskriptivstatistiken von Testrohwerten (1)

y_{ij} bezeichnet den beobachteten Wert der i-ten von n Testpersonen im j-ten von m Items.

Deskriptivstatistik	Bezeichnung	Formel
Summe der Itemwerte von Testperson i	Summenscore	$y_i = \sum_{j=1}^{m} y_{ij}$
Mittelwert der Summenscores	Mittelwert	$\bar{y} = \frac{1}{n} \sum_{i=1}^{n} y_i$
Empirische Standardabweichung der Summenscores	Standardabweichung	$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (y_i - \bar{y})^2}$
Mittelwert von Item j	Itemschwierigkeit	$\bar{y}_j = \frac{1}{n} \sum_{i=1}^{n} y_{ij}$
Empirische Varianz von Item j	Itemvarianz	$s_j^2 = \frac{1}{n-1} \sum_{i=1}^{n} (y_{ij} - \bar{y}_j)^2$
Empirische Standardabweichung von Item j	Itemstandardabweichung	$s_j = \sqrt{s_j^2}$

Standarddeskriptivstatistiken von Testrohwerten (2)

Deskriptivstatistik	Bezeichnung	Formel
Empirische Kovarianz von Item j und Item k	Itemkovarianz	$c_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} (y_{ij} - \bar{y}_j)(y_{ik} - \bar{y}_k)$
Empirische Kovarianzmatrix	Kovarianzmatrix	$C = (c_{jk})_{j,k=1}^{m} = \begin{pmatrix} s_1^2 & c_{12} & \cdots & c_{1m} \\ c_{21} & s_2^2 & \cdots & c_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & s_m^2 \end{pmatrix}$
Empirische Korrelation von Item j und Item k	Itemkorrelation	$r_{jk} = \frac{c_{jk}}{s_j s_k}$
Empirische Korrelationsmatrix	Korrelationsmatrix	$R = (r_{jk})_{j,k=1}^{m} = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1m} \\ r_{21} & 1 & \cdots & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ r_{m1} & r_{m2} & \cdots & 1 \end{pmatrix}$
Empirische Korrelation von Item j und Summenscore	Unbereinigte Trennschärfe	$r_{j,y} = \frac{\sum_{i=1}^{n} (y_{ij} - \bar{y}_j)(y_i - \bar{y})}{\sqrt{\left(\sum_{i=1}^{n} (y_{ij} - \bar{y}_j)^2\right)\left(\sum_{i=1}^{n} (y_i - \bar{y})^2\right)}}$

Z-Scores

- Z-Scores beschreiben die Abweichung vom Mittelwert der Normstichprobe in Standardabweichungen
- Berechnung aus Summenscore y_i, Mittelwert $\bar{y}$ und Standardabweichung s der Summenscores

$$z_i = \frac{y_i - \bar{y}}{s} \tag{1}$$

- In der Normstichprobe haben Z-Scores dann Mittelwert 0 und empirische Standardabweichung 1
- $z_i = 0$: durchschnittlich, $z_i = \pm 1$: eine empirische Standardabweichung darüber/darunter
- Bei normalverteilten Rohwerten sind Z-Scores standardnormalverteilt

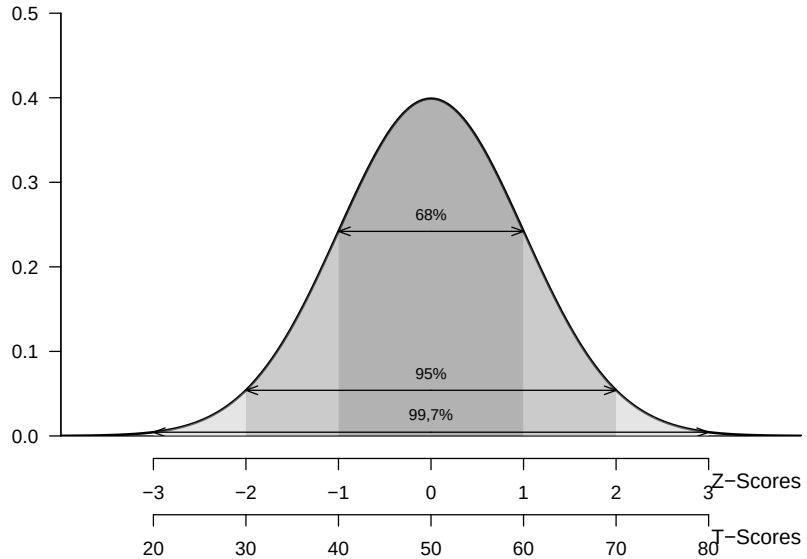
T-Scores

- T-Scores übertragen Z-Scores in einen "leichter lesbaren" Wertebereich
- Die dafür auf McCall (1922) zurückgehende Transformation lautet

$$t_i = 10 z_i + 50 \tag{2}$$

- In der Normstichprobe haben T-Scores dann den Mittelwert 50 und die Standardabweichung 10
- $z_i = -1,\ 0,\ 1$ entspricht also $t_i = 40,\ 50,\ 60$
- Bei normalverteilten Rohwerten sind T-Scores normalverteilt
- T-Scores haben nichts mit der T-Statistik der frequentistischen Inferenz zu tun

Z-Scores und T-Scores bei Normalverteilung einer Normstichprobe



Anwendungsbeispiel

- Eine Testperson habe einen BDI-II-Summenscore von $y_i = 30$.
- Die Normstichprobe habe den Mittelwert $\bar{y} = 20$ und die empirische Standardabweichung $s = 5$.
- Die Testperson hat dann einen Z-Score von $z_i = \frac{30-20}{5} = 2$.
- Das Ergebnis der Testperson liegt zwei Standardabweichungen über dem Mittelwert der Normstichprobe.
- "Leichter zu lesen" (?!) ist die Aussage, die Testperson hat einen T-Score von $t_i = 10 \cdot 2 + 50 = 70$.

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Testtheorien

- Probabilistische Modelle zum Zusammenhang von zu erfassendem Konstrukt und Testverhalten
- Grundlage der Fragebogendatenanalyse

Hauptrichtungen

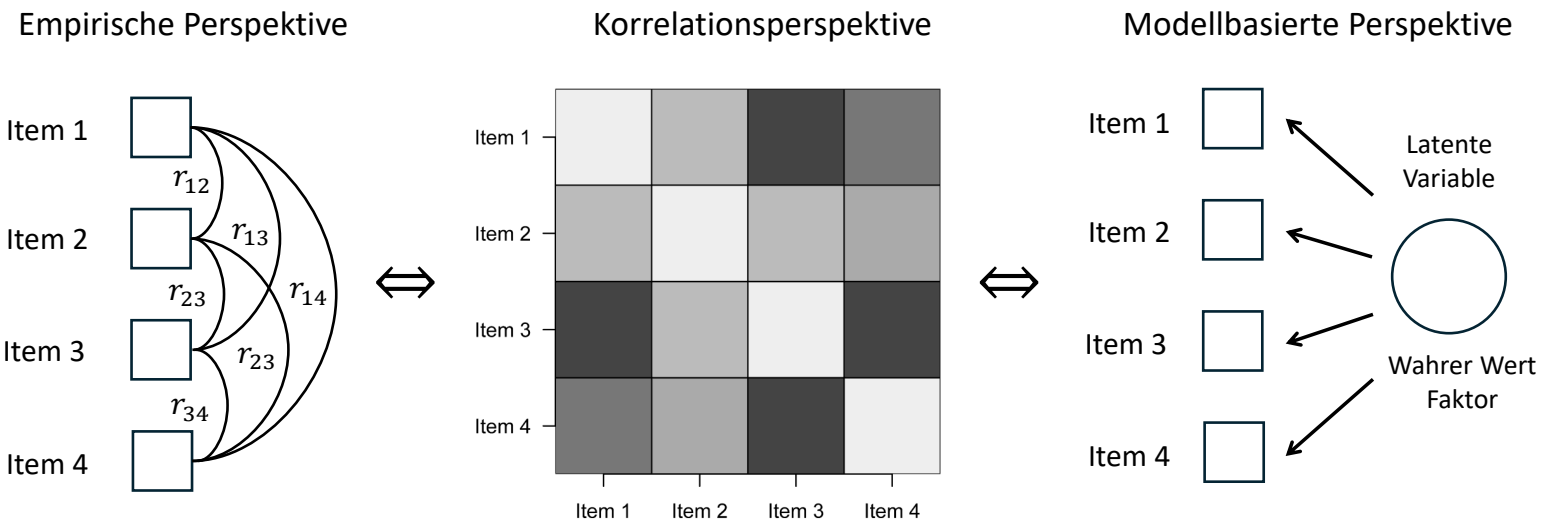
- Klassische Testtheorie
- Faktoranalyse
- Item-Response-Theorien

Besonderheiten

- Klassische Testtheorie und Faktoranalyse sind Modelle mit latenten Zufallsvariablen
- Item-Response-Theorien können latente Zufallsvariablen enthalten

Standardproblem der Testtheorie und Fragebogendatenanalyse

Erklärung der beobachteten Itemkorrelationsstruktur durch latente Variablen



Klassische Testtheorie

- Probabilistisches Modell der Itemwerte und Summenscores eines Tests
- Zentrale Beiträge von Gulliksen (1950) und Lord and Novick (1968)
- Latentes Variablenmodell der Form

$$\text{Beobachteter Wert} = \text{Wahrer Wert} + \text{Fehler} \tag{3}$$

- Wahrer Wert = Latente Zufallsvariable
- Meist als "Messfehlermodell" beschrieben
- Erklärung von Antwortmustern durch einen nicht direkt observierbaren True Score
- Modellierung von intra- und interindividueller Variabilität
- Grundlage der quantitativen Reliabilitätsbeurteilung

$\Rightarrow$ Paralleltest-Reliabilität, Cronbachs α, Spearman-Brown-Formel

Faktoranalysen

- Probabilistisches Modell der Itemvarianzen und Itemkovarianzen eines Tests
- Empirische Grundlage: Kovarianzmatrix C beziehungsweise Korrelationsmatrix R der Itemwerte
- Zentrale Beiträge von Spearman (1904), Hotelling (1933), Lawley (1940)
- Latentes Variablenmodell der Form

$$\text{Beobachtete Werte} = \text{Ladungen} \cdot \text{Faktorwerte} + \text{Fehler} \tag{4}$$

- Faktoren = Latente Zufallsvariablen
- Erklärung von Antwortmustern durch wenige nicht direkt observierbare Faktoren
- Exploratorische und konfirmatorische Varianten

$\Rightarrow$ Bestimmung der faktoriellen Validität

Item-Response-Theorien

- Probabilistisches Modell von Itemantworten als Funktion von latenten Zuständen
- Zentrale Beiträge von Rasch (1960), Novick (1966), Lord (1980)
- Verschiedene mathematische Formen der logistischen Regression

$$\mathbb{P}\left(\text{Itemantwort}\right) = f\left(\text{Testparameter, Personenparameter}\right) \tag{5}$$

- Personenparameter = Manchmal latente Zufallsvariable, manchmal nicht
- Einsatz und Entwicklung insbesondere bei Leistungstests (PISA)
- Zur Bedeutung im klinischen Kontext siehe Reise and Waller (2009)

$\Rightarrow$ Anwendung insbesondere im Bereich des adaptiven Leistungstestens

Definitionsversuche

Testarten

Antwortformate

Testgütekriterien

Testkonstruktion

Testtheorien

Selbstkontrollfragen

Selbstkontrollfragen I

1. Erläutern Sie den Begriff des psychologischen Tests nach Lienert (1968) und kommentiert von Rost (2004).
2. Nennen Sie die typischen Material- und Durchführungsbestandteile eines Tests.
3. Erläutern Sie die Begriffe Item, Itemstamm, Antwortformat.
4. Erläutern Sie den Begriff des psychometrischen Persönlichkeitstests.
5. Nennen Sie vier Formen psychometrischer Persönlichkeitstests.
6. Erläutern Sie den Begriff des Leistungstests.
7. Nennen Sie vier Formen von Leistungstests.
8. Erläutern Sie den Begriff des Persönlichkeitsentfaltungsverfahrens.
9. Nennen Sie drei Formen von Persönlichkeitsentfaltungsverfahren.
10. Erläutern Sie den Begriff des klinischen Tests.
11. Erläutern Sie den Begriff des Einstellungstests.
12. Erläutern Sie den Begriff des freien Antwortformats und nennen Sie zwei Beispiele.
13. Erläutern Sie Vor- und Nachteile freier Antwortformate.
14. Erläutern Sie den Begriff des gebundenen Antwortformats und nennen Sie drei Beispiele.
15. Erläutern Sie den Begriff der Ordnungsaufgabe und nennen Sie zwei Beispiele.
16. Erläutern Sie den Begriff der Auswahlaufgabe.
17. Erläutern Sie die Begriffe der Distraktoren, der Disjunktion und der Exhaustivität bei Auswahlaufgaben.
18. Erläutern Sie Vor- und Nachteile von Auswahlaufgaben.
19. Erläutern Sie den Begriff der Forced-Choice-Auswahlaufgabe.
20. Erläutern Sie den Begriff der Beurteilungsaufgabe.
21. Erläutern Sie die Begriffe des forcierten und unforcierten Ratings bei Beurteilungsaufgaben.
22. Erläutern Sie den Begriff der Ausweichkategorie bei Beurteilungsaufgaben.
23. Erläutern Sie den Begriff der Antwortskalenpolarität bei Beurteilungsaufgaben.
24. Erläutern Sie den Begriff der Antwortskalenbalance bei Beurteilungsaufgaben.
25. Erläutern Sie den Begriff der Antwortskalenverankerung bei Beurteilungsaufgaben.

Selbstkontrollfragen II

26. Erläutern Sie Vor- und Nachteile von Beurteilungsaufgaben.
27. Erläutern Sie den Begriff des Testgütekriteriums.
28. Nennen Sie die drei Hauptgütekriterien für psychologische Tests.
29. Nennen Sie sieben Nebengütekriterien für psychologische Tests.
30. Geben Sie die Definition der Objektivität nach Moosbrugger and Kelava (2012) wieder.
31. Erläutern Sie die Begriffe Durchführungsobjektivität, Auswertungsobjektivität, Interpretationsobjektivität.
32. Geben Sie die Definition der Reliabilität nach Moosbrugger and Kelava (2012) wieder.
33. Erläutern Sie die Begriffe der Retest-, Paralleltest- und Split-Half-Reliabilität.
34. Erläutern Sie den Begriff der internen Konsistenz eines psychologischen Tests.
35. Geben Sie die Definition der Validität nach Moosbrugger and Kelava (2012) wieder.
36. Erläutern Sie die Begriffe der Augenschein-, Inhalts- und Kriteriumsvalidität.
37. Erläutern Sie den Begriff der Konstruktvalidität eines psychologischen Tests.
38. Nennen Sie die drei Hauptrichtungen der Testtheorie.
39. Erläutern Sie die Testrohwertdatenstruktur.
40. Erläutern Sie das Standardproblem der Testtheorie und Fragebogendatenanalyse.
41. Erläutern Sie den Begriff der klassischen Testtheorie.
42. Erläutern Sie den Begriff der Faktoranalyse.
43. Erläutern Sie den Begriff der Item-Response-Theorie.
44. Skizzieren Sie wesentliche Schritte in der Konstruktion eines Tests.
45. Erläutern Sie den Begriff der Testnormierung.
46. Erläutern Sie die Begriffe Rohwert, Z-Score und T-Score.

Referenzen I

Beck, A. T. 1961. "An Inventory for Measuring Depression." *Archives of General Psychiatry* 4 (6): 561. https://doi.org/10.1001/archpsyc.1961.01710120031004.

Beck, Aaron T., Robert A. Steer, Roberta Ball, and William F. Ranieri. 1996. "Comparison of Beck Depression Inventories-IA and-II in Psychiatric Outpatients." *Journal of Personality Assessment* 67 (3): 588–97. https://doi.org/10.1207/s15327752jpa6703_13.

Bühner, Markus. 2010. *Einführung in die Test- und Fragebogenkonstruktion*. 2., aktualisierte und erw. Aufl., [Nachdr.]. Pearson Studium Psychologie. Pearson Studium.

Campbell, Donald T. 1963. "Social Attitudes and Other Acquired Behavioral Dispositions." In *Psychology: A Study of a Science. Study II. Empirical Substructure and Relations with Other Sciences. Volume 6. Investigations of Man as Socius: Their Place in Psychology and the Social Sciences*. McGraw-Hill. https://doi.org/10.1037/10590-003.

Gulliksen, Harold. 1950. *Theory of Mental Tests*. John Wiley & Sons Inc. https://doi.org/10.1037/13240-000.

Hautzinger, M, F. Keller, and C. Kühner. 2006. *BDI-II Beck Depressions-Inventar*. Pearson.

Hotelling, Harold. 1933. "Analysis of Complex Variables into Principal Components." *Journal of Educational Psychology* 24: 417-441 and 498-520.

Kaiser, F. G. 1998. "A General Measure of Ecological Behavior[1]." *Journal of Applied Social Psychology* 28 (5): 395–422. https://doi.org/10.1111/j.1559-1816.1998.tb01712.x.

Kaiser, F. G. 2020. *GEB-50. General Ecological Behavior Scale*. ZPID (Leibniz Institute for Psychology Information) – Open Test Archive. https://doi.org/10.23668/PSYCHARCHIVES.3453.

Kaiser, Florian, Katarzyna Byrka, and Terry Hartig. 2010. "Reviving Campbell's Paradigm for Attitude Research." *Personality and Social Psychology Review* 14 (4): 351–67. https://doi.org/10.1177/1088868310366452.

Referenzen II

Krauth, Joachim. 1995. *Testkonstruktion und Testtheorie*. Beltz, Psychologie Verl.-Union.

Lawley, Derrick. 1940. "The Estimation of Factor Loadings by the Method of Maximum Likelihood." *Proceedings of the Royal Society of Edinburgh. Section B: Biological Sciences*.

Lienert, Gustav A. 1968. *Testaufbau und Testanalyse*. 4th ed. Psychologie Verlags Union.

Lienert, Gustav A., and Ulrich Raatz. 1998. *Testaufbau und Testanalyse*. 6. Auflage. Beltz, Psychologie Verlags Union.

Lord, Frederic M. 1980. *Applications of Item Response Theory To Practical Testing Problems*. Routledge. https://doi.org/10.4324/9780203056615.

Lord, Frederic M., and Melvin R. Novick. 1968. *Statistical Theories of Mental Test Scores*. Nachdr. der Ausg. Reading, Mass. [u.a.], 1968. The Addison-Wesley Series in Behavioral Science: Quantitative Methods. Information Age Publ.

McCall, William A. 1922. *How to Measure in Education.* MacMillan Co. https://doi.org/10.1037/13551-000.

Moosbrugger, Helfried, and Augustin Kelava, eds. 2012. *Testtheorie und Fragebogenkonstruktion: mit 66 Abbildungen und 41 Tabellen*. 2., aktualisierte und überarbeitete Auflage. Springer-Lehrbuch. Springer.

Novick, Melvin R. 1966. "The Axioms and Principal Results of Classical Test Theory." *Journal of Mathematical Psychology* 3 (1): 1–18. https://doi.org/10.1016/0022-2496(66)90002-2.

Pospeschill, Markus. 2022. *Testtheorie, Testkonstruktion, Testevaluation*. 2nd ed. Ernst Reihnhardt Verlag.

Rasch, G. 1960. *Probabilistic Models for Some Intelligence and Attainment Tests*. Expanded ed. University of Chicago Press.

Reise, Steven P., and Niels G. Waller. 2009. "Item Response Theory and Clinical Measurement." *Annual Review of Clinical Psychology* 5 (1): 27–48. https://doi.org/10.1146/annurev.clinpsy.032408.153553.

Referenzen III

Revers, W. J, and K Taeber. 1968. *Der Thematische Apperzeptionstest*. Bern: Huber.

Rorschach, Hermann. 1921. *Psychodiagnostik: Methodik und Ergebnisse eines wahrnehmungsdiagnostischen Experiments*. Arbeiten zur angewandten Psychiatrie. Bircher.

Rost, Jürgen. 2004. *Lehrbuch Testtheorie, Testkonstruktion*. 2., vollständig überarbeitete und erweiterte Aufl. Aus dem Programm Huber. H. Huber.

Schmidt-Atzert, Lothar, and Karin Funsch. 2023. *KoKi - Konzentrationstest für Kinder*. 1st ed. Hogrefe Verlag.

Spearman, C. 1904. ""General Intelligence," Objectively Determined and Measured." *The American Journal of Psychology* 15 (2): 201. https://doi.org/10.2307/1412107.

Warren, Howard C. 1934. *Dictionary of Psychology*. Routledge Revivals Ser. Routledge.