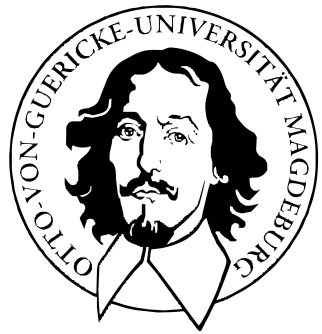


Grundlagen der Testtheorie

BSc Psychologie WiSe 2026/27

Prof. Dr. Dirk Ostwald

(3) Reliabilität und interne Konsistenz

Reliabilität

Praxis der Reliabilitätsschätzung

Interne Konsistenz

Selbstkontrollfragen

Reliabilität

Praxis der Reliabilitätsschätzung

Interne Konsistenz

Selbstkontrollfragen

Reliabilität

Testgütekriterium Reliabilität

„Ein Test ist dann *reliabel*, wenn er das Merkmal, das er misst, exakt, d.h. ohne Messfehler misst. Vor dem Hintergrund der Klassischen Testtheorie unterscheidet man die *Retest-Reliabilität*, die *Paralleltest-Reliabilität*, die *Testhalbierungs-Reliabilität (Split-Half-Reliabilität)* und die *Innere Konsistenz* eines Tests."

Moosbrugger and Kelava (2012), Kapitel 2

„Unter *Reliabilität* wird die Genauigkeit einer Messung verstanden. Ein Testverfahren ist perfekt reliabel, wenn die damit erhaltenen Testwerte frei von zufälligen Messfehlern sind. Das Testverfahren ist umso weniger reliabel, je größer die Einflüsse von zufälligen Messfehlern sind"

Moosbrugger and Kelava (2012), Kapitel 6

Reliabilität

Testgütekriterium Reliabilität

- Die Reliabilität ist definiert als die quadrierte Korrelation von beobachtetem und wahrem Wert.
- Anhand der Eigenschaften des Modells multipler Testmessungen ergeben sich verschiedene Interpretationen.
- Die Interpretation nach Moosbrugger and Kelava (2012) findet sich auch.
- Messfehlerfreie Testmessungen sind allerdings sicherlich nur ein nicht zu erreichendes Ideal.
- Wir betrachten zunächst die Reliabilität von Testmessungen im Modell multipler Testmessungen.
- Allerdings ergibt sich dabei keine Möglichkeit, die Reliabilität von Testmessungen empirisch zu messen.
- Zentral ist dann die Definition der *Paralleltestreliabilität*. Diese ist empirisch schätzbar.
- Bei der Retest-Reliabilität handelt es sich um eine spezielle Paralleltestreliabilität.
- Innere Konsistenz und Split-Half-Reliabilität betrachten wir im Abschnitt Interne Konsistenz.

Definition (Reliabilität einer Testmessung)

Gegeben sei das Modell multipler Testmessungen für eine beliebige Testmessung j mit $1 \leq j \leq m$,

$$\mathbb{P}(\tau_{1j}, y_{1j}, ..., \tau_{nj}, y_{nj}) := \prod_{i=1}^{n} \mathbb{P}(\tau_{ij}, y_{ij}) := \prod_{i=1}^{n} \mathbb{P}(y_{ij}|\tau_{ij})\mathbb{P}(\tau_{ij}) \tag{1}$$

wobei nach Definition des Modells gilt, dass

$$\mathbb{P}(\tau_{1j}, y_{1j}) = \cdots = \mathbb{P}(\tau_{nj}, y_{nj}). \tag{2}$$

Die *Reliabilität der Testmessung* j ist dann definiert als

$$\mathrm{R}_j := \rho(y_{ij}, \tau_{ij})^2 \text{ für ein beliebiges } 1 \leq i \leq n. \tag{3}$$

Bemerkungen

- Vor dem Hintergrund des vereinfachten Modells der Klassischen Testtheorie schreibt man auch $\mathrm{R} = \rho(y, \tau)^2$

Reliabilität

Bemerkungen (fortgesetzt)

- Die Reliabilität einer Testmessung ist als quadrierte Korrelation von beobachtetem und wahrem Wert definiert.
- Mit $-1 \leq \rho(y_{ij}, \tau_{ij}) \leq 1$ folgt direkt, dass $0 \leq \mathrm{R}_j \leq 1$.
- $\mathrm{R}_j = 0$ impliziert $\rho(y_{ij}, \tau_{ij}) = 0$, also die Unkorreliertheit von beobachtetem und wahrem Wert.
- $\mathrm{R}_j = 0$ impliziert also, dass der beobachtete Wert hinsichtlich des wahren Werts nicht aussagekräftig ist
- $\mathrm{R}_j = 1$ impliziert $\rho(y_{ij}, \tau_{ij}) = \pm 1$, also die linear-affine Abhängigkeit von beobachtetem und wahrem Wert.
- $\mathrm{R}_j = 1$ impliziert also, dass der beobachtete Wert hinsichtlich des wahren Werts aussagekräftig ist.
- Weil wahre Werte nur indirekt beobachtbar sind, wird eine alternative Form zur *Reliabilitätsschätzung* genutzt.

Theorem (Eigenschaften der Reliabilität einer Testmessung)

Gegeben sei das Modell multipler Testmessungen für eine beliebige Testmessung j mit $1 \leq j \leq m$,

$$\mathbb{P}(\tau_{1j}, y_{1j}, ..., \tau_{nj}, y_{nj}) := \prod_{i=1}^{n} \mathbb{P}(y_{ij}|\tau_{ij})\mathbb{P}(\tau_{ij}). \tag{4}$$

Dann gilt für die Reliabilität R_j der Testmessung j, dass

(1) $\mathsf{R}_j = \frac{\mathbb{V}(\tau_{ij})}{\mathbb{V}(y_{ij})}$

(2) $\mathsf{R}_j = 1 - \frac{\mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})}$

für alle $1 \leq i \leq n$.

Beweis

(1) Mit Aussage (5) von Theorem Eigenschaften bezüglich einer Testmessung (Foliensatz 2) gilt

$$\mathsf{R}_j = \rho(y_{ij}, \tau_{ij})^2 = \left(\frac{\mathbb{C}(y_{ij}, \tau_{ij})}{\mathbb{S}(y_{ij})\mathbb{S}(\tau_{ij})} \right)^2 = \frac{\mathbb{C}(y_{ij}, \tau_{ij})^2}{\mathbb{V}(y_{ij})\mathbb{V}(\tau_{ij})} = \frac{\mathbb{V}(\tau_{ij})^2}{\mathbb{V}(y_{ij})\mathbb{V}(\tau_{ij})} = \frac{\mathbb{V}(\tau_{ij})}{\mathbb{V}(y_{ij})}. \tag{5}$$

(2) Mit Aussage (4) von Theorem Eigenschaften bezüglich einer Testmessung (Foliensatz 2) gilt dann weiter

$$\mathsf{R}_j = \frac{\mathbb{V}(\tau_{ij})}{\mathbb{V}(y_{ij})} = \frac{\mathbb{V}(y_{ij}) - \mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})} = \frac{\mathbb{V}(y_{ij})}{\mathbb{V}(y_{ij})} - \frac{\mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})} = 1 - \frac{\mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})}. \tag{6}$$

□

Reliabilität

Bemerkungen

- Da τ_{ij} und ε_{ij} nicht direkt beobachtbar sind, sind (1) und (2) nur von theoretischem Interesse.
- Die Reliabilität einer Testmessung ist der Anteil der Varianz des wahren Werts an der des beobachteten Werts,

$$\mathsf{R}_j = \frac{\mathbb{V}(\tau_{ij})}{\mathbb{V}(y_{ij})} = \frac{\mathbb{V}(\tau_{ij})}{\mathbb{V}(\tau_{ij}) + \mathbb{V}(\varepsilon_{ij})}\,. \tag{7}$$

- Ist $\mathbb{V}(\tau_{ij}) = 0$, so ist auch $\mathsf{R}_j = 0$, ist $\mathbb{V}(\varepsilon_{ij}) = 0$ so ist $\mathsf{R}_j = 1$.
- $\mathsf{R}_j > 0$ impliziert also, dass der wahre Wert eine von Null verschiedene Varianz (über Testpersonen) hat.
- Die Reliabilität entspricht auch 1 minus dem Anteil der Varianz des Messfehlers an der des beobachteten Werts.
- Definition und Äquivalenzen nach Kelley (1927), Guttman (1945) und Lord and Novick (1968).
- Cronbach (1947, S. 6–7) kritisiert die Trennung in „wahre“ Anteile und Messfehler bei der Reliabilitätsdefinition.

Definition (Reliabilität einer Paralleltestmessung)

Gegeben sei das Modell paralleler Testmessungen für eine beliebige Testmessung j mit $1 \leq j \leq m$,

$$\mathbb{P}(\tau_1, y_{1j}, ..., \tau_n, y_{nj}) := \prod_{i=1}^{n} \mathbb{P}(\tau_i, y_{ij}) = \prod_{i=1}^{n} \mathbb{P}(\tau_i)\mathbb{P}(y_{ij}|\tau_i) \tag{8}$$

wobei nach Definition des Modells gilt, dass

$$\mathbb{P}(\tau_1, y_{1j}) = \cdots = \mathbb{P}(\tau_n, y_{nj}). \tag{9}$$

Die *Reliabilität der Paralleltestmessung* j ist dann definiert als

$$\mathsf{R}_j := \rho(y_{ij}, \tau_i)^2 \text{ für ein beliebiges } 1 \leq i \leq n. \tag{10}$$

Bemerkungen

- In Bezug auf das vereinfachte Modell der Klassischen Testtheorie schreibt man auch hier $\mathsf{R} = \rho(y, \tau)^2$

Theorem (Paralleltestreliabilität)

Gegeben sei das Modell paralleler Testmessungen. Dann gelten

(1) $\mathsf{R}_j = \frac{\mathbb{V}(\tau_i)}{\mathbb{V}(y_{ij})}$ für alle $1 \leq j \leq m$.

(2) $\mathsf{R}_j = 1 - \frac{\mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})}$ für alle $1 \leq j \leq m$.

(3) $\mathsf{R}_j = \rho(y_{ij}, y_{ik}) = \mathsf{R}_k$ für alle $1 \leq j, k \leq m$ mit $j \neq k$.

Bemerkungen

- Aussagen (1) und (2) sind analog zum Theorem der Reliabilität multipler Testmessungen.
- Aussage (3) des Theorems begründet die Paralleltest- und Retestreliabilitätsschätzung.
- Man sagt dazu vereinfachend, dass „die Korrelation paralleler Testmessungen gleich ihrer Reliabilität ist“.
- Zur Messung der Reliabilität nutzt man eine Schätzung der Korrelation zweier paralleler Testmessungen.
- Die Klassische Testtheorie begründet dieses Vorgehen durch Annahme von wahren Werten und Messfehlerwerten.

Beweis

(1) Mit Aussage (5) von Theorem Eigenschaften bezüglich einer Testmessung (Foliensatz 2) gilt

$$\mathsf{R}_j = \rho(y_{ij}, \tau_i)^2 = \left(\frac{\mathbb{C}(y_{ij}, \tau_i)}{\mathbb{S}(y_{ij})\mathbb{S}(\tau_i)} \right)^2 = \frac{\mathbb{C}(y_{ij}, \tau_i)^2}{\mathbb{V}(y_{ij})\mathbb{V}(\tau_i)} = \frac{\mathbb{V}(\tau_i)^2}{\mathbb{V}(y_{ij})\mathbb{V}(\tau_i)} = \frac{\mathbb{V}(\tau_i)}{\mathbb{V}(y_{ij})}. \tag{11}$$

(2) Mit Aussage (4) von Theorem Eigenschaften bezüglich einer Testmessung (Foliensatz 2) gilt

$$\mathsf{R}_j = \frac{\mathbb{V}(\tau_i)}{\mathbb{V}(y_{ij})} = \frac{\mathbb{V}(y_{ij}) - \mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})} = \frac{\mathbb{V}(y_{ij})}{\mathbb{V}(y_{ij})} - \frac{\mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})} = 1 - \frac{\mathbb{V}(\varepsilon_{ij})}{\mathbb{V}(y_{ij})}. \tag{12}$$

(3) Mit Aussagen (2) und (5) von Theorem Eigenschaften des Modells paralleler Testmessungen (Foliensatz 2) gilt

$$\mathsf{R}_j = \frac{\mathbb{V}(\tau_i)}{\mathbb{V}(y_{ij})} = \frac{\mathbb{C}(y_{ij}, y_{ik})}{\sqrt{\mathbb{V}(y_{ij})}\sqrt{\mathbb{V}(y_{ij})}} = \frac{\mathbb{C}(y_{ij}, y_{ik})}{\sqrt{\mathbb{V}(y_{ij})}\sqrt{\mathbb{V}(y_{ik})}} = \rho(y_{ij}, y_{ik}) \tag{13}$$

und dass ebenso

$$\mathsf{R}_k = \frac{\mathbb{V}(\tau_i)}{\mathbb{V}(y_{ik})} = \frac{\mathbb{C}(y_{ij}, y_{ik})}{\sqrt{\mathbb{V}(y_{ik})}\sqrt{\mathbb{V}(y_{ik})}} = \frac{\mathbb{C}(y_{ij}, y_{ik})}{\sqrt{\mathbb{V}(y_{ij})}\sqrt{\mathbb{V}(y_{ik})}} = \rho(y_{ij}, y_{ik}). \tag{14}$$

Normalverteilungsbeispiel

Wir betrachten den Fall zweier Testmessungen $j = 1, 2$ im Modell paralleler Testmessungen. Für alle $i = 1, \ldots, n$ seien in Wahrscheinlichkeitsdichteform, wobei wir der notationellen Einfachheit halber auf das i Subskript verzichten wollen,

$$p(t) = N(t; 0, \sigma_\tau^2) \text{ und } p(\tilde{y}_1|t) := N(\tilde{y}_1; t, \sigma_\varepsilon^2) \text{ und } p(\tilde{y}_2|t) := N(\tilde{y}_2; t, \sigma_\varepsilon^2) \tag{15}$$

Für Person i gibt es also nur eine Zufallsvariable des wahren Werts für alle Testmessungen und die Propensitätsverteilungen unterscheiden sich zwischen Testmessungen nicht.

Dann gilt zunächst mit dem Theorem zu gemeinsamen Normalverteilungen (Anhang zu Foliensatz 2, Folie 76) mit $A := 1$ und $b := 0$

$$p(t)p(\tilde{y}_1|t) = p(t, \tilde{y}_1) = N\left(\begin{pmatrix} t \\ \tilde{y}_1 \end{pmatrix}; \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_\tau^2 & \sigma_\tau^2 \\ \sigma_\tau^2 & \sigma_\tau^2 + \sigma_\varepsilon^2 \end{pmatrix}\right) \tag{16}$$

und weiterhin mit $A := \begin{pmatrix} 1 & 0 \end{pmatrix}$ und $b := 0$

$$p(t, \tilde{y}_1)p(\tilde{y}_2|t) = p(t, \tilde{y}_1, \tilde{y}_2) = N\left(\begin{pmatrix} t \\ \tilde{y}_1 \\ \tilde{y}_2 \end{pmatrix}; \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \sigma_\tau^2 & \sigma_\tau^2 & \sigma_\tau^2 \\ \sigma_\tau^2 & \sigma_\tau^2 + \sigma_\varepsilon^2 & \sigma_\tau^2 \\ \sigma_\tau^2 & \sigma_\tau^2 & \sigma_\tau^2 + \sigma_\varepsilon^2 \end{pmatrix}\right) \tag{17}$$

Normalverteilungsbeispiel (fortgeführt)

Damit gilt dann durch Ablesen am Kovarianzmatrixparameter von $p(t, \tilde{y}_1, \tilde{y}_2)$, dass

$$\rho(y_1, y_2) = \frac{\mathbb{C}(y_1, y_2)}{\sqrt{\mathbb{V}(y_1)}\sqrt{\mathbb{V}(y_2)}} = \frac{\sigma_\tau^2}{\sqrt{\sigma_\tau^2 + \sigma_\varepsilon^2}\sqrt{\sigma_\tau^2 + \sigma_\varepsilon^2}} = \frac{\sigma_\tau^2}{\sigma_\tau^2 + \sigma_\varepsilon^2} \tag{18}$$

Insbesondere gilt also auch für $j = 1, 2$

$$\mathsf{R}_j = \rho(y_j, \tau)^2 = \left(\frac{\mathbb{C}(y_j, \tau)}{\mathbb{S}(y_j)\mathbb{S}(\tau)}\right)^2 = \frac{\mathbb{C}(y_j, \tau)^2}{\mathbb{V}(y_j)\mathbb{V}(\tau)} = \frac{\left(\sigma_\tau^2\right)^2}{(\sigma_\tau^2 + \sigma_\varepsilon^2)\sigma_\tau^2} = \frac{\sigma_\tau^2}{\sigma_\tau^2 + \sigma_\varepsilon^2} = \rho(y_1, y_2). \tag{19}$$

Gilt also beispielsweise $\sigma_\tau^2 := 1.0$ und $\sigma_\varepsilon^2 := 0.2$, so ergibt sich für die Paralleltestreliabilität

$$\mathsf{R}_j = \rho(y_j, \tau)^2 = \rho(y_1, y_2) = \frac{1.0}{1.0 + 0.2} \approx 0.83. \tag{20}$$

Man beachte, dass es sich hierbei um eine auf Grundlage der Modellparameter bestimmte Größe, nicht um eine basierend auf beobachteten Daten geschätzte Größe handelt.

Reliabilität

Praxis der Reliabilitätsschätzung

Interne Konsistenz

Selbstkontrollfragen

Praxis der Paralleltestreliabilitätsschätzung

Die Items einer Paralleltestform müssen gleichzeitig anders und ähnlich zum Originaltest sein.

Je ähnlicher die Items, desto größer sollte der zeitliche Testabstand sein, um Lerneffekte zu vermindern.

Je unähnlicher die Items, desto kürzer sollte der zeitliche Testabstand sein, um systematische Einflüsse zu verringern.

Bei Leistungstests ist dies zum Teil möglich

- Für manche Aufmerksamkeits- und Schuleignungstests existieren Parallelformen
- Für manche Subtests von Intelligenztests existieren Parallelformen

Praktisch werden Teststichprobenmittel, -standardabweichungen, und -korrelationen bestimmt

Ähneln sich Stichprobenmittel und -varianzen bei hoher Korrelation, so schließt man auf Parallelität

Bei Persönlichkeitsfragebögen oder klinischen Tests gestaltet sich dies eher schwierig

- Meist sind diese Tests gerade durch ihre speziellen Items charakterisiert
- Es müssten große Pools ähnlicher Items existieren

Moosbrugger and Kelava (2012), Kapitel 6, Pospeschill (2022), Kapitel 6

Praxis der Retestreliabilitätsschätzung

Derselbe Test wird an derselben Stichprobe zweimal durchgeführt.

Die Korrelation der Messwerte über beide Darbietungen wird berechnet und als r_{tt} bezeichnet.

Es wird vorausgesetzt, dass die Annahmen des Modells paralleler Testmessungen gelten.

- Der wahre Wert einer Testperson bleibt über die Testmessungen hinweg konstant
- Die bedingten Varianzen der beobachteten Werte bleiben über Testwiederholungen konstant

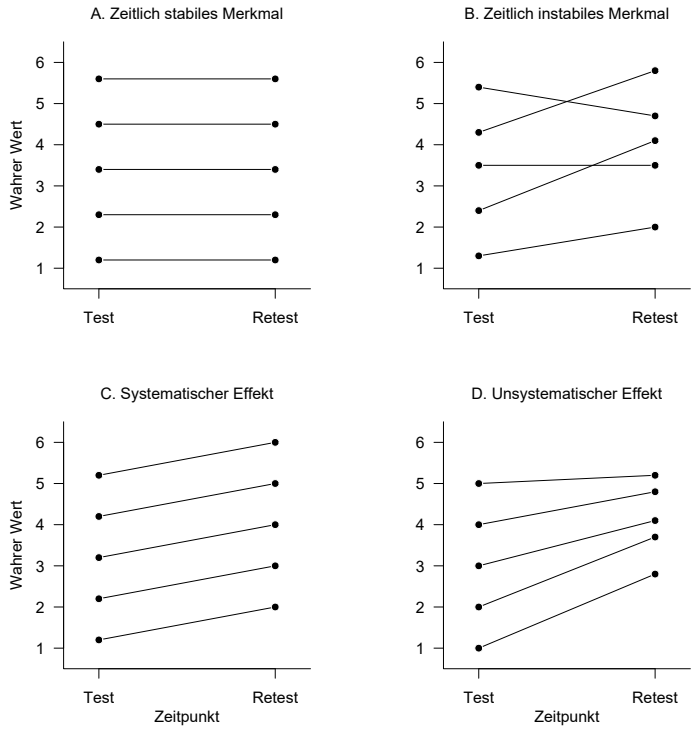
Mögliche Änderungen der wahren Werte im Zeitverlauf

- Unsystematische Veränderungen oder situative Faktoren, die über Testpersonen unterschiedlich ausgeprägt sind, wie z.B. interindividuell unterschiedliche Übungseffekte, Tagesformen, instabile Merkmale oder Erinnerungseffekte verringern die Retestreliabilität. Kurze Test-Retest-Intervalle minimieren dabei unsystematische Merkmalsveränderungen, aber maximieren Erinnerungseffekte und vice versa.
- Systematische Veränderungen oder situative Faktoren, die alle Testpersonen gleich betreffen, ändern die Retestreliabilität nicht. Im Modell der multiplen Testmessungen entspricht dies den hier nicht weiter vertieften wesentlich τ-äquivalenten Testmessungen.

Moosbrugger and Kelava (2012), Kapitel 6, Pospeschill (2022), Kapitel 6

Praxis der Reliabilitätsschätzung

Potentielle Dynamiken wahrer Werte von $n = 5$ Testpersonen über Testmessungen



A Identische wahre Werte bei einem stabilen Merkmal ⇒ Hohe Reliabilität

B Variierende wahre Werte bei einem instabilen Merkmal ⇒ Verringerung der Reliabilität

C Identische linear-affine Transformation des wahren Werts ⇒ Hohe Reliabilität

D Variable positiv linear-affine Transformation des wahren Werts ⇒ Verringerung der Reliabilität

Nach Pospeschill (2022), Kapitel 6

Definition (Reliabilitätsschätzer bei parallelen Testmessungen)

Gegeben sei das Modell paralleler Testmessungen für n Testpersonen und zwei Testmessungen $j = 1, 2$,

$$\mathbb{P}(\tau_1, y_{11}, y_{12}, ..., \tau_n, y_{n1}, y_{n2}) = \prod_{i=1}^{n} \mathbb{P}(\tau_i)\mathbb{P}(y_{i1}|\tau_i)\mathbb{P}(y_{i2}|\tau_i) \tag{21}$$

Dann wird der mit den Stichprobenmitteln

$$\bar{y}_1 := \frac{1}{n}\sum_{i=1}^{n} y_{i1} \text{ und } \bar{y}_2 := \frac{1}{n}\sum_{i=1}^{n} y_{i2} \tag{22}$$

definierte Stichprobenkorrelationskoeffizient

$$r_{12} := \frac{\frac{1}{n-1}\sum_{i=1}^{n}(y_{i1} - \bar{y}_1)(y_{i2} - \bar{y}_2)}{\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_{i1} - \bar{y}_1)^2}\sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_{i2} - \bar{y}_2)^2}} \tag{23}$$

Reliabilitätsschätzer genannt und häufig mit r_{tt} bezeichnet.

Bemerkungen

- Der Schätzer wird sowohl bei Paralleltest- als auch bei Retestverfahren verwendet.
- Voraussetzung ist, dass die jeweiligen Messungen als parallel angenommen werden können.
- **R** bietet mit der `cor()` Funktion eine Möglichkeit, Stichprobenkorrelationskoeffizienten zu berechnen.

Normalverteilungsbeispiel (fortgeführt)

Simulation des Normalverteilungsbeispiels für $n := 30$

$p(t_i) = N(t_i; 1, \sigma_\tau^2)$ und $p(y_{ij}|t_i) := N(y_{ij}; t_i, \sigma_\varepsilon^2)$ für $j = 1, 2$ mit $\sigma_\tau^2 := 1.0$ und $\sigma_\varepsilon^2 := 0.2$ für $i = 1, \ldots, n$.

```
n               = 30                                  # Personenanzahl
m               = 2                                   # Testmessungsanzahl
sigsqr_tau      = 1                                   # wahrer Wert Varianz
sigsqr_eps      = .2                                  # Messfehlervarianz
R_12            = sigsqr_tau/(sigsqr_tau+sigsqr_eps)  # Paralleltestreliabilität
Tau             = matrix(rep(NaN, n)  , nrow = n)     # wahrer Wert Array
Y               = matrix(rep(NaN, n*m), nrow = n)     # beobachteter Wert Array
E               = matrix(rep(NaN, n*m), nrow = n)     # Messfehler Array
for(i in 1:n){                                        # Personeniterationen
    Tau[i]      = rnorm(1,1,sqrt(sigsqr_tau))         # wahrer Wert Realisierung für j = 1,2
    for(j in 1:m){                                    # Testmessungsiterationen
        Y[i,j]  = rnorm(1,Tau[i],sqrt(sigsqr_eps))    # beobachteter Wert Realisierung
        E[i,j]  = Y[i,j] - Tau[i]}}                   # Messfehler Realisierung
r_12            = cor(Y[,1],Y[,2])                    # Reliabilitätsschätzer
```

```
Paralleltestreliabilität R_12 :  0.8333
Reliabilitätsschätzer r_12    :  0.8478
```

Theorem (Approximative Verteilung der Fishertransformation einer Stichprobenkorrelation)

Gegeben sei eine Stichprobe $(y_{11}, y_{12}), ..., (y_{n1}, y_{n2}) \sim \mathbb{P}(y_1, y_2)$ von Beobachtungen zweier Zufallsvariablen y_1 und y_2 mit Korrelation $\rho := \rho(y_1, y_2)$ und Stichprobenkorrelation r. Weiterhin bezeichne

$$\tilde{r} := \frac{1}{2} \ln \left(\frac{1+r}{1-r} \right) \tag{24}$$

die *Fishertransformation* von r. Dann ist $\tilde{r}$ asymptotisch normalverteilt mit

$$\tilde{r} \overset{a}{\sim} N \left(\frac{1}{2} \ln \left(\frac{1+\rho}{1-\rho} \right), (n-3)^{-1} \right). \tag{25}$$

Bemerkungen

- Die approximative Varianz der Fishertransformation ist unabhängig von ρ.
- Die Approximation ermöglicht die Konstruktion eines Konfidenzintervalls für ρ.
- Eine ausführliche Darstellung findet sich bei Johnson et al. (1994, Kapitel 32).

Theorem (Approximatives Konfidenzintervall einer Korrelation)

Gegeben sei eine Stichprobe $(y_{11}, y_{12}), \ldots, (y_{n1}, y_{n2}) \sim \mathbb{P}(y_1, y_2)$ von Beobachtungen zweier Zufallsvariablen y_1 und y_2 mit Korrelation ρ, Stichprobenkorrelation r und Fishertransformation $\tilde{r}$. Ferner sei $\delta \in]0, 1[$ ein Konfidenzlevel und es sei

$$z_\delta := \phi^{-1}\left(\frac{1+\delta}{2}\right) \tag{26}$$

mit der inversen KVF ϕ^{-1} einer standardnormalverteilten Zufallsvariable. Schließlich seien

$$\tilde{r}_u := \tilde{r} - z_\delta \left(\sqrt{n-3}\right)^{-1} \text{ und } \tilde{r}_o := \tilde{r} + z_\delta \left(\sqrt{n-3}\right)^{-1}. \tag{27}$$

Dann gilt für $n \to \infty$ für das Intervall

$$\kappa(r) := \left[\frac{\exp(2\tilde{r}_u) - 1}{\exp(2\tilde{r}_u) + 1}, \frac{\exp(2\tilde{r}_o) - 1}{\exp(2\tilde{r}_o) + 1}\right], \tag{28}$$

dass

$$\mathbb{P}_\rho\left(\kappa(r) \ni \rho\right) = \delta. \tag{29}$$

Bemerkungen

- Bei parallelen Testmessungen ist $\rho = R_{12} = R_1 = R_2$.
- Das Intervall ist dann ein approximatives Konfidenzintervall für die Reliabilität.

Simulation der Konfidenzintervallüberdeckung

Für $n = 30$ Personen und zwei parallele Testmessungen betrachten wir das bisherige Normalverteilungsmodell

$$p(t_i) = N(t_i; 1, \sigma_\tau^2), \qquad p(y_{ij} \mid t_i) = N(y_{ij}; t_i, \sigma_\varepsilon^2) \tag{30}$$

mit $\sigma_\tau^2 = 1$ und $\sigma_\varepsilon^2 = 0.2$. Damit gilt

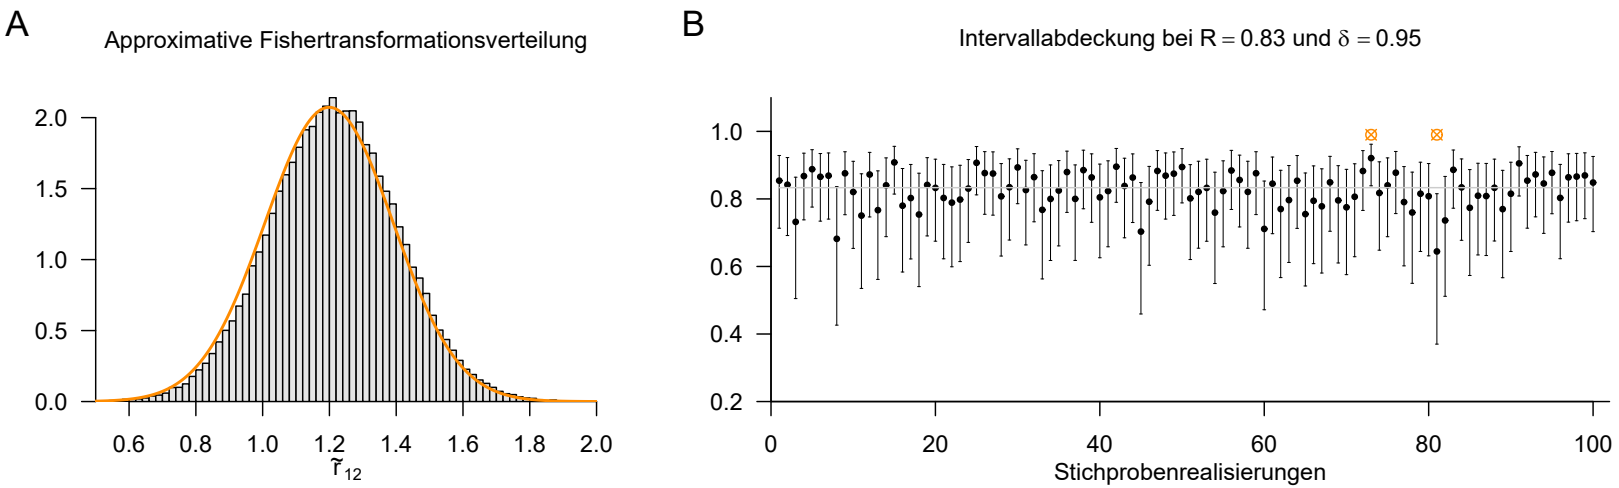
$$R_{12} = \frac{\sigma_\tau^2}{\sigma_\tau^2 + \sigma_\varepsilon^2} = \frac{1}{1.2} \approx 0.833. \tag{31}$$

Simulationsablauf

- Wir generieren 10^5 unabhängige Datensätze dieses Modells.
- Für jeden Datensatz berechnen wir r, $\tilde{r}$ und $\kappa(r)$ bei $\delta = 0.95$.
- Wir vergleichen die Verteilung von $\tilde{r}$ mit ihrer Normalapproximation.
- Wir prüfen, ob die Intervalle den festen Parameter R_{12} enthalten.

Praxis der Reliabilitätsschätzung

Simulationsergebnisse



Bemerkungen

- Die simulierte Verteilung ist gegenüber der Normalapproximation leicht nach rechts verschoben.
- Von den 100 dargestellten Intervallen enthalten 98 die wahre Reliabilität.
- Orange Markierungen kennzeichnen Intervalle, die die wahre Reliabilität nicht enthalten.
- Das Konfidenzlevel 0.95 verlangt keine Überdeckung in genau 95 von 100 Fällen.

Reliabilität

Praxis der Reliabilitätsschätzung

Interne Konsistenz

Selbstkontrollfragen

Interne Konsistenz

Überblick

Abschätzung der Reliabilität eines Tests anhand seiner Itemwerte aus einer einzigen Testdurchführung.

Cronbach's α

- Untere Grenze der Gesamtreliabilität eines Tests, bei Parallelität gleich der Gesamtreliabilität.
- Grundlage ist das m-*Komponententestmodell mit multiplen Testmessungen*
- Bestimmung aus (empirischen) Itemvarianzen und der Summenscorevarianz

Spearman-Brown-Formel

- Bestimmung der Gesamtreliabilität eines Tests aus der Reliabilität seiner Items
- Setzt ein m-Komponententestmodell mit parallelen Testmessungen voraus
- Verknüpfung der Anzahl der Komponenten mit ihrer gemeinsamen Reliabilität

McDonald's ω

- Bestimmung der Gesamtreliabilität in einem einfaktoriellen Faktorenanalysemodell
- Grundlage ist speziell das Modell *essentiell kongenerischer Items*
- Berechnung aus geschätzten Faktorladungen, Faktorvarianz und Fehlervarianzen

m-Komponententestmodell

y_{ij} bezeichnete bisher die Zufallsvariable zur Modellierung des beobachteten Werts der $j$ten Testmessung der $i$ten Testperson, wobei wir m Testmessungen $j = 1, \ldots, m$ und n Testpersonen $i = 1, \ldots, n$ angenommen haben.

$\Rightarrow$ Wir haben bisher offen gelassen, ob mit der *$j$ten Testmessung* ein *Test* oder ein *Item* gemeint ist.

$\Rightarrow$ In diesem Abschnitt identifizieren wir die $j$te Testmessung nun mit dem $j$ten Item *eines* Tests.

y_{ij} bezeichnet also nun die Zufallsvariable zur Modellierung des beobachteten Werts des $j$ten Items der $i$ten Testperson in einem Test, wobei wir weiterhin m Items $j = 1, \ldots, m$ und n Testpersonen $i = 1, \ldots, n$ annehmen.

Insbesondere gehen wir davon aus, dass für jede Testperson eine Summe von beobachteten Werten durch Summation über die Items eines Tests gebildet wird. Die Zufallsvariable zur Modellierung dieser Summe von beobachteten Werten bezeichnen wir mit

$$y_i := \sum_{j=1}^{m} y_{ij} \tag{32}$$

Wir fassen diese Vorüberlegungen in der Definition des *m-Komponententestmodells* zusammen.

Definition (m-Komponententestmodell)

Gegeben sei das Modell multipler Testmessungen für $i = 1, ..., n$ Testpersonen und $j = 1, ..., m$ Testmessungen. Für $i = 1, ..., n$ seien

- $y_i := \sum_{j=1}^{m} y_{ij}$ die *Summe der beobachteten Werte* und
- $\tau_i := \sum_{j=1}^{m} \tau_{ij}$ die *Summe der wahren Werte*.

Dann heißt die gemeinsame Verteilung der y_i und τ_i für $i = 1, ..., n$ mit der Faktorisierungseigenschaft

$$\mathbb{P}(\tau_1, ..., \tau_n, y_1, ..., y_n) := \prod_{i=1}^{n} \mathbb{P}(\tau_i, y_i) = \prod_{i=1}^{n} \mathbb{P}(y_i|\tau_i)\mathbb{P}(\tau_i) \tag{33}$$

das m-Komponententestmodell, wenn gilt, dass

$$\mathbb{P}(\tau_1, y_1) = \cdots = \mathbb{P}(\tau_n, y_n). \tag{34}$$

Bemerkung

- Die m *Komponenten* eines Tests entsprechen seinen m Items.

Definition (Reliabilitäten von m-Komponententestmodellen)

Gegeben sei ein m-Komponententestmodell.

(1) Für $j = 1, \ldots, m$ ist die Reliabilität der $j$ten Testmessung definiert als

$$\mathrm{R}_j := \frac{\mathbb{V}(\tau_{ij})}{\mathbb{V}(y_{ij})} \text{ für ein beliebiges } 1 \leq i \leq n. \tag{35}$$

(2) Die Gesamtreliabilität des m-Komponententestmodells ist definiert als

$$\mathrm{R} := \frac{\mathbb{V}(\tau_i)}{\mathbb{V}(y_i)} \text{ für ein beliebiges } 1 \leq i \leq n. \tag{36}$$

Bemerkung

- Die Definitionen nutzen die erste Umformung der im vorherigen Abschnitt genutzten Definition.
- In R_j gehen die Varianzen des $j$ten wahren Werts τ_{ij} und $j$ten beobachteten Werts y_{ij} ein.
- In R gehen die Varianzen der Summe τ_i der wahren Werte und der Summe y_i der beobachteten Werte ein.
- Wenn das m-Komponententestmodell einen psychologischen Test bestehend aus m Items modelliert, dann wird R_j auch *Itemreliabilität* des $j$ten Items und R *Reliabilität des Tests* genannt.

Interne Konsistenz | Cronbach's α

Grundlage der Bestimmung von Cronbach's α ist die Idee der *Testhalbierungsreliabilität*.

- Bei der Testhalbierung werden zwei Testhälften gebildet, die als parallele Testmessungen angenommen werden.
- Die Korrelation der Testhälften entspricht dann der Reliabilität einer Testhälfte.
- Zur Bestimmung der Gesamttestreliabilität muss die volle Testlänge berücksichtigt werden.

Bei parallelen Items wächst die Varianz der Summe der wahren Werte quadratisch mit der Itemanzahl:

$$\mathbb{V}\left(\sum_{j=1}^{m} \tau_{ij}\right) = \mathbb{V}(m\tau_{i1}) = m^2\mathbb{V}(\tau_{i1}). \tag{37}$$

Die Varianz der Summe der Messfehler wächst dagegen nur linear:

$$\mathbb{V}\left(\sum_{j=1}^{m} \varepsilon_{ij}\right) = \sum_{j=1}^{m} \mathbb{V}(\varepsilon_{ij}) = m\mathbb{V}(\varepsilon_{i1}). \tag{38}$$

- Bei parallelen Items sind die wahren Werte identisch.
- Die Messfehler sind unabhängig und haben dieselbe Varianz.

Von der Testhalbierung zu Cronbach's α

- Bei parallelen Items nimmt die Gesamtreliabilität mit zunehmender Testlänge zu.
- Die Spearman-Brown-Formel rechnet die Korrelation paralleler Testhälften auf die volle Testlänge um.
- Die Formel geht auf Spearman (1910) und Brown (1910) zurück.
- Ein Test kann auch in mehr als zwei Komponenten aufgeteilt werden.

Cronbach's α ist auch ohne Parallelität definiert und entspricht bei parallelen Items der Gesamtreliabilität.

Wir betrachten im Folgenden die Spearman-Brown-Formel und ihre Eigenschaften als Spezialfall von Cronbach's α.

Definition (Cronbach's α)

Gegeben sei ein m-Komponententestmodell. Dann heißt

$$\alpha := \frac{m}{m-1}\left(1 - \frac{\sum_{j=1}^{m} \mathbb{V}(y_{ij})}{\mathbb{V}(y_i)}\right) \text{ für ein beliebiges } 1 \leq i \leq n \tag{39}$$

Cronbach's α oder *Koeffizient* α.

Bemerkungen

- $\mathbb{V}(y_{ij})$ ist die Varianz der beobachteten Werte für Testpersonen $i = 1, \ldots, n$ und Items $j = 1, \ldots, m$.
- $\mathbb{V}(y_i)$ ist die Varianz der Summe der beobachteten Werte für Testpersonen $i = 1, \ldots, n$.
- Die Formel wurde durch Cronbach (1951) als *Coefficient* α popularisiert
- Frühere Anwendungen finden sich zum Beispiel in Hoyt (1941) und Guttman (1945)

Bemerkungen (fortgesetzt)

- Da nach Annahme des Modells multipler Testmessungen die Verteilungen der beobachteten Werte über Personen identisch sind, wird Cronbach's α häufig auch geschrieben als

$$\alpha := \frac{m}{m-1}\left(1 - \frac{\sum_{j=1}^{m}\mathbb{V}(y_j)}{\mathbb{V}(y)}\right) \tag{40}$$

- Zum Verständnis von α unterstellen wir im Folgenden, dass die Anzahl der Items hoch, also $\frac{m}{m-1} \approx 1$ ist.
- Nach Theorem Varianz einer Linearkombination (Anhang zu Foliensatz 2, Folie 89) gilt dann allgemein

$$\mathbb{V}(y) = \sum_{j=1}^{m}\mathbb{V}(y_j) + 2\sum_{j=1}^{m-1}\sum_{k=j+1}^{m}\mathbb{C}(y_j, y_k) \tag{41}$$

- Sind die beobachteten Werte in diesem Fall (marginal) unabhängig, so gilt

$$\mathbb{C}(y_j, y_k) = 0 \text{ für alle } 1 \leq j, k \leq m \text{ mit } j \neq k \tag{42}$$

- Bei Unabhängigkeit der beobachteten Werte gilt also exakt

$$\alpha = \frac{m}{m-1}\left(1 - \frac{\sum_{j=1}^{m}\mathbb{V}(y_j)}{\sum_{j=1}^{m}\mathbb{V}(y_j)}\right) = 0. \tag{43}$$

- Ist die Summe der Kovarianzbeiträge wesentlich größer als die Summe der Itemvarianzen, so folgt

$$\mathbb{V}(y) = \sum_{j=1}^{m}\mathbb{V}(y_j) + 2\sum_{j=1}^{m-1}\sum_{k=j+1}^{m}\mathbb{C}(y_j, y_k) \gg \sum_{j=1}^{m}\mathbb{V}(y_j) \Rightarrow \frac{\sum_{j=1}^{m}\mathbb{V}(y_j)}{\mathbb{V}(y)} \approx 0 \Rightarrow \alpha \approx 1 \tag{44}$$

Theorem (Cronbach's α und Gesamtreliabilität)

Gegeben sei ein m-Komponententestmodell mit Gesamtreliabilität R. Dann gilt für Cronbach's α, dass

$$\alpha \leq \mathrm{R} \tag{45}$$

und Gleichheit tritt insbesondere dann ein, wenn die Testmessungen des m-Komponententestmodells parallel sind.

Bemerkungen

- Cronbach's α ist eine untere Grenze für die Gesamtreliabilität eines m-Komponententestmodells.
- Die Gesamtreliabilität eines m-Komponententestmodells ist mindestens so groß wie Cronbach's α.
- Die Gesamtreliabilität eines m-Komponententestmodells kann größer als Cronbach's α sein.
- Für parallele Testmessungen (Items) ist die Gesamtreliabilität eines m-Komponententestmodells gleich α.
- Der Beweis des Theorems geht unter anderem auf Novick and Lewis (1967) zurück.

Beweis

Zur Vereinfachung der Notation verzichten wir auf die explizite Auszeichnung der Testpersonen $i = 1, \ldots, n$ und setzen

$$y_j := y_{ij}, \tau_j := \tau_{ij}, y := \sum_{j=1}^{m} y_j \text{ und } \tau := \sum_{j=1}^{m} \tau_j, \tag{46}$$

sowie

$$\mathsf{R} := \frac{\mathbb{V}(\tau)}{\mathbb{V}(y)} \text{ und } \alpha := \frac{m}{m-1} \left(1 - \frac{\sum_{j=1}^{m} \mathbb{V}(y_j)}{\mathbb{V}(y)} \right). \tag{47}$$

Wir gehen in vier Schritten vor.

(1) (*Summendarstellung*) Wir schreiben zunächst die Summe von m Zahlen um. Speziell gilt für reelle Zahlen $\tau_1, \ldots, \tau_m$, dass

$$\sum_{j=1}^{m} \tau_j = \frac{1}{m-1} \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} (\tau_j + \tau_k). \tag{48}$$

Beweis

Anstelle eines Beweises betrachten wir den Fall $m := 4$. Dann gilt

$$\begin{aligned}
\frac{1}{3}\sum_{j=1}^{3}\sum_{k=j+1}^{4}(\tau_j+\tau_k) &= \frac{1}{3}\left(\sum_{k=1+1}^{4}(\tau_1+\tau_k)+\sum_{k=2+1}^{4}(\tau_2+\tau_k)+\sum_{k=3+1}^{4}(\tau_3+\tau_k)\right)\\
&= \frac{1}{3}\left(\sum_{k=2}^{4}(\tau_1+\tau_k)+\sum_{k=3}^{4}(\tau_2+\tau_k)+\sum_{k=4}^{4}(\tau_3+\tau_k)\right)\\
&= \frac{1}{3}\left((\tau_1+\tau_2)+(\tau_1+\tau_3)+(\tau_1+\tau_4)+(\tau_2+\tau_3)+(\tau_2+\tau_4)+(\tau_3+\tau_4)\right)\\
&= \frac{1}{3}\left((\tau_1+\tau_1+\tau_1)+(\tau_2+\tau_2+\tau_2)+(\tau_3+\tau_3+\tau_3)+(\tau_4+\tau_4+\tau_4)\right)\\
&= \frac{1}{3}\left(3\tau_1+3\tau_2+3\tau_3+3\tau_4\right)\\
&= \tau_1+\tau_2+\tau_3+\tau_4\\
&= \sum_{j=1}^{4}\tau_j
\end{aligned} \tag{49}$$

Beweis (fortgeführt)

(2) (*Kovarianzungleichung für den wahren Wert*) Wir leiten nun im Modell multipler Testmessungen eine Ungleichung her. Dazu betrachten wir im Modell multipler Testmessungen die Varianz der Differenz zweier wahrer Werte τ_j und τ_k. Mit Theorem Nichtnegativität der Varianz (Anhang zu Foliensatz 2, Folie 95) und Theorem Varianzen spezieller Linearkombinationen (Anhang zu Foliensatz 2, Folie 69) ergibt sich

$$\mathbb{V}(\tau_j - \tau_k) \geq 0 \Leftrightarrow \mathbb{V}(\tau_j) + \mathbb{V}(\tau_k) - 2\mathbb{C}(\tau_j, \tau_k) \geq 0 \Leftrightarrow \mathbb{V}(\tau_j) + \mathbb{V}(\tau_k) \geq 2\mathbb{C}(\tau_j, \tau_k) \tag{50}$$

Weiterhin ergibt sich für beliebige $1 \leq j, k \leq m$ parallele Testmessungen, dass

$$\mathbb{V}(\tau_j - \tau_k) = \mathbb{V}(f_j(\tau_1) - f_k(\tau_1)) = \mathbb{V}(\tau_1 - \tau_1) = \mathbb{V}(0) = 0. \tag{51}$$

In diesem Fall ergibt sich in obiger Ungleichung und ihrer Anwendung im Folgenden also Gleichheit.

(3) (*Varianzungleichung für die Summe wahrer Werte*) Wir betrachten nun die Varianz der Summe der wahren Werte im m-Komponententestmodell. Mit Theorem Varianz einer Linearkombination (Anhang zu Foliensatz 2, Folie 89), der Summendarstellung aus (1) und der Kovarianzungleichung für den wahren Wert aus (2) ergibt sich zunächst

Beweis (fortgeführt)

$$
\begin{aligned}
\mathbb{V}(\tau) &= \mathbb{V}\left(\sum_{j=1}^{m} \tau_j\right) \\
&= \sum_{j=1}^{m} \mathbb{V}(\tau_j) + 2 \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} \mathbb{C}(\tau_j, \tau_k) \\
&= \frac{1}{m-1} \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} \Big(\mathbb{V}(\tau_j) + \mathbb{V}(\tau_k)\Big) + 2 \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} \mathbb{C}(\tau_j, \tau_k) \\
&\geq \frac{1}{m-1} \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(\tau_j, \tau_k) + \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(\tau_j, \tau_k) \\
&= \Big(\frac{1}{m-1} + 1\Big) \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(\tau_j, \tau_k) \\
&= \Big(\frac{1}{m-1} + \frac{m-1}{m-1}\Big) \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(\tau_j, \tau_k) \\
&= \frac{1+m-1}{m-1} \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(\tau_j, \tau_k) \\
&= \frac{m}{m-1} \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(\tau_j, \tau_k)
\end{aligned}
\tag{52}
$$

Beweis (fortgeführt)

Mit Aussage (5) von Theorem Eigenschaften bezüglich zweier Testmessungen (Foliensatz 2) und wiederum mit Theorem Varianz einer Linearkombination (Anhang zu Foliensatz 2, Folie 89) gilt dann

$$\begin{aligned}
\mathbb{V}(\tau) &\geq \frac{m}{m-1} \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(\tau_j, \tau_k) \\
&= \frac{m}{m-1} \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 2\mathbb{C}(y_j, y_k) \\
&= \frac{m}{m-1} \left(\mathbb{V}\left(\sum_{j=1}^{m} y_j \right) - \sum_{j=1}^{m} \mathbb{V}\left(y_j \right) \right) \\
&= \frac{m}{m-1} \left(\mathbb{V}(y) - \sum_{j=1}^{m} \mathbb{V}\left(y_j \right) \right)
\end{aligned} \tag{53}$$

Beweis (fortgeführt)

(4) (*Gesamtreliabilität*) Wir betrachten schließlich die Gesamtreliabilität im m-Komponententestmodell. Es ergibt sich

$$\begin{aligned}
\mathsf{R} &= \frac{\mathbb{V}(\tau)}{\mathbb{V}(y)} \\
&\geq \frac{\frac{m}{m-1}\left(\mathbb{V}(y) - \sum_{j=1}^{m}\mathbb{V}\left(y_j\right)\right)}{\mathbb{V}(y)} \\
&= \frac{m}{m-1}\left(\frac{\mathbb{V}(y)}{\mathbb{V}(y)} - \frac{\sum_{j=1}^{m}\mathbb{V}\left(y_j\right)}{\mathbb{V}(y)}\right) \\
&= \frac{m}{m-1}\left(1 - \frac{\sum_{j=1}^{m}\mathbb{V}\left(y_j\right)}{\mathbb{V}(y)}\right) \\
&=: \alpha.
\end{aligned} \tag{54}$$

□

Definition (Cronbach's α Schätzer)

Gegeben sei das m-Komponententestmodell mit beobachteten Werten y_{ij} für $i = 1, \ldots, n$ Testpersonen und $j = 1, \ldots, m$ Testkomponenten (Items). Dann ist ein Schätzer für die Varianz des $j$ten Items gegeben durch

$$s_j^2 := \frac{1}{n-1} \sum_{i=1}^{n} \left(y_{ij} - \bar{y}_j \right)^2 \text{ mit } \bar{y}_j := \frac{1}{n} \sum_{i=1}^{n} y_{ij} \tag{55}$$

und ein Schätzer für die Varianz der Testsummenscores ist gegeben durch

$$s^2 := \frac{1}{n-1} \sum_{i=1}^{n} \left(y_i - \bar{y} \right)^2 \text{ mit } y_i := \sum_{j=1}^{m} y_{ij} \text{ und } \bar{y} := \frac{1}{n} \sum_{i=1}^{n} y_i \tag{56}$$

Ein Schätzer für α ergibt sich entsprechend zu

$$\hat{\alpha} = \frac{m}{m-1} \left(1 - \frac{\sum_{j=1}^{m} s_j^2}{s^2} \right). \tag{57}$$

Bemerkung

- Zur frequentistischen Verteilungstheorie dieses Schätzers, siehe z.B. Kristof (1963), Feldt (1965), Feldt et al. (1987), Van Zyl et al. (2000), Yuan and Bentler (2002).

Simulation im Modell paralleler Testmessungen

$$n := 30, m := 21 \text{ mit } \mathbb{P}(\tau_i) := N(1,1), \mathbb{P}(y_{ij}|\tau_i) := N(\tau_i, 4) \text{ für } i = 1, ..., n, j = 1, ..., m. \quad (58)$$

```r
library(psych)                                  # R Paket zur Testanalyse
set.seed(0)                                     # Reproduzierbarkeit
n        = 30                                   # Personenanzahl
m        = 21                                   # Itemanzahl
mu       = 1                                    # Wahrer Wert Erwartungswertparameter
Tau      = matrix(rep(NaN, n),   nrow = n)      # Wahrer Wert Array
Y        = matrix(rep(NaN, n*m), nrow = n)      # Beobachteter Wert Array
for(i in 1:n){                                  # Iteration über Testpersonen
  Tau[i] = rnorm(1, mu, sqrt(1))                # Wahrer Wert Realisierung
  for(j in 1:m){                                # Iteration über Items
    Y[i,j] = rnorm(1, Tau[i], sqrt(4))}}        # Beobachteter Wert Realisierung
vsi      = var(apply(Y, 1, sum))                # Stichprobenvarianz der beobachteten Wert-Summen
siv      = sum(apply(Y, 2, var))                # Summe der Item-Stichprobenvarianzen
a        = (m/(m-1))*(1 - (siv/vsi))            # Direkte Berechnung von Cronbach's alpha
ap       = alpha(Y, warnings = F)               # Berechnung von Cronbach's alpha mit psych
```

```
Cronbach's alpha (manuell) :  0.866
Cronbach's alpha (psych)   :  0.866
```

Theorem (Spearman-Brown-Formel)

Gegeben sei ein m-Komponententestmodell mit parallelen Testmessungen, Reliabilität R und Komponentenreliabilitäten $\mathsf{R}_1, \ldots, \mathsf{R}_m$. Dann gilt

$$\mathsf{R} = \frac{m\mathsf{R}_1}{1 + (m-1)\mathsf{R}_1} \tag{59}$$

Bemerkungen

- Die Testhalbierungsreliabilität ergibt sich als der Spezialfall $m = 2$.
- Sei dazu R_1 die durch $\rho(y_{i1}, y_{i2})$ gegebene Paralleltestreliabilität. Für die Gesamttestreliabilität ergibt sich

$$\mathsf{R} = \frac{2 \cdot \mathsf{R}_1}{1 + (2-1)\mathsf{R}_1} = \frac{2\rho(y_{i1}, y_{i2})}{1 + \rho(y_{i1}, y_{i2})} \tag{60}$$

- Für $\mathsf{R}_1 = 0.7$ ergibt sich beispielsweise

$$\mathsf{R} = \frac{2 \cdot 0.7}{1 + 0.7} \approx 0.82 \tag{61}$$

- In der Praxis unterscheidet man folgende Methoden zur Testhalbierung
- Odd-Even: Eine Testhälfte besteht aus den ungerade, die andere aus den gerade nummerierten Items
- Zeitpartitionierung: Der Test wird in zwei Abschnitte geteilt, deren Bearbeitung die gleiche Zeit beansprucht.
- Itemzwillinge: Es werden Itemzwillinge konstruiert und zufällig einer der Testhälften zugeordnet.

Beweis

Wir halten zunächst fest, dass nach Theorem ?? und durch Annahme paralleler Testmessungen gilt, dass

$$\mathsf{R} = \frac{m}{m-1}\left(1 - \frac{\sum_{j=1}^{m} \mathbb{V}(y_j)}{\mathbb{V}(y)}\right) \tag{62}$$

(1) *(Summe der Varianzen der beobachteten Werte bei Parallelität)* Nach Theorem Eigenschaften des Modells paralleler Testmessungen (Foliensatz 2) sind die Varianzen aller beobachteten Werte über Testmessungen bei parallelen Testmessungen identisch. Es gilt also

$$\sum_{j=1}^{m} \mathbb{V}(y_j) = \sum_{j=1}^{m} \mathbb{V}(y_1) = m\mathbb{V}(y_1) \tag{63}$$

Beweis (fortgeführt)

(2) *(Varianz der Summe der beobachteten Werte bei Parallelität)*

Mit Theorem Varianz einer Linearkombination (Anhang zu Foliensatz 2, Folie 89) gilt

$$
\begin{aligned}
\mathbb{V}(y) &= \mathbb{V}\left(\sum_{j=1}^{m} y_j\right) \\
&= \sum_{j=1}^{m} \mathbb{V}(y_j) + 2 \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} \mathbb{C}(y_j, y_k) \\
&\overset{(a)}{=} \sum_{j=1}^{m} \mathbb{V}(y_1) + 2 \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} \mathbb{C}(y_1, y_2) \\
&= m\mathbb{V}(y_1) + 2\mathbb{C}(y_1, y_2) \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 1 \\
&\overset{(b)}{=} m\mathbb{V}(y_1) + 2\mathbb{C}(y_1, y_2) \frac{m(m-1)}{2} \\
&= m\mathbb{V}(y_1) + m(m-1)\rho(y_1, y_2)\sqrt{\mathbb{V}(y_1)}\sqrt{\mathbb{V}(y_2)} \\
&\overset{(c)}{=} m\mathbb{V}(y_1) + m(m-1)\rho(y_1, y_2)\sqrt{\mathbb{V}(y_1)}\sqrt{\mathbb{V}(y_1)} \\
&\overset{(d)}{=} m\mathbb{V}(y_1) + m(m-1)\mathsf{R}_1\mathbb{V}(y_1) \\
&= m\mathbb{V}(y_1)\left(1 + (m-1)\mathsf{R}_1\right)
\end{aligned}
\tag{64}
$$

Beweis (fortgeführt)

Dabei gilt

- $\overset{(a)}{=}$ mit Aussage (5) von Theorem Eigenschaften des Modells paralleler Testmessungen (Foliensatz 2), dass

$$\mathbb{C}(y_j, y_k) = \mathbb{V}(\tau_1) \text{ für } 1 \leq j, k \leq m \text{ mit } j \neq k \tag{65}$$

  also, dass die Kovarianzen der beobachteten Werte beliebiger Paare paralleler Testmessungen identisch und damit insbesondere identisch zu $\mathbb{C}(y_1, y_2)$ sind,
- $\overset{(b)}{=}$ mit der unter (4) per Induktionsbeweis gezeigten Identität

$$\sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 1 = \frac{m(m-1)}{2} \tag{66}$$

- $\overset{(c)}{=}$ mit Aussage (2) von Theorem Eigenschaften des Modells paralleler Testmessungen (Foliensatz 2),
- $\overset{(d)}{=}$ mit Aussage (3) von Theorem ??

Beweis (fortgeführt)

(3) *(Einsetzen in Cronbach's α)*

Einsetzen ergibt dann

$$
\begin{aligned}
\mathsf{R} &= \frac{m}{m-1}\left(1 - \frac{\sum_{j=1}^{m}\mathbb{V}(y_j)}{\mathbb{V}(y)}\right) \\
&= \frac{m}{m-1}\left(1 - \frac{m\mathbb{V}(y_1)}{m\mathbb{V}(y_1)\left(1+(m-1)\mathsf{R}_1\right)}\right) \\
&= \frac{m}{m-1}\left(1 - \frac{1}{1+(m-1)\mathsf{R}_1}\right) \\
&= \frac{m}{m-1}\left(\frac{1+(m-1)\mathsf{R}_1}{1+(m-1)\mathsf{R}_1} - \frac{1}{1+(m-1)\mathsf{R}_1}\right) \\
&= \frac{m}{m-1}\left(\frac{1+(m-1)\mathsf{R}_1-1}{1+(m-1)\mathsf{R}_1}\right) \\
&= \frac{m}{m-1}\cdot\frac{(m-1)\mathsf{R}_1}{1+(m-1)\mathsf{R}_1} \\
&= \frac{m\mathsf{R}_1}{1+(m-1)\mathsf{R}_1}.
\end{aligned}
\tag{67}
$$

Beweis (fortgeführt)

(4) *(Induktionsbeweis der Doppelsummenform)*

Es bleibt zu zeigen, dass

$$S_m := \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 1 = \frac{m(m-1)}{2} =: P_m \tag{68}$$

(1) Induktionsanfang: Für $m := 2$ gilt

$$S_2 = \sum_{j=1}^{2-1} \sum_{k=j+1}^{2} 1 = \sum_{j=1}^{1} \sum_{k=j+1}^{2} 1 = \sum_{k=1+1}^{2} 1 = \sum_{k=2}^{2} 1 = 1 = \frac{2(2-1)}{2} = P_2 \tag{69}$$

Zu Demonstrationszwecken betrachten wir auch $m := 3$. Hier gilt

$$S_3 = \sum_{j=1}^{3-1} \sum_{k=j+1}^{3} 1 = \sum_{j=1}^{2} \sum_{k=j+1}^{3} 1 = \sum_{k=1+1}^{3} 1 + \sum_{k=2+1}^{3} 1 = \sum_{k=2}^{3} 1 + \sum_{k=3}^{3} 1 = 3 = \frac{3(3-1)}{2} = P_3 \tag{70}$$

(2) Induktionsschritt: Es gelte nun für ein $m \geq 2$

$$S_m = \sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 1 = \frac{m(m-1)}{2} = P_m \tag{71}$$

Beweis (fortgeführt)

Dann gilt nach Definition für $m+1$

$$
\begin{aligned}
S_{m+1} &= \sum_{j=1}^{m+1-1} \sum_{k=j+1}^{m+1} 1 \\
&= \sum_{j=1}^{m} \sum_{k=j+1}^{m+1} 1 \\
&= \sum_{j=1}^{m-1} \sum_{k=j+1}^{m+1} 1 + \sum_{k=m+1}^{m+1} 1 \\
&= \left(\sum_{j=1}^{m-1} \sum_{k=j+1}^{m+1} 1 \right) + 1 \\
&= \left(\sum_{j=1}^{m-1} \left(\sum_{k=j+1}^{m} 1 + 1 \right) \right) + 1 \\
&= \left(\sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 1 \right) + \left(\sum_{j=1}^{m-1} 1 \right) + 1 \\
&= \left(\sum_{j=1}^{m-1} \sum_{k=j+1}^{m} 1 \right) + (m-1) + 1 \\
&= S_m + m
\end{aligned}
\tag{72}
$$

Beweis (fortgeführt)

Dann aber gilt nach der Induktionsschrittannahme

$$
\begin{aligned}
S_{m+1} &= S_m + m \\
&= P_m + m \\
&= \frac{m(m-1)}{2} + m \\
&= \frac{m(m-1)}{2} + \frac{2m}{2} \\
&= \frac{m(m-1)+2m}{2} \\
&= \frac{m^2 - m + 2m}{2} \\
&= \frac{m^2 + m}{2} \\
&= \frac{m(m+1)}{2} \\
&= \frac{(m+1)((m+1)-1)}{2} \\
&= P_{m+1}
\end{aligned}
\tag{73}
$$

Normalverteilungsbeispiel zur Spearman-Brown-Formel

Wir betrachten den Fall eines m-Komponententestmodells mit m parallelen Testmessungen. Für alle $i = 1, ..., n$ gelte die folgende Darstellung durch Wahrscheinlichkeitsdichten. Dabei verzichten wir wiederum auf das Subskript i:

$$p(t_1) := N(t_1; 1, \sigma_\tau^2), t_2 := t_1, ..., t_m := t_1 \tag{74}$$

sowie

$$p(y_1|t_1) := N(y_1; t_1, \sigma_\varepsilon^2), ..., p(y_m|t_1) := N(y_m; t_1, \sigma_\varepsilon^2) \tag{75}$$

Per Definition gilt im m-Komponententest mit parallelen Testmessungen für die Gesamtreliabilität

$$\mathsf{R} := \frac{\mathbb{V}(\tau)}{\mathbb{V}(y)} = \frac{\mathbb{V}\left(\sum_{j=1}^{m} \tau_j\right)}{\mathbb{V}\left(\sum_{j=1}^{m} y_j\right)} \tag{76}$$

Für den Zähler halten wir fest, dass mit der Identität der wahren Werte im Modell paralleler Testmessungen gilt

$$\mathbb{V}\left(\sum_{j=1}^{m} \tau_j\right) = \mathbb{V}\left(\sum_{j=1}^{m} \tau_1\right) = \mathbb{V}\left(m\tau_1\right) = m^2\mathbb{V}\left(\tau_1\right) = m^2\sigma_\tau^2 \tag{77}$$

Normalverteilungsbeispiel zur Spearman-Brown-Formel (fortgesetzt)

Für den Nenner betrachten wir die Wahrscheinlichkeitsdichtefunktion der gemeinsamen Verteilung von $\tau_1, y_1, ..., y_m$, die in Generalisierung des im Abschnitt Reliabilität betrachteten Normalverteilungsbeispiels die folgende Form hat:

$$p\left(t_1, y_1, ..., y_m\right) = N\left(\begin{pmatrix} t_1 \\ y_1 \\ \vdots \\ y_m \end{pmatrix}; \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}, \begin{pmatrix} \sigma_\tau^2 & \sigma_\tau^2 & \cdots & \sigma_\tau^2 \\ \sigma_\tau^2 & \sigma_\tau^2 + \sigma_\varepsilon^2 & \cdots & \sigma_\tau^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_\tau^2 & \sigma_\tau^2 & \cdots & \sigma_\tau^2 + \sigma_\varepsilon^2 \end{pmatrix}\right) \tag{78}$$

Um nun die Varianz der Summe der beobachteten Werte zu bestimmen, bestimmen wir mithilfe des Theorem zur linear-affinen Transformation eines normalverteilten Zufallsvektors (Anhang zu Foliensatz 2, Folie 78) die Kovarianzmatrix des durch die Matrix $A := \begin{pmatrix} 0 & 1 & \ldots & 1 \end{pmatrix} \in \mathbb{R}^{1\times(m+1)}$ transformierten Zufallsvektors $(\tau_1, y_1, ..., y_m)^T$, also die Kovarianzmatrix von

$$\sum_{j=1}^{m} y_j = \begin{pmatrix} 0 & 1 & \ldots & 1 \end{pmatrix} \begin{pmatrix} \tau_1 \\ y_1 \\ \vdots \\ y_m \end{pmatrix} \tag{79}$$

Normalverteilungsbeispiel zur Spearman-Brown-Formel (fortgesetzt)

Es ergibt sich

$$\begin{pmatrix}0 & 1 & \dots & 1\end{pmatrix}\begin{pmatrix}\sigma_\tau^2 & \sigma_\tau^2 & \cdots & \sigma_\tau^2\\ \sigma_\tau^2 & \sigma_\tau^2+\sigma_\varepsilon^2 & \cdots & \sigma_\tau^2\\ \vdots & \vdots & \ddots & \vdots\\ \sigma_\tau^2 & \sigma_\tau^2 & \cdots & \sigma_\tau^2+\sigma_\varepsilon^2\end{pmatrix}\begin{pmatrix}0\\1\\\vdots\\1\end{pmatrix} = \begin{pmatrix}m\sigma_\tau^2 & m\sigma_\tau^2+\sigma_\varepsilon^2 & \dots & m\sigma_\tau^2+\sigma_\varepsilon^2\end{pmatrix}\begin{pmatrix}0\\1\\\vdots\\1\end{pmatrix}$$

$$= m\left(m\sigma_\tau^2+\sigma_\varepsilon^2\right)$$

$$= m^2\sigma_\tau^2+m\sigma_\varepsilon^2$$

Für die Gesamtreliabilität ergibt sich folglich

$$\mathsf{R} = \frac{\mathbb{V}(\tau)}{\mathbb{V}(y)} = \frac{\mathbb{V}\left(\sum_{j=1}^m \tau_j\right)}{\mathbb{V}\left(\sum_{j=1}^m y_j\right)} = \frac{m^2\sigma_\tau^2}{m^2\sigma_\tau^2+m\sigma_\varepsilon^2} \tag{80}$$

Gilt also beispielsweise $\sigma_\tau^2 := 1.0$ und $\sigma_\varepsilon^2 := 0.2$, so ergibt sich für R bei $m := 21$ parallelen Testmessungen

$$\mathsf{R} = \frac{(21)^2\cdot 1.0}{(21)^2\cdot 1.0+21\cdot 0.2} = \frac{441}{441+4.2} \approx 0.990566 \tag{81}$$

Basierend auf der im Abschnitt Reliabilität bestimmten Itemreliabilität $\mathsf{R}_1 = \frac{1.0}{1.2}$ ergibt sich mithilfe der Spearman-Brown-Formel dasselbe Ergebnis

$$\mathsf{R} = \frac{m\mathsf{R}_1}{1+(m-1)\mathsf{R}_1} = \frac{21\cdot\frac{1.0}{1.2}}{1+20\cdot\frac{1.0}{1.2}} \approx 0.990566. \tag{82}$$

Normalverteilungsbeispiel zur Spearman-Brown-Formel (fortgesetzt)

```
n                     = 1e1                                                  # Anzahl Testpersonen
m                     = 21                                                   # Anzahl Testmessungen
k                     = 2                                                    # Anzahl Testwiederholungen
sigsqr_tau            = 1                                                    # Varianz der wahren Werte
sigsqr_eps            = 0.2                                                  # Varianz der Messfehler
R_1                   = sigsqr_tau/(sigsqr_tau + sigsqr_eps)                 # Itemreliabilität
R                     = ((m^2)*sigsqr_tau)/(((m^2)*sigsqr_tau + m*sigsqr_eps))  # Gesamtreliabilität nach Beispiel
SBF                   = (m*R_1)/(1 + (m-1)*R_1)                              # Gesamtreliabilität nach SB-Formel
Tau                   = matrix(rep(NaN,n)  , nrow = n)                       # Initialisierung wahre Werte
Y_sb                  = array(NaN, dim = c(n, m, k))                         # Initialisierung beobachtete Werte
for(i in 1:n){                                                               # Iteration über Testpersonen
    Tau[i]            = rnorm(1,1,sqrt(sigsqr_tau))                          # Realisierung wahrer Werte pro Testperson
    for(t in 1:k){                                                           # Iteration über parallele Testwiederholungen
        for(j in 1:m){                                                       # Iteration über parallele Testmessungen
            Y_sb[i,j,t] = rnorm(1,Tau[i], sqrt(sigsqr_eps))}}}               # Realisierung beobachteter Werte
R_tt                  = cor(apply(Y_sb, c(1, 3), sum))[1,2]                  # Korrelation der Summenscores
```

```
Itemreliabilität                                 :  0.8333333
Gesamtreliabilität nach Normalverteilungsbeispiel :  0.990566
Gesamtreliabilität nach Spearman-Brown-Formel     :  0.990566
Korrelation der Summenscores über Paralleltests   :  0.9940101
```

Theorem (McDonald's einfaktorielles essentiell kongenerisches ω)

Gegeben sei das essentiell kongenerische Testmodell. Dann gilt für die Gesamtreliabilität R, dass

$$\mathsf{R} = \frac{\left(\sum_{j=1}^{m} l_j\right)^2 \Phi}{\left(\sum_{j=1}^{m} l_j\right)^2 \Phi + \sum_{j=1}^{m} \psi_j} \tag{83}$$

und wird als *McDonald's einfaktorielles essentiell kongenerisches* ω bezeichnet.

Bemerkungen

- ω_t berücksichtigt die Varianzbeiträge aller gemeinsamen Faktoren, ω_h nur die eines Generalfaktors.
- Das hier betrachtete einfaktorielle ω ist ein Spezialfall von ω_t.
- Offenbar ist zur Berechnung von ω eine Schätzung der Faktorenanalysemodellparameter nötig.
- Unterschiedliche Faktorenanalysemodellparameterschätzer können zu unterschiedlichen ω-Schätzwerten führen.

Beweis

Zur Vereinfachung der Notation verzichten wir wie im Abschnitt Modelle kongenerischer Testmessungen auf die Auszeichnung der Testpersonen durch Subskripte $i = 1, \ldots, n$. Es gilt dann für die Gesamtreliabilität

$$\mathsf{R} = \frac{\mathbb{V}(\tau)}{\mathbb{V}(y)} = \frac{\mathbb{V}\left(\sum_{j=1}^{m} \tau_j\right)}{\mathbb{V}\left(\sum_{j=1}^{m} y_j\right)} \tag{84}$$

Wir betrachten zunächst die Varianz der Summe der wahren Werte. Mit der Definition der wahren Werte im essentiell kongenerischen Testmodell und Theorem Kovarianz von Linearkombinationen von Zufallsvariablen (Anhang zu Foliensatz 2, Folie 86) gilt, dass

$$\begin{aligned}
\mathbb{V}\left(\sum_{j=1}^{m} \tau_j\right) &= \mathbb{V}\left(\sum_{j=1}^{m} \left(\mu_j + l_j x\right)\right) \\
&= \mathbb{V}\left(\sum_{j=1}^{m} \mu_j + \sum_{j=1}^{m} l_j x\right) \\
&= \mathbb{C}\left(\sum_{j=1}^{m} \mu_j + \sum_{j=1}^{m} l_j x, \sum_{j=1}^{m} \mu_j + \sum_{j=1}^{m} l_j x\right) \\
&= \mathbb{C}\left(\sum_{j=1}^{m} \mu_j + \sum_{j=1}^{m} l_j x, \sum_{k=1}^{m} \mu_k + \sum_{k=1}^{m} l_k x\right) \\
&= \mathbb{C}\left(\sum_{j=1}^{m} l_j x, \sum_{k=1}^{m} l_k x\right) \\
&= \sum_{j=1}^{m} \sum_{k=1}^{m} l_j l_k \mathbb{C}(x, x)
\end{aligned} \tag{85}$$

Beweis (fortgeführt)

Weiter gilt dann

$$
\begin{aligned}
\mathbb{V}\left(\sum_{j=1}^{m}\tau_j\right) &= \sum_{j=1}^{m}\left(\sum_{k=1}^{m}\left(l_j l_k \mathbb{C}(x,x)\right)\right) \\
&= \sum_{j=1}^{m}\left(\sum_{k=1}^{m}\left(l_j l_k \mathbb{V}(x)\right)\right) \\
&= \sum_{j=1}^{m}\left(\sum_{k=1}^{m}\left(l_j l_k \Phi\right)\right) \\
&= \Phi\sum_{j=1}^{m}\left(\sum_{k=1}^{m}\left(l_j l_k\right)\right) \\
&= \Phi\sum_{j=1}^{m}\left(l_j\left(\sum_{k=1}^{m} l_k\right)\right) \\
&= \Phi\left(\sum_{k=1}^{m} l_k\right)\left(\sum_{j=1}^{m} l_j\right) \\
&= \left(\sum_{j=1}^{m} l_j\right)^2 \Phi
\end{aligned}
\tag{86}
$$

Beweis (fortgeführt)

Weiterhin gilt für die Varianz der Summe der beobachteten Werte mit Theorem Kovarianz von Linearkombinationen von Zufallsvariablen (Anhang zu Foliensatz 2, Folie 86) und wiederholter Anwendung von Theorem Kovarianz bei paarweiser Addition (Anhang zu Foliensatz 2, Folie 81)

$$\begin{aligned}
\mathbb{V}\left(\sum_{j=1}^{m} y_j\right) &= \mathbb{C}\left(\sum_{j=1}^{m} y_j, \sum_{j=1}^{m} y_j\right) \\
&= \mathbb{C}\left(\sum_{j=1}^{m} y_j, \sum_{k=1}^{m} y_k\right) \\
&= \sum_{j=1}^{m}\sum_{k=1}^{m} \mathbb{C}\left(y_j, y_k\right) \\
&= \sum_{j=1}^{m}\sum_{k=1}^{m} \mathbb{C}\left(\tau_j + \varepsilon_j, \tau_k + \varepsilon_k\right) \\
&= \sum_{j=1}^{m}\sum_{k=1}^{m} \left(\mathbb{C}(\tau_j, \tau_k) + \mathbb{C}(\tau_j, \varepsilon_k) + \mathbb{C}(\varepsilon_j, \tau_k) + \mathbb{C}(\varepsilon_j, \varepsilon_k)\right).
\end{aligned} \tag{87}$$

Für die verbleibenden Kovarianzen gilt mit der Definition der wahren Werte im essentiell kongenerischen Testmodell, wiederum unter Anwendung von Theorem Kovarianz von Linearkombinationen von Zufallsvariablen (Anhang zu Foliensatz 2, Folie 86), dass

Beweis (fortgeführt)

$$\mathbb{C}(\tau_j, \tau_k) = \mathbb{C}(\mu_j + l_j x, \mu_k + l_k x) = l_j l_k \mathbb{C}(x, x) = l_j l_k \mathbb{V}(x) = l_j l_k \Phi \text{ für alle } j, k \text{ mit } 1 \leq j, k \leq m \tag{88}$$

$$\mathbb{C}(\tau_j, \varepsilon_k) = \mathbb{C}(\mu_j + l_j x, \varepsilon_k) = l_j \mathbb{C}(x, \varepsilon_k) = 0 \text{ für alle } j, k \text{ mit } 1 \leq j, k \leq m \tag{89}$$

$$\mathbb{C}(\varepsilon_j, \tau_k) = \mathbb{C}(\varepsilon_j, \mu_k + l_k x) = l_k \mathbb{C}(\varepsilon_j, x) = 0 \text{ für alle } j, k \text{ mit } 1 \leq j, k \leq m \tag{90}$$

sowie

$$\mathbb{C}(\varepsilon_j, \varepsilon_k) = \mathbb{C}(\varepsilon_j, \varepsilon_k) = \begin{cases} 0 & \text{für } j \neq k \\ \psi_j & \text{für } j = k \end{cases} \tag{91}$$

Entsprechend folgt

$$\begin{aligned} \mathbb{V}\left(\sum_{j=1}^{m} y_j\right) &= \sum_{j=1}^{m}\sum_{k=1}^{m}\left(\mathbb{C}(\tau_j, \tau_k) + \mathbb{C}(\tau_j, \varepsilon_k) + \mathbb{C}(\varepsilon_j, \tau_k) + \mathbb{C}(\varepsilon_j, \varepsilon_k)\right) \\ &= \sum_{j=1}^{m}\sum_{k=1}^{m}\left(l_j l_k \Phi + 0 + 0 + \mathbb{C}(\varepsilon_j, \varepsilon_k)\right) \\ &= \sum_{j=1}^{m}\sum_{k=1}^{m}\left(l_j l_k \Phi\right) + \sum_{j=1}^{m}\sum_{k=1}^{m}\mathbb{C}(\varepsilon_j, \varepsilon_k) \\ &= \left(\sum_{j=1}^{m} l_j\right)^2 \Phi + \sum_{j=1}^{m}\psi_j. \end{aligned} \tag{92}$$

Durch Einsetzen von Zähler und Nenner in die Definition der Gesamtreliabilität ergibt sich schließlich

$$\mathsf{R} = \frac{\mathbb{V}\left(\sum_{j=1}^{m}\tau_j\right)}{\mathbb{V}\left(\sum_{j=1}^{m} y_j\right)} = \frac{\left(\sum_{j=1}^{m} l_j\right)^2 \Phi}{\left(\sum_{j=1}^{m} l_j\right)^2 \Phi + \sum_{j=1}^{m}\psi_j}. \tag{93}$$

Interne Konsistenz | McDonald's ω

Schätzung von ω im Normalverteilungsmodell zur Schätzung von Cronbach's α

```
# McDonald's einfaktorielles kongenerisches Omega mit psych
library(psych)                                                  # psych
psycho  = omega(Y, nfactors = 1, plot = FALSE, covar = TRUE)    # Omega auf ursprünglicher Itemskalierung
L_p     = as.numeric(psycho$schmid$sl[, 1])                     # Faktorladungsmatrixschätzer
Psi_p   = as.numeric(psycho$schmid$sl[, "u2"])                  # Fehlervarianzschätzer
Phi_p   = 1                                                     # Standardisierte Faktorvarianz
omega_f = ((sum(L_p)^2)*Phi_p)/((sum(L_p)^2)*Phi_p+ sum(Psi_p)) # Omega für \Phi := 1 und die obigen Schätzer
omega_p = psycho$omega.tot                                      # Omega mit empirischer Summenscorevarianz

# McDonald's einfaktorielles kongenerisches Omega mit lavaan
library(lavaan)                                                 # lavaan
colnames(Y) = paste0("y", 1:m)                                  # Itemnamen für lavaan
model   = paste0("y =~ ",paste(colnames(Y), collapse = " + "))  # Einfaktorielle CFA Spezifikation für lavaan
fam     = cfa(model, data = as.data.frame(Y))                   # Schätzung der CFA mit lavaan
theta_l = lavInspect(fam, what = "est")                         # Extraktion geschätzter Parameter
L_l     = theta_l$lambda                                        # Faktorladungsmatrixschätzer
Phi_l   = theta_l$psi                                           # Faktorvarianzschätzer
Psi_l   = theta_l$theta                                         # Fehlerkovarianzmatrixschätzer
omega_l = (sum(L_l)^2*Phi_l)/(sum(L_l)^2*Phi_l+sum(Psi_l))      # Omega für die obigen Schätzer
```

```
Omega (psych, empirische Summenscorevarianz)       :  0.875
Omega (psych-Parameter, modellimplizierte Varianz) :  0.883
Omega (lavaan, modellimplizierte Varianz)          :  0.868
```

- Alle Berechnungen beziehen sich auf die ursprüngliche Itemskalierung.
- Die direkte psych-Ausgabe nutzt die empirische, die Formel die modellimplizierte Summenscorevarianz.

Reliabilität

Praxis der Reliabilitätsschätzung

Interne Konsistenz

Selbstkontrollfragen

Selbstkontrollfragen I

1. Geben Sie die Definition der Reliabilität einer Testmessung wieder.
2. Geben Sie das Theorem zu den Eigenschaften der Reliabilität einer Testmessung wieder.
3. Erläutern Sie die drei äquivalenten Formen der Reliabilität einer Testmessung im Modell multipler Testmessungen.
4. Geben Sie die Definition der Reliabilität einer Paralleltestmessung wieder.
5. Geben Sie das Theorem zur Paralleltestreliabilität wieder.
6. Warum ist die Annahme paralleler Testmessungen für die empirische Messung der Reliabilität zentral?
7. Geben Sie die Definition des Paralleltestreliabilitätsschätzers wieder.
8. Erläutern Sie das praktische Vorgehen zur Durchführung einer Paralleltestreliabilitätsschätzung.
9. Erläutern Sie das praktische Vorgehen zur Durchführung einer Retestreliabilitätsschätzung.
10. Diskutieren Sie mögliche Probleme der Validität einer Retestreliabilitätsschätzung.
11. Geben Sie die Definition eines m-Komponententestmodells wieder.
12. Erläutern Sie die Gemeinsamkeiten des Modells multipler Testmessungen und des m-Komponententestmodells.
13. Erläutern Sie die Unterschiede des Modells multipler Testmessungen und des m-Komponententestmodells.
14. Geben Sie die Definition der Reliabilitäten von m-Komponententestmodellen wieder.
15. Skizzieren Sie den intuitiven Zusammenhang zwischen einer Testhalbierungsreliabilität und Cronbach's α.
16. Geben Sie die Definition von Cronbach's α wieder.
17. Erläutern Sie die Intuition zu Cronbach's α basierend auf dem Theorem zur Varianz einer Linearkombination.
18. Geben Sie das Theorem zu Cronbach's α und der Gesamtreliabilität eines m-Komponententestmodells wieder.
19. Wann ist die Gesamtreliabilität eines m-Komponententestmodells mit Cronbach's α identisch?
20. Geben Sie die Definition des Cronbach's α Schätzers wieder.
21. Geben Sie das Theorem zur Spearman-Brown-Formel wieder.
22. Erläutern Sie die Spearman-Brown-Formel mit Bezugnahme auf die Testhalbierungsreliabilität.
23. Geben Sie die Definition von McDonald's ω wieder.
24. Erläutern Sie das McDonald's ω zugrundeliegende Testmodell.

Referenzen I

Brown, William. 1910. "Some Experimental Results in the Correlation of Mental Abilities." *British Journal of Psychology, 1904-1920* 3 (3): 296–322. https://doi.org/10.1111/j.2044-8295.1910.tb00207.x.

Cronbach, L. 1951. "Coefficient Alpha and the Internal Structure of Tests." *Psychometrika* 16 (3): 297–334.

Cronbach, Lee J. 1947. "Test 'Reliability': Its Meaning and Determination." *Psychometrika* 12 (1): 1–16. https://doi.org/10.1007/BF02289289.

Feldt, Leonard S. 1965. "The Approximate Sampling Distribution of Kuder-Richardson Reliability Coefficient Twenty." *Psychometrika* 30 (3): 357–70. https://doi.org/10.1007/BF02289499.

Feldt, Leonard S., David J. Woodruff, and Fathi A. Salih. 1987. "Statistical Inference for Coefficient Alpha." *Applied Psychological Measurement* 11 (1): 93–103. https://doi.org/10.1177/014662168701100107.

Guttman, Louis. 1945. "A Basis for Analyzing Test-Retest Reliability." *Psychometrika* 10 (4): 255–82. https://doi.org/10.1007/BF02288892.

Hoyt, Cyril. 1941. "Test Reliability Estimated by Analysis of Variance." *Psychometrika* 6 (3): 153–60.

Johnson, John, Kotz, and N. Balakrishnan. 1994. *Continuous Univariate Distributions, Volume 1*.

Kelley, Truman. 1927. *Interpretation of Educational Measurements*. Yonkers-on-Hudson.

Kristof, Walter. 1963. "The Statistical Theory of Stepped-up Reliability Coefficients When a Test Has Been Divided into Several Equivalent Parts." *Psychometrika* 28 (3): 221–2238. https://doi.org/10.1007/BF02289571.

Lord, Frederic M., and Melvin R. Novick. 1968. *Statistical Theories of Mental Test Scores*. Nachdr. der Ausg. Reading, Mass. [u.a.], 1968. The Addison-Wesley Series in Behavioral Science: Quantitative Methods. Information Age Publ.

Referenzen II

Moosbrugger, Helfried, and Augustin Kelava, eds. 2012. *Testtheorie und Fragebogenkonstruktion: mit 66 Abbildungen und 41 Tabellen*. 2., aktualisierte und überarbeitete Auflage. Springer-Lehrbuch. Springer.

Novick, Melvin R., and Charles Lewis. 1967. "Coefficient Alpha and the Reliability of Composite Measurements." *Psychometrika* 32 (1): 1–13.

Pospeschill, Markus. 2022. *Testtheorie, Testkonstruktion, Testevaluation*. 2nd ed. Ernst Reihnhardt Verlag.

Spearman, C. 1910. "Correlation Calculated from Faulty Data." *British Journal of Psychology, 1904-1920* 3 (3): 271–95. https://doi.org/10.1111/j.2044-8295.1910.tb00206.x.

Van Zyl, J. M., H. Neudecker, and D. G. Nel. 2000. "On the Distribution of the Maximum Likelihood Estimator of Cronbach's Alpha." *Psychometrika* 65 (3): 271–80. https://doi.org/10.1007/BF02296146.

Yuan, Ke-Hai, and Peter M. Bentler. 2002. "On Robusiness of the Normal-Theory Based Asymptotic Distributions of Three Reliability Coefficient Estimates." *Psychometrika* 67 (2): 251–59. https://doi.org/10.1007/BF02294845.