

Grundlagen der Testtheorie

Dirk Ostwald

Wintersemester 2026/2027

Inhaltsverzeichnis

Vorbemerkungen **3**
Zitation . . . 3
Lizenz . . . 3

1 Psychologische Tests **4**
1.1 Definitionsversuche . . . 4
1.2 Testarten . . . 6
1.3 Antwortformate . . . 9
1.4 Testgütekriterien . . . 17
1.5 Testtheorien . . . 21
1.6 Testkonstruktion . . . 24
1.7 Selbstkontrollfragen . . . 28

Referenzen **30**

Vorbemerkungen

Dieses Vorlesungsskript begleitet die Veranstaltung *Grundlagen der Testtheorie* am Institut für Psychologie der Otto-von-Guericke-Universität Magdeburg im Wintersemester 2026/2027. Die Kapitel dieses Skripts sind unverändert dem Lehrbuch *Probabilistische Datenwissenschaft für die Psychologie (PDWP)* entnommen.

Zitation

Ostwald, D. (2024) Probabilistische Datenwissenschaft für die Psychologie. 10.5281/zenodo.10730199

Lizenz

Dieses Werk ist lizenziert unter einer Creative Commons Namensnennung 4.0 International Lizenz (CC BY 4.0).

Verweise auf Abschnitte außerhalb dieses Skripts führen zu den entsprechenden Stellen im PDWP-Onlinelehrbuch.

1 Psychologische Tests

Tests und Fragebögen sind in der alltäglichen Erfahrung unterschiedlicher Natur. Mit dem Begriff *Test* verbindet man vermutlich am ehesten kleinere Prüfungen, bei denen es korrekte Antworten gibt und eine Leistungsfähigkeit überprüft wird. Mit dem Begriff des *Fragebogens* verbindet man vermutlich mehr oder weniger interessante Sammlungen von Fragen, bei denen man eventuell zu einem wahrheitsgemäßen Antwortverhalten aufgefordert wird, bei denen es aber auch klar ist, dass es keine richtigen oder falschen Antworten gibt. Obwohl mit Tests und Fragebögen in der alltäglichen Erfahrung also durchaus unterschiedliche Verfahren verbunden sind, unterscheidet die psychologische Testtheorie zwischen diesen nicht grundlegend. Historisch ist die Analyse von Testdaten sicherlich zunächst durch die Analyse von Leistungstestdaten geprägt, allerdings werden heutzutage die dort entwickelten Konzepte der Testtheorie auf die gleiche Art und Weise zur Analyse von klinischen Fragebogendaten genutzt. In diesem Abschnitt wollen wir zunächst einen kurzen Überblick zum Begriff des *Psychologischen Tests* geben.

1.1 Definitionsversuche

Der Begriff *Test* hat in unterschiedlichen Kontexten unterschiedliche Bedeutungen. Das englische Wort *test* bedeutet „Probe“, „Prüfung“ oder „Kontrolle“. Im psychologischen Kontext bezeichnet der Begriff *Test* üblicherweise ein Verfahren zur Untersuchung eines Persönlichkeitsmerkmals, den Vorgang der Durchführung einer solchen Untersuchung oder die Gesamtheit der dafür nötigen Materialien, wie man sie in einer Testothek ausleihen kann. Daneben wird der Begriff bekanntlich auch für statistische Verfahren, die sogenannten Hypothesentests, verwendet, die hier aber nicht gemeint sind. Letztlich wird der Begriff in vielen weiteren Zusammenhängen, z. B. für kurze, außerplanmäßige Zettelarbeiten im Schulunterricht oder technische Prüfverfahren in der Produktentwicklung, verwendet (Lienert & Raatz, 1998). Im Folgenden wollen wir einige gebräuchliche Definitionen eines psychologischen Tests in der Fachliteratur betrachten.

Eine frühe Definition findet sich bei Warren (1934). Für den psychologischen Kontext beschreibt er einen Test als:

> “a routine examination administered to individuals belonging to the same group, in order to determine the relative position of a given individual in the group with respect to one or more mental traits, motor abilities, etc. or in order to compare one group with another in these characteristics.”

Eine auf Lienert (1968) zurückgehende Definition eines Tests lautet:

> „Ein *Test* ist ein wissenschaftliches Routineverfahren zur Erfassung eines oder mehrerer empirisch abgrenzbarer Persönlichkeitsmerkmale mit dem Ziel einer möglichst genauen quantitativen Aussage über den Grad der individuellen Merkmalsausprägung.“

Rost (2004) interpretiert in dieser Definition den Begriff *wissenschaftlich* dadurch, dass eine Testtheorie den Schluss von manifesten auf latente Variablen begründet. Der Begriff *Routineverfahren* verweist nach Rost (2004) darauf, dass Durchführung und Auswertung an einer Normstichprobe erprobt und dokumentiert sind. Mit *Persönlichkeitsmerkmalen* sind stabile Merkmale der Testperson gemeint, die für das im Test gezeigte Verhalten verantwortlich sind. *Quantitativ* schließlich bezieht sich auf die Bestimmung des relativen Grades der Merkmalsausprägung. Darüber hinaus differenziert Rost (2004) zwischen *Tests im engeren Sinn* und *Tests im weiteren Sinn*. Tests im engeren Sinn sind Verfahren, deren Ergebnisse die Testperson nicht willentlich in eine gewünschte Richtung verfälschen kann. Tests im weiteren Sinn umfassen auch Fragebögen, standardisierte Interviews und standardisierte Beobachtungen.

Bühner (2010) beschreibt einen psychometrischen Test mit Blick auf seinen Zweck und seine theoretischen Grundlagen:

> „Ein *psychometrischer Test* ist ein wissenschaftliches Routineverfahren zur Untersuchung eines oder mehrerer empirisch abgrenzbarer Persönlichkeitsmerkmale (vgl. Lienert & Raatz, 1998, S. 1). Das Ziel eines psychometrischen Tests besteht darin, die absolute oder relative Ausprägung einer Eigenschaft, einer Fähigkeit oder eines Zustands bei einer oder mehreren Personen zu messen oder eine qualitative Aussage zu treffen, welcher Personenklasse Personen zugeordnet werden können (vgl. Rost, 2004). Psychometrische Tests sind nach der Klassischen oder probabilistischen Testtheorie entwickelt, sind theoretisch fundiert und genügen genau definierten Gütekriterien (Haupt- und Nebengütekriterien)."

Ähnlich wie Lienert stellt Bühner damit die wissenschaftliche Validierung eines Tests in den Vordergrund. Ein Test soll theoretisch fundiert sein und nachweislich definierten Gütekriterien genügen.

Krauth (1995) schließlich stellt in seiner Definition die Zuordnung beobachtbarer Reaktionen zu latenten Merkmalen in den Vordergrund:

> „Ein *psychologischer Test* besteht aus einer Menge von Reizen mit den zugehörigen zugelassenen Reaktionen, d. h. aus einer Menge von manifesten Variablen, und einer Vorschrift (Skala), die den Reaktionsmustern der manifesten Variablen Ausprägungen einer oder mehrerer latenter Variablen zuordnet. Anders ausgedrückt ist ein Test ein Messinstrument zur Messung von nicht direkt beobachtbaren (latenten) Variablen, deren Existenz man bei Personen (gelegentlich auch bei Tieren) postuliert."

Diese Definition ist insbesondere vor dem Hintergrund testtheoretischer Modelle hilfreich. Sie unterscheidet zwischen beobachtbaren Reaktionen als manifesten Variablen und den nicht direkt beobachtbaren Merkmalen als latenten Variablen, deren Zusammenhang durch solche Modelle beschrieben wird.

Testkomponenten

Die Bestandteile eines psychologischen Tests lassen sich in Material- und Durchführungsbestandteile gliedern. Zu den Materialbestandteilen gehören das Testmanual, das Testmaterial mit den einzelnen Items sowie die Auswertungshilfen. Die Durchführungsbestandteile umfassen die Testanweisung, die eigentliche Testdurchführung und die Testauswertung (Lienert & Raatz, 1998).

Zentraler Baustein eines Tests ist das sogenannte *Item*. Ein Item bezeichnet die kleinste Beobachtungseinheit eines psychologischen Tests und besteht aus einem *Itemstamm* und einem *Antwortformat*. Der Itemstamm ist der Reiz, auf den eine Reaktion erwartet wird, beispielsweise eine Frage, eine Aussage, ein Bild, eine Geschichte oder eine Rechenaufgabe. Das Antwortformat legt die Art und Weise fest, in der diese Reaktion registriert wird, etwa durch ein Kreuz auf einer Skala, einen Eintrag in eine leere Zeile oder eine Zeichnung auf Zeichenpapier. Häufig besteht ein Test aus mehreren Untertests, die ihrerseits mehrere Items umfassen. Prinzipiell können Untertests und Tests jedoch auch aus nur einem Item bestehen. In diesem Sinn kann jedes Item selbst als Test angesehen werden (Lord & Novick, 1968; Rost, 2004).

Die Konstruktion und die Durchführung eines psychologischen Tests können als ein speziell konstruiertes psychologisches Experiment verstanden werden. In dieser Betrachtungsweise entspricht der Test einer unabhängigen Variable, deren Stufen die einzelnen Items bilden. Als abhängige Variable werden die Itemantworten oder der daraus gebildete Gesamtsummenscore betrachtet. Die experimentellen Einheiten sind die Testpersonen, bei denen durch die Bearbeitung mehrerer Items wiederholte Messungen vorgenommen werden. Psychologische Tests lassen sich damit als Testpersonen-×-Items-Designs konzeptualisieren (Rost, 2004).

1.2 Testarten

Psychometrische Persönlichkeitstests erfassen eine akute Symptomatik (*state*) oder eine stabile Eigenschaft (*trait*). Häufig handelt es sich um Selbstauskunftsfragebögen, bei denen es keine richtigen oder falschen Antworten gibt. Ihre Bearbeitung setzt Metakognition, also die Fähigkeit zur Reflexion über das eigene Denken und Erleben, sowie die Bereitschaft voraus, über sich selbst Auskunft zu geben. Die Absicht der Fragen ist in der Regel leicht durchschaubar, und die Antworten können entsprechend leicht verfälscht werden. Zu den psychometrischen Persönlichkeitstests zählt man üblicherweise:

- Klinische Tests
- Einstellungstests
- Persönlichkeitsstrukturtests
- Interessentests

Leistungstests erfassen eine Leistung anhand von Aufgaben, deren Bearbeitung als richtig oder falsch klassifiziert werden kann. Dabei unterscheidet man Schnelligkeitstests (*Speedtests*), bei denen die Bearbeitungsgeschwindigkeit im Vordergrund steht, und Niveautests (*Powertests*), bei denen das bewältigte Schwierigkeitsniveau entscheidend ist. Eine Verfälschung nach unten ist möglich, indem eine Testperson absichtlich eine geringere Leistung zeigt. Zu den Leistungstests zählt man üblicherweise:

- Entwicklungstests
- Intelligenztests
- Allgemeine Leistungstests
- Schultests
- Spezielle Funktionsprüfungs- und Eignungstests

Persönlichkeitsentfaltungsverfahren werden auch als projektive Verfahren bezeichnet. Sie beziehen sich auf die psychoanalytische Vorstellung der Projektion als Abwehrmechanismus. Nach dieser Vorstellung projiziert das Ich Triebregungen, die mit den Anforderungen des Über-Ichs in Konflikt stehen, nach außen. Die Verfahren sind üblicherweise unstrukturiert und qualitativ ausgerichtet. Zu den Persönlichkeitsentfaltungsverfahren zählt man üblicherweise:

- Formdeuteverfahren
- Verbal-thematische Verfahren
- Zeichnerische und Gestaltungsverfahren

Im Folgenden wollen wir uns etwas genauer mit *Klinischen Tests* und *Einstellungstests* beschäftigen und jeweils ein konkretes Beispiel betrachten.

Klinische Tests

Klinische Tests sind Fragebogenverfahren, die die Diagnose psychischer Störungen anhand der Klassifikationssysteme ICD und DSM unterstützen. Dabei unterscheidet man störungsübergreifende Verfahren, die verschiedene Bereiche psychischer Beschwerden erfassen, und störungsspezifische Verfahren, die sich auf eine bestimmte Störung beziehen.

Ein Beispiel für ein störungsspezifisches Verfahren ist das *Beck-Depressionsinventar II* (*BDI-II*), ein Selbstbeurteilungsinstrument zur Erfassung der Schwere depressiver Symptomatik. Es wurde von Beck et al. (1996) als Nachfolger des Beck-Depressionsinventars (Beck, 1961) entwickelt. Die deutschsprachige Fassung stammt von Hautzinger et al. (2006). Die Überarbeitung umfasste sprachliche Anpassungen und eine Angleichung an die damaligen Diagnosemanuale. Das BDI-II besteht aus 21 Items, deren Antworten mit Werten von 0 bis 3 bewertet und zu einem Gesamtwert summiert werden. Die Items betreffen beispielsweise Traurigkeit, Pessimismus, Verlust an Freude, Schuldgefühle, Energieverlust und Konzentrationsschwierigkeiten (vgl. Abbildung 1.1).

Das Item zur Traurigkeit veranschaulicht die abgestuften Antwortmöglichkeiten:

- (0) Ich bin nicht traurig
- (1) Ich bin oft traurig
- (2) Ich bin ständig traurig
- (3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte

Zur Einordnung des Gesamtwerts werden folgende Grenzwerte angegeben, wobei diese Einteilung lediglich die Ausprägung der mit dem Fragebogen erfassten Symptomatik beschreibt und der BDI-II-Gesamtwert allein keine klinische Diagnose begründet.

Gesamtwert	Einordnung
0–13	Keine Depression bzw. klinisch unauffällig oder remittiert
14–19	Leichtes depressives Syndrom
20–28	Mittelgradiges depressives Syndrom
Ab 29	Schweres depressives Syndrom

BDI-II

1. Traurigkeit
- ○ (0) Ich bin nicht traurig
- ○ (1) Ich bin oft traurig
- ○ (2) Ich bin ständig traurig
- ○ (3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte

2. Pessimismus
- ○ (0) Ich sehe nicht mutlos in die Zukunft
- ○ (1) Ich sehe mutloser in die Zukunft als sonst
- ○ (2) Ich bin mutlos und erwarte nicht, dass meine Situation besser wird
- ○ (3) Ich glaube, dass meine Zukunft hoffnungslos ist und nur noch schlechter wird

3. Versagensgefühle
- ○ (0) Ich fühle mich nicht als Versager:in
- ○ (1) Ich habe häufiger Versagensgefühle als sonst
- ○ (2) Wenn ich zurückblicke, sehe ich viele Fehlschläge
- ○ (3) Ich habe das Gefühl, als Mensch ein:e völlige:r Versager:in zu sein

4. Verlust von Freude
- ○ (0) Ich kann die Dinge genauso gut genießen wie früher
- ○ (1) Ich kann die Dinge nicht mehr so genießen wie früher
- ○ (2) Dinge, die mir früher Freude gemacht haben, kann ich kaum mehr genießen
- ○ (3) Dinge, die mir früher Freude gemacht haben, kann ich überhaupt nicht mehr genießen

5. Schuldgefühle
- ○ (0) Ich habe keine besonderen Schuldgefühle
- ○ (1) Ich habe oft Schuldgefühle wegen Dingen, die ich getan habe oder hätte tun sollen
- ○ (2) Ich habe die meiste Zeit Schuldgefühle
- ○ (3) Ich habe ständig Schuldgefühle

6. Bestrafungsgefühle
- ○ (0) Ich habe nicht das Gefühl, für etwas bestraft zu sein
- ○ (1) Ich habe das Gefühl, vielleicht bestraft zu werden
- ○ (2) Ich erwarte, bestraft zu werden
- ○ (3) Ich habe das Gefühl, bestraft zu sein

7. Selbstablehnung
- ○ (0) Ich halte von mir genauso viel wie immer
- ○ (1) Ich habe Vertrauen in mich verloren
- ○ (2) Ich bin von mir enttäuscht
- ○ (3) Ich lehne mich völlig ab

8. Selbstvorwürfe
- ○ (0) Ich kritisiere oder tadle mich nicht mehr als sonst
- ○ (1) Ich bin mir gegenüber kritischer als sonst
- ○ (2) Ich kritisiere mich für all meine Mängel
- ○ (3) Ich gebe mir die Schuld für alles Schlimme, was passiert

9. Selbstmordgedanken
- ○ (0) Ich denke nicht daran, mir etwas anzutun
- ○ (1) Ich denke manchmal an Selbstmord, aber ich würde es nicht tun
- ○ (2) Ich möchte mich am liebsten umbringen
- ○ (3) Ich würde mich umbringen, wenn ich die Gelegenheit dazu hätte

10. Weinen
- ○ (0) Ich weine nicht öfter als früher
- ○ (1) Ich weine jetzt mehr als früher
- ○ (2) Ich weine beim geringsten Anlass
- ○ (3) Ich möchte gern weinen, aber ich kann nicht

11. Unruhe
- ○ (0) Ich bin nicht unruhiger als sonst
- ○ (1) Ich bin unruhiger als sonst
- ○ (2) Ich bin so unruhig, dass es mir schwer fällt, stillzusitzen
- ○ (3) Ich bin so unruhig, dass ich mich ständig bewegen oder etwas tun muss

12. Interessenverlust
- ○ (0) Ich habe das Interesse an anderen Menschen oder an Tätigkeiten nicht verloren
- ○ (1) Ich habe weniger Interesse an anderen Menschen oder an Dingen als sonst
- ○ (2) Ich habe das Interesse an anderen Menschen oder an Dingen zum größten Teil verloren
- ○ (3) Es fällt mir schwer, mich überhaupt für irgendetwas zu interessieren

13. Entschlussunfähigkeit
- ○ (0) Ich bin so entschlussfreudig wie immer
- ○ (1) Es fällt mir schwerer als sonst, Entscheidungen zu treffen
- ○ (2) Es fällt mir sehr viel schwerer als sonst, Entscheidungen zu treffen
- ○ (3) Ich habe Mühe, überhaupt Entscheidungen zu treffen

14. Wertlosigkeit
- ○ (0) Ich fühle mich nicht wertlos
- ○ (1) Ich halte mich für weniger wertvoll und nützlich als sonst
- ○ (2) Verglichen mit anderen Menschen fühle ich mich viel weniger wert
- ○ (3) Ich fühle mich völlig wertlos

15. Energieverlust
- ○ (0) Ich habe so viel Energie wie immer
- ○ (1) Ich habe weniger Energie als sonst
- ○ (2) Ich habe so wenig Energie, dass ich kaum noch etwas schaffe
- ○ (3) Ich habe keine Energie mehr, um überhaupt noch etwas zu tun

16. Reizbarkeit
- ○ (0) Ich bin nicht reizbarer als sonst
- ○ (1) Ich bin reizbarer als sonst
- ○ (2) Ich bin viel reizbarer als sonst
- ○ (3) Ich fühle mich dauernd gereizt

17. Veränderungen des Appetits
- ○ (0) Mein Appetit hat sich nicht verändert
- ○ (1) Mein Appetit ist etwas schlechter als sonst
- ○ (1) Mein Appetit ist etwas größer als sonst
- ○ (2) Mein Appetit ist viel schlechter als sonst
- ○ (2) Mein Appetit ist viel größer als sonst
- ○ (3) Ich habe überhaupt keinen Appetit
- ○ (3) Ich habe ständig Heißhunger

18. Konzentrationsschwierigkeiten
- ○ (0) Ich kann mich so gut konzentrieren wie immer
- ○ (1) Ich kann mich nicht mehr so gut konzentrieren wie sonst
- ○ (2) Es fällt mir schwer, mich längere Zeit auf irgendetwas zu konzentrieren
- ○ (3) Ich kann mich überhaupt nicht mehr konzentrieren

19. Ermüdung oder Erschöpfung
- ○ (0) Ich fühle mich nicht müder oder erschöpfter als sonst
- ○ (1) Ich werde schneller müde oder erschöpft als sonst
- ○ (2) Für viele Dinge, die ich üblicherweise tue, bin ich zu müde oder erschöpft
- ○ (3) Ich bin so müde oder erschöpft, dass ich fast nichts mehr tun kann

20. Verlust an sexuellem Interesse
- ○ (0) Mein Interesse an Sexualität hat sich in letzter Zeit nicht verändert
- ○ (1) Ich interessiere mich weniger für Sexualität als früher
- ○ (2) Ich interessiere mich jetzt viel weniger für Sexualität
- ○ (3) Ich habe das Interesse an Sexualität völlig verloren

21. Veränderungen der Schlafgewohnheiten
- ○ (0) Meine Schlafgewohnheiten haben sich nicht verändert
- ○ (1) Ich schlafe etwas mehr als sonst
- ○ (1) Ich schlafe etwas weniger als sonst
- ○ (2) Ich schlafe viel mehr als sonst
- ○ (2) Ich schlafe viel weniger als sonst
- ○ (3) Ich schlafe fast den ganzen Tag
- ○ (3) Ich wache 1-2 Stunden früher auf als gewöhnlich und kann nicht mehr einschlafen

Abbildung 1.1 BDI-II nach Hautzinger et al. (2006). Testpersonen werden dabei gebeten, für jede Gruppe die Aussage auszuwählen, die ihr Befinden in den vergangenen zwei Wochen einschließlich heute am besten beschreibt. Treffen mehrere Aussagen gleichermaßen zu, wird die Aussage mit dem höheren Zahlenwert gewählt. Auch bei Schlafgewohnheiten und Appetit ist jeweils nur eine Antwort auszuwählen.

Einstellungstests

Eine *psychologische Einstellung* ist eine relativ stabile, aber veränderbare innere Haltung gegenüber Objekten, Personen, Gruppen, Ideen oder Situationen. Sie umfasst kognitive, affektive und konative, also auf die Handlungsbereitschaft bezogene, Komponenten. *Einstellungstests* sind psychologische Messinstrumente zur systematischen Erfassung solcher Einstellungen. Sie werden meist als Fragebögen oder Skalen umgesetzt, in denen Testpersonen Aussagen in unterschiedlichem Maß bewerten. Zu ihren Anwendungsbereichen gehören die Erhebung von Wertorientierungen, Vorurteilen und politischen oder religiösen Überzeugungen, die Messung arbeits- und organisationsbezogener Einstellungen sowie die Forschung zu sozialen Einstellungen, etwa gegenüber Minderheiten, Umweltschutz oder Gesundheit.

Ein Beispiel ist die *General Ecological Behavior Scale*, hier in der Fassung mit 50 Items (*GEB-50*). Sie wurde ursprünglich als Instrument zur Erfassung umweltschützenden Verhaltens entwickelt (Kaiser, 1998) und später als Instrument zur Messung individueller Umwelteinstellungen interpretiert (Kaiser et al., 2010). Ihre theoretische Grundlage bildet das *Campbell-Paradigma* (Campbell, 1963). Dessen Grundidee ist, dass sich die Stärke einer Einstellung anhand der dafür in Kauf genommenen *Verhaltenskosten* erfassen lässt. Der Einstellung entspricht dabei ein Ziel, beispielsweise der Schutz der Umwelt. Die Verhaltenskosten ergeben sich aus den Mitteln, die eine Person zur Erreichung dieses Ziels einsetzt.

Unterschiedliche Verhaltensweisen sind mit unterschiedlichen Kosten verbunden. So kann Recycling mit vergleichsweise geringen Kosten verbunden sein, während die Mitgliedschaft in einer Umweltschutzorganisation höhere Kosten verursacht. Zu den Verhaltenskosten gehören Aufwand, Zeit und Geld. Auch soziale Normen und kulturelle Praktiken können beeinflussen, wie aufwendig eine Verhaltensweise ist. Nach dem Campbell-Paradigma spricht es für eine stärker ausgeprägte Umwelteinstellung, wenn eine Person mehr umweltschützende Verhaltensweisen ausführt und dabei auch höhere Kosten in Kauf nimmt.

Die GEB-50 umfasst 50 Selbstberichte zu Verhaltensweisen, mit denen Menschen die Umwelt schützen. Bei 32 Items wird nach der Häufigkeit des jeweiligen Verhaltens gefragt. Die Antwortmöglichkeiten lauten „nie“, „selten“, „gelegentlich“, „oft“ und „sehr oft“. Weitere 18 Items werden mit „ja“ oder „nein“ beantwortet. Bei allen Items ist außerdem „keine Angabe“ möglich. Beispiele für Items mit Häufigkeitsangaben sind „Ich kaufe Lebensmittel aus kontrolliert biologischem Anbau.“ und „Altglas bringe ich zum Sammelcontainer.“ Ein Beispiel für ein Item mit Ja/Nein-Antwortformat ist „Ich bin Mitglied in einer Umweltschutzorganisation.“ Die Antworten beziehen sich somit auf konkrete Verhaltensweisen, die im Rahmen des Campbell-Paradigmas als Hinweise auf die zugrunde liegende Umwelteinstellung interpretiert werden (vgl. Abbildung 1.2).

1.3 Antwortformate

Das *Antwortformat* eines psychologischen Tests bestimmt die Art und Weise, wie Testpersonen auf die gestellten Aufgaben reagieren sollen. Die Wahl des Antwortformats hängt von der Testart und der jeweiligen Testaufgabe ab. Grundsätzlich unterscheidet man *freie oder offene Antwortformate* und *gebundene oder geschlossene Antwortformate*. Zu den offenen Antwortformaten gehören Kurzaufsatzaufgaben und Ergänzungsaufgaben. Gebundene Antwortformate umfassen Ordnungsaufgaben, Auswahlaufgaben und Beurteilungsaufgaben. Bei der folgenden Darstellung orientieren wir uns eng an Pospeschill (2022, Kapitel 2).

GEB-50: Fragebogen zum Umweltverhalten

1 = Nie · 2 = Selten · 3 = Gelegentlich · 4 = Oft · 5 = Sehr oft · KA = Keine Angabe

Häufigkeit

		1	2	3	4	5	KA
1	Für den Arbeits- bzw. Schulweg benutze ich das Fahrrad, öffentliche Verkehrsmittel oder gehe zu Fuß.	☐	☐	☐	☐	☐	☐
2	Ich kaufe Lebensmittel aus kontrolliert biologischem Anbau.	☐	☐	☐	☐	☐	☐
3	Ich kaufe Getränke in Dosen.	☐	☐	☐	☐	☐	☐
4	Zum Reinigen des Backofens verwende ich ein Spray.	☐	☐	☐	☐	☐	☐
5	Ich warte, bis ich eine volle Wäschetrommel habe, bevor ich wasche.	☐	☐	☐	☐	☐	☐
6	Ich fahre mit dem Auto in die Stadt bzw. ich fahre in der Stadt Auto.	☐	☐	☐	☐	☐	☐
7	Auch im Winter lüfte ich, indem ich bei laufender Heizung das Fenster ankippe.	☐	☐	☐	☐	☐	☐
8	Beim Waschen verzichte ich auf den Vorwaschgang.	☐	☐	☐	☐	☐	☐
9	Ich fahre auf der Autobahn höchstens 100 km/h.	☐	☐	☐	☐	☐	☐
10	Wenn ich in einem Geschäft eine Plastiktüte bekomme, nehme ich sie.	☐	☐	☐	☐	☐	☐
11	Für Fahrten in die umliegende Gegend (bis 30 km) benutze ich öffentliche Nahverkehrsmittel oder das Fahrrad.	☐	☐	☐	☐	☐	☐
12	Ich sammle altes Papier und gebe es zum Recycling.	☐	☐	☐	☐	☐	☐
13	Altglas bringe ich zum Sammelcontainer.	☐	☐	☐	☐	☐	☐
14	Ich mache jemanden, der/die sich umweltschädigend verhält, darauf aufmerksam.	☐	☐	☐	☐	☐	☐
15	Ich spende Geld für Umweltschutzorganisationen.	☐	☐	☐	☐	☐	☐
16	Ich kaufe Mehrweg- statt Einwegflaschen.	☐	☐	☐	☐	☐	☐
17	Ich kaufe gebleichtes oder gefärbtes Toilettenpapier.	☐	☐	☐	☐	☐	☐
18	Ich kaufe Fertiggerichte.	☐	☐	☐	☐	☐	☐
19	Ich kaufe Artikel in Nachfüllpackungen.	☐	☐	☐	☐	☐	☐
20	Ich kaufe Möbel aus einheimischen Hölzern.	☐	☐	☐	☐	☐	☐
21	Ich boykottiere Produkte von Firmen, die sich nachweislich umweltschädigend verhalten.	☐	☐	☐	☐	☐	☐
22	Ich kaufe Obst und Gemüse der Jahreszeit entsprechend.	☐	☐	☐	☐	☐	☐
23	Ich benutze einen Wäschetrockner.	☐	☐	☐	☐	☐	☐
24	Ich besorge mir Bücher, Informationsschriften oder andere Materialien, die sich mit Umweltproblemen befassen.	☐	☐	☐	☐	☐	☐
25	Ich unterhalte mich mit Bekannten über Konsequenzen von Umweltverschmutzung, Klimawandel und Energieverbrauch.	☐	☐	☐	☐	☐	☐

Häufigkeit (Fortsetzung)

		1	2	3	4	5	KA
26	Für längere Reisen (6 Stunden Autofahrt und länger) nehme ich das Flugzeug.	☐	☐	☐	☐	☐	☐
27	Vor geschlossenen Bahnschranken lasse ich den Motor laufen.	☐	☐	☐	☐	☐	☐
28	Vor roten Ampeln lasse ich den Motor laufen.	☐	☐	☐	☐	☐	☐
29	Insekten bekämpfe ich mit chemischen Mitteln.	☐	☐	☐	☐	☐	☐
30	Im Winter drehe ich meine Heizung herunter, wenn ich meine Wohnung für mehr als 4 Stunden verlasse.	☐	☐	☐	☐	☐	☐
31	Zum Spazierengehen fahre ich mit dem Auto an den Ausgangspunkt des Spazierganges.	☐	☐	☐	☐	☐	☐
32	Ich dusche (statt zu baden).	☐	☐	☐	☐	☐	☐

Zutreffen

		Ja	Nein	KA
1	Ich verwende Einkaufstüten oder -taschen mehrfach.	☐	☐	☐
2	In meiner Wohnung ist es im Winter so warm, dass man ohne Pullover nicht friert.	☐	☐	☐
3	Ich benutze beim Waschen einen Weichspüler.	☐	☐	☐
4	Leere Batterien werfe ich in den Hausmüll.	☐	☐	☐
5	Breiige Essensreste leere ich in die Toilette.	☐	☐	☐
6	In der Toilette benutze ich chemische Duftsteine für den guten Geruch.	☐	☐	☐
7	Ich bin Mitglied in einer Umweltschutzorganisation.	☐	☐	☐
8	Im Hotel lasse ich täglich die Handtücher wechseln.	☐	☐	☐
9	Ich besitze eine Geschirrspülmaschine der Effizienzklasse A+ oder besser.	☐	☐	☐
10	Ich verlasse nach einem Picknick den Platz genauso, wie ich ihn angetroffen habe.	☐	☐	☐
11	Ich habe eine Solaranlage zur Energie- bzw. Wärmeerzeugung angeschafft.	☐	☐	☐
12	Ich habe mich über Vor- und Nachteile einer Solaranlage informiert.	☐	☐	☐
13	Ich beziehe Strom aus erneuerbarer Energie.	☐	☐	☐
14	Ich verzichte auf ein Auto.	☐	☐	☐
15	Ich bin in einem „Car-Sharing“-Pool.	☐	☐	☐
16	Durch mein Fahrverhalten versuche ich, den Kraftstoffverbrauch so niedrig wie möglich zu halten.	☐	☐	☐
17	Ich besitze ein verbrauchsreduziertes Auto (weniger als 6 Liter Treibstoff pro 100 km).	☐	☐	☐
18	Ich ernähre mich vegetarisch.	☐	☐	☐

Kaiser (2020), CC BY-SA 4.0.

Abbildung 1.2 GEB-50 nach Kaiser (2020). Testpersonen werden dabei gebeten, bei 32 Handlungen anzugeben, wie häufig sie diese ausführen, und bei weiteren 18 Handlungen mit Ja oder Nein anzugeben, was eher auf sie zutrifft. „Keine Angabe“ (KA) ist zu wählen, wenn eine Handlung auf die momentane Lebenssituation nicht zutrifft, etwa bei Fragen zum Fahrverhalten ohne Führerschein. CC BY-SA 4.0.

Offene Antwortformate

Bei *offenen Antwortformaten* formuliert die Testperson ihre Antwort auf Grundlage einer strukturellen Vorgabe eigenständig. Solche Formate werden beispielsweise bei projektiven Verfahren und zur Abfrage komplexer Wissensinhalte eingesetzt. Man unterscheidet dabei *Kurzaufsatzaufgaben* und *Ergänzungsaufgaben*. Bei Kurzaufsatzaufgaben besteht die Antwort aus einer kurzen schriftlichen Abhandlung, deren Umfang von einem Wort bis zu mehreren Sätzen reichen kann (vgl. Abbildung 1.3). Eine Begrenzung der Wortzahl kann dabei sinnvoll sein. Ergänzungsaufgaben können als offene Fragen gestaltet sein, bei denen ein Schlüsselwort am Satzende ergänzt werden soll, oder als Lückentexte, bei denen Schlüsselwörter im laufenden Text einzusetzen sind (vgl. Abbildung 1.4).

Ein Vorteil offener Antwortformate besteht bei Leistungstests darin, dass die Testperson eine eigenständige Leistung erbringen muss und keine vorgegebenen Antwortalternativen durch bloßes Ankreuzen zufällig treffen kann. Offene Antwortformate ermöglichen die Erfassung von Sprachverständnis, Motivation, Interesse und Kreativität sowie die Prüfung von Reproduktions- und Transferleistungen. Dem stehen ein hoher Bearbeitungsaufwand und eine hohe kognitive Belastung für die Testpersonen gegenüber. Für die Testenden entstehen ein hoher Auswertungsaufwand und Schwierigkeiten, eine objektive Auswertung sicherzustellen.

Beispiel: Wissen über psychologische Tests

Erläutern Sie an einem Beispiel, wodurch eine Testanweisung missverständlich werden kann. Beschränken Sie Ihre Antwort auf zwei bis drei Sätze.

Antwort: .....

.....

.....

Auswertung: Die Antwort nennt eine missverständliche Testanweisung und erläutert anhand zweier möglicher Interpretationen, wie diese zu unterschiedlichen Antworten führen kann.

Abbildung 1.3 Kurzaufsatzaufgabe.

Offene Fragen mit Schlüsselwort

(Einfachantwort) Wie bezeichnet man die kleinste Einheit eines psychologischen Tests? .....

(Reihenantwort) Wie heißen die drei klassischen Testgütekriterien? .....

(Analogieantwort) Länge verhält sich zu Meter wie Masse zu .....

(Folgenantwort) Welche Zahl setzt die Zahlenfolge fort? $2, 4, 8, 16,$ .....

Lückentext

Ergänzen Sie die fehlenden Fachbegriffe.

Die kleinste Einheit eines psychologischen Tests heißt _____. Bei _____ Antwortformaten formuliert die Testperson ihre Antwort selbst. Bei _____ Antwortformaten stehen Antwortmöglichkeiten zur Verfügung.

Abbildung 1.4 Ergänzungsaufgaben mit offenen Fragen und Lückentext.

Ordnungsaufgaben

Bei *Ordnungsaufgaben* unterscheidet man *Umordnungsaufgaben* und *Zuordnungsaufgaben*. In Umordnungsaufgaben werden vorgegebene Elemente in eine sinnvolle Reihenfolge gebracht (vgl. Abbildung 1.5). Damit lassen sich schlussfolgerndes Denken oder das Verständnis von Ursache-Wirkungs-Zusammenhängen prüfen. Nichtverbale Aufgaben vermeiden dabei eine Beeinträchtigung durch die Lesefähigkeit der Testperson. Die Entwicklung bildlicher Aufgaben ist allerdings mit einem hohen Materialentwicklungsaufwand verbunden.

Beispiel: Ablauf einer psychologischen Untersuchung

Bringen Sie die folgenden Schritte in eine sinnvolle zeitliche Reihenfolge. Tragen Sie dazu die Buchstaben in die Antwortzeile ein.

A. Die erhobenen Daten statistisch auswerten

B. Eine überprüfbare Hypothese formulieren

C. Die Ergebnisse im Hinblick auf die Hypothese interpretieren

D. Die Untersuchung planen und die Messinstrumente auswählen

E. Die Untersuchung durchführen und Daten erheben

Reihenfolge: _____ → _____ → _____ → _____ → _____

Abbildung 1.5 Umordnungsaufgabe.

Bei Zuordnungsaufgaben werden vorgegebene Elemente einander zugeordnet (vgl. Abbildung 1.6). Sie dienen der Wissensprüfung durch Wiedererkennung und sind vergleichsweise einfach zu konstruieren, ökonomisch und objektiv auszuwerten. Eine eigenständige Reproduktion des Wissens ist nicht erforderlich, da die Wiedererkennung ausreicht. Zufallstreffer sind möglich, insbesondere wenn keine zusätzlichen Antwortalternativen vorhanden sind, die keinem der vorgegebenen Elemente zugeordnet werden können.

Beispiel: Psychologische Erhebungsverfahren

Ordnen Sie jedem Beispiel das passende Verfahren zu. Tragen Sie den zugehörigen Buchstaben ein. Jedes Verfahren wird genau einmal verwendet.

A. Fremdbeurteilung B. Leistungstest C. Selbstbeurteilung

Beispiel	Antwort
Eine Person berichtet in einem Fragebogen über ihre eigene Stimmung.	_____
Eine Person markiert unter Zeitdruck vorgegebene Zielbilder. Die Anzahl korrekt markierter Bilder wird ausgewertet.	_____
Eine Lehrperson beurteilt die Konzentrationsfähigkeit eines Kindes.	_____

Abbildung 1.6 Zuordnungsaufgabe.

Auswahlaufgaben

Bei *Auswahlaufgaben* wählt die Testperson zutreffende Antworten aus mehreren vorgegebenen Alternativen aus. Dichotome Aufgaben bieten zwei Antwortmöglichkeiten, während *Multiple-Choice-Aufgaben* mehrere Antwortmöglichkeiten vorgeben (vgl. Abbildung 1.7). Bei Leistungstests dienen *Distraktoren*, also Ablenkungsantworten, dazu, die Schwierigkeit einer Aufgabe zu gestalten. Wichtig ist dabei die *Disjunktion*, also die eindeutige Trennung zwischen richtigen und falschen Aussagen (vgl. Abbildung 1.8). Bei Persönlichkeitstests spielt die *Exhaustivität*, also die Vollständigkeit der Antwortalternativen, eine wichtige Rolle (vgl. Abbildung 1.8). Fehlt eine passende Antwortmöglichkeit, muss sich die Testperson dennoch für eine der vorgegebenen Alternativen entscheiden. In diesem Sinn führt fehlende Exhaustivität zu *Forced-Choice-Antworten* (vgl. Abbildung 1.9).

Auswahlaufgaben sind einfach zu handhaben, ökonomisch und objektiv auszuwerten. Als Nachteile gelten die hohe Ratewahrscheinlichkeit und die Beschränkung auf Wiedererkennungsleistungen, wenn lediglich bereits bekanntes Wissen ausgewählt werden muss. Eine solche Rekognitionsleistung erfordert keine eigenständige Problemlöse- oder Kreativitätsleistung. Zudem kann die Entwicklung geeigneter Distraktoren aufwendig und komplex sein.

Beispiel: Einfachwahlaufgabe

Welche Aussage beschreibt einen standardisierten Test am besten?

Kreuzen Sie genau **eine** Antwort an.

☐ Jede Person erhält eine frei gewählte Instruktion.

☐ Durchführung und Auswertung folgen festgelegten Regeln.

☐ Jede Antwort wird ausschließlich intuitiv beurteilt.

Beispiel: Mehrfachwahlaufgabe

Welche der folgenden Aufgaben haben ein offenes Antwortformat?

Kreuzen Sie **alle** zutreffenden Antworten an.

☐ Einen Begriff in eigenen Worten erklären

☐ Eine Aussage als richtig oder falsch markieren

☐ Ein fehlendes Wort in einem Lückentext ergänzen

☐ Eine Aussage auf einer Ratingskala beurteilen

Abbildung 1.7 Einfachwahl- und Mehrfachwahlaufgaben.

Beurteilungsaufgaben

Eine *Beurteilung* wird auch als *Rating* bezeichnet. *Beurteilungsaufgaben* werden vorzugsweise in klinischen Fragebögen und Persönlichkeitstests eingesetzt. Die Testperson schätzt dabei eine Aussage mithilfe einer diskreten Ratingskala oder einer kontinuierlichen Analogskala ein. Aus den gegebenenfalls gewichteten Punktwerten der einzelnen Antworten wird meist ein Gesamtpunktwert, ein sogenannter *Score*, berechnet. Bei der Gestaltung solcher Aufgaben sind verschiedene Aspekte zu berücksichtigen.

Beispiel: Nicht disjunkte Antwortalternativen

Wo haben Sie gestern zuletzt gelernt? Wählen Sie eine Antwort.

☐ Zu Hause ☐ In einer Bibliothek ☐ An der Universität

Beispiel: Nicht exhaustive Antwortalternativen

Wo haben Sie gestern zuletzt gelernt? Wählen Sie eine Antwort.

☐ Zu Hause ☐ In einer Bibliothek

Abbildung 1.8 Auswahlaufgaben mit nicht disjunkten und nicht exhaustiven Antwortalternativen. Eine Universitätsbibliothek passt zu zwei Kategorien. Die Antwortalternativen überschneiden sich und sind daher nicht disjunkt. Andere Lernorte und der Fall, dass die Person gestern nicht gelernt hat, fehlen. Die Antwortalternativen sind daher nicht exhaustiv.

Beispiel: Relative Präferenz

Welche Aussage beschreibt Sie eher? Bitte wählen Sie **eine** der beiden Aussagen.

☐ Beim Lernen suche ich gern den Austausch mit anderen.

☐ Beim Lernen arbeite ich gern für mich allein.

Abbildung 1.9 Forced-Choice-Aufgabe. Die Testperson muss sich zwischen den vorgegebenen Aussagen entscheiden. Die Antwort beschreibt nur eine relative Präferenz innerhalb des Aussagenpaares.

Die *Anzahl der Skalenstufen* hängt davon ab, wie fein Testpersonen ihr Urteil differenzieren können, und bestimmt zugleich, wie differenziert sie es ausdrücken können. Als Orientierung nennt Pospeschill (2022) für eine einzelne Ratingskala bei einem Test mit nur einem Item meist 9 ± 1 Skalenstufen und für Itembatterien, also Tests mit vielen Items, meist 5 ± 2 Skalenstufen. Bei kontinuierlichen grafischen Analogskalen entfällt die Festlegung einer Anzahl diskreter Skalenstufen.

Die *Forciertheit des Ratings* ergibt sich daraus, ob die Antwortskala einen Mittelpunkt enthält. Bei einer ungeraden Anzahl von Kategorien steht ein Mittelpunkt zur Verfügung, der als mittleres Urteil oder als Ausweichoption genutzt werden kann. Seine Interpretation kann daher uneindeutig sein. Man spricht in diesem Fall von einem *unforcierten Rating* (vgl. Abbildung 1.10). Bei einer geraden Anzahl von Kategorien fehlt ein solcher Mittelpunkt, sodass sich die Testperson bei der Auswahl einer Kategorie für eine Richtung entscheiden muss. Dies wird als *forciertes Rating* bezeichnet (vgl. Abbildung 1.11). *Ausweichkategorien* wie „weiß nicht“, „nicht anwendbar“ oder „keine Meinung“ ermöglichen es, eine inhaltliche Beurteilung ausdrücklich auszusetzen. Sie können damit valide Informationen darüber liefern, weshalb eine Testperson ein Item nicht bearbeitet oder nicht inhaltlich beantwortet.

Die *Polarität der Antwortskala* betrifft die Unterscheidung zwischen bipolaren und unipolaren Skalen. *Bipolare Skalen* reichen von einem negativen Pol, etwa starker Ablehnung, bis zu einem positiven Pol, etwa starker Zustimmung. *Unipolare Skalen* reichen dagegen von einem Bezugspunkt geringster Intensität bis zu einem Pol größter Intensität (vgl. Abbildung 1.12). Welche Form geeignet ist, hängt vom Gegenstandsbereich und vom Inhalt des jeweiligen Items ab.

Die *Balance der Antwortskala* bezeichnet das Verhältnis positiver und negativer Antwort-

Beispiel: Lernen im Studium

Wählen Sie für jede Frage eine Antwort.

(Häufigkeit) Wie häufig lernen Sie gemeinsam mit anderen?

☐ Nie ☐ Selten ☐ Manchmal ☐ Oft ☐ Immer

(Intensität) Wie stark fühlen Sie sich beim Lernen unter Zeitdruck?

☐ Gar nicht ☐ Wenig ☐ Mittelmäßig ☐ Stark ☐ Sehr stark

(Wahrscheinlichkeit) Wie wahrscheinlich ist es, dass Sie morgen lernen?

☐ Sehr unwahrscheinlich ☐ Eher unwahrscheinlich ☐ Weder wahrscheinlich noch unwahrscheinlich ☐ Eher wahrscheinlich ☐ Sehr wahrscheinlich

(Bewertung) Wie beurteilen Sie die Lernbedingungen an Ihrer Universität?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

(Einstellung) „Gemeinsames Lernen ist sinnvoll."

☐ Stimme überhaupt nicht zu ☐ Stimme eher nicht zu ☐ Stimme weder zu noch lehne ab ☐ Stimme eher zu ☐ Stimme völlig zu

Abbildung 1.10 Verbale, unforcierte Ratingskalen.

Beispiel: Lernen im Studium

Wählen Sie für jede Frage eine Antwort.

(Häufigkeit) Wie häufig lernen Sie gemeinsam mit anderen?

☐ Nie ☐ Selten ☐ Oft ☐ Immer

(Intensität) Wie stark fühlen Sie sich beim Lernen unter Zeitdruck?

☐ Gar nicht ☐ Wenig ☐ Stark ☐ Sehr stark

(Wahrscheinlichkeit) Wie wahrscheinlich ist es, dass Sie morgen lernen?

☐ Sehr unwahrscheinlich ☐ Eher unwahrscheinlich ☐ Eher wahrscheinlich ☐ Sehr wahrscheinlich

(Bewertung) Wie beurteilen Sie die Lernbedingungen an Ihrer Universität?

☐ Sehr schlecht ☐ Eher schlecht ☐ Eher gut ☐ Sehr gut

(Einstellung) „Gemeinsames Lernen ist sinnvoll."

☐ Stimme überhaupt nicht zu ☐ Stimme eher nicht zu ☐ Stimme eher zu ☐ Stimme völlig zu

Abbildung 1.11 Verbale, forcierte Ratingskalen.

kategorien. *Balancierte Skalen* enthalten gleich viele positive und negative Kategorien, während diese Anzahl bei *unbalancierten Skalen* unterschiedlich ist (vgl. Abbildung 1.13). Im Allgemeinen werden balancierte Skalen vorgezogen. Unbalancierte Skalen können jedoch sinnvoll sein, wenn begründete Annahmen darüber bestehen, in welchem Bereich die Antworten überwiegend liegen werden.

Die *Verankerung der Antwortskala* legt die Bedeutung der Skalenendpunkte und der einzelnen Skalenstufen fest. Bei einer *numerischen Verankerung* werden dafür Zahlen verwendet, bei einer *verbalen Verankerung* Wörter oder Sätze (vgl. Abbildung 1.14). Aus einer sol-

Beispiel: Unipolare Ratingskala

Wie stark sind Ihre Schmerzen momentan?

☐ Keine ☐ Leichte ☐ Mittlere ☐ Starke ☐ Sehr starke

Beispiel: Bipolare Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

Beispiele: Analogskalen

Markieren Sie Ihre Einschätzung jeweils durch einen Strich auf der Linie.

Unipolar: Wie stark sind Ihre Schmerzen momentan?



Bipolar: Wie bewerten Sie die Lehrveranstaltung?



Abbildung 1.12 Unipolare und bipolare Rating- und Analogskalen.

Beispiel: Balancierte Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

Zwei negative und zwei positive Kategorien sowie eine neutrale Kategorie.

Beispiel: Unbalancierte Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Gut ☐ Sehr gut

Abbildung 1.13 Balancierte und unbalancierte Ratingskalen. Eine negative und drei positive Kategorien sowie eine neutrale Kategorie. Der positive Bewertungsbereich wird feiner unterteilt.

chen Verankerung lässt sich im Allgemeinen nicht ableiten, dass die mit den Kategorien verbundenen Urteile äquidistant sind, also gleiche Abstände aufweisen.

Symbole und Marker können Antwortskalen für Personen zugänglich machen, die im Umgang mit Zahlen oder sprachlichen Kategorien wenig geübt sind. Als Kennzeichnungen kommen beispielsweise Plus- und Minuszeichen, Gesichter mit unterschiedlichen Ausdrücken oder unterschiedlich große Kreise infrage (vgl. Abbildung 1.14).

Kombinierte Antwortskalen verbinden mehrere Formen der Verankerung. Eine Antwortkategorie kann beispielsweise gleichzeitig durch eine Zahl, eine verbale Beschreibung und ein Symbol gekennzeichnet werden. Auf diese Weise wird die Antwortskala mehrfach verankert (vgl. Abbildung 1.14).

Das *Skalenniveau im Sinne der Repräsentationstheorie des Messens* ist bei Ratingskalen im Allgemeinen unbestimmt. Aus gleichen Abständen zwischen den dargestellten Ratingkategorien folgen keine gleichen Abstände zwischen den Urteilen der Testpersonen. Bei der

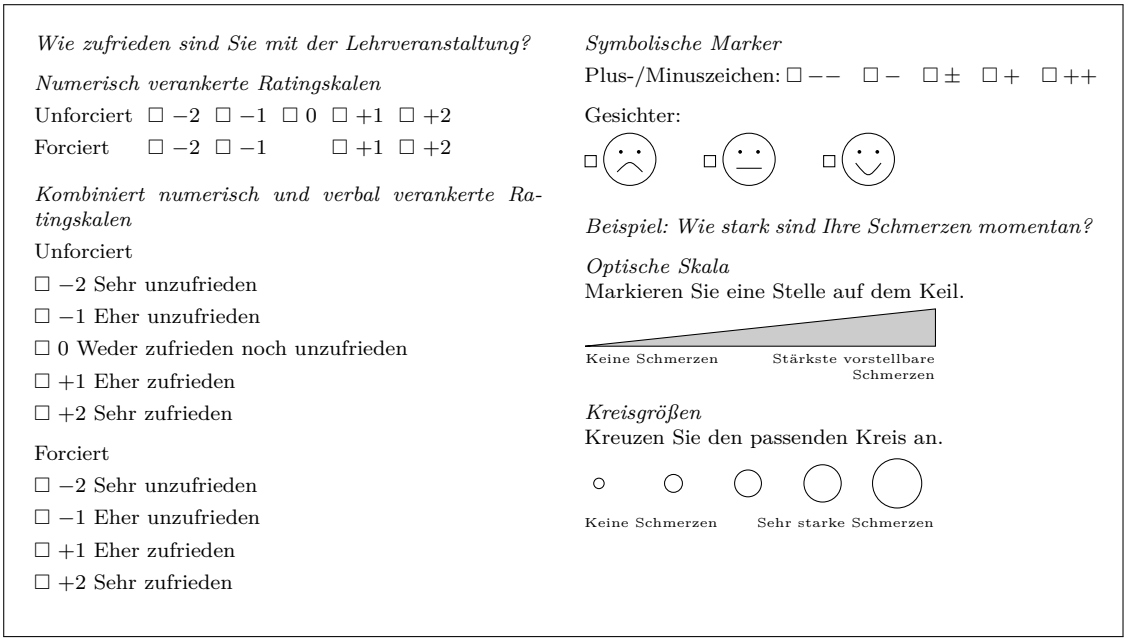


Abbildung 1.14 Numerisch und kombiniert verankerte Ratingskalen, symbolische Marker und optische Skalen.

Entstehung eines Ratings wirken zudem das zu erfassende Merkmal, das Messinstrument und die urteilende Person zusammen.

Vorteile von Beurteilungsaufgaben sind ihre leichte Handhabung, ihre Ökonomie und ihre allgemeine Akzeptanz. Als Nachteil gilt, dass ihre Ergebnisse eher Ordinal- als Intervallskalencharakter haben. Zudem können Testpersonen die Antwortkategorien unterschiedlich interpretieren. So müssen Bezeichnungen wie „selten“, „manchmal“ und „oft“ nicht für alle Personen dieselbe Bedeutung haben.

1.4 Testgütekriterien

Testgütekriterien beschreiben Qualitätseigenschaften psychologischer Tests und bilden die Grundlage für die Beurteilung der Wissenschaftlichkeit eines Testverfahrens. Es handelt sich um qualitative Konzepte, die nur zum Teil quantitativ erfasst werden können. Man unterscheidet dabei *Hauptgütekriterien* und *Nebengütekriterien*. Zu den Hauptgütekriterien zählen *Objektivität*, *Reliabilität* und *Validität*. Die Nebengütekriterien umfassen *Normierung*, *Skalierung*, *Testökonomie*, *Nützlichkeit*, *Zumutbarkeit*, *Unverfälschbarkeit* und *Fairness*. Bei der folgenden Darstellung orientieren wir uns an Moosbrugger & Kelava (2012, Kapitel 2).

Objektivität

Ein Test ist *objektiv*, wenn die Messung des interessierenden Merkmals unabhängig von den Personen erfolgt, die den Test durchführen und auswerten. Darüber hinaus müssen klare und anwenderunabhängige Regeln für die Interpretation der Ergebnisse vorliegen. Man unterscheidet *Durchführungsobjektivität*, *Auswertungsobjektivität* und *Interpretationsobjektivität* (Moosbrugger & Kelava, 2012).

Durchführungsobjektivität bezeichnet die Unabhängigkeit der Antworten einer Testperson von den Testleitenden und der Testsituation. Sie wird durch eine standardisierte Durchführung anhand des Testmanuals und eine möglichst weitgehende Kontrolle der Testsituation angestrebt.

Auswertungsobjektivität bezeichnet die Unabhängigkeit der Testauswertung von den auswertenden Personen. Bei gebundenen Antwortformaten und automatisierter Auswertung ist sie üblicherweise gegeben. Bei offenen Antwortformaten ist sie aufwendiger herzustellen, da die Antworten anhand festgelegter Kriterien beurteilt werden müssen.

Interpretationsobjektivität bezeichnet die Unabhängigkeit der Schlussfolgerungen aus den Testergebnissen von den Personen, die den Test anwenden. Sie wird häufig durch festgelegte Normwertklassifikationen gewährleistet, die eine einheitliche Einordnung der Ergebnisse ermöglichen.

Die Objektivität des BDI-II wird in der Dokumentation wie folgt dargestellt (Hautzinger et al., 2006).

> *Durchführungsobjektivität durch schriftliche Durchführungsinstruktion*
>
> Dieser Fragebogen enthält 21 Gruppen von Aussagen. Bitte lesen Sie jede dieser Gruppen von Aussagen sorgfältig durch und suchen Sie sich dann in jeder Gruppe eine Aussage heraus, die am besten beschreibt, wie Sie sich in den letzten zwei Wochen, einschließlich heute, gefühlt haben. Kreuzen Sie die Zahl neben der Aussage an, die Sie sich herausgesucht haben (0,1,2 oder 3). Falls in einer Gruppe mehrere Aussagen gleichermaßen auf Sie zutreffen, kreuzen Sie die Aussage mit der höheren Zahl an. Achten Sie bitte darauf, dass Sie in jeder Gruppe nicht mehr als eine Aussage ankreuzen, das gilt auch für Gruppe 16 (Veränderungen der Schlafgewohnheiten) oder Gruppe 18 (Veränderungen des Appetits).
>
> *Auswertungsobjektivität*
>
> Der Fragebogen wird durch die einfache Addition der angekreuzten Aussagen ausgewertet. Jedes Item wird auf einer 4-Punkt-Skala bewertet, die von 0 bis 3 reicht. Kreuzt ein Proband bei einem Item mehrere Aussagen an, so geht nur die Aussage mit der höchsten Ziffer in den Summenwert ein. Der Gesamtwert des BDI-II kann Werte zwischen 0 und 63 Punkten annehmen.
>
> *Interpretationsobjektivität*
>
> 0 - 8 Keine, 9 - 13 minimale, 14 - 19 leichte, 20 - 28 mittelschwere, 29 - 63 schwere Depression

Reliabilität

Reliabilität bezeichnet die Genauigkeit, mit der ein Test das von ihm erfasste Merkmal misst. Ein vollständig reliabler Test würde das Merkmal exakt, also ohne Messfehler, erfassen. Die klassische Testtheorie bettet diese Vorstellung in ein probabilistisches Modell ein und ermöglicht damit eine quantitative Beschreibung der Messgenauigkeit. Sie ist in erster Linie eine quantitative Reliabilitätstheorie.

Man unterscheidet vier gebräuchliche Ansätze zur Bestimmung der Reliabilität. Die *Retest-Reliabilität* ergibt sich aus der Korrelation der Ergebnisse desselben Tests bei zwei Messungen an denselben Personen. Sie hängt unter anderem vom Zeitintervall zwischen den Messungen sowie von Erinnerungs- und Lerneffekten ab. Die *Paralleltest-Reliabilität* wird

anhand der Korrelation der Ergebnisse eines Tests mit denen eines Paralleltests bestimmt. Ein Paralleltest besteht aus möglichst ähnlichen Items, die auch als *Itemzwillinge* bezeichnet werden. Bei der *Testhalbierungs-Reliabilität* oder *Split-Half-Reliabilität* wird ein Test in zwei möglichst parallele Hälften unterteilt. Die Korrelation der Ergebnisse beider Testhälften wird mithilfe der *Spearman-Brown-Formel* auf die ursprüngliche Itemanzahl des gesamten Tests hochgerechnet. Die *interne Konsistenz* verallgemeinert den Ansatz der Testhalbierung auf die Ebene einzelner Items. Ein gebräuchliches Maß dafür ist *Cronbachs* α aus der klassischen Testtheorie.

Die Reliabilität des BDI-II wird in der Dokumentation wie folgt dargestellt (Hautzinger et al., 2006):

> *Beispiel BDI-II*
>
> In der Studie von Beck et al. (1996) resultierte bei 26 Patienten, die im Abstand von einer Woche untersucht wurden, ein Retestkoeffizient von $r_{tt} = .93$. Aus Studentenstichproben werden für ein- bis zweiwöchige Zeiträume Koeffizienten von $r_{tt} = .74-.96$ berichtet (Leigh & Antony-Tolbert, 2001; Al-Musawi, 2001; Sprinkle, Lurie, Insko et al., 2002; Ghassemzadeh, Mojtabai, Karamghadiri & Ebrahimkhani, 2005). In Tabelle 2 sind bisherige Ergebnisse zur internen Konsistenz (Cronbach's α) des BDI II aufgelistet. In psychiatrischen Stichproben lag die interne Konsistenz im Bereich von $.89 \leq \alpha \leq .94$, in nichtklinischen Stichproben im Bereich von $.84 \leq \alpha \leq .91$.

Die Reliabilität der GEB-50 wird in der Dokumentation wie folgt dargestellt (Kaiser, 2020):

> *Beispiel GEB-50*
>
> Die gefundene Test-Retest-Reliabilität liegt bei $r_{tt} = .76$ (Kaiser & Wilson, 2000) und $r_{tt} = .83$ (Kaiser, Frick & Stoll-Kleemann, 2001) und sogar bei $r_{tt} = .96$ (Kaiser & Byrka, 2011) und $r_{tt} = .99$ (Kaiser, Brügger, Hartig, Bogner & Gutscher, 2014), wenn korrigiert um die Messfehlerausdünnung.

Validität

Validität bezeichnet das Ausmaß, in dem ein Test tatsächlich das Merkmal erfasst, das er messen soll. Ein Test gilt demnach als valide, wenn seine Ergebnisse als Ausdruck des beabsichtigten Merkmals interpretiert werden können. Zur Begründung dieser Interpretation werden je nach Testart unterschiedliche qualitative und quantitative Befunde herangezogen. Man unterscheidet eine Reihe von Validitätsarten (Moosbrugger & Kelava, 2012), im Folgenden wollen wir kurz die Augenschein-, Inhalts-, Kriteriums- und Konstruktvalidität betrachten.

Augenscheinvalidität bezeichnet den Grad, in dem ein Test aus Sicht von Laien das zu messende Merkmal intuitiv nachvollziehbar erfasst. Entscheidend ist, ob die Aufgaben auf den ersten Blick zum angegebenen Testzweck passen. So erscheint eine Frage nach häufig erlebter Traurigkeit als plausibler Bestandteil eines Depressionsfragebogens. Diese Einschätzung kann die Akzeptanz des Tests und die Bereitschaft zu seiner Bearbeitung unterstützen. Sie liefert jedoch noch keinen wissenschaftlichen Nachweis dafür, dass der Test das beabsichtigte Merkmal tatsächlich misst.

Inhaltsvalidität bezeichnet den Grad, in dem die Aufgaben eines Tests den zu erfassenden Merkmalsbereich aus fachlicher Sicht repräsentativ abdecken. Die Einschätzung erfolgt durch Expertinnen und Experten auf Grundlage einer inhaltlichen Bestimmung des

Merkmals und seiner Teilbereiche. Dabei wird geprüft, ob wichtige Aspekte ausreichend berücksichtigt werden und ob einzelne Aspekte im Verhältnis zum Testzweck über- oder unterrepräsentiert sind. Beispielsweise sollte ein Test zu den Grundlagen der Testtheorie die vorgesehenen Themenbereiche angemessen abbilden. Ein Test, der ausschließlich Definitionen von Testarten abfragt, würde diesen Inhaltsbereich nur unvollständig erfassen.

Kriteriumsvalidität bezeichnet den Grad des Zusammenhangs zwischen einem Testergebnis und einem externen Kriterium. Ein solches Kriterium ist eine außerhalb des Tests erfasste Größe, die für den vorgesehenen Verwendungszweck relevant ist. Beispielsweise lässt sich untersuchen, in welchem Ausmaß die Ergebnisse eines Studieneingangstests spätere Leistungen im Psychologiestudium vorhersagen. Der Zusammenhang kann durch eine Korrelation oder den Anteil der aufgeklärten Varianz beschrieben werden. Für die Aussagekraft dieser Befunde ist entscheidend, dass das gewählte Kriterium zum Testzweck passt und selbst angemessen erfasst wird.

Konstruktvalidität bezeichnet den Grad der wissenschaftlichen Fundierung des Schlusses von Testwerten auf die interessierenden Merkmale. Bei einem *strukturSuchenden Vorgehen* können exploratorische Faktoranalysen Hinweise auf die dem Test zugrunde liegenden Faktoren liefern. Darüber hinaus werden die Übereinstimmung mit Messungen ähnlicher Merkmale als *konvergente Validität* und die Abgrenzung gegenüber Messungen anderer Merkmale als *diskriminante Validität* untersucht. Bei einem *strukturprüfenden Vorgehen* werden theoretisch begründete Annahmen über die Teststruktur geprüft. Dazu gehören die Untersuchung der *faktoriellen Validität* mithilfe konfirmatorischer Faktoranalysen, Homogenitätsprüfungen mithilfe von Item-Response-Theorie-Modellen und die Evaluation von Strukturgleichungsmodellen.

Für die Validität des BDI-II wird wie folgt argumentiert (Hautzinger et al., 2006):

> *Konvergente und diskriminante Validität*
>
> In Tabelle 3 sind Studien zum Zusammenhang des BDI II mit anderen Selbst- und Fremdbeurteilungsskalen aufgeführt. Wie daraus hervorgeht, korreliert das Verfahren mit anderen Depressionsskalen zwischen $r = .68$ bis $r = .89$, etwas geringer mit selbst- und fremdbeurteilter Angst/Ängstlichkeit ($.37 \leq r \leq .60$) sowie im ähnlichen Bereich mit konstruktnahen kognitiven Skalen ($.37 \leq r \leq .68$). Die Differenzierungsfähigkeit bezüglich Depression und Angst anhand des BDI II ist eingeschränkt und abhängig von der Methode: fremdbeurteilte Angst anhand der HRSA korreliert niedriger mit dem BDI II als selbstbeurteilte Angst anhand des BAI (vgl. Tabelle 3). Bislang fehlen Studien, die Zusammenhänge zwischen BDI II und konstruktfernen Verfahren (z.B. symptomferne Persönlichkeitstraits) erfassen.
>
> *Faktorielle Validität*
>
> In der Untersuchung von Beck et al. (1996) legten Scree-Tests aus explorativen Faktorenanalysen sowohl für die Patientenstichprobe als auch für die Studentenstichprobe die Extraktion zweier Faktoren nahe. Nach parallel durchgeführten Hauptachsenanalysen mit anschließender obliquer (Promax-)Rotation resultierte für die Patientenstichprobe ein Faktor, den die Autoren als "somatisch-affektiven" Faktor bezeichneten, auf einem zweiten Faktor luden v.a. kognitive Items des BDI-II, er wurde demnach als "kognitiver" Faktor bezeichnet. Die beiden obliquen Faktoren korrelierten miteinander zu $r = 0.66$. In der Studentenstichprobe repräsentierte dagegen der erste Faktor die "kognitiv-affektive", der zweite Faktor die "somatische" Dimension. Hier betrug die Korrelation der beiden Faktoren $r = 0.62$.

Für die Validität der GEB-50 wird wie folgt argumentiert (Kaiser & Wilson, 2004):

Validität

Obwohl sich das mehrdimensionale Rasch-Modell dem eindimensionalen Rasch-Modell bei der mittels GEB erfassten Neigung, sich umweltschützend zu verhalten, als formal überlegen erwies, ist der Informationsverlust des eindimensionalen Modells vernachlässigbar gering. So lagen die messfehlerkorrigierten Korrelationen zwischen den Verhaltensneigungen in den verschiedenen Verhaltensdomänen in der Regel jenseits von .50 und im Bereich der Reliabilitäten der einzelnen Skalen. Entsprechend erscheint es nicht nur machbar, sondern aus Sparsamkeitsgründen auch ratsam, Umweltschutzneigung, wie beabsichtigt, als eine mehr oder weniger konsistente, allgemeine Verhaltensneigung zu erfassen (Kaiser & Wilson, 2004).

Beziehungen zwischen den Hauptgütekriterien

Die drei Hauptgütekriterien *Objektivität*, *Reliabilität* und *Validität* stehen in einem engen Zusammenhang. Objektivität ist eine Voraussetzung für Reliabilität, da ein Test, dessen Ergebnisse von der Testsituation oder den beteiligten Personen abhängen, das interessierende Merkmal nicht zuverlässig erfassen kann. Reliabilität ist wiederum eine Voraussetzung für Validität, da ein Test, der ein Konstrukt zu ungenau misst, dieses nicht sehr valide erfassen kann. Objektivität allein gewährleistet jedoch noch keine Reliabilität, und Reliabilität allein noch keine Validität. Darüber hinaus beschreibt das *Reliabilitäts-Kriteriumsvaliditäts-Dilemma* der klassischen Testtheorie den Umstand, dass eine Erhöhung der Reliabilität mit einer Abnahme der Kriteriumsvalidität einhergehen kann (Rost, 2004, 6.4.3).

Nebengütekriterien

Neben den Hauptgütekriterien werden sieben Nebengütekriterien zur Beurteilung psychologischer Tests herangezogen. Die folgende Tabelle fasst ihre Bedeutung in Anlehnung an Moosbrugger & Kelava (2012) zusammen.

1.5 Testtheorien

Testtheorien sind probabilistische Modelle, die den Zusammenhang zwischen dem zu erfassenden Konstrukt und dem beobachtbaren Testverhalten beschreiben. Sie bilden damit die Grundlage für die Analyse von Fragebogendaten. Als Hauptrichtungen lassen sich die *klassische Testtheorie*, die *Faktoranalyse* und die *Item-Response-Theorien* unterscheiden. Die klassische Testtheorie und die Faktoranalyse modellieren dabei latente, also nicht direkt beobachtbare Merkmale mithilfe von Zufallsvariablen. Auch Item-Response-Theorien können latente Zufallsvariablen enthalten.

Standarddatenstruktur

Die Standarddatenstruktur der Testtheorie und Fragebogendatenanalyse ergibt sich aus der Beobachtung der Antworten von n Testpersonen auf m Items. Diese Antworten werden in einer Datenmatrix mit n Zeilen und m Spalten angeordnet. Jede Zeile enthält die Antworten einer Testperson, jede Spalte die Antworten aller Testpersonen auf ein bestimmtes Item. Ein Eintrag der Matrix bezeichnet somit die Antwort einer bestimmten Testperson

Tabelle 1.1 Nebengütekriterien psychologischer Tests.

Nebengütekriterium	Definition
Normierung	Für einen Test liegen geeignete Vergleichswerte vor, mit deren Hilfe das Ergebnis einer Testperson im Verhältnis zu einer relevanten Bezugsgruppe eingeordnet und interpretiert werden kann.
Skalierung	Die nach den Auswertungsregeln gebildeten Testwerte geben die qualitativen Beziehungen zwischen den Merkmalsausprägungen angemessen wieder. Formale Skalierungseigenschaften werden meist im Rahmen der Item-Response-Theorie geprüft.
Testökonomie	Der finanzielle und zeitliche Aufwand eines Tests ist im Verhältnis zum diagnostischen Erkenntnisgewinn gering.
Nützlichkeit	Das erfasste Merkmal ist praktisch relevant, und die auf den Testergebnissen beruhenden Entscheidungen oder Maßnahmen lassen mehr Nutzen als Schaden erwarten.
Zumutbarkeit	Die zeitliche, psychische und physische Belastung der Testperson bleibt sowohl für sich genommen als auch im Verhältnis zum Nutzen der Testanwendung angemessen.
Unverfälschbarkeit	Der Test ist so gestaltet, dass die Testperson ihre Testwerte nicht durch gezieltes Antwort- oder Bearbeitungsverhalten steuern oder verzerren kann.
Fairness	Die Testwerte führen zu keiner systematischen Benachteiligung von Personen aufgrund ihrer Zugehörigkeit zu ethnischen, soziokulturellen oder geschlechtsspezifischen Gruppen.

auf ein bestimmtes Item. Tabelle 1.2 veranschaulicht diese Struktur anhand simulierter Antworten von 20 Testpersonen auf 10 Items mit einer Antwortskala von 1 bis 5.

Tabelle 1.2 20 Testpersonen × 10 Items (Antwortskala 1 bis 5).

Testperson	Item 1	Item 2	Item 3	Item 4	Item 5	Item 6	Item 7	Item 8	Item 9	Item 10
1	1	5	3	4	2	1	1	4	3	2
2	4	2	2	4	2	3	4	2	4	5
3	1	2	2	1	5	3	1	2	5	5
4	2	1	5	5	2	3	4	4	4	4
5	5	4	2	5	5	3	2	5	1	4
6	3	1	1	1	4	4	5	1	1	1
7	2	4	3	1	5	1	2	5	5	2
8	3	3	3	3	4	1	2	5	5	4
9	3	2	4	2	1	4	2	5	1	1
10	1	2	3	2	3	2	3	4	5	1
11	5	4	1	3	2	1	1	4	4	3
12	5	4	4	2	3	2	2	4	2	1
13	2	4	5	4	3	3	3	2	2	1
14	2	2	1	3	1	4	3	1	1	4
15	1	4	1	5	5	1	3	3	5	3
16	5	1	4	2	4	3	3	1	5	5
17	5	1	5	2	4	5	5	1	2	3
18	1	4	5	1	1	3	3	4	5	5
19	1	1	4	3	5	4	1	5	2	1
20	5	2	5	3	5	2	2	1	4	1

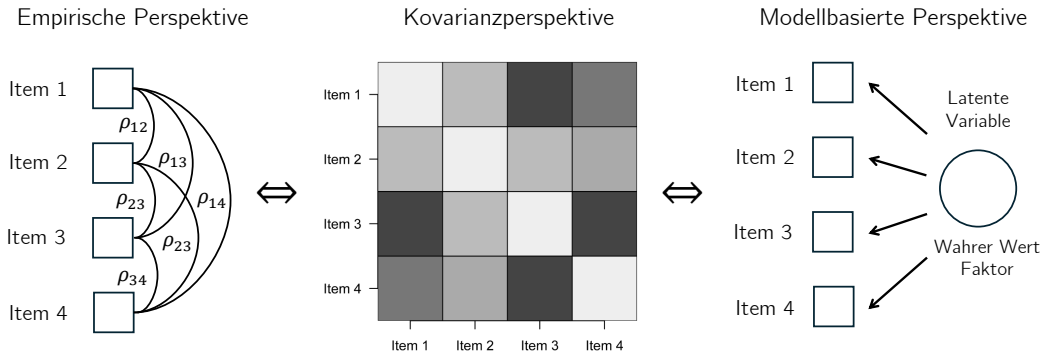


Abbildung 1.15 Empirische Perspektive, Kovarianzperspektive und modellbasierte Perspektive auf das Standardproblem der Testtheorie.

Standardproblem der Testtheorie und Fragebogendatenanalyse

Das Standardproblem der Testtheorie und Fragebogendatenanalyse besteht darin, die beobachteten Zusammenhänge zwischen Itemantworten durch latente Merkmale zu erklären (vgl. Abbildung 1.15). Aus einer *empirischen Perspektive* können Items miteinander korrelieren. Bei einer positiven Korrelation weisen Testpersonen mit hohen beziehungsweise niedrigen Werten in einem bestimmten Item häufig auch in einem anderen Item hohe beziehungsweise niedrige Werte auf. Aus einer *modellbasierten Perspektive* werden solche Zusammenhänge auf den Testpersonen eigene latente Merkmale zurückgeführt, die sich über mehrere Items hinweg wiederholt äußern. Je nach testtheoretischem Ansatz werden diese als *wahre Werte* in der klassischen Testtheorie, als *Faktoren* in der Faktoranalyse oder als *Personeneigenschaften* in den Item-Response-Theorien bezeichnet. Gemeinsam ist ihnen, dass ihre Ausprägungen nicht direkt beobachtet werden können, sondern aus den beobachteten Itemantwortwerten erschlossen werden müssen. Konkret bedeutet die Analyse von Fragebogendaten deshalb neben der Betrachtung von Deskriptivstatistiken wie Summenscores häufig die Modellierung der *empirischen Kovarianzmatrix*. Diese fasst die paarweisen Kovarianzen zwischen den Items sowie deren Varianzen auf der Diagonale zusammen. Durch Standardisierung erhält man die entsprechende Korrelationsmatrix mit den paarweisen Itemkorrelationen. Für die Struktur dieser Zusammenhänge lassen sich mathematisch präzise Modelle formulieren, die die Verbindung zwischen der empirischen und der modellbasierten Perspektive herstellen.

Klassische Testtheorie

Die *klassische Testtheorie* ist ein probabilistisches Modell der Item- und Summenwerte eines Tests. Zentrale Beiträge stammen von Gulliksen (1950) sowie Lord & Novick (1968). Ihr latentes Variablenmodell lässt sich grob wie folgt skizzieren:

$$\text{Beobachteter Wert} = \text{Wahrer Wert} + \text{Fehler} \tag{1.1}$$

Der *wahre Wert* ist dabei eine latente Zufallsvariable, mit deren Hilfe die beobachteten Antwortmuster erklärt werden. Da sich der beobachtete Wert aus dem wahren Wert und einem *Fehler* zusammensetzt, wird die klassische Testtheorie häufig als *Messfehlermodell*

bezeichnet. Das Modell berücksichtigt sowohl intraindividuelle als auch interindividuelle Variabilität und bildet die Grundlage für die quantitative Beurteilung der Reliabilität. Dazu gehören insbesondere die Paralleltest-Reliabilität, Cronbachs α und die Spearman-Brown-Formel.

Faktoranalyse

Die *Faktoranalyse* ist ein probabilistisches Modell der Kovarianzeigenschaften der Items eines Tests. Zentrale Beiträge stammen von Spearman (1904), Hotelling (1933) und Lawley (1940). Die Grundstruktur des Modells lässt sich vereinfacht wie folgt darstellen:

$$\text{Beobachtete Werte} = \text{Ladungen} \cdot \text{Faktorwerte} + \text{Fehler} \tag{1.2}$$

Die *Faktoren* werden als latente Zufallsvariablen modelliert. Die beobachteten Werte ergeben sich aus den mit *Ladungen* gewichteten Faktorwerten und einem Fehleranteil. Auf diese Weise werden die beobachteten Antwortmuster durch wenige, nicht direkt beobachtbare Faktoren erklärt. Man unterscheidet exploratorische und konfirmatorische Varianten der Faktoranalyse. Insbesondere die konfirmatorische Faktoranalyse dient der Überprüfung der faktoriellen Validität.

Item-Response-Theorien

Item-Response-Theorien beschreiben die Wahrscheinlichkeiten von Itemantworten als Funktion latenter Zustände beziehungsweise Merkmalsausprägungen. Zentrale Beiträge stammen von Rasch (1960), Novick (1966) und Lord (1980). Häufig werden dafür verschiedene mathematische Formen der logistischen Regression verwendet. In schematischer Form ergibt sich dabei:

$$\mathbb{P}(\text{Itemantwort}) = f(\text{Testparameter}, \text{Personenparameter}) \tag{1.3}$$

Die Wahrscheinlichkeit einer Itemantwort hängt dabei von *Testparametern* und *Personenparametern* ab. Personenparameter werden je nach Modell als latente Zufallsvariablen oder als feste, unbekannte Größen behandelt. Item-Response-Theorien wurden insbesondere für Leistungstests entwickelt und werden beispielsweise im Kontext der PISA-Studien eingesetzt (OECD, 2024). Sie bilden außerdem eine wichtige Grundlage des adaptiven Leistungstestens. Ihre Bedeutung im klinischen Kontext wird unter anderem bei Reise & Waller (2009) behandelt.

1.6 Testkonstruktion

Die *Testkonstruktion* umfasst die Entwicklung und wissenschaftliche Prüfung eines psychologischen Tests. Im Folgenden geben wir dazu einen Kurzüberblick auf Grundlage von Bühner et al. (2026). Ausgangspunkt der Testkonstruktion ist die Definition des zu erfassenden Merkmals, aus der geeignete Fragen oder Aufgaben abgeleitet werden. Anschließend wird untersucht, ob der daraus zusammengestellte Test das Merkmal zuverlässig und

valide erfasst. Für die Interpretation individueller Testergebnisse werden schließlich Vergleichswerte aus einer Normstichprobe bereitgestellt. Die Erstellung des Testentwurfs, seine Validierung und seine Normierung bilden damit zentrale Schritte der Testkonstruktion. Die testtheoretischen Verfahren, die diese Schritte unterstützen, werden in den folgenden Kapiteln genauer behandelt.

Konstruktdefinition und Testplanung

Zu Beginn der Testkonstruktion wird festgelegt, welches psychologische Merkmal mit dem Test erfasst werden soll. Eine möglichst präzise *Konstruktdefinition* beschreibt die inhaltliche Bedeutung des Merkmals und gegebenenfalls seine verschiedenen Teilbereiche oder Facetten. Sie bildet die Grundlage dafür, geeignete Items zu entwickeln und später zu beurteilen, ob diese das Merkmal in seiner Breite angemessen abbilden. Außerdem ist zu bestimmen, für welche Personengruppe und welchen Anwendungszweck der Test vorgesehen ist. Diese Festlegungen beeinflussen sowohl die Auswahl der Inhalte und Antwortformate als auch die Anforderungen an Durchführung, Auswertung und Interpretation.

Itemkonstruktion und Antwortformate

Aus der Konstruktdefinition werden Fragen oder Aufgaben abgeleitet und zunächst zu einer vorläufigen Sammlung von Items zusammengestellt. Dabei ist zu prüfen, welche Aspekte des Merkmals die einzelnen Items erfassen und ob wichtige Teilbereiche ausreichend vertreten sind. Die Beurteilung der Inhaltsvalidität stützt sich insbesondere auf die zugrunde liegende Theorie, die Konstruktdefinition und die Einschätzung fachkundiger Personen. Für die Items werden passende Antwortformate gewählt, etwa Auswahlaufgaben für einen Leistungstest oder Beurteilungsaufgaben für einen Persönlichkeitstest. Das Antwortformat bestimmt zugleich, welche Art von Daten entsteht und welche testtheoretischen Modelle für deren Analyse geeignet sind. Bereits beim Testentwurf werden außerdem einheitliche Instruktionen sowie Regeln für die Auswertung festgelegt, um die Objektivität des Tests zu unterstützen.

Erprobung und Auswahl der Items

Der Testentwurf wird an einer Stichprobe erprobt. Die dabei gewonnenen Antworten ermöglichen es, die Eigenschaften der einzelnen Items und ihr Zusammenwirken zu untersuchen. Testtheoretische Modelle helfen beispielsweise zu beurteilen, ob die Items durch ein gemeinsames latentes Merkmal erklärt werden können oder ob mehrere unterscheidbare Merkmale berücksichtigt werden müssen. Wenn ein Modell nicht besonders gut zu den Daten passt, kann dies auf ungeeignete Items, unzutreffende Modellannahmen oder Probleme der zugrunde liegenden Konstruktdefinition hinweisen. Entsprechend können Items umformuliert oder entfernt, zusätzliche Items entwickelt oder die angenommene Struktur des Tests überarbeitet werden.

Bei der Zusammenstellung der endgültigen Skala sind statistische Ergebnisse und inhaltliche Überlegungen gemeinsam zu berücksichtigen. So kann das Entfernen eines Items zwar die geschätzte Reliabilität erhöhen, zugleich aber die Inhaltsvalidität beeinträchtigen, wenn dadurch ein wesentlicher Teilbereich des Merkmals nicht mehr erfasst wird. In einem solchen Fall kommt auch eine Umformulierung des Items in Betracht. Ebenso lässt

sich die Reliabilität unter geeigneten Modellannahmen durch zusätzliche Items erhöhen, wobei die damit verbundene längere Bearbeitungszeit zu berücksichtigen ist. Die Testkonstruktion ist deshalb häufig ein wiederholter Prozess aus Entwicklung, Erprobung, Analyse und Überarbeitung.

Validierung und Dokumentation

Im Rahmen der Validierung wird untersucht, inwieweit die beabsichtigte Interpretation und Verwendung der Testergebnisse gerechtfertigt ist. Dazu werden die zuvor behandelten Gütekriterien herangezogen. Neben der Objektivität und Reliabilität sind insbesondere die inhaltliche Abdeckung des Konstrukts, die Struktur der Itemzusammenhänge und die Beziehungen zu anderen Merkmalen oder relevanten Außenkriterien zu untersuchen. Die Ergebnisse werden zusammen mit Angaben zur Testentwicklung, Durchführung, Auswertung und Interpretation in einem *Testmanual* dokumentiert. Dieses enthält auch die Normwerte, die eine Einordnung individueller Testergebnisse ermöglichen.

Normierung

Das primäre quantitative Ergebnis eines psychologischen Tests ist zunächst ein *Rohwert*. Auf der Ebene eines einzelnen Items kann dies beispielsweise der Zahlenwert sein, der einer gewählten Antwort zugeordnet wird. Beim Traurigkeitsitem des BDI-II sind die möglichen Rohwerte 0, 1, 2 und 3. Über mehrere Items hinweg ergibt sich häufig ein *Summenscore*, also die Summe der einzelnen Itemwerte. Der Summenscore des BDI-II kann beispielsweise Werte zwischen 0 und 63 annehmen. Alternativ kann ein *Mittelwertscore* gebildet werden, indem die Summe der Itemwerte durch die Anzahl der berücksichtigten Items geteilt wird.

Ein Rohwert lässt für sich genommen häufig noch nicht erkennen, ob eine Merkmalsausprägung im Vergleich zu anderen Personen niedrig, durchschnittlich oder hoch ist. Bei der *Normierung* wird deshalb ein Bezugssystem bereitgestellt, das die Einordnung eines individuellen Testergebnisses in die Verteilung der Ergebnisse einer Vergleichsgruppe ermöglicht. Dazu wird der Test einer hinreichend großen und für die vorgesehene Vergleichsgruppe möglichst repräsentativen *Normstichprobe* vorgelegt. Welche Vergleichsgruppe angemessen ist, hängt vom Anwendungszweck des Tests ab. So kann ein Ergebnis beispielsweise im Vergleich zur Allgemeinbevölkerung oder zu einer klinischen Gruppe interpretiert werden. Die Zusammensetzung der Normstichprobe und das Vorgehen bei der Normierung werden im Testmanual dokumentiert.

Eine verbreitete Möglichkeit der Normierung besteht darin, Rohwerte in *Z Scores* zu transformieren. Dazu wird von einem Rohwert x das Mittel m der Normstichprobe abgezogen und die Differenz durch deren Standardabweichung s geteilt:

$$z = \frac{x - m}{s} \tag{1.4}$$

Ein Z Score gibt somit an, um wie viele Standardabweichungen ein Rohwert vom Mittel der Normstichprobe abweicht. Ein Wert von $z = 0$ entspricht dem Mittelwert, ein Wert von $z = 1$ liegt eine Standardabweichung darüber und ein Wert von $z = -1$ eine Standardabweichung darunter. Die auf diese Weise standardisierten Werte der Normstichprobe

haben einen Mittelwert von 0 und eine Standardabweichung von 1. Wenn die Rohwerte näherungsweise normalverteilt sind, sind auch die Z Scores näherungsweise standardnormalverteilt.

Da Z Scores negativ sein können und ihre Darstellung häufig Nachkommastellen erfordert, werden sie oft in einen anderen Wertebereich überführt. Eine verbreitete, auf McCall (1922) zurückgehende Transformation liefert die sogenannten *T Scores*:

$$t = 10z + 50 \tag{1.5}$$

T Scores haben in der Normstichprobe einen Mittelwert von 50 und eine Standardabweichung von 10. Ein T Score von 50 entspricht somit einem Z Score von 0, ein T Score von 60 einem Z Score von 1 und ein T Score von 40 einem Z Score von −1. Die Bezeichnung T Score ist von der T-Statistik und der zugehörigen Verteilung aus der frequentistischen Inferenz zu unterscheiden. Die Umrechnung simulierter Rohwerte in Z Scores und T Scores ist in der zugehörigen Abbildung veranschaulicht (vgl. Abbildung 1.16).

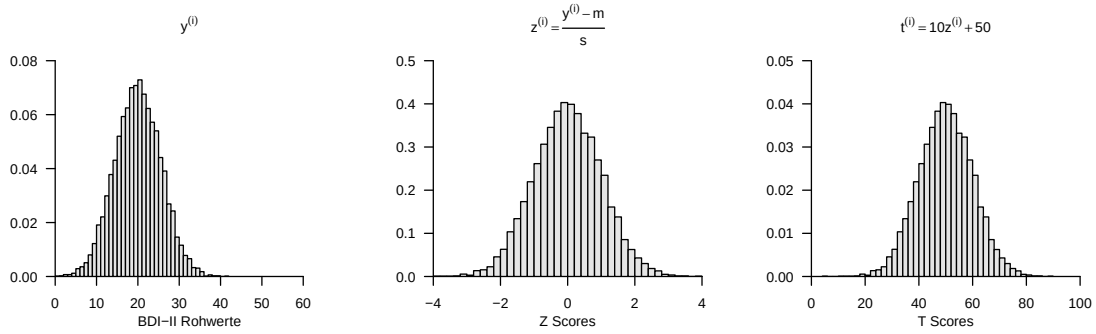


Abbildung 1.16 Simulierte BDI-II-Rohwerte sowie die daraus berechneten Z Scores und T Scores.

Unter der zusätzlichen Annahme einer Normalverteilung liegen ungefähr 68% der Werte innerhalb einer Standardabweichung um den Mittelwert, ungefähr 95% innerhalb von zwei und ungefähr 99,7% innerhalb von drei Standardabweichungen. Auf der T-Skala entsprechen diese Bereiche den Intervallen von 40 bis 60, von 30 bis 70 und von 20 bis 80. Diese Anteile gelten entsprechend nur näherungsweise für empirische Verteilungen, die sich durch eine Normalverteilung gut beschreiben lassen (vgl. Abbildung 1.17).

Das Vorgehen lässt sich an einem hypothetischen Beispiel verdeutlichen. Angenommen, ein Testrohwert beträgt 30 und die Normstichprobe weist einen Mittelwert von 20 sowie eine Standardabweichung von 5 auf. Dann ergibt sich:

$$z = \frac{30 - 20}{5} = 2 \tag{1.6}$$

$$t = 10 \cdot 2 + 50 = 70 \tag{1.7}$$

Der Rohwert liegt somit zwei Standardabweichungen über dem Mittelwert der Vergleichsgruppe. Ob eine solche Ausprägung als günstig oder ungünstig zu bewerten ist, hängt vom erfassten Merkmal und vom Anwendungszweck ab.

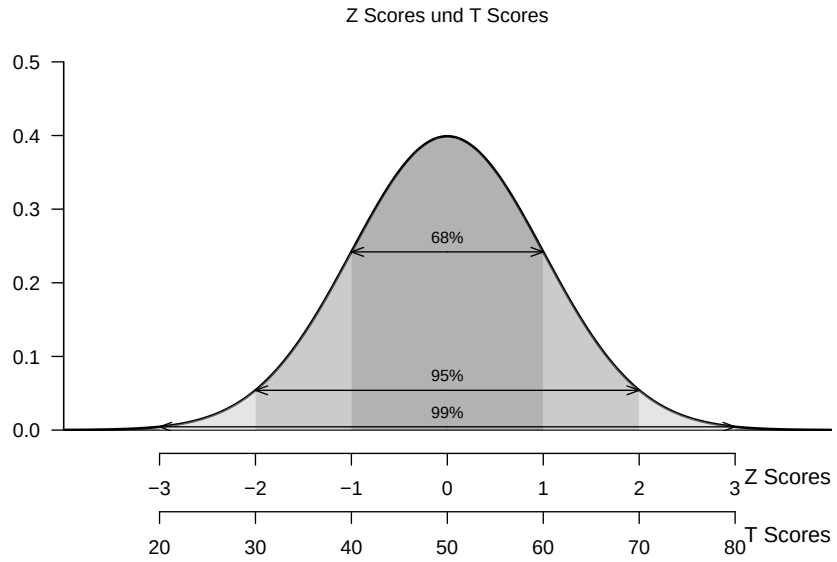


Abbildung 1.17 Z Scores und T Scores bei einer Normalverteilung. Die eingezeichneten Anteile sind näherungsweise angegeben.

Neben Z Scores und T Scores sind weitere Normskalen gebräuchlich. IQ-Werte werden üblicherweise auf einen Mittelwert von 100 und eine Standardabweichung von 15 bezogen. *Stanine-Werte* und *Sten-Werte* fassen standardisierte Ergebnisse in neun beziehungsweise zehn Kategorien zusammen. Die Wahl einer Normskala verändert bei einer linearen Transformation lediglich die numerische Darstellung der relativen Position. Gleiche Normwerte in verschiedenen Tests bedeuten daher eine vergleichbare relative Position in der jeweiligen Vergleichsgruppe, aber nicht notwendigerweise die gleiche psychologische Merkmalsausprägung.

Eine Normierung beseitigt schließlich nicht die Messunsicherheit eines Tests. Wird zu einem Testergebnis ein Konfidenzintervall angegeben, müssen bei einer linearen Umrechnung in Normwerte auch dessen Grenzen entsprechend transformiert werden. Die Verfahren zur Bestimmung dieser Unsicherheit setzen testtheoretische Modelle voraus und werden später behandelt.

1.7 Selbstkontrollfragen

1. Erläutern Sie den Begriff des psychologischen Tests nach Lienert (1968) und kommentiert von Rost (2004).
2. Nennen Sie die typischen Material- und Durchführungsbestandteile eines Tests.
3. Erläutern Sie die Begriffe Item, Itemstamm, Antwortformat.
4. Erläutern Sie den Begriff des psychometrischen Persönlichkeitstests.
5. Nennen Sie vier Formen psychometrischer Persönlichkeitstests.
6. Erläutern Sie den Begriff des Leistungstests.
7. Nennen Sie vier Formen von Leistungstests.
8. Erläutern Sie den Begriff des Persönlichkeitsentfaltungsverfahrens.
9. Nennen Sie drei Formen von Persönlichkeitsentfaltungsverfahren.

10. Erläutern Sie den Begriff des klinischen Tests.
11. Erläutern Sie den Begriff des Einstellungstests.
12. Erläutern Sie den Begriff des freien Antwortformats und nennen Sie zwei Beispiele.
13. Erläutern Sie Vor- und Nachteile freier Antwortformate.
14. Erläutern Sie den Begriff des gebundenen Antwortformats und nennen Sie drei Beispiele.
15. Erläutern Sie den Begriff der Ordnungsaufgabe und nennen Sie zwei Beispiele.
16. Erläutern Sie den Begriff der Auswahlaufgabe.
17. Erläutern Sie die Begriffe der Distraktoren, der Disjunktion und der Exhaustivität bei Auswahlaufgaben.
18. Erläutern Sie Vor- und Nachteile von Auswahlaufgaben.
19. Erläutern Sie den Begriff der Forced-Choice-Auswahlaufgabe.
20. Erläutern Sie den Begriff der Beurteilungsaufgabe.
21. Erläutern Sie die Begriffe des forcierten und unforcierten Ratings bei Beurteilungaufgaben.
22. Erläutern Sie den Begriff der Ausweichkategorie bei Beurteilungsaufgaben.
23. Erläutern Sie den Begriff der Antwortskalenpolarität bei Beurteilungsaufgaben.
24. Erläutern Sie den Begriff der Antwortskalenbalance bei Beurteilungsaufgaben.
25. Erläutern Sie den Begriff der Antwortskalenverankerung bei Beurteilungsaufgaben.
26. Erläutern Sie Vor- und Nachteile von Beurteilungsaufgaben.
27. Erläutern Sie den Begriff des Testgütekriteriums.
28. Nennen Sie die drei Hauptgütekriterien für psychologische Tests.
29. Nennen Sie sieben Nebengütekriterien für psychologische Tests.
30. Geben Sie die Definition der Objektivität nach Moosbrugger & Kelava (2012) wieder.
31. Erläutern Sie die Begriffe Durchführungsobjektivität, Auswertungsobjektivität, Interpretationsobjektivität
32. Geben Sie die Definition der Reliabilität nach Moosbrugger & Kelava (2012) wieder.
33. Erläutern Sie die Begriffe der Retest-, Paralleltest- und Split-Half-Reliabililtät
34. Erläutern Sie den Begriff der internen Konsistenz eines psychologischen Tests.
35. Geben Sie die Definition der Validität nach Moosbrugger & Kelava (2012) wieder.
36. Erläutern Sie die Begriffe der Augenschein-, Inhalts- und Kriteriumsvalidität.
37. Erläutern Sie den Begriff der Konstruktvalidität eines psychologischen Tests.
38. Nennen Sie die drei Hauptrichtungen der Testtheorie.
39. Erläutern Sie die Standarddatenstruktur der Testtheorie und Fragebogendatenanalyse.
40. Erläutern Sie das Standardproblem der Testtheorie und Fragebogendatenanalyse.
41. Erläutern Sie den Begriff der Klassischen Testtheorie.
42. Erläutern Sien den Begriff der Faktoranalyse.
43. Erläutern Sie den Begriff der Item-Response-Theorien.
44. Skizzieren Sie wesentliche Schritte in der Konstruktion eines Tests.
45. Erläutern Sie den Begriff der Testnormierung.
46. Erläutern Sie die Begriffe Raw Score, Z Score und T Score.

Referenzen

Beck, A. T. (1961). An Inventory for Measuring Depression. *Archives of General Psychiatry*, *4*(6), 561. https://doi.org/10.1001/archpsyc.1961.01710120031004

Beck, A. T., Steer, R. A., Ball, R., & Ranieri, W. F. (1996). Comparison of Beck Depression Inventories-IA and-II in Psychiatric Outpatients. *Journal of Personality Assessment*, *67*(3), 588–597. https://doi.org/10.1207/s15327752jpa6703_13

Bühner, M. (2010). *Einführung in die Test- und Fragebogenkonstruktion* (2., aktualisierte und erw. Aufl., [Nachdr.]). Pearson Studium.

Bühner, M. et al. (2026). *Psychologische Testtheorie: Vorlesungsfolien*. Lehrstuhl für Psychologische Methodenlehre und Diagnostik, Ludwig-Maximilians-Universität München; Open Educational Resources. https://www.oer.psy.lmu.de/Diag1.html

Campbell, D. T. (1963). Social Attitudes and Other Acquired Behavioral Dispositions. In *Psychology: A Study of a Science. Study II. Empirical Substructure and Relations with Other Sciences. Volume 6. Investigations of Man as Socius: Their Place in Psychology and the Social Sciences* (S. 94–172). McGraw-Hill. https://doi.org/10.1037/10590-003

Gulliksen, H. (1950). *Theory of Mental Tests*. John Wiley & Sons Inc. https://doi.org/10.1037/13240-000

Hautzinger, M., Keller, F., & Kühner, C. (2006). *BDI-II Beck Depressions-Inventar*. Pearson.

Hotelling, H. (1933). Analysis of Complex Variables into Principal Components. *Journal of Educational Psychology*, *24*, 417-441 and 498-520.

Kaiser, F. G. (1998). A General Measure of Ecological Behavior[1]. *Journal of Applied Social Psychology*, *28*(5), 395–422. https://doi.org/10.1111/j.1559-1816.1998.tb01712.x

Kaiser, F. G. (2020). *GEB-50. General Ecological Behavior Scale*. ZPID (Leibniz Institute for Psychology Information) – Open Test Archive. https://doi.org/10.23668/PSYCHARCHIVES.3453

Kaiser, F. G., Byrka, K., & Hartig, T. (2010). Reviving Campbell's Paradigm for Attitude Research. *Personality and Social Psychology Review*, *14*(4), 351–367. https://doi.org/10.1177/1088868310366452

Kaiser, F. G., & Wilson, M. (2004). Goal-Directed Conservation Behavior: The Specific Composition of a General Performance. *Personality and Individual Differences*, *36*(7), 1531–1544. https://doi.org/10.1016/j.paid.2003.06.003

Krauth, J. (1995). *Testkonstruktion und Testtheorie*. Beltz, Psychologie Verl.-Union.

Lawley, D. N. (1940). The Estimation of Factor Loadings by the Method of Maximum Likelihood. *Proceedings of the Royal Society of Edinburgh. Section B: Biological Sciences*.

Lienert, G. A. (1968). *Testaufbau und Testanalyse* (4. Aufl.). Psychologie Verlags Union.

Lienert, G. A., & Raatz, U. (1998). *Testaufbau und Testanalyse* (6. Auflage). Beltz, Psychologie Verlags Union.

Lord, F. M. (1980). *Applications of Item Response Theory To Practical Testing Problems* (0. Aufl.). Routledge. https://doi.org/10.4324/9780203056615

Lord, F. M., & Novick, M. R. (1968). *Statistical Theories of Mental Test Scores* (Nachdr. der Ausg. Reading, Mass. [u.a.], 1968). Information Age Publ.

McCall, W. A. (1922). *How to Measure in Education*. MacMillan Co. https://doi.org/10.1037/13551-000

Moosbrugger, H., & Kelava, A. (Hrsg.). (2012). *Testtheorie und Fragebogenkonstruktion: mit 66 Abbildungen und 41 Tabellen* (2., aktualisierte und überarbeitete Auflage). Springer.

Novick, M. R. (1966). The Axioms and Principal Results of Classical Test Theory. *Journal of Mathematical Psychology*, *3*(1), 1–18. https://doi.org/10.1016/0022-2496(66)90002-2

OECD. (2024). *PISA 2022 Technical Report*. OECD. https://doi.org/10.1787/01820d6d-en

Rasch, G. (1960). *Probabilistic Models for Some Intelligence and Attainment Tests* (Expanded ed). University of Chicago Press.

Reise, S. P., & Waller, N. G. (2009). Item Response Theory and Clinical Measurement. *Annual Review of Clinical Psychology*, *5*(1), 27–48. https://doi.org/10.1146/annurev.clinpsy.032408.153553

Rost, J. (2004). *Lehrbuch Testtheorie, Testkonstruktion* (2., vollständig überarbeitete und erweiterte Aufl). H. Huber.

Spearman, C. (1904). "General Intelligence," Objectively Determined and Measured. *The American Journal of Psychology*, *15*(2), 201. https://doi.org/10.2307/1412107

Warren, H. C. (1934). *Dictionary of Psychology*. Routledge.