

Grundlagen der Testtheorie
- 2027 -

Dirk Ostwald

Wintersemester 2026/2027

Inhaltsverzeichnis

Vorbemerkungen **3**
Zitation . . . 3
Lizenz . . . 3

1. Psychologische Tests **4**
1.1. Definitionsversuche . . . 4
1.2. Testarten . . . 6
1.3. Antwortformate . . . 9
1.4. Testgütekriterien . . . 17
1.5. Testtheorien . . . 21
1.6. Testkonstruktion . . . 25
1.7. Selbstkontrollfragen . . . 29

2. Modelle der klassischen Testtheorie **31**
2.1. Das Modell multipler Testmessungen . . . 33
2.2. Das Modell paralleler Testmessungen . . . 46
2.3. Modelle kongenerischer Testmessungen . . . 50
2.4. Selbstkontrollfragen . . . 54

Referenzen **56**

Anhang **59**

A. Wahrscheinlichkeitstheoretische Ergänzungen **59**
A.1. Erwartungswerte . . . 59
A.2. Varianzen und Kovarianzen . . . 62
A.3. Normalverteilungen . . . 69

Vorbemerkungen

Dieses Vorlesungsskript begleitet die Veranstaltung *Grundlagen der Testtheorie* am Institut für Psychologie der Otto-von-Guericke-Universität Magdeburg im Wintersemester 2026/2027. Die Kapitel dieses Skripts sind unverändert dem Lehrbuch *Probabilistische Datenwissenschaft für die Psychologie (PDWP)* entnommen.

Zitation

Ostwald, D. (2024) Probabilistische Datenwissenschaft für die Psychologie. 10.5281/zenodo.10730199

Lizenz

Dieses Werk ist lizenziert unter einer Creative Commons Namensnennung 4.0 International Lizenz (CC BY 4.0).

Verweise auf Abschnitte außerhalb dieses Skripts führen zu den entsprechenden Stellen im PDWP-Onlinelehrbuch.

1. Psychologische Tests

Tests und Fragebögen sind in der alltäglichen Erfahrung unterschiedlicher Natur. Mit dem Begriff *Test* verbindet man vermutlich am ehesten kleinere Prüfungen, bei denen es korrekte Antworten gibt und eine Leistungsfähigkeit überprüft wird. Mit dem Begriff des *Fragebogens* verbindet man vermutlich mehr oder weniger interessante Sammlungen von Fragen, bei denen man eventuell zu einem wahrheitsgemäßen Antwortverhalten aufgefordert wird, bei denen es aber auch klar ist, dass es keine richtigen oder falschen Antworten gibt. Obwohl mit Tests und Fragebögen in der alltäglichen Erfahrung also durchaus unterschiedliche Verfahren verbunden sind, unterscheidet die psychologische Testtheorie zwischen diesen nicht grundlegend. Historisch ist die Analyse von Testdaten sicherlich zunächst durch die Analyse von Leistungstestdaten geprägt, allerdings werden heutzutage die dort entwickelten Konzepte der Testtheorie auf die gleiche Art und Weise zur Analyse von klinischen Fragebogendaten genutzt. In diesem Abschnitt wollen wir zunächst einen kurzen Überblick zum Begriff des *Psychologischen Tests* geben.

1.1. Definitionsversuche

Der Begriff *Test* hat in unterschiedlichen Kontexten unterschiedliche Bedeutungen. Das englische Wort *test* bedeutet „Probe“, „Prüfung“ oder „Kontrolle“. Im psychologischen Kontext bezeichnet der Begriff *Test* üblicherweise ein Verfahren zur Untersuchung eines Persönlichkeitsmerkmals, den Vorgang der Durchführung einer solchen Untersuchung oder die Gesamtheit der dafür nötigen Materialien, wie man sie in einer Testothek ausleihen kann. Daneben wird der Begriff bekanntlich auch für statistische Verfahren, die sogenannten Hypothesentests, verwendet, die hier aber nicht gemeint sind. Letztlich wird der Begriff in vielen weiteren Zusammenhängen, z. B. für kurze, außerplanmäßige Zettelarbeiten im Schulunterricht oder technische Prüfverfahren in der Produktentwicklung, verwendet (Lienert & Raatz, 1998). Im Folgenden wollen wir einige gebräuchliche Definitionen eines psychologischen Tests in der Fachliteratur betrachten.

Eine frühe Definition findet sich bei Warren (1934). Für den psychologischen Kontext beschreibt er einen Test als:

> “a routine examination administered to individuals belonging to the same group, in order to determine the relative position of a given individual in the group with respect to one or more mental traits, motor abilities, etc. or in order to compare one group with another in these characteristics.”

Eine auf Lienert (1968) zurückgehende Definition eines Tests lautet:

> „Ein *Test* ist ein wissenschaftliches Routineverfahren zur Erfassung eines oder mehrerer empirisch abgrenzbarer Persönlichkeitsmerkmale mit dem Ziel einer möglichst genauen quantitativen Aussage über den Grad der individuellen Merkmalsausprägung.“

Rost (2004) interpretiert in dieser Definition den Begriff *wissenschaftlich* dadurch, dass eine Testtheorie den Schluss von manifesten auf latente Variablen begründet. Der Begriff *Routineverfahren* verweist nach Rost (2004) darauf, dass Durchführung und Auswertung an einer Normstichprobe erprobt und dokumentiert sind. Mit *Persönlichkeitsmerkmalen* sind stabile Merkmale der Testperson gemeint, die für das im Test gezeigte Verhalten verantwortlich sind. *Quantitativ* schließlich bezieht sich auf die Bestimmung des relativen Grades der Merkmalsausprägung. Darüber hinaus differenziert Rost (2004) zwischen *Tests im engeren Sinn* und *Tests im weiteren Sinn*. Tests im engeren Sinn sind Verfahren, deren Ergebnisse die Testperson nicht willentlich in eine gewünschte Richtung verfälschen kann. Tests im weiteren Sinn umfassen auch Fragebögen, standardisierte Interviews und standardisierte Beobachtungen.

Bühner (2010) beschreibt einen psychometrischen Test mit Blick auf seinen Zweck und seine theoretischen Grundlagen:

> „Ein *psychometrischer Test* ist ein wissenschaftliches Routineverfahren zur Untersuchung eines oder mehrerer empirisch abgrenzbarer Persönlichkeitsmerkmale (vgl. Lienert & Raatz, 1998, S. 1). Das Ziel eines psychometrischen Tests besteht darin, die absolute oder relative Ausprägung einer Eigenschaft, einer Fähigkeit oder eines Zustands bei einer oder mehreren Personen zu messen oder eine qualitative Aussage zu treffen, welcher Personenklasse Personen zugeordnet werden können (vgl. Rost, 2004). Psychometrische Tests sind nach der Klassischen oder probabilistischen Testtheorie entwickelt, sind theoretisch fundiert und genügen genau definierten Gütekriterien (Haupt- und Nebengütekriterien)."

Ähnlich wie Lienert stellt Bühner damit die wissenschaftliche Validierung eines Tests in den Vordergrund. Ein Test soll theoretisch fundiert sein und nachweislich definierten Gütekriterien genügen.

Krauth (1995) schließlich stellt in seiner Definition die Zuordnung beobachtbarer Reaktionen zu latenten Merkmalen in den Vordergrund:

> „Ein *psychologischer Test* besteht aus einer Menge von Reizen mit den zugehörigen zugelassenen Reaktionen, d. h. aus einer Menge von manifesten Variablen, und einer Vorschrift (Skala), die den Reaktionsmustern der manifesten Variablen Ausprägungen einer oder mehrerer latenter Variablen zuordnet. Anders ausgedrückt ist ein Test ein Messinstrument zur Messung von nicht direkt beobachtbaren (latenten) Variablen, deren Existenz man bei Personen (gelegentlich auch bei Tieren) postuliert."

Diese Definition ist insbesondere vor dem Hintergrund testtheoretischer Modelle hilfreich. Sie unterscheidet zwischen beobachtbaren Reaktionen als manifesten Variablen und den nicht direkt beobachtbaren Merkmalen als latenten Variablen, deren Zusammenhang durch solche Modelle beschrieben wird.

Testkomponenten

Die Bestandteile eines psychologischen Tests lassen sich in Material- und Durchführungsbestandteile gliedern. Zu den Materialbestandteilen gehören das Testmanual, das Testmaterial mit den einzelnen Items sowie die Auswertungshilfen. Die Durchführungsbestandteile umfassen die Testanweisung, die eigentliche Testdurchführung und die Testauswertung (Lienert & Raatz, 1998).

Zentraler Baustein eines Tests ist das sogenannte *Item*. Ein Item bezeichnet die kleinste Beobachtungseinheit eines psychologischen Tests und besteht aus einem *Itemstamm* und einem *Antwortformat*. Der Itemstamm ist der Reiz, auf den eine Reaktion erwartet wird, beispielsweise eine Frage, eine Aussage, ein Bild, eine Geschichte oder eine Rechenaufgabe. Das Antwortformat legt die Art und Weise fest, in der diese Reaktion registriert wird, etwa durch ein Kreuz auf einer Skala, einen Eintrag in eine leere Zeile oder eine Zeichnung auf Zeichenpapier. Häufig besteht ein Test aus mehreren Untertests, die ihrerseits mehrere Items umfassen. Prinzipiell können Untertests und Tests jedoch auch aus nur einem Item bestehen. In diesem Sinn kann jedes Item selbst als Test angesehen werden (Lord & Novick, 1968; Rost, 2004).

Die Konstruktion und die Durchführung eines psychologischen Tests können als ein speziell konstruiertes psychologisches Experiment verstanden werden. In dieser Betrachtungsweise entspricht der Test einer unabhängigen Variable, deren Stufen die einzelnen Items bilden. Als abhängige Variable werden die Itemantworten oder der daraus gebildete Summenscore betrachtet. Die experimentellen Einheiten sind die Testpersonen, bei denen durch die Bearbeitung mehrerer Items wiederholte Messungen vorgenommen werden. Psychologische Tests lassen sich damit als Testpersonen-×-Items-Designs konzeptualisieren (Rost, 2004).

1.2. Testarten

Psychometrische Persönlichkeitstests erfassen eine akute Symptomatik (*state*) oder eine stabile Eigenschaft (*trait*). Häufig handelt es sich um Selbstauskunftsfragebögen, bei denen es keine richtigen oder falschen Antworten gibt. Ihre Bearbeitung setzt Metakognition, also die Fähigkeit zur Reflexion über das eigene Denken und Erleben, sowie die Bereitschaft voraus, über sich selbst Auskunft zu geben. Die Absicht der Fragen ist in der Regel leicht durchschaubar, und die Antworten können entsprechend leicht verfälscht werden. Zu den psychometrischen Persönlichkeitstests zählt man üblicherweise:

- Klinische Tests
- Einstellungstests
- Persönlichkeitsstrukturtests
- Interessentests

Leistungstests erfassen eine Leistung anhand von Aufgaben, deren Bearbeitung als richtig oder falsch klassifiziert werden kann. Dabei unterscheidet man Schnelligkeitstests (*Speedtests*), bei denen die Bearbeitungsgeschwindigkeit im Vordergrund steht, und Niveautests (*Powertests*), bei denen das bewältigte Schwierigkeitsniveau entscheidend ist. Eine Verfälschung nach unten ist möglich, indem eine Testperson absichtlich eine geringere Leistung zeigt. Zu den Leistungstests zählt man üblicherweise:

- Entwicklungstests
- Intelligenztests
- Allgemeine Leistungstests
- Schultests
- Spezielle Funktionsprüfungs- und Eignungstests

Persönlichkeitsentfaltungsverfahren werden auch als projektive Verfahren bezeichnet. Sie beziehen sich auf die psychoanalytische Vorstellung der Projektion als Abwehrmechanismus. Nach dieser Vorstellung projiziert das Ich Triebregungen, die mit den Anforderungen des Über-Ichs in Konflikt stehen, nach außen. Die Verfahren sind üblicherweise unstrukturiert und qualitativ ausgerichtet. Zu den Persönlichkeitsentfaltungsverfahren zählt man üblicherweise:

- Formdeuteverfahren
- Verbal-thematische Verfahren
- Zeichnerische und Gestaltungsverfahren

Im Folgenden wollen wir uns etwas genauer mit *Klinischen Tests* und *Einstellungstests* beschäftigen und jeweils ein konkretes Beispiel betrachten.

Klinische Tests

Klinische Tests sind Fragebogenverfahren, die die Diagnose psychischer Störungen anhand der Klassifikationssysteme ICD und DSM unterstützen. Dabei unterscheidet man störungsübergreifende Verfahren, die verschiedene Bereiche psychischer Beschwerden erfassen, und störungsspezifische Verfahren, die sich auf eine bestimmte Störung beziehen.

Ein Beispiel für ein störungsspezifisches Verfahren ist das *Beck-Depressionsinventar II* (*BDI-II*), ein Selbstbeurteilungsinstrument zur Erfassung der Schwere depressiver Symptomatik. Es wurde von Beck et al. (1996) als Nachfolger des Beck-Depressionsinventars (Beck, 1961) entwickelt. Die deutschsprachige Fassung stammt von Hautzinger et al. (2006). Die Überarbeitung umfasste sprachliche Anpassungen und eine Angleichung an die damaligen Diagnosemanuale. Das BDI-II besteht aus 21 Items, deren Antworten mit Werten von 0 bis 3 bewertet und zu einem Gesamtwert summiert werden. Die Items betreffen beispielsweise Traurigkeit, Pessimismus, Verlust an Freude, Schuldgefühle, Energieverlust und Konzentrationsschwierigkeiten (vgl. Abbildung 1.1).

Das Item zur Traurigkeit veranschaulicht die abgestuften Antwortmöglichkeiten:

- (0) Ich bin nicht traurig
- (1) Ich bin oft traurig
- (2) Ich bin ständig traurig
- (3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte

Zur Einordnung des Gesamtwerts werden folgende Grenzwerte angegeben, wobei diese Einteilung lediglich die Ausprägung der mit dem Fragebogen erfassten Symptomatik beschreibt und der BDI-II-Gesamtwert allein keine klinische Diagnose begründet.

Gesamtwert	Einordnung
0–13	Keine Depression bzw. klinisch unauffällig oder remittiert
14–19	Leichtes depressives Syndrom
20–28	Mittelgradiges depressives Syndrom
Ab 29	Schweres depressives Syndrom

BDI-II

1. Traurigkeit
- ○ (0) Ich bin nicht traurig
- ○ (1) Ich bin oft traurig
- ○ (2) Ich bin ständig traurig
- ○ (3) Ich bin so traurig oder unglücklich, dass ich es nicht aushalte

2. Pessimismus
- ○ (0) Ich sehe nicht mutlos in die Zukunft
- ○ (1) Ich sehe mutloser in die Zukunft als sonst
- ○ (2) Ich bin mutlos und erwarte nicht, dass meine Situation besser wird
- ○ (3) Ich glaube, dass meine Zukunft hoffnungslos ist und nur noch schlechter wird

3. Versagensgefühle
- ○ (0) Ich fühle mich nicht als Versager:in
- ○ (1) Ich habe häufiger Versagensgefühle als sonst
- ○ (2) Wenn ich zurückblicke, sehe ich viele Fehlschläge
- ○ (3) Ich habe das Gefühl, als Mensch ein:e völlige:r Versager:in zu sein

4. Verlust von Freude
- ○ (0) Ich kann die Dinge genauso gut genießen wie früher
- ○ (1) Ich kann die Dinge nicht mehr so genießen wie früher
- ○ (2) Dinge, die mir früher Freude gemacht haben, kann ich kaum mehr genießen
- ○ (3) Dinge, die mir früher Freude gemacht haben, kann ich überhaupt nicht mehr genießen

5. Schuldgefühle
- ○ (0) Ich habe keine besonderen Schuldgefühle
- ○ (1) Ich habe oft Schuldgefühle wegen Dingen, die ich getan habe oder hätte tun sollen
- ○ (2) Ich habe die meiste Zeit Schuldgefühle
- ○ (3) Ich habe ständig Schuldgefühle

6. Bestrafungsgefühle
- ○ (0) Ich habe nicht das Gefühl, für etwas bestraft zu sein
- ○ (1) Ich habe das Gefühl, vielleicht bestraft zu werden
- ○ (2) Ich erwarte, bestraft zu werden
- ○ (3) Ich habe das Gefühl, bestraft zu sein

7. Selbstablehnung
- ○ (0) Ich halte von mir genauso viel wie immer
- ○ (1) Ich habe Vertrauen in mich verloren
- ○ (2) Ich bin von mir enttäuscht
- ○ (3) Ich lehne mich völlig ab

8. Selbstvorwürfe
- ○ (0) Ich kritisiere oder tadle mich nicht mehr als sonst
- ○ (1) Ich bin mir gegenüber kritischer als sonst
- ○ (2) Ich kritisiere mich für all meine Mängel
- ○ (3) Ich gebe mir die Schuld für alles Schlimme, was passiert

9. Selbstmordgedanken
- ○ (0) Ich denke nicht daran, mir etwas anzutun
- ○ (1) Ich denke manchmal an Selbstmord, aber ich würde es nicht tun
- ○ (2) Ich möchte mich am liebsten umbringen
- ○ (3) Ich würde mich umbringen, wenn ich die Gelegenheit dazu hätte

10. Weinen
- ○ (0) Ich weine nicht öfter als früher
- ○ (1) Ich weine jetzt mehr als früher
- ○ (2) Ich weine beim geringsten Anlass
- ○ (3) Ich möchte gern weinen, aber ich kann nicht

11. Unruhe
- ○ (0) Ich bin nicht unruhiger als sonst
- ○ (1) Ich bin unruhiger als sonst
- ○ (2) Ich bin so unruhig, dass es mir schwer fällt, stillzusitzen
- ○ (3) Ich bin so unruhig, dass ich mich ständig bewegen oder etwas tun muss

12. Interessenverlust
- ○ (0) Ich habe das Interesse an anderen Menschen oder an Tätigkeiten nicht verloren
- ○ (1) Ich habe weniger Interesse an anderen Menschen oder an Dingen als sonst
- ○ (2) Ich habe das Interesse an anderen Menschen oder an Dingen zum größten Teil verloren
- ○ (3) Es fällt mir schwer, mich überhaupt für irgendetwas zu interessieren

13. Entschlussunfähigkeit
- ○ (0) Ich bin so entschlussfreudig wie immer
- ○ (1) Es fällt mir schwerer als sonst, Entscheidungen zu treffen
- ○ (2) Es fällt mir sehr viel schwerer als sonst, Entscheidungen zu treffen
- ○ (3) Ich habe Mühe, überhaupt Entscheidungen zu treffen

14. Wertlosigkeit
- ○ (0) Ich fühle mich nicht wertlos
- ○ (1) Ich halte mich für weniger wertvoll und nützlich als sonst
- ○ (2) Verglichen mit anderen Menschen fühle ich mich viel weniger wert
- ○ (3) Ich fühle mich völlig wertlos

15. Energieverlust
- ○ (0) Ich habe so viel Energie wie immer
- ○ (1) Ich habe weniger Energie als sonst
- ○ (2) Ich habe so wenig Energie, dass ich kaum noch etwas schaffe
- ○ (3) Ich habe keine Energie mehr, um überhaupt noch etwas zu tun

16. Reizbarkeit
- ○ (0) Ich bin nicht reizbarer als sonst
- ○ (1) Ich bin reizbarer als sonst
- ○ (2) Ich bin viel reizbarer als sonst
- ○ (3) Ich fühle mich dauernd gereizt

17. Veränderungen des Appetits
- ○ (0) Mein Appetit hat sich nicht verändert
- ○ (1) Mein Appetit ist etwas schlechter als sonst
- ○ (1) Mein Appetit ist etwas größer als sonst
- ○ (2) Mein Appetit ist viel schlechter als sonst
- ○ (2) Mein Appetit ist viel größer als sonst
- ○ (3) Ich habe überhaupt keinen Appetit
- ○ (3) Ich habe ständig Heißhunger

18. Konzentrationsschwierigkeiten
- ○ (0) Ich kann mich so gut konzentrieren wie immer
- ○ (1) Ich kann mich nicht mehr so gut konzentrieren wie sonst
- ○ (2) Es fällt mir schwer, mich längere Zeit auf irgendetwas zu konzentrieren
- ○ (3) Ich kann mich überhaupt nicht mehr konzentrieren

19. Ermüdung oder Erschöpfung
- ○ (0) Ich fühle mich nicht müder oder erschöpfter als sonst
- ○ (1) Ich werde schneller müde oder erschöpft als sonst
- ○ (2) Für viele Dinge, die ich üblicherweise tue, bin ich zu müde oder erschöpft
- ○ (3) Ich bin so müde oder erschöpft, dass ich fast nichts mehr tun kann

20. Verlust an sexuellem Interesse
- ○ (0) Mein Interesse an Sexualität hat sich in letzter Zeit nicht verändert
- ○ (1) Ich interessiere mich weniger für Sexualität als früher
- ○ (2) Ich interessiere mich jetzt viel weniger für Sexualität
- ○ (3) Ich habe das Interesse an Sexualität völlig verloren

21. Veränderungen der Schlafgewohnheiten
- ○ (0) Meine Schlafgewohnheiten haben sich nicht verändert
- ○ (1) Ich schlafe etwas mehr als sonst
- ○ (1) Ich schlafe etwas weniger als sonst
- ○ (2) Ich schlafe viel mehr als sonst
- ○ (2) Ich schlafe viel weniger als sonst
- ○ (3) Ich schlafe fast den ganzen Tag
- ○ (3) Ich wache 1-2 Stunden früher auf als gewöhnlich und kann nicht mehr einschlafen

Abbildung 1.1. BDI-II nach Hautzinger et al. (2006). Testpersonen werden dabei gebeten, für jede Gruppe die Aussage auszuwählen, die ihr Befinden in den vergangenen zwei Wochen einschließlich heute am besten beschreibt. Treffen mehrere Aussagen gleichermaßen zu, wird die Aussage mit dem höheren Zahlenwert gewählt. Auch bei Schlafgewohnheiten und Appetit ist jeweils nur eine Antwort auszuwählen.

Einstellungstests

Eine *psychologische Einstellung* ist eine relativ stabile, aber veränderbare innere Haltung gegenüber Objekten, Personen, Gruppen, Ideen oder Situationen. Sie umfasst kognitive, affektive und konative, also auf die Handlungsbereitschaft bezogene, Komponenten. *Einstellungstests* sind psychologische Messinstrumente zur systematischen Erfassung solcher Einstellungen. Sie werden meist als Fragebögen oder Skalen umgesetzt, in denen Testpersonen Aussagen in unterschiedlichem Maß bewerten. Zu ihren Anwendungsbereichen gehören die Erhebung von Wertorientierungen, Vorurteilen und politischen oder religiösen Überzeugungen, die Messung arbeits- und organisationsbezogener Einstellungen sowie die Forschung zu sozialen Einstellungen, etwa gegenüber Minderheiten, Umweltschutz oder Gesundheit.

Ein Beispiel ist die *General Ecological Behavior Scale*, hier in der Fassung mit 50 Items (*GEB-50*). Sie wurde ursprünglich als Instrument zur Erfassung umweltschützenden Verhaltens entwickelt (Kaiser, 1998) und später als Instrument zur Messung individueller Umwelteinstellungen interpretiert (Kaiser et al., 2010). Ihre theoretische Grundlage bildet das *Campbell-Paradigma* (Campbell, 1963). Dessen Grundidee ist, dass sich die Stärke einer Einstellung anhand der dafür in Kauf genommenen *Verhaltenskosten* erfassen lässt. Der Einstellung entspricht dabei ein Ziel, beispielsweise der Schutz der Umwelt. Die Verhaltenskosten ergeben sich aus den Mitteln, die eine Person zur Erreichung dieses Ziels einsetzt.

Unterschiedliche Verhaltensweisen sind mit unterschiedlichen Kosten verbunden. So kann Recycling mit vergleichsweise geringen Kosten verbunden sein, während die Mitgliedschaft in einer Umweltschutzorganisation höhere Kosten verursacht. Zu den Verhaltenskosten gehören Aufwand, Zeit und Geld. Auch soziale Normen und kulturelle Praktiken können beeinflussen, wie aufwendig eine Verhaltensweise ist. Nach dem Campbell-Paradigma spricht es für eine stärker ausgeprägte Umwelteinstellung, wenn eine Person mehr umweltschützende Verhaltensweisen ausführt und dabei auch höhere Kosten in Kauf nimmt.

Die GEB-50 umfasst 50 Selbstberichte zu Verhaltensweisen, mit denen Menschen die Umwelt schützen. Bei 32 Items wird nach der Häufigkeit des jeweiligen Verhaltens gefragt. Die Antwortmöglichkeiten lauten „nie“, „selten“, „gelegentlich“, „oft“ und „sehr oft“. Weitere 18 Items werden mit „ja“ oder „nein“ beantwortet. Bei allen Items ist außerdem „keine Angabe“ möglich. Beispiele für Items mit Häufigkeitsangaben sind „Ich kaufe Lebensmittel aus kontrolliert biologischem Anbau.“ und „Altglas bringe ich zum Sammelcontainer.“ Ein Beispiel für ein Item mit Ja/Nein-Antwortformat ist „Ich bin Mitglied in einer Umweltschutzorganisation.“ Die Antworten beziehen sich somit auf konkrete Verhaltensweisen, die im Rahmen des Campbell-Paradigmas als Hinweise auf die zugrunde liegende Umwelteinstellung interpretiert werden (vgl. Abbildung 1.2).

1.3. Antwortformate

Das *Antwortformat* eines psychologischen Tests bestimmt die Art und Weise, wie Testpersonen auf die gestellten Aufgaben reagieren sollen. Die Wahl des Antwortformats hängt von der Testart und der jeweiligen Testaufgabe ab. Grundsätzlich unterscheidet man *freie oder offene Antwortformate* und *gebundene oder geschlossene Antwortformate*. Zu den offenen Antwortformaten gehören Kurzaufsatzaufgaben und Ergänzungsaufgaben. Gebundene Antwortformate umfassen Ordnungsaufgaben, Auswahlaufgaben und Beurteilungsaufgaben. Bei der folgenden Darstellung orientieren wir uns eng an Pospeschill (2022, Kapitel 2).

GEB-50: Fragebogen zum Umweltverhalten

1 = Nie · 2 = Selten · 3 = Gelegentlich · 4 = Oft · 5 = Sehr oft · KA = Keine Angabe

Häufigkeit

		1	2	3	4	5	KA
1	Für den Arbeits- bzw. Schulweg benutze ich das Fahrrad, öffentliche Verkehrsmittel oder gehe zu Fuß.	☐	☐	☐	☐	☐	☐
2	Ich kaufe Lebensmittel aus kontrolliert biologischem Anbau.	☐	☐	☐	☐	☐	☐
3	Ich kaufe Getränke in Dosen.	☐	☐	☐	☐	☐	☐
4	Zum Reinigen des Backofens verwende ich ein Spray.	☐	☐	☐	☐	☐	☐
5	Ich warte, bis ich eine volle Wäschetrommel habe, bevor ich wasche.	☐	☐	☐	☐	☐	☐
6	Ich fahre mit dem Auto in die Stadt bzw. ich fahre in der Stadt Auto.	☐	☐	☐	☐	☐	☐
7	Auch im Winter lüfte ich, indem ich bei laufender Heizung das Fenster ankippe.	☐	☐	☐	☐	☐	☐
8	Beim Waschen verzichte ich auf den Vorwaschgang.	☐	☐	☐	☐	☐	☐
9	Ich fahre auf der Autobahn höchstens 100 km/h.	☐	☐	☐	☐	☐	☐
10	Wenn ich in einem Geschäft eine Plastiktüte bekomme, nehme ich sie.	☐	☐	☐	☐	☐	☐
11	Für Fahrten in die umliegende Gegend (bis 30 km) benutze ich öffentliche Nahverkehrsmittel oder das Fahrrad.	☐	☐	☐	☐	☐	☐
12	Ich sammle altes Papier und gebe es zum Recycling.	☐	☐	☐	☐	☐	☐
13	Altglas bringe ich zum Sammelcontainer.	☐	☐	☐	☐	☐	☐
14	Ich mache jemanden, der/die sich umweltschädigend verhält, darauf aufmerksam.	☐	☐	☐	☐	☐	☐
15	Ich spende Geld für Umweltschutzorganisationen.	☐	☐	☐	☐	☐	☐
16	Ich kaufe Mehrweg- statt Einwegflaschen.	☐	☐	☐	☐	☐	☐
17	Ich kaufe gebleichtes oder gefärbtes Toilettenpapier.	☐	☐	☐	☐	☐	☐
18	Ich kaufe Fertiggerichte.	☐	☐	☐	☐	☐	☐
19	Ich kaufe Artikel in Nachfüllpackungen.	☐	☐	☐	☐	☐	☐
20	Ich kaufe Möbel aus einheimischen Hölzern.	☐	☐	☐	☐	☐	☐
21	Ich boykottiere Produkte von Firmen, die sich nachweislich umweltschädigend verhalten.	☐	☐	☐	☐	☐	☐
22	Ich kaufe Obst und Gemüse der Jahreszeit entsprechend.	☐	☐	☐	☐	☐	☐
23	Ich benutze einen Wäschetrockner.	☐	☐	☐	☐	☐	☐
24	Ich besorge mir Bücher, Informationsschriften oder andere Materialien, die sich mit Umweltproblemen befassen.	☐	☐	☐	☐	☐	☐
25	Ich unterhalte mich mit Bekannten über Konsequenzen von Umweltverschmutzung, Klimawandel und Energieverbrauch.	☐	☐	☐	☐	☐	☐

Häufigkeit (Fortsetzung)

		1	2	3	4	5	KA
26	Für längere Reisen (6 Stunden Autofahrt und länger) nehme ich das Flugzeug.	☐	☐	☐	☐	☐	☐
27	Vor geschlossenen Bahnschranken lasse ich den Motor laufen.	☐	☐	☐	☐	☐	☐
28	Vor roten Ampeln lasse ich den Motor laufen.	☐	☐	☐	☐	☐	☐
29	Insekten bekämpfe ich mit chemischen Mitteln.	☐	☐	☐	☐	☐	☐
30	Im Winter drehe ich meine Heizung herunter, wenn ich meine Wohnung für mehr als 4 Stunden verlasse.	☐	☐	☐	☐	☐	☐
31	Zum Spazierengehen fahre ich mit dem Auto an den Ausgangspunkt des Spazierganges.	☐	☐	☐	☐	☐	☐
32	Ich dusche (statt zu baden).	☐	☐	☐	☐	☐	☐

Zutreffen

		Ja	Nein	KA
1	Ich verwende Einkaufstüten oder -taschen mehrfach.	☐	☐	☐
2	In meiner Wohnung ist es im Winter so warm, dass man ohne Pullover nicht friert.	☐	☐	☐
3	Ich benutze beim Waschen einen Weichspüler.	☐	☐	☐
4	Leere Batterien werfe ich in den Hausmüll.	☐	☐	☐
5	Breiige Essensreste leere ich in die Toilette.	☐	☐	☐
6	In der Toilette benutze ich chemische Duftsteine für den guten Geruch.	☐	☐	☐
7	Ich bin Mitglied in einer Umweltschutzorganisation.	☐	☐	☐
8	Im Hotel lasse ich täglich die Handtücher wechseln.	☐	☐	☐
9	Ich besitze eine Geschirrspülmaschine der Effizienzklasse A+ oder besser.	☐	☐	☐
10	Ich verlasse nach einem Picknick den Platz genauso, wie ich ihn angetroffen habe.	☐	☐	☐
11	Ich habe eine Solaranlage zur Energie- bzw. Wärmeerzeugung angeschafft.	☐	☐	☐
12	Ich habe mich über Vor- und Nachteile einer Solaranlage informiert.	☐	☐	☐
13	Ich beziehe Strom aus erneuerbarer Energie.	☐	☐	☐
14	Ich verzichte auf ein Auto.	☐	☐	☐
15	Ich bin in einem „Car-Sharing“-Pool.	☐	☐	☐
16	Durch mein Fahrverhalten versuche ich, den Kraftstoffverbrauch so niedrig wie möglich zu halten.	☐	☐	☐
17	Ich besitze ein verbrauchsreduziertes Auto (weniger als 6 Liter Treibstoff pro 100 km).	☐	☐	☐
18	Ich ernähre mich vegetarisch.	☐	☐	☐

Kaiser (2020), CC BY-SA 4.0.

Abbildung 1.2. GEB-50 nach Kaiser (2020). Testpersonen werden dabei gebeten, bei 32 Handlungen anzugeben, wie häufig sie diese ausführen, und bei weiteren 18 Handlungen mit Ja oder Nein anzugeben, was eher auf sie zutrifft. „Keine Angabe“ (KA) ist zu wählen, wenn eine Handlung auf die momentane Lebenssituation nicht zutrifft, etwa bei Fragen zum Fahrverhalten ohne Führerschein. CC BY-SA 4.0.

Offene Antwortformate

Bei *offenen Antwortformaten* formuliert die Testperson ihre Antwort auf Grundlage einer strukturellen Vorgabe eigenständig. Solche Formate werden beispielsweise bei projektiven Verfahren und zur Abfrage komplexer Wissensinhalte eingesetzt. Man unterscheidet dabei *Kurzaufsatzaufgaben* und *Ergänzungsaufgaben*. Bei Kurzaufsatzaufgaben besteht die Antwort aus einer kurzen schriftlichen Abhandlung, deren Umfang von einem Wort bis zu mehreren Sätzen reichen kann (vgl. Abbildung 1.3). Eine Begrenzung der Wortzahl kann dabei sinnvoll sein. Ergänzungsaufgaben können als offene Fragen gestaltet sein, bei denen ein Schlüsselwort am Satzende ergänzt werden soll, oder als Lückentexte, bei denen Schlüsselwörter im laufenden Text einzusetzen sind (vgl. Abbildung 1.4).

Ein Vorteil offener Antwortformate besteht bei Leistungstests darin, dass die Testperson eine eigenständige Leistung erbringen muss und keine vorgegebenen Antwortalternativen durch bloßes Ankreuzen zufällig treffen kann. Offene Antwortformate ermöglichen die Erfassung von Sprachverständnis, Motivation, Interesse und Kreativität sowie die Prüfung von Reproduktions- und Transferleistungen. Dem stehen ein hoher Bearbeitungsaufwand und eine hohe kognitive Belastung für die Testpersonen gegenüber. Für die Testenden entstehen ein hoher Auswertungsaufwand und Schwierigkeiten, eine objektive Auswertung sicherzustellen.

Beispiel: Wissen über psychologische Tests

Erläutern Sie an einem Beispiel, wodurch eine Testanweisung missverständlich werden kann. Beschränken Sie Ihre Antwort auf zwei bis drei Sätze.

Antwort: .....

.....

.....

Auswertung: Die Antwort nennt eine missverständliche Testanweisung und erläutert anhand zweier möglicher Interpretationen, wie diese zu unterschiedlichen Antworten führen kann.

Abbildung 1.3. Kurzaufsatzaufgabe.

Offene Fragen mit Schlüsselwort

(Einfachantwort) Wie bezeichnet man die kleinste Einheit eines psychologischen Tests? .....

(Reihenantwort) Wie heißen die drei klassischen Testgütekriterien? .....

(Analogieantwort) Länge verhält sich zu Meter wie Masse zu .....

(Folgenantwort) Welche Zahl setzt die Zahlenfolge fort? $2, 4, 8, 16,$ .....

Lückentext

Ergänzen Sie die fehlenden Fachbegriffe.

Die kleinste Einheit eines psychologischen Tests heißt _____. Bei _____ Antwortformaten formuliert die Testperson ihre Antwort selbst. Bei _____ Antwortformaten stehen Antwortmöglichkeiten zur Verfügung.

Abbildung 1.4. Ergänzungsaufgaben mit offenen Fragen und Lückentext.

Ordnungsaufgaben

Bei *Ordnungsaufgaben* unterscheidet man *Umordnungsaufgaben* und *Zuordnungsaufgaben*. In Umordnungsaufgaben werden vorgegebene Elemente in eine sinnvolle Reihenfolge gebracht (vgl. Abbildung 1.5). Damit lassen sich schlussfolgerndes Denken oder das Verständnis von Ursache-Wirkungs-Zusammenhängen prüfen. Nichtverbale Aufgaben vermeiden dabei eine Beeinträchtigung durch die Lesefähigkeit der Testperson. Die Entwicklung bildlicher Aufgaben ist allerdings mit einem hohen Materialentwicklungsaufwand verbunden.

Beispiel: Ablauf einer psychologischen Untersuchung

Bringen Sie die folgenden Schritte in eine sinnvolle zeitliche Reihenfolge. Tragen Sie dazu die Buchstaben in die Antwortzeile ein.

A. Die erhobenen Daten statistisch auswerten

B. Eine überprüfbare Hypothese formulieren

C. Die Ergebnisse im Hinblick auf die Hypothese interpretieren

D. Die Untersuchung planen und die Messinstrumente auswählen

E. Die Untersuchung durchführen und Daten erheben

Reihenfolge: _____ → _____ → _____ → _____ → _____

Abbildung 1.5. Umordnungsaufgabe.

Bei Zuordnungsaufgaben werden vorgegebene Elemente einander zugeordnet (vgl. Abbildung 1.6). Sie dienen der Wissensprüfung durch Wiedererkennung und sind vergleichsweise einfach zu konstruieren, ökonomisch und objektiv auszuwerten. Eine eigenständige Reproduktion des Wissens ist nicht erforderlich, da die Wiedererkennung ausreicht. Zufallstreffer sind möglich, insbesondere wenn keine zusätzlichen Antwortalternativen vorhanden sind, die keinem der vorgegebenen Elemente zugeordnet werden können.

Beispiel: Psychologische Erhebungsverfahren

Ordnen Sie jedem Beispiel das passende Verfahren zu. Tragen Sie den zugehörigen Buchstaben ein. Jedes Verfahren wird genau einmal verwendet.

A. Fremdbeurteilung B. Leistungstest C. Selbstbeurteilung

Beispiel	Antwort
Eine Person berichtet in einem Fragebogen über ihre eigene Stimmung.	_____
Eine Person markiert unter Zeitdruck vorgegebene Zielbilder. Die Anzahl korrekt markierter Bilder wird ausgewertet.	_____
Eine Lehrperson beurteilt die Konzentrationsfähigkeit eines Kindes.	_____

Abbildung 1.6. Zuordnungsaufgabe.

Auswahlaufgaben

Bei *Auswahlaufgaben* wählt die Testperson zutreffende Antworten aus mehreren vorgegebenen Alternativen aus. Dichotome Aufgaben bieten zwei Antwortmöglichkeiten, während *Multiple-Choice-Aufgaben* mehrere Antwortmöglichkeiten vorgeben (vgl. Abbildung 1.7). Bei Leistungstests dienen *Distraktoren*, also Ablenkungsantworten, dazu, die Schwierigkeit einer Aufgabe zu gestalten. Wichtig ist dabei die *Disjunktion*, also die eindeutige Trennung zwischen richtigen und falschen Aussagen (vgl. Abbildung 1.8). Bei Persönlichkeitstests spielt die *Exhaustivität*, also die Vollständigkeit der Antwortalternativen, eine wichtige Rolle (vgl. Abbildung 1.8). Fehlt eine passende Antwortmöglichkeit, muss sich die Testperson dennoch für eine der vorgegebenen Alternativen entscheiden. In diesem Sinn führt fehlende Exhaustivität zu *Forced-Choice-Antworten* (vgl. Abbildung 1.9).

Auswahlaufgaben sind einfach zu handhaben, ökonomisch und objektiv auszuwerten. Als Nachteile gelten die hohe Ratewahrscheinlichkeit und die Beschränkung auf Wiedererkennungsleistungen, wenn lediglich bereits bekanntes Wissen ausgewählt werden muss. Eine solche Rekognitionsleistung erfordert keine eigenständige Problemlöse- oder Kreativitätsleistung. Zudem kann die Entwicklung geeigneter Distraktoren aufwendig und komplex sein.

Beispiel: Einfachwahlaufgabe

Welche Aussage beschreibt einen standardisierten Test am besten?

Kreuzen Sie genau **eine** Antwort an.

☐ Jede Person erhält eine frei gewählte Instruktion.

☐ Durchführung und Auswertung folgen festgelegten Regeln.

☐ Jede Antwort wird ausschließlich intuitiv beurteilt.

Beispiel: Mehrfachwahlaufgabe

Welche der folgenden Aufgaben haben ein offenes Antwortformat?

Kreuzen Sie **alle** zutreffenden Antworten an.

☐ Einen Begriff in eigenen Worten erklären

☐ Eine Aussage als richtig oder falsch markieren

☐ Ein fehlendes Wort in einem Lückentext ergänzen

☐ Eine Aussage auf einer Ratingskala beurteilen

Abbildung 1.7. Einfachwahl- und Mehrfachwahlaufgaben.

Beurteilungsaufgaben

Eine *Beurteilung* wird auch als *Rating* bezeichnet. *Beurteilungsaufgaben* werden vorzugsweise in klinischen Fragebögen und Persönlichkeitstests eingesetzt. Die Testperson schätzt dabei eine Aussage mithilfe einer diskreten Ratingskala oder einer kontinuierlichen Analogskala ein. Aus den gegebenenfalls gewichteten Punktwerten der einzelnen Antworten wird meist ein Gesamtpunktwert, ein sogenannter *Score*, berechnet. Bei der Gestaltung solcher Aufgaben sind verschiedene Aspekte zu berücksichtigen.

Beispiel: Nicht disjunkte Antwortalternativen

Wo haben Sie gestern zuletzt gelernt? Wählen Sie eine Antwort.

☐ Zu Hause ☐ In einer Bibliothek ☐ An der Universität

Beispiel: Nicht exhaustive Antwortalternativen

Wo haben Sie gestern zuletzt gelernt? Wählen Sie eine Antwort.

☐ Zu Hause ☐ In einer Bibliothek

Abbildung 1.8. Auswahlaufgaben mit nicht disjunkten und nicht exhaustiven Antwortalternativen. Eine Universitätsbibliothek passt zu zwei Kategorien. Die Antwortalternativen überschneiden sich und sind daher nicht disjunkt. Andere Lernorte und der Fall, dass die Person gestern nicht gelernt hat, fehlen. Die Antwortalternativen sind daher nicht exhaustiv.

Beispiel: Relative Präferenz

Welche Aussage beschreibt Sie eher? Bitte wählen Sie **eine** der beiden Aussagen.

☐ Beim Lernen suche ich gern den Austausch mit anderen.

☐ Beim Lernen arbeite ich gern für mich allein.

Abbildung 1.9. Forced-Choice-Aufgabe. Die Testperson muss sich zwischen den vorgegebenen Aussagen entscheiden. Die Antwort beschreibt nur eine relative Präferenz innerhalb des Aussagenpaares.

Die *Anzahl der Skalenstufen* hängt davon ab, wie fein Testpersonen ihr Urteil differenzieren können, und bestimmt zugleich, wie differenziert sie es ausdrücken können. Als Orientierung nennt Pospeschill (2022) für eine einzelne Ratingskala bei einem Test mit nur einem Item meist 9 ± 1 Skalenstufen und für Itembatterien, also Tests mit vielen Items, meist 5 ± 2 Skalenstufen. Bei kontinuierlichen grafischen Analogskalen entfällt die Festlegung einer Anzahl diskreter Skalenstufen.

Die *Forciertheit des Ratings* ergibt sich daraus, ob die Antwortskala einen Mittelpunkt enthält. Bei einer ungeraden Anzahl von Kategorien steht ein Mittelpunkt zur Verfügung, der als mittleres Urteil oder als Ausweichoption genutzt werden kann. Seine Interpretation kann daher uneindeutig sein. Man spricht in diesem Fall von einem *unforcierten Rating* (vgl. Abbildung 1.10). Bei einer geraden Anzahl von Kategorien fehlt ein solcher Mittelpunkt, sodass sich die Testperson bei der Auswahl einer Kategorie für eine Richtung entscheiden muss. Dies wird als *forciertes Rating* bezeichnet (vgl. Abbildung 1.11). *Ausweichkategorien* wie „weiß nicht“, „nicht anwendbar“ oder „keine Meinung“ ermöglichen es, eine inhaltliche Beurteilung ausdrücklich auszusetzen. Sie können damit valide Informationen darüber liefern, weshalb eine Testperson ein Item nicht bearbeitet oder nicht inhaltlich beantwortet.

Die *Polarität der Antwortskala* betrifft die Unterscheidung zwischen bipolaren und unipolaren Skalen. *Bipolare Skalen* reichen von einem negativen Pol, etwa starker Ablehnung, bis zu einem positiven Pol, etwa starker Zustimmung. *Unipolare Skalen* reichen dagegen von einem Bezugspunkt geringster Intensität bis zu einem Pol größter Intensität (vgl. Abbildung 1.12). Welche Form geeignet ist, hängt vom Gegenstandsbereich und vom Inhalt des jeweiligen Items ab.

Die *Balance der Antwortskala* bezeichnet das Verhältnis positiver und negativer Antwort-

Beispiel: Lernen im Studium

Wählen Sie für jede Frage eine Antwort.

(Häufigkeit) Wie häufig lernen Sie gemeinsam mit anderen?

☐ Nie ☐ Selten ☐ Manchmal ☐ Oft ☐ Immer

(Intensität) Wie stark fühlen Sie sich beim Lernen unter Zeitdruck?

☐ Gar nicht ☐ Wenig ☐ Mittelmäßig ☐ Stark ☐ Sehr stark

(Wahrscheinlichkeit) Wie wahrscheinlich ist es, dass Sie morgen lernen?

☐ Sehr unwahrscheinlich ☐ Eher unwahrscheinlich ☐ Weder wahrscheinlich noch unwahrscheinlich ☐ Eher wahrscheinlich ☐ Sehr wahrscheinlich

(Bewertung) Wie beurteilen Sie die Lernbedingungen an Ihrer Universität?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

(Einstellung) „Gemeinsames Lernen ist sinnvoll."

☐ Stimme überhaupt nicht zu ☐ Stimme eher nicht zu ☐ Stimme weder zu noch lehne ab ☐ Stimme eher zu ☐ Stimme völlig zu

Abbildung 1.10. Verbale, unforcierte Ratingskalen.

Beispiel: Lernen im Studium

Wählen Sie für jede Frage eine Antwort.

(Häufigkeit) Wie häufig lernen Sie gemeinsam mit anderen?

☐ Nie ☐ Selten ☐ Oft ☐ Immer

(Intensität) Wie stark fühlen Sie sich beim Lernen unter Zeitdruck?

☐ Gar nicht ☐ Wenig ☐ Stark ☐ Sehr stark

(Wahrscheinlichkeit) Wie wahrscheinlich ist es, dass Sie morgen lernen?

☐ Sehr unwahrscheinlich ☐ Eher unwahrscheinlich ☐ Eher wahrscheinlich ☐ Sehr wahrscheinlich

(Bewertung) Wie beurteilen Sie die Lernbedingungen an Ihrer Universität?

☐ Sehr schlecht ☐ Eher schlecht ☐ Eher gut ☐ Sehr gut

(Einstellung) „Gemeinsames Lernen ist sinnvoll."

☐ Stimme überhaupt nicht zu ☐ Stimme eher nicht zu ☐ Stimme eher zu ☐ Stimme völlig zu

Abbildung 1.11. Verbale, forcierte Ratingskalen.

kategorien. *Balancierte Skalen* enthalten gleich viele positive und negative Kategorien, während diese Anzahl bei *unbalancierten Skalen* unterschiedlich ist (vgl. Abbildung 1.13). Im Allgemeinen werden balancierte Skalen vorgezogen. Unbalancierte Skalen können jedoch sinnvoll sein, wenn begründete Annahmen darüber bestehen, in welchem Bereich die Antworten überwiegend liegen werden.

Die *Verankerung der Antwortskala* legt die Bedeutung der Skalenendpunkte und der einzelnen Skalenstufen fest. Bei einer *numerischen Verankerung* werden dafür Zahlen verwendet, bei einer *verbalen Verankerung* Wörter oder Sätze (vgl. Abbildung 1.14). Aus einer sol-

Beispiel: Unipolare Ratingskala

Wie stark sind Ihre Schmerzen momentan?

☐ Keine ☐ Leichte ☐ Mittlere ☐ Starke ☐ Sehr starke

Beispiel: Bipolare Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

Beispiele: Analogskalen

Markieren Sie Ihre Einschätzung jeweils durch einen Strich auf der Linie.

Unipolar: Wie stark sind Ihre Schmerzen momentan?



Bipolar: Wie bewerten Sie die Lehrveranstaltung?



Abbildung 1.12. Unipolare und bipolare Rating- und Analogskalen.

Beispiel: Balancierte Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Sehr schlecht ☐ Eher schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Sehr gut

Zwei negative und zwei positive Kategorien sowie eine neutrale Kategorie.

Beispiel: Unbalancierte Ratingskala

Wie bewerten Sie die Lehrveranstaltung?

☐ Schlecht ☐ Weder gut noch schlecht ☐ Eher gut ☐ Gut ☐ Sehr gut

Abbildung 1.13. Balancierte und unbalancierte Ratingskalen. Eine negative und drei positive Kategorien sowie eine neutrale Kategorie. Der positive Bewertungsbereich wird feiner unterteilt.

chen Verankerung lässt sich im Allgemeinen nicht ableiten, dass die mit den Kategorien verbundenen Urteile äquidistant sind, also gleiche Abstände aufweisen.

Symbole und Marker können Antwortskalen für Personen zugänglich machen, die im Umgang mit Zahlen oder sprachlichen Kategorien wenig geübt sind. Als Kennzeichnungen kommen beispielsweise Plus- und Minuszeichen, Gesichter mit unterschiedlichen Ausdrücken oder unterschiedlich große Kreise infrage (vgl. Abbildung 1.14).

Kombinierte Antwortskalen verbinden mehrere Formen der Verankerung. Eine Antwortkategorie kann beispielsweise gleichzeitig durch eine Zahl, eine verbale Beschreibung und ein Symbol gekennzeichnet werden. Auf diese Weise wird die Antwortskala mehrfach verankert (vgl. Abbildung 1.14).

Das *Skalenniveau im Sinne der Repräsentationstheorie des Messens* ist bei Ratingskalen im Allgemeinen unbestimmt. Aus gleichen Abständen zwischen den dargestellten Ratingkategorien folgen keine gleichen Abstände zwischen den Urteilen der Testpersonen. Bei der

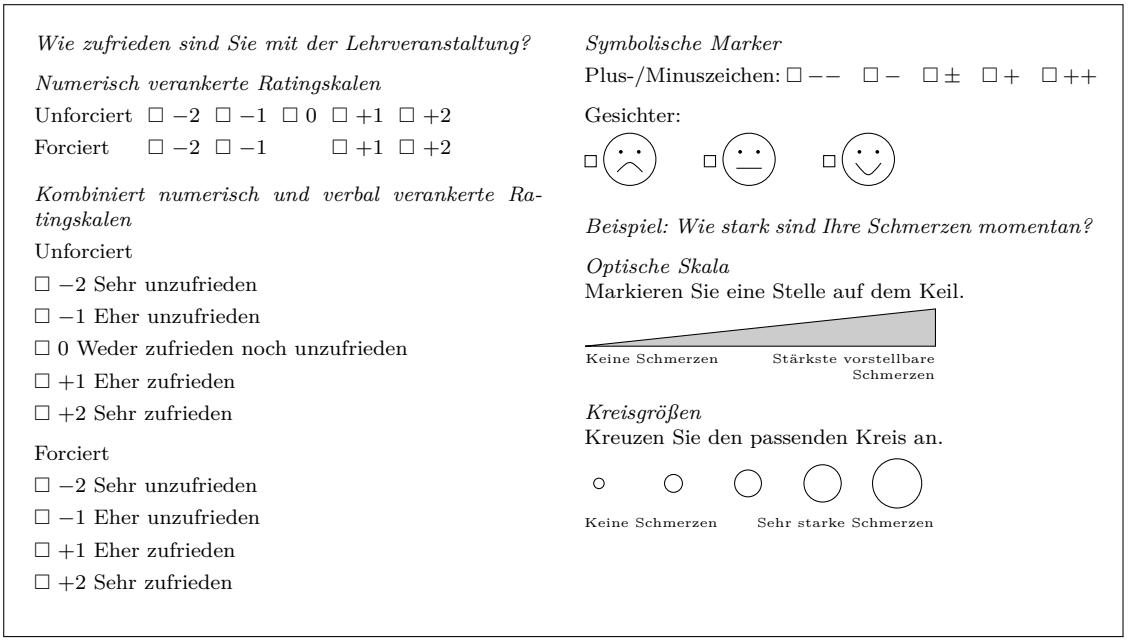


Abbildung 1.14. Numerisch und kombiniert verankerte Ratingskalen, symbolische Marker und optische Skalen.

Entstehung eines Ratings wirken zudem das zu erfassende Merkmal, das Messinstrument und die urteilende Person zusammen.

Vorteile von Beurteilungsaufgaben sind ihre leichte Handhabung, ihre Ökonomie und ihre allgemeine Akzeptanz. Als Nachteil gilt, dass ihre Ergebnisse eher Ordinal- als Intervallskalencharakter haben. Zudem können Testpersonen die Antwortkategorien unterschiedlich interpretieren. So müssen Bezeichnungen wie „selten“, „manchmal“ und „oft“ nicht für alle Personen dieselbe Bedeutung haben.

1.4. Testgütekriterien

Testgütekriterien beschreiben Qualitätseigenschaften psychologischer Tests und bilden die Grundlage für die Beurteilung der Wissenschaftlichkeit eines Testverfahrens. Es handelt sich um qualitative Konzepte, die nur zum Teil quantitativ erfasst werden können. Man unterscheidet dabei *Hauptgütekriterien* und *Nebengütekriterien*. Zu den Hauptgütekriterien zählen *Objektivität*, *Reliabilität* und *Validität*. Die Nebengütekriterien umfassen *Normierung*, *Skalierung*, *Testökonomie*, *Nützlichkeit*, *Zumutbarkeit*, *Unverfälschbarkeit* und *Fairness*. Bei der folgenden Darstellung orientieren wir uns an Moosbrugger & Kelava (2012, Kapitel 2).

Objektivität

Ein Test ist *objektiv*, wenn die Messung des interessierenden Merkmals unabhängig von den Personen erfolgt, die den Test durchführen und auswerten. Darüber hinaus müssen klare und anwenderunabhängige Regeln für die Interpretation der Ergebnisse vorliegen. Man unterscheidet *Durchführungsobjektivität*, *Auswertungsobjektivität* und *Interpretationsobjektivität* (Moosbrugger & Kelava, 2012).

Durchführungsobjektivität bezeichnet die Unabhängigkeit der Antworten einer Testperson von den Testleitenden und der Testsituation. Sie wird durch eine standardisierte Durchführung anhand des Testmanuals und eine möglichst weitgehende Kontrolle der Testsituation angestrebt.

Auswertungsobjektivität bezeichnet die Unabhängigkeit der Testauswertung von den auswertenden Personen. Bei gebundenen Antwortformaten und automatisierter Auswertung ist sie üblicherweise gegeben. Bei offenen Antwortformaten ist sie aufwendiger herzustellen, da die Antworten anhand festgelegter Kriterien beurteilt werden müssen.

Interpretationsobjektivität bezeichnet die Unabhängigkeit der Schlussfolgerungen aus den Testergebnissen von den Personen, die den Test anwenden. Sie wird häufig durch festgelegte Normwertklassifikationen gewährleistet, die eine einheitliche Einordnung der Ergebnisse ermöglichen.

Die Objektivität des BDI-II wird in der Dokumentation wie folgt dargestellt (Hautzinger et al., 2006).

> *Durchführungsobjektivität durch schriftliche Durchführungsinstruktion*
>
> Dieser Fragebogen enthält 21 Gruppen von Aussagen. Bitte lesen Sie jede dieser Gruppen von Aussagen sorgfältig durch und suchen Sie sich dann in jeder Gruppe eine Aussage heraus, die am besten beschreibt, wie Sie sich in den letzten zwei Wochen, einschließlich heute, gefühlt haben. Kreuzen Sie die Zahl neben der Aussage an, die Sie sich herausgesucht haben (0,1,2 oder 3). Falls in einer Gruppe mehrere Aussagen gleichermaßen auf Sie zutreffen, kreuzen Sie die Aussage mit der höheren Zahl an. Achten Sie bitte darauf, dass Sie in jeder Gruppe nicht mehr als eine Aussage ankreuzen, das gilt auch für Gruppe 16 (Veränderungen der Schlafgewohnheiten) oder Gruppe 18 (Veränderungen des Appetits).
>
> *Auswertungsobjektivität*
>
> Der Fragebogen wird durch die einfache Addition der angekreuzten Aussagen ausgewertet. Jedes Item wird auf einer 4-Punkt-Skala bewertet, die von 0 bis 3 reicht. Kreuzt ein Proband bei einem Item mehrere Aussagen an, so geht nur die Aussage mit der höchsten Ziffer in den Summenwert ein. Der Gesamtwert des BDI-II kann Werte zwischen 0 und 63 Punkten annehmen.
>
> *Interpretationsobjektivität*
>
> 0 - 8 Keine, 9 - 13 minimale, 14 - 19 leichte, 20 - 28 mittelschwere, 29 - 63 schwere Depression

Reliabilität

Reliabilität bezeichnet die Genauigkeit, mit der ein Test das von ihm erfasste Merkmal misst. Ein vollständig reliabler Test würde das Merkmal exakt, also ohne Messfehler, erfassen. Die klassische Testtheorie bettet diese Vorstellung in ein probabilistisches Modell ein und ermöglicht damit eine quantitative Beschreibung der Messgenauigkeit. Sie ist in erster Linie eine quantitative Reliabilitätstheorie.

Man unterscheidet vier gebräuchliche Ansätze zur Bestimmung der Reliabilität. Die *Retest-Reliabilität* ergibt sich aus der Korrelation der Ergebnisse desselben Tests bei zwei Messungen an denselben Personen. Sie hängt unter anderem vom Zeitintervall zwischen den Messungen sowie von Erinnerungs- und Lerneffekten ab. Die *Paralleltest-Reliabilität* wird

anhand der Korrelation der Ergebnisse eines Tests mit denen eines Paralleltests bestimmt. Ein Paralleltest besteht aus möglichst ähnlichen Items, die auch als *Itemzwillinge* bezeichnet werden. Bei der *Testhalbierungs-Reliabilität* oder *Split-Half-Reliabilität* wird ein Test in zwei möglichst parallele Hälften unterteilt. Die Korrelation der Ergebnisse beider Testhälften wird mithilfe der *Spearman-Brown-Formel* auf die ursprüngliche Itemanzahl des gesamten Tests hochgerechnet. Die *interne Konsistenz* verallgemeinert den Ansatz der Testhalbierung auf die Ebene einzelner Items. Ein gebräuchliches Maß dafür ist *Cronbachs* α aus der klassischen Testtheorie.

Die Reliabilität des BDI-II wird in der Dokumentation wie folgt dargestellt (Hautzinger et al., 2006):

> *Beispiel BDI-II*
>
> In der Studie von Beck et al. (1996) resultierte bei 26 Patienten, die im Abstand von einer Woche untersucht wurden, ein Retestkoeffizient von $r_{tt} = .93$. Aus Studentenstichproben werden für ein- bis zweiwöchige Zeiträume Koeffizienten von $r_{tt} = .74-.96$ berichtet (Leigh & Antony-Tolbert, 2001; Al-Musawi, 2001; Sprinkle, Lurie, Insko et al., 2002; Ghassemzadeh, Mojtabai, Karamghadiri & Ebrahimkhani, 2005). In Tabelle 2 sind bisherige Ergebnisse zur internen Konsistenz (Cronbach's α) des BDI II aufgelistet. In psychiatrischen Stichproben lag die interne Konsistenz im Bereich von $.89 \leq \alpha \leq .94$, in nichtklinischen Stichproben im Bereich von $.84 \leq \alpha \leq .91$.

Die Reliabilität der GEB-50 wird in der Dokumentation wie folgt dargestellt (Kaiser, 2020):

> *Beispiel GEB-50*
>
> Die gefundene Test-Retest-Reliabilität liegt bei $r_{tt} = .76$ (Kaiser & Wilson, 2000) und $r_{tt} = .83$ (Kaiser, Frick & Stoll-Kleemann, 2001) und sogar bei $r_{tt} = .96$ (Kaiser & Byrka, 2011) und $r_{tt} = .99$ (Kaiser, Brügger, Hartig, Bogner & Gutscher, 2014), wenn korrigiert um die Messfehlerausdünnung.

Validität

Validität bezeichnet das Ausmaß, in dem ein Test tatsächlich das Merkmal erfasst, das er messen soll. Ein Test gilt demnach als valide, wenn seine Ergebnisse als Ausdruck des beabsichtigten Merkmals interpretiert werden können. Zur Begründung dieser Interpretation werden je nach Testart unterschiedliche qualitative und quantitative Befunde herangezogen. Man unterscheidet eine Reihe von Validitätsarten (Moosbrugger & Kelava, 2012), im Folgenden wollen wir kurz die Augenschein-, Inhalts-, Kriteriums- und Konstruktvalidität betrachten.

Augenscheinvalidität bezeichnet den Grad, in dem ein Test aus Sicht von Laien das zu messende Merkmal intuitiv nachvollziehbar erfasst. Entscheidend ist, ob die Aufgaben auf den ersten Blick zum angegebenen Testzweck passen. So erscheint eine Frage nach häufig erlebter Traurigkeit als plausibler Bestandteil eines Depressionsfragebogens. Diese Einschätzung kann die Akzeptanz des Tests und die Bereitschaft zu seiner Bearbeitung unterstützen. Sie liefert jedoch noch keinen wissenschaftlichen Nachweis dafür, dass der Test das beabsichtigte Merkmal tatsächlich misst.

Inhaltsvalidität bezeichnet den Grad, in dem die Aufgaben eines Tests den zu erfassenden Merkmalsbereich aus fachlicher Sicht repräsentativ abdecken. Die Einschätzung erfolgt durch Expertinnen und Experten auf Grundlage einer inhaltlichen Bestimmung des

Merkmals und seiner Teilbereiche. Dabei wird geprüft, ob wichtige Aspekte ausreichend berücksichtigt werden und ob einzelne Aspekte im Verhältnis zum Testzweck über- oder unterrepräsentiert sind. Beispielsweise sollte ein Test zu den Grundlagen der Testtheorie die vorgesehenen Themenbereiche angemessen abbilden. Ein Test, der ausschließlich Definitionen von Testarten abfragt, würde diesen Inhaltsbereich nur unvollständig erfassen.

Kriteriumsvalidität bezeichnet den Grad des Zusammenhangs zwischen einem Testergebnis und einem externen Kriterium. Ein solches Kriterium ist eine außerhalb des Tests erfasste Größe, die für den vorgesehenen Verwendungszweck relevant ist. Beispielsweise lässt sich untersuchen, in welchem Ausmaß die Ergebnisse eines Studieneingangstests spätere Leistungen im Psychologiestudium vorhersagen. Der Zusammenhang kann durch eine Korrelation oder den Anteil der aufgeklärten Varianz beschrieben werden. Für die Aussagekraft dieser Befunde ist entscheidend, dass das gewählte Kriterium zum Testzweck passt und selbst angemessen erfasst wird.

Konstruktvalidität bezeichnet den Grad der wissenschaftlichen Fundierung des Schlusses von Testwerten auf die interessierenden Merkmale. Bei einem *strukturSuchenden Vorgehen* können exploratorische Faktoranalysen Hinweise auf die dem Test zugrunde liegenden Faktoren liefern. Darüber hinaus werden die Übereinstimmung mit Messungen ähnlicher Merkmale als *konvergente Validität* und die Abgrenzung gegenüber Messungen anderer Merkmale als *diskriminante Validität* untersucht. Bei einem *strukturprüfenden Vorgehen* werden theoretisch begründete Annahmen über die Teststruktur geprüft. Dazu gehören die Untersuchung der *faktoriellen Validität* mithilfe konfirmatorischer Faktoranalysen, Homogenitätsprüfungen mithilfe von Item-Response-Theorie-Modellen und die Evaluation von Strukturgleichungsmodellen.

Für die Validität des BDI-II wird wie folgt argumentiert (Hautzinger et al., 2006):

> *Konvergente und diskriminante Validität*
>
> In Tabelle 3 sind Studien zum Zusammenhang des BDI II mit anderen Selbst- und Fremdbeurteilungsskalen aufgeführt. Wie daraus hervorgeht, korreliert das Verfahren mit anderen Depressionsskalen zwischen $r = .68$ bis $r = .89$, etwas geringer mit selbst- und fremdbeurteilter Angst/Ängstlichkeit ($.37 \leq r \leq .60$) sowie im ähnlichen Bereich mit konstruktnahen kognitiven Skalen ($.37 \leq r \leq .68$). Die Differenzierungsfähigkeit bezüglich Depression und Angst anhand des BDI II ist eingeschränkt und abhängig von der Methode: fremdbeurteilte Angst anhand der HRSA korreliert niedriger mit dem BDI II als selbstbeurteilte Angst anhand des BAI (vgl. Tabelle 3). Bislang fehlen Studien, die Zusammenhänge zwischen BDI II und konstruktfernen Verfahren (z.B. symptomferne Persönlichkeitstraits) erfassen.
>
> *Faktorielle Validität*
>
> In der Untersuchung von Beck et al. (1996) legten Scree-Tests aus explorativen Faktorenanalysen sowohl für die Patientenstichprobe als auch für die Studentenstichprobe die Extraktion zweier Faktoren nahe. Nach parallel durchgeführten Hauptachsenanalysen mit anschließender obliquer (Promax-)Rotation resultierte für die Patientenstichprobe ein Faktor, den die Autoren als "somatisch-affektiven" Faktor bezeichneten, auf einem zweiten Faktor luden v.a. kognitive Items des BDI-II, er wurde demnach als "kognitiver" Faktor bezeichnet. Die beiden obliquen Faktoren korrelierten miteinander zu $r = 0.66$. In der Studentenstichprobe repräsentierte dagegen der erste Faktor die "kognitiv-affektive", der zweite Faktor die "somatische" Dimension. Hier betrug die Korrelation der beiden Faktoren $r = 0.62$.

Für die Validität der GEB-50 wird wie folgt argumentiert (Kaiser & Wilson, 2004):

Validität

Obwohl sich das mehrdimensionale Rasch-Modell dem eindimensionalen Rasch-Modell bei der mittels GEB erfassten Neigung, sich umweltschützend zu verhalten, als formal überlegen erwies, ist der Informationsverlust des eindimensionalen Modells vernachlässigbar gering. So lagen die messfehlerkorrigierten Korrelationen zwischen den Verhaltensneigungen in den verschiedenen Verhaltensdomänen in der Regel jenseits von .50 und im Bereich der Reliabilitäten der einzelnen Skalen. Entsprechend erscheint es nicht nur machbar, sondern aus Sparsamkeitsgründen auch ratsam, Umweltschutzneigung, wie beabsichtigt, als eine mehr oder weniger konsistente, allgemeine Verhaltensneigung zu erfassen (Kaiser & Wilson, 2004).

Beziehungen zwischen den Hauptgütekriterien

Die drei Hauptgütekriterien *Objektivität*, *Reliabilität* und *Validität* stehen in einem engen Zusammenhang. Objektivität ist eine Voraussetzung für Reliabilität, da ein Test, dessen Ergebnisse von der Testsituation oder den beteiligten Personen abhängen, das interessierende Merkmal nicht zuverlässig erfassen kann. Reliabilität ist wiederum eine Voraussetzung für Validität, da ein Test, der ein Konstrukt zu ungenau misst, dieses nicht sehr valide erfassen kann. Objektivität allein gewährleistet jedoch noch keine Reliabilität, und Reliabilität allein noch keine Validität. Darüber hinaus beschreibt das *Reliabilitäts-Kriteriumsvaliditäts-Dilemma* der klassischen Testtheorie den Umstand, dass eine Erhöhung der Reliabilität mit einer Abnahme der Kriteriumsvalidität einhergehen kann (Rost, 2004, 6.4.3).

Nebengütekriterien

Neben den Hauptgütekriterien werden sieben Nebengütekriterien zur Beurteilung psychologischer Tests herangezogen. Die folgende Tabelle fasst ihre Bedeutung in Anlehnung an Moosbrugger & Kelava (2012) zusammen.

1.5. Testtheorien

Testtheorien sind probabilistische Modelle, die den Zusammenhang zwischen dem zu erfassenden Konstrukt und dem beobachtbaren Testverhalten beschreiben. Sie bilden damit die Grundlage für die Analyse von Fragebogendaten. Als Hauptrichtungen lassen sich die *klassische Testtheorie*, die *Faktoranalyse* und die *Item-Response-Theorien* unterscheiden. Die klassische Testtheorie und die Faktoranalyse modellieren dabei latente, also nicht direkt beobachtbare Merkmale mithilfe von Zufallsvariablen. Auch Item-Response-Theorien können latente Zufallsvariablen enthalten.

Standarddatenstruktur und Standarddeskriptivstatistiken

Die Standarddatenstruktur der Testtheorie und Fragebogendatenanalyse ergibt sich aus der Beobachtung der Antworten von n Testpersonen auf m Items. Diese Antworten werden in einer Datenmatrix mit n Zeilen und m Spalten angeordnet. Jede Zeile enthält die Antworten einer Testperson, jede Spalte die Antworten aller Testpersonen auf ein bestimmtes Item. Ein Eintrag der Matrix bezeichnet somit die Antwort einer bestimmten Testperson

Tabelle 1.1. Nebengütekriterien psychologischer Tests.

Nebengütekriterium	Definition
Normierung	Für einen Test liegen geeignete Vergleichswerte vor, mit deren Hilfe das Ergebnis einer Testperson im Verhältnis zu einer relevanten Bezugsgruppe eingeordnet und interpretiert werden kann.
Skalierung	Die nach den Auswertungsregeln gebildeten Testwerte geben die qualitativen Beziehungen zwischen den Merkmalsausprägungen angemessen wieder. Formale Skalierungseigenschaften werden meist im Rahmen der Item-Response-Theorie geprüft.
Testökonomie	Der finanzielle und zeitliche Aufwand eines Tests ist im Verhältnis zum diagnostischen Erkenntnisgewinn gering.
Nützlichkeit	Das erfasste Merkmal ist praktisch relevant, und die auf den Testergebnissen beruhenden Entscheidungen oder Maßnahmen lassen mehr Nutzen als Schaden erwarten.
Zumutbarkeit	Die zeitliche, psychische und physische Belastung der Testperson bleibt sowohl für sich genommen als auch im Verhältnis zum Nutzen der Testanwendung angemessen.
Unverfälschbarkeit	Der Test ist so gestaltet, dass die Testperson ihre Testwerte nicht durch gezieltes Antwort- oder Bearbeitungsverhalten steuern oder verzerren kann.
Fairness	Die Testwerte führen zu keiner systematischen Benachteiligung von Personen aufgrund ihrer Zugehörigkeit zu ethnischen, soziokulturellen oder geschlechtsspezifischen Gruppen.

auf ein bestimmtes Item. Tabelle 1.2 veranschaulicht diese Struktur anhand simulierter Antworten von 20 Testpersonen auf 10 Items mit einer Antwortskala von 1 bis 5.

Tabelle 1.2. 20 Testpersonen × 10 Items (Antwortskala 1 bis 5).

Testperson	Item 1	Item 2	Item 3	Item 4	Item 5	Item 6	Item 7	Item 8	Item 9	Item 10
1	1	5	3	4	2	1	1	4	3	2
2	4	2	2	4	2	3	4	2	4	5
3	1	2	2	1	5	3	1	2	5	5
4	2	1	5	5	2	3	4	4	4	4
5	5	4	2	5	5	3	2	5	1	4
6	3	1	1	1	4	4	5	1	1	1
7	2	4	3	1	5	1	2	5	5	2
8	3	3	3	3	4	1	2	5	5	4
9	3	2	4	2	1	4	2	5	1	1
10	1	2	3	2	3	2	3	4	5	1
11	5	4	1	3	2	1	1	4	4	3
12	5	4	4	2	3	2	2	4	2	1
13	2	4	5	4	3	3	3	2	2	1
14	2	2	1	3	1	4	3	1	1	4
15	1	4	1	5	5	1	3	3	5	3
16	5	1	4	2	4	3	3	1	5	5
17	5	1	5	2	4	5	5	1	2	3
18	1	4	5	1	1	3	3	4	5	5
19	1	1	4	3	5	4	1	5	2	1
20	5	2	5	3	5	2	2	1	4	1

Tabelle 1.3. Standarddeskriptivstatistiken der Fragebogendatenanalyse. y_{ij} sei der beobachtete Wert der i-ten von n Testpersonen für das j-te von m Items.

Deskriptivstatistik	Bezeichnung	Formel
Summe der Itemwerte von Testperson i	Summenscore	$y_i = \sum_{j=1}^{m} y_{ij}$
Mittelwert von Item j	Itemschwierigkeit	$\bar{y}_j = \frac{1}{n} \sum_{i=1}^{n} y_{ij}$
Varianz von Item j	Itemvarianz	$s_j^2 = \frac{1}{n-1} \sum_{i=1}^{n} (y_{ij} - \bar{y}_j)^2$
Standardabweichung von Item j	Itemstandard-abweichung	$s_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^{n} (y_{ij} - \bar{y}_j)^2}$
Kovarianz von Item j und Item k	Itemkovarianz	$c_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} (y_{ij} - \bar{y}_j)(y_{ik} - \bar{y}_k)$
Matrix der paarweisen Itemkovarianzen	Kovarianzmatrix	$C = (c_{jk})_{j,k=1}^{m} = \begin{pmatrix} s_1^2 & c_{12} & \cdots & c_{1m} \\ c_{21} & s_2^2 & \cdots & c_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & s_m^2 \end{pmatrix}$
Korrelation von Item j und Item k	Itemkorrelation	$r_{jk} = \frac{c_{jk}}{s_j s_k}$
Matrix der paarweisen Itemkorrelationen	Korrelationsmatrix	$R = (r_{jk})_{j,k=1}^{m} = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1m} \\ r_{21} & 1 & \cdots & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ r_{m1} & r_{m2} & \cdots & 1 \end{pmatrix}$
Korrelation von Item j und Summenscore	Unbereinigte Trennschärfe	$r_{j,y} = \frac{\sum_{i=1}^{n} (y_{ij} - \bar{y}_j)(y_i - \bar{y})}{\sqrt{\left(\sum_{i=1}^{n} (y_{ij} - \bar{y}_j)^2\right) \left(\sum_{i=1}^{n} (y_i - \bar{y})^2\right)}}$

Basierend auf einem Datensatz wie dem in Tabelle 1.2 dargestellten lassen sich zunächst eine Reihe üblicher Deskriptivstatistiken berechnen. Dazu gehören personenspezifische *Summenscores* sowie Itemmittelwerte, Itemvarianzen, Itemstandardabweichungen, Itemkovarianzen und Itemkorrelationen über die Testpersonen hinweg. Tabelle 1.3 gibt einen Überblick über die gängigen Bezeichnungen und Berechnungsformeln. Einige Bezeichnungen, wie der Begriff der *Itemschwierigkeit* für einen Itemmittelwert oder der *unbereinigten Trennschärfe* für eine Item-Summenscore-Korrelation, werden an späterer Stelle näher erläutert.

Standardproblem der Testtheorie und Fragebogendatenanalyse

Das Standardproblem der Testtheorie und Fragebogendatenanalyse besteht darin, die beobachteten Zusammenhänge zwischen Itemantworten durch latente Merkmale zu erklären

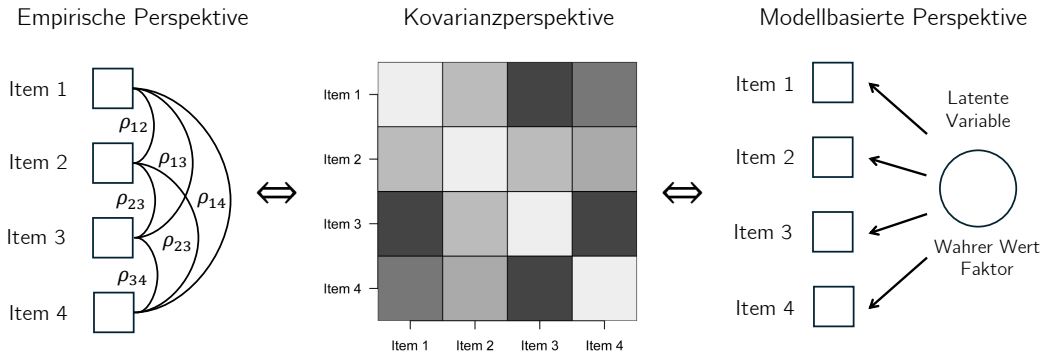


Abbildung 1.15. Empirische Perspektive, Kovarianzperspektive und modellbasierte Perspektive auf das Standardproblem der Testtheorie.

(vgl. Abbildung 1.15). Aus einer *empirischen Perspektive* können Items miteinander korrelieren. Bei einer positiven Korrelation weisen Testpersonen mit hohen beziehungsweise niedrigen Werten in einem bestimmten Item häufig auch in einem anderen Item hohe beziehungsweise niedrige Werte auf. Aus einer *modellbasierten Perspektive* werden solche Zusammenhänge auf den Testpersonen eigene latente Merkmale zurückgeführt, die sich über mehrere Items hinweg wiederholt äußern. Je nach testtheoretischem Ansatz werden diese als *wahre Werte* in der klassischen Testtheorie, als *Faktoren* in der Faktoranalyse oder als *Personeneigenschaften* in den Item-Response-Theorien bezeichnet. Gemeinsam ist ihnen, dass ihre Ausprägungen nicht direkt beobachtet werden können, sondern aus den beobachteten Itemantwortwerten erschlossen werden müssen. Konkret bedeutet die Analyse von Fragebogendaten deshalb neben der Betrachtung von Deskriptivstatistiken wie Summenscores häufig die Modellierung der *Kovarianzmatrix* C der beobachteten Itemwerte. Diese fasst die paarweisen Itemkovarianzen sowie die Itemvarianzen auf der Diagonale zusammen. Durch Standardisierung erhält man die entsprechende *Korrelationsmatrix* R mit den paarweisen Itemkorrelationen. Für die Struktur dieser Zusammenhänge lassen sich mathematisch präzise Modelle formulieren, die die Verbindung zwischen der empirischen und der modellbasierten Perspektive herstellen.

Klassische Testtheorie

Die *klassische Testtheorie* ist ein probabilistisches Modell der Itemwerte und Summenscores eines Tests. Zentrale Beiträge stammen von Gulliksen (1950) sowie Lord & Novick (1968). Ihr latentes Variablenmodell lässt sich grob wie folgt skizzieren:

$$\text{Beobachteter Wert} = \text{Wahrer Wert} + \text{Fehler} \tag{1.1}$$

Der *wahre Wert* ist dabei eine latente Zufallsvariable, mit deren Hilfe die beobachteten Antwortmuster erklärt werden. Da sich der beobachtete Wert aus dem wahren Wert und einem *Fehler* zusammensetzt, wird die klassische Testtheorie häufig als *Messfehlermodell* bezeichnet. Das Modell berücksichtigt sowohl intraindividuelle als auch interindividuelle Variabilität und bildet die Grundlage für die quantitative Beurteilung der Reliabilität. Dazu gehören insbesondere die Paralleltest-Reliabilität, Cronbachs α und die Spearman-Brown-Formel.

Faktoranalyse

Die *Faktoranalyse* ist ein probabilistisches Modell der Itemvarianzen und Itemkovarianzen eines Tests. Die empirische Grundlage bildet dabei die Kovarianzmatrix C beziehungsweise die Korrelationsmatrix R der beobachteten Itemwerte. Zentrale Beiträge stammen von Spearman (1904a), Hotelling (1933) und Lawley (1940). Die Grundstruktur des Modells lässt sich vereinfacht wie folgt darstellen:

$$\text{Beobachtete Werte} = \text{Ladungen} \cdot \text{Faktorwerte} + \text{Fehler} \tag{1.2}$$

Die *Faktoren* werden als latente Zufallsvariablen modelliert. Die beobachteten Werte ergeben sich aus den mit *Ladungen* gewichteten Faktorwerten und einem Fehleranteil. Auf diese Weise werden die beobachteten Antwortmuster durch wenige, nicht direkt beobachtbare Faktoren erklärt. Man unterscheidet exploratorische und konfirmatorische Varianten der Faktoranalyse. Insbesondere die konfirmatorische Faktoranalyse dient der Überprüfung der faktoriellen Validität.

Item-Response-Theorien

Item-Response-Theorien beschreiben die Wahrscheinlichkeiten von Itemantworten als Funktion latenter Zustände beziehungsweise Merkmalsausprägungen. Zentrale Beiträge stammen von Rasch (1960), Novick (1966) und Lord (1980). Häufig werden dafür verschiedene mathematische Formen der logistischen Regression verwendet. In schematischer Form ergibt sich dabei:

$$\mathbb{P}(\text{Itemantwort}) = f(\text{Testparameter}, \text{Personenparameter}) \tag{1.3}$$

Die Wahrscheinlichkeit einer Itemantwort hängt dabei von *Testparametern* und *Personenparametern* ab. Personenparameter werden je nach Modell als latente Zufallsvariablen oder als feste, unbekannte Größen behandelt. Item-Response-Theorien wurden insbesondere für Leistungstests entwickelt und werden beispielsweise im Kontext der PISA-Studien eingesetzt (OECD, 2024). Sie bilden außerdem eine wichtige Grundlage des adaptiven Leistungstestens. Ihre Bedeutung im klinischen Kontext wird unter anderem bei Reise & Waller (2009) behandelt.

1.6. Testkonstruktion

Die *Testkonstruktion* umfasst die Entwicklung und wissenschaftliche Prüfung eines psychologischen Tests. Im Folgenden geben wir dazu einen Kurzüberblick auf Grundlage von Bühner et al. (2026). Ausgangspunkt der Testkonstruktion ist die Definition des zu erfassenden Merkmals, aus der geeignete Fragen oder Aufgaben abgeleitet werden. Anschließend wird untersucht, ob der daraus zusammengestellte Test das Merkmal zuverlässig und valide erfasst. Für die Interpretation individueller Testergebnisse werden schließlich Vergleichswerte aus einer Normstichprobe bereitgestellt. Die Erstellung des Testentwurfs, seine Validierung und seine Normierung bilden damit zentrale Schritte der Testkonstruktion. Die testtheoretischen Verfahren, die diese Schritte unterstützen, werden in den folgenden Kapiteln genauer behandelt.

Konstruktdefinition und Testplanung

Zu Beginn der Testkonstruktion wird festgelegt, welches psychologische Merkmal mit dem Test erfasst werden soll. Eine möglichst präzise *Konstruktdefinition* beschreibt die inhaltliche Bedeutung des Merkmals und gegebenenfalls seine verschiedenen Teilbereiche oder Facetten. Sie bildet die Grundlage dafür, geeignete Items zu entwickeln und später zu beurteilen, ob diese das Merkmal in seiner Breite angemessen abbilden. Außerdem ist zu bestimmen, für welche Personengruppe und welchen Anwendungszweck der Test vorgesehen ist. Diese Festlegungen beeinflussen sowohl die Auswahl der Inhalte und Antwortformate als auch die Anforderungen an Durchführung, Auswertung und Interpretation.

Itemkonstruktion und Antwortformate

Aus der Konstruktdefinition werden Fragen oder Aufgaben abgeleitet und zunächst zu einer vorläufigen Sammlung von Items zusammengestellt. Dabei ist zu prüfen, welche Aspekte des Merkmals die einzelnen Items erfassen und ob wichtige Teilbereiche ausreichend vertreten sind. Die Beurteilung der Inhaltsvalidität stützt sich insbesondere auf die zugrunde liegende Theorie, die Konstruktdefinition und die Einschätzung fachkundiger Personen. Für die Items werden passende Antwortformate gewählt, etwa Auswahlaufgaben für einen Leistungstest oder Beurteilungsaufgaben für einen Persönlichkeitstest. Das Antwortformat bestimmt zugleich, welche Art von Daten entsteht und welche testtheoretischen Modelle für deren Analyse geeignet sind. Bereits beim Testentwurf werden außerdem einheitliche Instruktionen sowie Regeln für die Auswertung festgelegt, um die Objektivität des Tests zu unterstützen.

Erprobung und Auswahl der Items

Der Testentwurf wird an einer Stichprobe erprobt. Die dabei gewonnenen Antworten ermöglichen es, die Eigenschaften der einzelnen Items und ihr Zusammenwirken zu untersuchen. Testtheoretische Modelle helfen beispielsweise zu beurteilen, ob die Items durch ein gemeinsames latentes Merkmal erklärt werden können oder ob mehrere unterscheidbare Merkmale berücksichtigt werden müssen. Wenn ein Modell nicht besonders gut zu den Daten passt, kann dies auf ungeeignete Items, unzutreffende Modellannahmen oder Probleme der zugrunde liegenden Konstruktdefinition hinweisen. Entsprechend können Items umformuliert oder entfernt, zusätzliche Items entwickelt oder die angenommene Struktur des Tests überarbeitet werden.

Bei der Zusammenstellung der endgültigen Skala sind statistische Ergebnisse und inhaltliche Überlegungen gemeinsam zu berücksichtigen. So kann das Entfernen eines Items zwar die geschätzte Reliabilität erhöhen, zugleich aber die Inhaltsvalidität beeinträchtigen, wenn dadurch ein wesentlicher Teilbereich des Merkmals nicht mehr erfasst wird. In einem solchen Fall kommt auch eine Umformulierung des Items in Betracht. Ebenso lässt sich die Reliabilität unter geeigneten Modellannahmen durch zusätzliche Items erhöhen, wobei die damit verbundene längere Bearbeitungszeit zu berücksichtigen ist. Die Testkonstruktion ist deshalb häufig ein wiederholter Prozess aus Entwicklung, Erprobung, Analyse und Überarbeitung.

Validierung und Dokumentation

Im Rahmen der Validierung wird untersucht, inwieweit die beabsichtigte Interpretation und Verwendung der Testergebnisse gerechtfertigt ist. Dazu werden die zuvor behandelten Gütekriterien herangezogen. Neben der Objektivität und Reliabilität sind insbesondere die inhaltliche Abdeckung des Konstrukts, die Struktur der Itemzusammenhänge und die Beziehungen zu anderen Merkmalen oder relevanten Außenkriterien zu untersuchen. Die Ergebnisse werden zusammen mit Angaben zur Testentwicklung, Durchführung, Auswertung und Interpretation in einem *Testmanual* dokumentiert. Dieses enthält auch die Normwerte, die eine Einordnung individueller Testergebnisse ermöglichen.

Normierung

Das primäre quantitative Ergebnis eines psychologischen Tests ist zunächst ein *Rohwert*. Auf der Ebene eines einzelnen Items kann dies beispielsweise der Zahlenwert sein, der einer gewählten Antwort zugeordnet wird. Beim Traurigkeitsitem des BDI-II sind die möglichen Rohwerte 0, 1, 2 und 3. Über mehrere Items hinweg ergibt sich häufig ein *Summenscore*, also die Summe der einzelnen Itemwerte. Der Summenscore des BDI-II kann beispielsweise Werte zwischen 0 und 63 annehmen. Alternativ kann ein *Mittelwertscore* gebildet werden, indem die Summe der Itemwerte durch die Anzahl der berücksichtigten Items geteilt wird.

Ein Rohwert lässt für sich genommen häufig noch nicht erkennen, ob eine Merkmalsausprägung im Vergleich zu anderen Personen niedrig, durchschnittlich oder hoch ist. Bei der *Normierung* wird deshalb ein Bezugssystem bereitgestellt, das die Einordnung eines individuellen Testergebnisses in die Verteilung der Ergebnisse einer Vergleichsgruppe ermöglicht. Dazu wird der Test einer hinreichend großen und für die vorgesehene Vergleichsgruppe möglichst repräsentativen *Normstichprobe* vorgelegt. Welche Vergleichsgruppe angemessen ist, hängt vom Anwendungszweck des Tests ab. So kann ein Ergebnis beispielsweise im Vergleich zur Allgemeinbevölkerung oder zu einer klinischen Gruppe interpretiert werden. Die Zusammensetzung der Normstichprobe und das Vorgehen bei der Normierung werden im Testmanual dokumentiert.

Eine verbreitete Möglichkeit der Normierung besteht darin, Rohwerte in *Z Scores* zu transformieren. Dazu wird von einem Rohwert x der Mittelwert m der Normstichprobe abgezogen und die Differenz durch deren Standardabweichung s geteilt:

$$z = \frac{x - m}{s} \tag{1.4}$$

Ein Z Score gibt somit an, um wie viele Standardabweichungen ein Rohwert vom Mittelwert der Normstichprobe abweicht. Ein Wert von $z = 0$ entspricht dem Mittelwert, ein Wert von $z = 1$ liegt eine Standardabweichung darüber und ein Wert von $z = -1$ eine Standardabweichung darunter. Die auf diese Weise standardisierten Werte der Normstichprobe haben einen Mittelwert von 0 und eine Standardabweichung von 1. Wenn die Rohwerte näherungsweise normalverteilt sind, sind auch die Z Scores näherungsweise standardnormalverteilt.

Da Z Scores negativ sein können und ihre Darstellung häufig Nachkommastellen erfordert, werden sie oft in einen anderen Wertebereich überführt. Eine verbreitete, auf McCall (1922) zurückgehende Transformation liefert die sogenannten *T Scores*:

$$t = 10z + 50 \tag{1.5}$$

T Scores haben in der Normstichprobe einen Mittelwert von 50 und eine Standardabweichung von 10. Ein T Score von 50 entspricht somit einem Z Score von 0, ein T Score von 60 einem Z Score von 1 und ein T Score von 40 einem Z Score von −1. Die Bezeichnung T Score ist von der T-Statistik und der zugehörigen Verteilung aus der frequentistischen Inferenz zu unterscheiden. Die Umrechnung simulierter Rohwerte in Z Scores und T Scores ist in der zugehörigen Abbildung veranschaulicht (vgl. Abbildung 1.16).

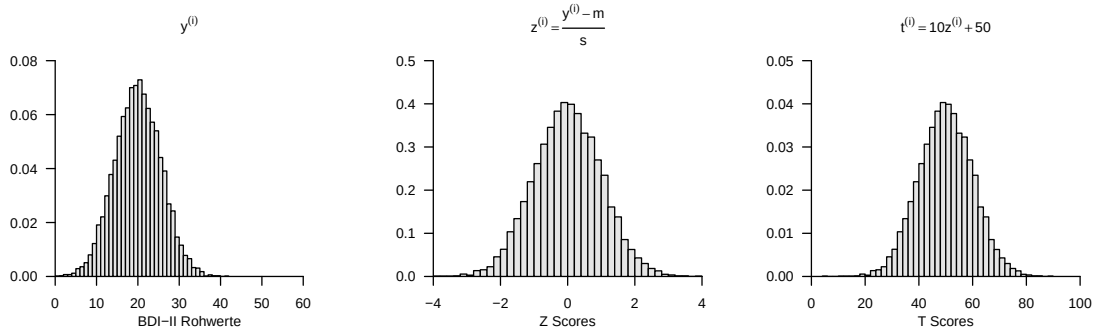


Abbildung 1.16. Simulierte BDI-II-Rohwerte sowie die daraus berechneten Z Scores und T Scores.

Unter der zusätzlichen Annahme einer Normalverteilung liegen ungefähr 68% der Werte innerhalb einer Standardabweichung um den Mittelwert, ungefähr 95% innerhalb von zwei und ungefähr 99,7% innerhalb von drei Standardabweichungen. Auf der T-Skala entsprechen diese Bereiche den Intervallen von 40 bis 60, von 30 bis 70 und von 20 bis 80. Diese Anteile gelten entsprechend nur näherungsweise für empirische Verteilungen, die sich durch eine Normalverteilung gut beschreiben lassen (vgl. Abbildung 1.17).

Das Vorgehen lässt sich an einem hypothetischen Beispiel verdeutlichen. Angenommen, ein Testrohwert beträgt 30 und die Normstichprobe weist einen Mittelwert von 20 sowie eine Standardabweichung von 5 auf. Dann ergibt sich:

$$z = \frac{30 - 20}{5} = 2 \tag{1.6}$$

$$t = 10 \cdot 2 + 50 = 70 \tag{1.7}$$

Der Rohwert liegt somit zwei Standardabweichungen über dem Mittelwert der Vergleichsgruppe. Ob eine solche Ausprägung als günstig oder ungünstig zu bewerten ist, hängt vom erfassten Merkmal und vom Anwendungszweck ab.

Neben Z Scores und T Scores sind weitere Normskalen gebräuchlich. IQ-Werte werden üblicherweise auf einen Mittelwert von 100 und eine Standardabweichung von 15 bezogen. *Stanine-Werte* und *Sten-Werte* fassen standardisierte Ergebnisse in neun beziehungsweise zehn Kategorien zusammen. Die Wahl einer Normskala verändert bei einer linearen Transformation lediglich die numerische Darstellung der relativen Position. Gleiche Normwerte in verschiedenen Tests bedeuten daher eine vergleichbare relative Position in der jeweiligen

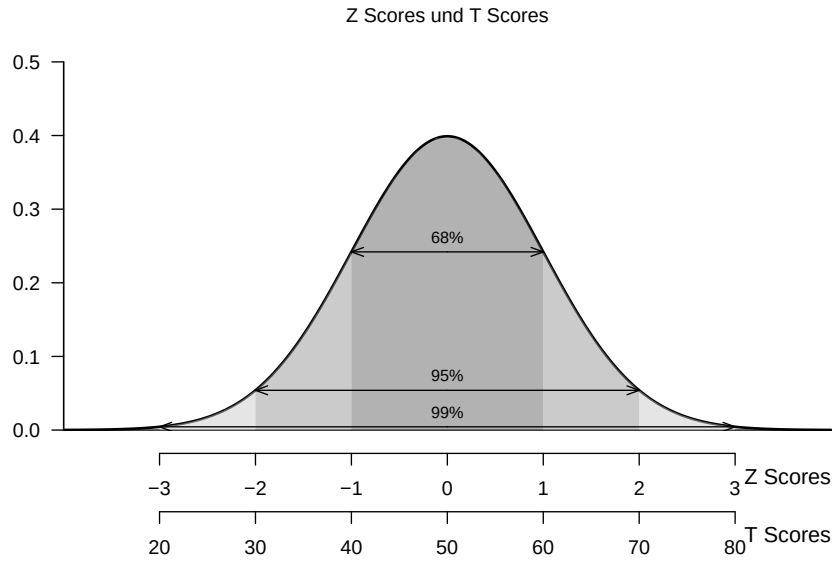


Abbildung 1.17. Z Scores und T Scores bei einer Normalverteilung. Die eingezeichneten Anteile sind näherungsweise angegeben.

Vergleichsgruppe, aber nicht notwendigerweise die gleiche psychologische Merkmalsausprägung.

Eine Normierung beseitigt schließlich nicht die Messunsicherheit eines Tests. Wird zu einem Testergebnis ein Konfidenzintervall angegeben, müssen bei einer linearen Umrechnung in Normwerte auch dessen Grenzen entsprechend transformiert werden. Die Verfahren zur Bestimmung dieser Unsicherheit setzen testtheoretische Modelle voraus und werden später behandelt.

1.7. Selbstkontrollfragen

1. Erläutern Sie den Begriff des psychologischen Tests nach Lienert (1968) und kommentiert von Rost (2004).
2. Nennen Sie die typischen Material- und Durchführungsbestandteile eines Tests.
3. Erläutern Sie die Begriffe Item, Itemstamm, Antwortformat.
4. Erläutern Sie den Begriff des psychometrischen Persönlichkeitstests.
5. Nennen Sie vier Formen psychometrischer Persönlichkeitstests.
6. Erläutern Sie den Begriff des Leistungstests.
7. Nennen Sie vier Formen von Leistungstests.
8. Erläutern Sie den Begriff des Persönlichkeitsentfaltungsverfahrens.
9. Nennen Sie drei Formen von Persönlichkeitsentfaltungsverfahren.
10. Erläutern Sie den Begriff des klinischen Tests.
11. Erläutern Sie den Begriff des Einstellungstests.
12. Erläutern Sie den Begriff des freien Antwortformats und nennen Sie zwei Beispiele.
13. Erläutern Sie Vor- und Nachteile freier Antwortformate.
14. Erläutern Sie den Begriff des gebundenen Antwortformats und nennen Sie drei Beispiele.
15. Erläutern Sie den Begriff der Ordnungsaufgabe und nennen Sie zwei Beispiele.
16. Erläutern Sie den Begriff der Auswahlaufgabe.
17. Erläutern Sie die Begriffe der Distraktoren, der Disjunktion und der Exhaustivität bei Auswahlaufgaben.
18. Erläutern Sie Vor- und Nachteile von Auswahlaufgaben.

19. Erläutern Sie den Begriff der Forced-Choice-Auswahlaufgabe.
20. Erläutern Sie den Begriff der Beurteilungsaufgabe.
21. Erläutern Sie die Begriffe des forcierten und unforcierten Ratings bei Beurteilungaufgaben.
22. Erläutern Sie den Begriff der Ausweichkategorie bei Beurteilungsaufgaben.
23. Erläutern Sie den Begriff der Antwortskalenpolarität bei Beurteilungsaufgaben.
24. Erläutern Sie den Begriff der Antwortskalenbalance bei Beurteilungsaufgaben.
25. Erläutern Sie den Begriff der Antwortskalenverankerung bei Beurteilungsaufgaben.
26. Erläutern Sie Vor- und Nachteile von Beurteilungsaufgaben.
27. Erläutern Sie den Begriff des Testgütekriteriums.
28. Nennen Sie die drei Hauptgütekriterien für psychologische Tests.
29. Nennen Sie sieben Nebengütekriterien für psychologische Tests.
30. Geben Sie die Definition der Objektivität nach Moosbrugger & Kelava (2012) wieder.
31. Erläutern Sie die Begriffe Durchführungsobjektivität, Auswertungsobjektivität, Interpretationsobjektivität
32. Geben Sie die Definition der Reliabilität nach Moosbrugger & Kelava (2012) wieder.
33. Erläutern Sie die Begriffe der Retest-, Paralleltest- und Split-Half-Reliabililtät
34. Erläutern Sie den Begriff der internen Konsistenz eines psychologischen Tests.
35. Geben Sie die Definition der Validität nach Moosbrugger & Kelava (2012) wieder.
36. Erläutern Sie die Begriffe der Augenschein-, Inhalts- und Kriteriumsvalidität.
37. Erläutern Sie den Begriff der Konstruktvalidität eines psychologischen Tests.
38. Nennen Sie die drei Hauptrichtungen der Testtheorie.
39. Erläutern Sie die Standarddatenstruktur der Testtheorie und Fragebogendatenanalyse.
40. Erläutern Sie das Standardproblem der Testtheorie und Fragebogendatenanalyse.
41. Erläutern Sie den Begriff der klassischen Testtheorie.
42. Erläutern Sien den Begriff der Faktoranalyse.
43. Erläutern Sie den Begriff der Item-Response-Theorien.
44. Skizzieren Sie wesentliche Schritte in der Konstruktion eines Tests.
45. Erläutern Sie den Begriff der Testnormierung.
46. Erläutern Sie die Begriffe Raw Score, Z Score und T Score.

2. Modelle der klassischen Testtheorie

Die klassische Testtheorie beschreibt Item- und Summenwerte psychologischer Tests mithilfe eines probabilistischen Modells. Ausgangspunkt ist die Vorstellung, dass sich ein beobachteter Testwert aus einem wahren Wert und einem Messfehler zusammensetzt:

$$\text{Beobachteter Wert} = \text{Wahrer Wert} + \text{Messfehler}. \tag{2.1}$$

Der wahre Wert ist dabei nicht direkt beobachtbar, sondern wird als latente Größe zur Erklärung der beobachteten Antwortmuster herangezogen. Weil die Unterscheidung zwischen wahrem Wert und Messfehler im Mittelpunkt steht, wird die klassische Testtheorie häufig als „Messfehlertheorie“ bezeichnet.

Anders als im allgemeinen linearen Modell (ALM) wird dabei auch der wahre Wert als Zufallsvariable modelliert. Auf diese Weise lassen sich sowohl Unterschiede zwischen Personen als auch Schwankungen wiederholter Messungen derselben Person beschreiben. Die klassische Testtheorie verbindet damit die Modellierung interindividueller und intraindividueller Variabilität. Meist werden dafür jedoch keine konkreten Verteilungsfamilien festgelegt, sondern stattdessen Annahmen über Erwartungswerte, Varianzen und Kovarianzen formuliert und deren Konsequenzen für die beobachteten Testwerte untersucht. Unter entsprechenden Zusatzannahmen lässt sich das Modell als Spezialfall eines faktoranalytischen Modells darstellen, gleichzeitig bestehen auch zu linearen gemischten Modellen enge Beziehungen.

Im Vordergrund steht bei der klassischen Testtheorie die Formulierung eines theoretischen Modells, aus dessen Annahmen Beziehungen zwischen beobachtbaren Größen abgeleitet werden. Die vollständige Anpassung eines parametrischen Modells an einen Datensatz und die Schätzung seiner einzelnen Parameter stehen dagegen häufig nicht im Zentrum. Die praktische Auswertung konzentriert sich vielmehr auf die Schätzung von Varianzen, Kovarianzen und insbesondere Korrelationen. Die theoretischen Annahmen begründen, unter welchen Bedingungen diese Zusammenhänge Auskunft über die Zuverlässigkeit einer Messung geben. So kann etwa die Korrelation zwischen zwei Messzeitpunkten über Testpersonen als Maß der Retest-Reliabilität herangezogen werden. Die klassische Testtheorie liefert hierfür den Modellrahmen, in dem solche empirischen Kennwerte interpretiert werden können. Speziellere klassische testtheoretische Modelle lassen sich allerdings auch ausdrücklich an Daten anpassen, etwa im Rahmen einer Faktorenanalyse.

Historischer Überblick

Die klassische Testtheorie entstand aus praktischen Problemen der Leistungsbeurteilung (Traub, 1997). Ende des 19. Jahrhunderts ging es beispielsweise in den Arbeiten von Edgeworth (1888) zunächst um die Verlässlichkeit von Prüfungsnoten und die Unterschiede zwischen Beurteilenden. Im frühen 20. Jahrhundert verband dann Spearman die Analyse von Messfehlern mit der Untersuchung von Intelligenz und Fähigkeiten (Spearman,

1904b). Seine Korrektur messfehlerbedingt abgeschwächter Korrelationen wurde zu einem Ausgangspunkt der Reliabilitätstheorie. Die frühen Anwendungen betrafen damit vor allem Prüfungs-, Leistungs- und Fähigkeitstests, noch nicht primär die heute verbreiteten Persönlichkeits- und Symptomfragebögen. Mit der gesellschaftlichen Ausweitung standardisierter Bildungs- und psychologischer Tests wuchs der Bedarf an einer systematischen Theorie ihrer Genauigkeit. Gulliksen (1950) bündelte die bis dahin entwickelten Verfahren und Cronbach (1951) formulierte mit dem Koeffizienten α einen bis heute verbreiteten Zugang zur internen Testkonsistenz.

Eine präzise axiomatische Grundlage der klassischen Testtheorie gaben Novick (1966) und insbesondere Lord & Novick (1968). Sie definierten den wahren Wert einer Testperson als Erwartungswert ihrer beobachteten Werte unter einem festgelegten Wiederholungsexperiment. Im operationalistisch geprägten Umfeld der damaligen Psychologie ließ sich der wahre Wert damit über seine theoretische Nützlichkeit und überprüfbaren Konsequenzen rechtfertigen, ohne ihm eine vom Messverfahren unabhängige psychische Realität zuzuschreiben (vgl. Lord & Novick (1968, Kapitel 2) und Borsboom (2005, Kapitel 2)). Die Bedeutung und Grenzen dieser Definition betrachten wir im folgenden Abschnitt genauer.

Die weitere Entwicklung erweiterte sowohl die Modelle der klassischen Testtheorie als auch ihre statistische Prüfung (Brennan, 2024). Jöreskog (1971) zum Beispiel behandelte sogenannte *kongenerische Testmodelle*, deren wahre Werte unterschiedliche lineare Beziehungen zu einem gemeinsamen latenten Konstrukt haben dürfen. Die schon durch Lord & Novick (1968) beschriebenen *parallelen* und *τ-äquivalenten* Modelle erscheinen darin als restriktivere Spezialfälle. Allerdings blieb die klassische Testtheorie nicht unumstritten: Kritik richtete sich unter anderem gegen die Gleichsetzung von Reliabilität und gelungener Messung sowie gegen die routinemäßige Berechnung von Kennwerten ohne Prüfung der zugrunde liegenden Modelle (vgl. Borsboom (2006) und Sijtsma (2009)).

Dennoch spielt die klassische Testtheorie bis heute in der psychologischen Forschung eine große Rolle und wurde dort nie vollständig durch ein neues datenanalytisches Paradigma abgelöst. Borsboom (2006) deutete die geringe Aufnahme neuerer psychometrischer Verfahren auch als Folge von Ausbildungstraditionen, begrifflichen Gewohnheiten und praktischen Hürden. So greift die Entwicklung neuer Fragebögen bis heute vielfach auf klassische Itemanalysen und Reliabilitätskonzepte zurück, wenn auch mittlerweile oft mit Faktorenanalysen oder IRT-Ansätzen kombiniert (vgl. Stefana et al. (2025)).

Letztlich bleibt die klassische Testtheorie besonders in Psychologie und Bildungsdiagnostik verankert, stellt aber kein allgemeines Modellierungsparadigma der modernen Datenwissenschaft dar. Dies ist insofern überraschend, als sich ihre Fragen nach wahren Werten und Messfehlern zugleich in breitere statistische Modellklassen übersetzen lassen, wie sie in der fachübergreifenden Datenanalyse häufig zum Einsatz kommen. Lineare gemischte Modelle bieten etwa einen Rahmen für Personenunterschiede und wiederholte Messungen, Strukturgleichungsmodelle für latente Variablen und Messmodelle. Hier stehen, wie im modernen datenanalytischen Kontext üblich, explizite Modellspezifikation, Parameterschätzung und Modellprüfung im Vordergrund. Die klassische Testtheorie lässt sich daher heute als historisch gewachsene, anwendungsbezogene und idiosynkratische Perspektive auf solche allgemeineren datenanalytischen Modellierungsprobleme einordnen.

Im Folgenden betrachten wir die Modelle der klassischen Testtheorie in drei Hauptabschnitten. Zunächst formulieren wir das Modell multipler Testmessungen als allgemeinen probabilistischen Rahmen für die beobachteten Werte, wahren Werte und Messfehler mehrerer

Tabelle 2.1. Beispieldatensatz mit 20 Personen und 4 Testmessungen

Person	Testmessung 1	Testmessung 2	Testmessung 3	Testmessung 4
1	13	43	41	34
2	48	34	23	32
3	10	24	11	29
4	43	42	27	48
5	32	29	31	38
6	23	44	23	22
7	27	15	47	31
8	42	19	10	38
9	30	47	49	37
10	30	29	15	42
11	19	37	32	30
12	16	29	15	40
13	18	32	49	47
14	24	15	48	26
15	30	49	20	18
16	46	34	26	48
17	50	15	45	32
18	34	48	22	28
19	46	15	49	35
20	46	33	34	39

Testmessungen und leiten seine grundlegenden Eigenschaften ab. Dabei bleibt zunächst offen, wie die wahren Werte einer Person über die verschiedenen Testmessungen hinweg zusammenhängen. Anschließend untersuchen wir mit dem Modell paralleler Testmessungen einen speziellen Fall, in dem die wahren Werte einer Person über alle Testmessungen hinweg übereinstimmen und zusätzlich gleiche Messfehlervarianzen vorausgesetzt werden. Abschließend betrachten wir Modelle kongenerischer Testmessungen, die einen Bezug zwischen den klassischen Modellen der Testtheorie und der Faktorenanalyse herstellen.
Die Modelle erlauben dabei unterschiedliche lineare Beziehungen der Testmessungen zu einem gemeinsamen latenten Faktor und ordnen kongenerische, τ-äquivalente und parallele Testmodelle sowie ihre essentiellen Varianten anhand zunehmend restriktiver Annahmen in eine gemeinsame Modellhierarchie ein.

2.1. Das Modell multipler Testmessungen

Wir formulieren die klassische Testtheorie als Modell mit latenten Zufallsvariablen in Anlehnung an Novick (1966) und Lord & Novick (1968). Zu den klassischen Grundlagen zählt auch Gulliksen (1950). Eine ähnliche probabilistische Darstellung findet sich bei Foster (2020). Als Beispiel betrachten wir die beobachteten Werte von $n = 20$ Personen bei $m = 4$ Testmessungen. Tabelle 2.1 veranschaulicht die Datenstruktur. Personen bezeichnen wir mit dem Index $i = 1, \dots, 20$ und Testmessungen mit dem Index $j = 1, \dots, 4$.

Die folgende Definition legt zunächst die Bedeutung des wahren Werts, des beobachteten Werts und des Messfehlers im Modell fest. Sie nutzt dabei das Konzept eines bedingten Erwartungswerts nach Definition A.1.

Definition 2.1 (Wahrer Wert, beobachteter Wert und Messfehler)**.** Für $i = 1, ..., n$ und $j = 1, ..., m$ ist der *wahre Wert (true score)* einer Person i für eine Testmessung j als Zu-

fallsvariable τ_{ij} modelliert. Der *beobachtete Wert (observed score)* wird durch die Zufallsvariable y_{ij} modelliert. Die gemeinsame Verteilung des wahren Werts und des beobachteten Werts erfülle $\mathbb{E}(y_{ij}|\tau_{ij}) = \tau_{ij}$. Bedingt auf $\tau_{ij} = t_{ij}$ gilt damit

$$\mathbb{E}(y_{ij}|\tau_{ij} = t_{ij}) = t_{ij}. \tag{2.2}$$

Der *Messfehler (error score)* einer Person für diese Testmessung ist definiert als die Zufallsvariable

$$\varepsilon_{ij} := y_{ij} - \tau_{ij}. \tag{2.3}$$

•

Mit dem Begriff einer *Testmessung* ist hier etwas unspezifisch und je nach Anwendung entweder eine Messung mithilfe eines einzelnen Items oder mithilfe der Summe mehrerer Items gemeint. Auf die Unterscheidung zwischen *Itemscores* und *Testsummenscores* gehen wir bei der Behandlung der internen Konsistenz genauer ein. Letztere induzieren im Rahmen der klassischen Testtheorie den Begriff der *m-Komponententestmodelle*. Man beachte, dass in Definition 2.1 der Definition bedingter Erwartungswerte gemäß τ_{ij}, y_{ij} und ε_{ij} Zufallsvariablen sind und $t_{ij} \in \mathbb{R}$ eine Konstante ist.

Wie im historischen Überblick angesprochen, sollte die Definition des wahren Werts als Erwartungswert eine Festlegung auf eine vom Messverfahren unabhängige psychische Realität vermeiden. Novick (1966) und Lord & Novick (1968) wählten hierzu einen operationalistisch orientierten Zugang: Der wahre Wert einer Person für eine Testmessung wird über die Vorstellung wiederholter Messungen unter identischen Bedingungen erläutert. Zur Veranschaulichung zitieren Lord & Novick (1968, S. 29–30) Lazarsfeld (1959):

„Angenommen, wir fragen eine Person, Herrn Brown, wiederholt, ob er die Vereinten Nationen befürwortet; nehmen wir weiter an, dass wir ihm nach jeder Frage „das Gehirn waschen“ und ihm dann dieselbe Frage erneut stellen. Da Herr Brown unsicher ist, wie er zu den Vereinten Nationen steht, wird er manchmal eine befürwortende und manchmal eine ablehnende Antwort geben. Nachdem wir dieses Verfahren viele Male durchgeführt haben, berechnen wir anschließend den Anteil der Male, in denen Herr Brown die Vereinten Nationen befürwortet hat.“

Diese Proportion wollen Novick (1966) und Lord & Novick (1968) dann als wahren Wert verstehen (vgl. auch Borsboom et al. (2004)). Natürlich ist dieser Versuch einer antimetaphysischen Grundhaltung nicht durchhaltbar: Zum einen handelt es sich bei der „wiederholten Testmessung unter identischen Bedingungen“ um ein idealisiertes, in der Realität nicht durchführbares Gedankenexperiment. Zum anderen definieren Novick (1966) und Lord & Novick (1968) den wahren Wert auch gerade nicht als (endlichen) Mittelwert einer Messreihe, sondern als idealisierten Erwartungswert einer Zufallsvariable. Als wirklich operationalistische Definition überzeugt die klassische Ausgangsdefinition also nicht, verkompliziert die Entwicklung einer Standardmessfehlertheorie, wie sie beispielsweise die klassische Formalisierung des allgemeinen linearen Modells darstellt, für die Analyse von Tests und Fragebögen aber beträchtlich. Dies mag einer der Gründe sein, warum die klassische Testtheorie bis heute lediglich in der Psychologie und wenig darüber hinaus von Bedeutung ist.

Ähnlich gelagert ist die Bezeichnung der bedingten Verteilung des beobachteten Werts $\mathbb{P}(y_{ij}|\tau_{ij} = t_{ij})$ als *Propensitätsverteilung* durch Lord & Novick (1968), welche die intraindividuelle Variabilität des beobachteten Werts bei festem wahren Wert modelliert. Dabei

klingt an, dass Lord & Novick (1968) eine Propensitätsinterpretation von Wahrscheinlichkeiten als kausal bedingte „Verwirklichungstendenzen“, die, im Gegensatz zur frequentistischen Interpretation auch im Einzelfall Sinn ergeben, implizieren. Allerdings unterstellen Propensitätsverteilungen kausale Prozesse, die in der Regel nicht spezifiziert und damit auch nicht beobachtbar sind, und führen damit letztlich auch wieder auf metaphysische Aussagen (vgl. auch Borsboom et al. (2004) und Borsboom (2009)).

In unserer Darstellung folgen wir einem modellbasierten, realistischen Ansatz und wählen deshalb mit Definition 2.2 eine Formulierung des Modells multipler Testmessungen der klassischen Testtheorie, die mit Definition 2.1 und damit natürlich auch den theoretischen Ergebnissen der klassischen Testtheorie kongruent ist, aber nicht versucht, ihren Modellcharakter zu verschleiern. Insbesondere betont unser Ansatz dabei das Gesamtziel der Modellierung einer Menge von m Testmessungen von n Personen als eines Datensatzes von nm Datenpunkten. Wir definieren das *Modell multipler Testmessungen* daher wie folgt.

Definition 2.2 (Modell multipler Testmessungen)**.** Für $i = 1, ..., n$ und $j = 1, ..., m$ seien τ_{ij} eine Zufallsvariable, die den *wahren Wert* der $i$ten Person in der $j$ten Testmessung modelliere, und y_{ij} eine Zufallsvariable, die den *beobachteten Wert* der $i$ten Person in der $j$ten Testmessung modelliere. Dann nennen wir die gemeinsame Verteilung der τ_{ij} und y_{ij} mit der Faktorisierungseigenschaft

$$\mathbb{P}\left(\tau_{11}, y_{11}, ..., \tau_{nm}, y_{nm}\right) := \prod_{i=1}^{n} \left(\mathbb{P}(\tau_{i1}, ..., \tau_{im}) \prod_{j=1}^{m} \mathbb{P}(y_{ij}|\tau_{ij}) \right) \tag{2.4}$$

das *Modell multipler Testmessungen*, wenn gilt, dass

$$\mathbb{P}(\tau_{11}, ..., \tau_{1m}) \prod_{j=1}^{m} \mathbb{P}(y_{1j}|\tau_{1j}) = \cdots = \mathbb{P}(\tau_{n1}, ..., \tau_{nm}) \prod_{j=1}^{m} \mathbb{P}(y_{nj}|\tau_{nj}). \tag{2.5}$$

Außerdem gelte $\mathbb{E}(y_{ij}|\tau_{ij}) = \tau_{ij}$ für alle $i = 1, ..., n$ und $j = 1, ..., m$.

•

Die Definition des Modells multipler Testmessungen bildet einige grundlegende Annahmen zur Unabhängigkeit und Identität von Verteilungen in der klassischen Testtheorie ab. Zunächst einmal wird angenommen, dass die gemeinsame Verteilung der τ_{ij} und y_{ij} über $i = 1, ..., n$ faktorisiert, dass die Verteilungen der wahren Werte und beobachteten Werte also über Personen unabhängig sind. Wissen um wahre oder beobachtete Werte einer Person ändert die angenommenen Verteilungen der wahren und beobachteten Werte anderer Personen also nicht. Im Gegensatz dazu faktorisiert für jedes $i = 1, ..., n$ die gemeinsame Verteilung der $\tau_{i1}, ..., \tau_{im}$ über Testmessungen $j = 1, ..., m$ nicht notwendigerweise. Die wahren Werte einer Person können also voneinander abhängig sein. Die Kenntnis des wahren Werts bei einer Testmessung kann daher die angenommene Verteilung des wahren Werts bei einer anderen Testmessung derselben Person verändern. In der klassischen Testtheorie werden verschiedene Arten dieser Form von Abhängigkeiten unterschieden und, wie wir später sehen werden, beispielsweise als *Parallelität*, *τ-Äquivalenz* oder *essentielle τ-Äquivalenz* bezeichnet. Weiterhin wird für jede Person $i = 1, ..., n$ angenommen, dass die beobachteten Werte $y_{i1}, ..., y_{im}$ bedingt unabhängig gegeben den Vektor der wahren Werte $(\tau_{i1}, ..., \tau_{im})$ sind. Die bedingte Verteilung von y_{ij} gegeben alle wahren Werte hängt nur von τ_{ij} ab. Ohne diese Konditionierung können die beobachteten Werte verschiedener

Testmessungen statistisch zusammenhängen, weil ihre wahren Werte zusammenhängen können.

Schließlich wird angenommen, dass die Marginalverteilungen

$$\mathbb{P}(\tau_{i1}, y_{i1}, ..., \tau_{im}, y_{im}) = \mathbb{P}(\tau_{i1}, ..., \tau_{im}) \prod_{j=1}^{m} \mathbb{P}(y_{ij}|\tau_{ij}) \tag{2.6}$$

über Personen $i = 1, ..., n$ identisch sind. Man kann sich die wahren und beobachteten Werte der verschiedenen Personen also als unabhängige Realisierungen aus derselben „Populationsverteilung“

$$\mathbb{P}(\tau_{\bullet 1}, y_{\bullet 1}, ..., \tau_{\bullet m}, y_{\bullet m}) = \mathbb{P}(\tau_{\bullet 1}, ..., \tau_{\bullet m}) \prod_{j=1}^{m} \mathbb{P}(y_{\bullet j}|\tau_{\bullet j}) \tag{2.7}$$

vorstellen, wobei das Subskript $\bullet$ die Unspezifität dieser Verteilung bezüglich einer Person symbolisieren soll.

Betrachtet man den Spezialfall einer einzelnen Testmessung bei n Personen, so ergibt sich eine vereinfachte Form von Definition 2.2, auf die man häufig in der psychologischen Literatur trifft. Nach Definition 2.2 gilt für eine Testmessung, also $m = 1$,

$$\mathbb{P}\left(\tau_{11}, y_{11}, ..., \tau_{n1}, y_{n1}\right) := \prod_{i=1}^{n} \left(\mathbb{P}(\tau_{i1})\mathbb{P}(y_{i1}|\tau_{i1})\right), \tag{2.8}$$

wobei nach Annahme von Definition 2.2 die gemeinsamen Marginalverteilungen $\mathbb{P}(\tau_{i1}, y_{i1})$ über Personen $i = 1, ..., n$ identisch sind. Wie oben kann man sich die wahren und beobachteten Werte für eine Testmessung also als unabhängige Realisierungen der „Populationsverteilung“

$$\mathbb{P}(\tau_{\bullet 1})\mathbb{P}(y_{\bullet 1}|\tau_{\bullet 1}) \tag{2.9}$$

vorstellen. Verzichtet man nun noch auf die Subskripte $\bullet 1$, gelangt man zu folgender vereinfachter Definition des Modells der klassischen Testtheorie.

Definition 2.3 (Vereinfachtes Modell der klassischen Testtheorie)**.** τ sei eine Zufallsvariable, die die Verteilung der *wahren Werte* einer Testmessung in einer Population von Individuen beschreibt und y sei eine Zufallsvariable, die die Verteilung der *beobachteten Werte* dieser Testmessung beschreibt. Dann heißt die gemeinsame Verteilung von τ und y

$$\mathbb{P}\left(\tau, y\right) = \mathbb{P}(\tau)\mathbb{P}(y|\tau) \tag{2.10}$$

das *vereinfachte Modell der klassischen Testtheorie*. Dabei gelte $\mathbb{E}(y|\tau) = \tau$.

•

Definition 2.3 hat gegenüber Definition 2.2 den Vorteil, dass weniger Zufallsvariablen und Indizes auftreten und auf die Redundanz der unterschiedlichen Bezeichnung vieler gleicher Verteilungen verzichtet werden kann. Im Sinne frequentistischer Produktmodelle mag man bezüglich der Daten von n Personen hier auch

$$(\tau_1, y_1), ..., (\tau_n, y_n) \sim \mathbb{P}(\tau, y) \tag{2.11}$$

schreiben, wobei nur die $y_1, ..., y_n$ beobachtete, die $\tau_1, ..., \tau_n$ dagegen latente Zufallsvariablen sind. Weiterhin gilt, dass man viele wichtige Eigenschaften des Modells der klassischen Testtheorie schon basierend auf den Eigenschaften von $\mathbb{P}(\tau, y)$ begründen kann, wie wir unten sehen werden. Generell ist das vereinfachte Modell der klassischen Testtheorie einfacher zu handhaben als das Modell multipler Testmessungen. Problematisch wird es allerdings, sobald mehrere Testmessungen ins Spiel kommen, beispielsweise bei Abhängigkeitsbetrachtungen zwischen zwei Tests oder zwei Items eines Tests. Dies ist allerdings bei den meisten Aussagen der klassischen Testtheorie der Fall. Außerdem gilt auch, dass Schätzer der Modellparameter immer auf allen Werten der beobachteten Zufallsvariablen $y_{1j}, ...y_{nj}$ beruhen, diese in Definition 2.3 aber überhaupt nicht auftreten. Definition 2.3 ist für theoretische Betrachtungen also oft einfacher zu handhaben als Definition 2.2, der Anwendung der klassischen Testtheorie in der Testdatenanalyse liegt im Allgemeinen aber Definition 2.2 zugrunde. Wir werden je nach Bedarf zwischen beiden Modellformulierungen hin und her wechseln, halten aber fest, dass die Modellformulierung im Sinne von Definition 2.2 unser Standardfall ist.

Eigenschaften des Modells multipler Testmessungen

Eigenschaften bezüglich einer Testmessung

Das Modell multipler Testmessungen nach Definition 2.2 hat zunächst eine Reihe von Eigenschaften bezüglich einer und damit jeder Testmessung, die für die Anwendung der klassischen Testtheorie grundlegend sind. Wir fassen fünf dieser Eigenschaften in folgendem Theorem zusammen.

Theorem 2.1 (Eigenschaften bezüglich einer Testmessung)**.** *Gegeben sei das Modell multipler Testmessungen. Dann gelten für alle* $i = 1, ..., n$ *und alle* $j = 1, ..., m$

(1) $\mathbb{E}(\varepsilon_{ij}|\tau_{ij} = t_{ij}) = 0$
(2) $\mathbb{E}(\varepsilon_{ij}) = 0$
(3) $\mathbb{C}(\tau_{ij}, \varepsilon_{ij}) = 0$
(4) $\mathbb{V}(y_{ij}) = \mathbb{V}(\tau_{ij}) + \mathbb{V}(\varepsilon_{ij})$
(5) $\mathbb{C}(y_{ij}, \tau_{ij}) = \mathbb{V}(\tau_{ij})$

∘

Beweis. Zur Vereinfachung der Notation im Sinne des einfachen Modells der klassischen Testtheorie nach Definition 2.3 setzen wir zunächst für alle $i = 1, ..., n$ und $j = 1, ...m$

$$y := y_{ij} \text{ und } \tau := \tau_{ij} \text{ mit Ergebnisräumen } \mathcal{Y} := \mathcal{Y}_{ij} \text{ und } \mathcal{T} := \mathcal{T}_{ij}. \tag{2.12}$$

Die Werte von τ bezeichnen wir mit t. Schließlich betrachten wir nur den diskreten Fall, setzen also die Existenz einer WMF $p : \mathcal{Y} \times \mathcal{T} \to [0, 1]$ der Form

$$p(t, y) = p(y|t)p(t) \tag{2.13}$$

voraus. Der kontinuierliche Fall oder gemischt diskret-kontinuierliche Fall folgt dann jeweils analog.

(1) Es gilt

$$\begin{aligned}\mathbb{E}(\varepsilon|\tau=t) &:= \mathbb{E}(y-\tau|\tau=t)\\ &= \sum_{y\in\mathcal{Y}}(y-t)\,p(y|t)\\ &= \sum_{y\in\mathcal{Y}} yp(y|t) - \sum_{y\in\mathcal{Y}} tp(y|t)\\ &= \mathbb{E}(y|\tau=t) - t\sum_{y\in\mathcal{Y}} p(y|t)\\ &= t - t\cdot 1\\ &= 0.\end{aligned} \tag{2.14}$$

(2) Es gilt

$$\begin{aligned}\mathbb{E}(\varepsilon) &:= \mathbb{E}(y-\tau)\\ &= \sum_{t\in\mathcal{T}}\sum_{y\in\mathcal{Y}}(y-t)\,p(t,y)\\ &= \sum_{t\in\mathcal{T}}\sum_{y\in\mathcal{Y}}(y-t)\,p(y|t)p(t)\\ &= \sum_{t\in\mathcal{T}}\sum_{y\in\mathcal{Y}}(yp(y|t)p(t) - tp(y|t)p(t))\\ &= \sum_{t\in\mathcal{T}}\sum_{y\in\mathcal{Y}}p(t)\,(yp(y|t) - tp(y|t))\\ &= \sum_{t\in\mathcal{T}}p(t)\left(\sum_{y\in\mathcal{Y}}yp(y|t) - t\sum_{y\in\mathcal{Y}}p(y|t)\right)\\ &= \sum_{t\in\mathcal{T}}p(t)\,(t-t\cdot 1)\\ &= \sum_{t\in\mathcal{T}}p(t)\cdot 0\\ &= 0.\end{aligned} \tag{2.15}$$

(3) Es gilt

$$\begin{aligned}\mathbb{C}(\tau,\varepsilon) &= \mathbb{E}\left((\tau-\mathbb{E}(\tau))(\varepsilon-\mathbb{E}(\varepsilon))\right)\\ &= \mathbb{E}\left((\tau-\mathbb{E}(\tau))\varepsilon\right)\\ &= \mathbb{E}\left((\tau-\mathbb{E}(\tau))(y-\tau)\right)\\ &= \sum_{t\in\mathcal{T}}\sum_{y\in\mathcal{Y}}\left((t-\mathbb{E}(\tau))(y-t)\right)p(t,y)\\ &= \sum_{t\in\mathcal{T}}\sum_{y\in\mathcal{Y}}(t-\mathbb{E}(\tau))(y-t)p(y|t)p(t)\\ &= \sum_{t\in\mathcal{T}}p(t)(t-\mathbb{E}(\tau))\sum_{y\in\mathcal{Y}}(y-t)\,p(y|t)\\ &= \sum_{t\in\mathcal{T}}p(t)(t-\mathbb{E}(\tau))\sum_{y\in\mathcal{Y}}(yp(y|t)-tp(y|t))\\ &= \sum_{t\in\mathcal{T}}p(t)(t-\mathbb{E}(\tau))\left(\sum_{y\in\mathcal{Y}}yp(y|t) - t\sum_{y\in\mathcal{Y}}p(y|t)\right)\\ &= \sum_{t\in\mathcal{T}}p(t)(t-\mathbb{E}(\tau))\,(t-t\cdot 1)\\ &= \sum_{t\in\mathcal{T}}p(t)(t-\mathbb{E}(\tau))\cdot 0\\ &= 0.\end{aligned} \tag{2.16}$$

(4) Mit dem Theorem zu Varianzen von Summen und Differenzen von Zufallsvariablen (Theorem A.3) sowie Aussage (3) des vorliegenden Theorems gilt

$$\mathbb{V}(y) = \mathbb{V}(\tau+\varepsilon) = \mathbb{V}(\tau) + \mathbb{V}(\varepsilon) + 2\mathbb{C}(\tau,\varepsilon) = \mathbb{V}(\tau) + \mathbb{V}(\varepsilon) + 2\cdot 0 = \mathbb{V}(\tau) + \mathbb{V}(\varepsilon) \tag{2.17}$$

(5) Mit dem Kovarianzverschiebungssatz (Theorem A.4), der Linearkombinationseigenschaft des Erwartungswerts (Theorem A.1), Aussage (2) des vorliegenden Theorems und der Tatsache, dass mit Aussage (4) des vorliegenden Theorems außerdem folgt, dass

$$\mathbb{E}(\varepsilon\tau) = \mathbb{E}(\tau\varepsilon) = \mathbb{C}(\tau, \varepsilon) + \mathbb{E}(\tau)\mathbb{E}(\varepsilon) = 0 + \mathbb{E}(\tau) \cdot 0 = 0, \tag{2.18}$$

gilt

$$\begin{aligned}
\mathbb{C}(y, \tau) &= \mathbb{E}(y\tau) - \mathbb{E}(y)\mathbb{E}(\tau) \\
&= \mathbb{E}((\tau + \varepsilon)\tau) - \mathbb{E}(\tau + \varepsilon)\mathbb{E}(\tau) \\
&= \mathbb{E}(\tau^2 + \varepsilon\tau) - (\mathbb{E}(\tau) + \mathbb{E}(\varepsilon))\,\mathbb{E}(\tau) \\
&= \mathbb{E}(\tau^2) + \mathbb{E}(\varepsilon\tau) - \mathbb{E}(\tau)^2 - \mathbb{E}(\varepsilon)\mathbb{E}(\tau) \\
&= \mathbb{E}(\tau^2) + \mathbb{E}(\varepsilon\tau) - \mathbb{E}(\tau)^2 - 0 \cdot \mathbb{E}(\tau) \\
&= \mathbb{E}(\tau^2) + 0 - \mathbb{E}(\tau)^2 - 0 \cdot \mathbb{E}(\tau) \\
&= \mathbb{E}(\tau^2) - \mathbb{E}(\tau)^2 \\
&= \mathbb{V}(\tau).
\end{aligned} \tag{2.19}$$

□

Wie die Subskripte in Theorem 2.1 verdeutlichen, beziehen sich die Aussagen von Theorem 2.1 auf die Zufallsvariablen zur Modellierung der Daten einer Person i und einer Testmessung j und gelten gleichermaßen für alle $i = 1, ..., n$ und $j = 1, ..., m$. Aussage (1) von Theorem 2.1 betrifft den Erwartungswert des Messfehlers bedingt auf einen festen wahren Wert, in diesem Fall ist der wahre Wert also *keine* Zufallsvariable und die Verteilung von Interesse ist $\mathbb{P}(\varepsilon_{ij}|\tau_{ij} = t_{ij})$. Aussagen (2) bis (5) beziehen sich auf Eigenschaften der (gemeinsamen) Marginalverteilungen von y_{ij}, τ_{ij} und ε_{ij}. Im Sinne des vereinfachten Modells der klassischen Testtheorie (Definition 2.3) werden obige Eigenschaften oft auch als

(1) $\mathbb{E}(\varepsilon|\tau = t) = 0$
(2) $\mathbb{E}(\varepsilon) = 0$
(3) $\mathbb{C}(\tau, \varepsilon) = 0$
(4) $\mathbb{V}(y) = \mathbb{V}(\tau) + \mathbb{V}(\varepsilon)$
(5) $\mathbb{C}(y, \tau) = \mathbb{V}(\tau)$

geschrieben.

Insbesondere *folgt* nach Aussage (1) von Theorem 2.1 für das Modell multipler Messungen, dass der bedingte Erwartungswert des Messfehlers $\mathbb{E}(\varepsilon|\tau = t)$ gleich null ist. Dies folgt aus der Bedingung $\mathbb{E}(y|\tau) = \tau$ und der Definition $\varepsilon := y - \tau$. Dies steht im direkten Gegenentwurf zu typischen Annahmen über Messfehler, die üblicherweise einen Messfehler mit einem (bedingten) Erwartungswert von null *definieren*, da sie von null verschiedene Beiträge zu einem Datenpunkt als Teil der durch sie repräsentierten Theorie konzeptualisieren. Weil im Modell multipler Testmessungen der bedingte Erwartungswert des Messfehlers für *jeden* wahren Wert t gleich null ist, folgt dann nach (2) von Theorem 2.1, dass auch der marginale Erwartungswert des Messfehlers $\mathbb{E}(\varepsilon)$ gleich null ist.

Sofern $\mathbb{V}(\tau) > 0$ und $\mathbb{V}(\varepsilon) > 0$ gelten, folgt aus $\mathbb{C}(\tau, \varepsilon) = 0$ auch $\rho(\tau, \varepsilon) = 0$.

Aussage (3) von Theorem 2.1, dass im Modell multipler Testmessungen also gilt, dass die Kovarianz der wahren Werte und der Messfehler gleich null ist, besagt bekanntlich, dass hohe oder niedrige wahre Werte nicht systematisch mit hohen oder niedrigen Messfehlern assoziiert sind. Die daraus folgenden Aussagen (4) und (5) von Theorem 2.1, dass also die Varianz der beobachteten Werte additiv in Varianzbeiträge der wahren Werte und der

Messfehler zerlegt werden kann und dass die Kovarianz der beobachteten Werte und der wahren Werte einer Testmessung der Varianz der wahren Werte entspricht, werden an späterer Stelle essentiell für die Eigenschaften der Reliabilität von Testmessungen sein.

Beispiel 2.1 (Normalverteilungsbeispiel für eine Testmessung)**.** Im Folgenden wollen wir Theorem 2.1 noch an einem konkreten ersten Beispiel nach Lord & Novick (1968), Exercise 2.17 für ein Modell multipler Testmessungen veranschaulichen, wobei wir hierbei natürlich auf eine einzige Testmessung fokussieren.

Es seien $i = 1, ..., n$ und $m := 1$ mit

$$\mathbb{P}(\tau_{i1}) := N(\mu, 1) \text{ und } \mathbb{P}(y_{i1}|\tau_{i1}) := N(\tau_{i1}, 1) \tag{2.20}$$

Dann gelten

(1) $\mathbb{P}(y_{i1}) = N(\mu, 2)$
(2) $\mathbb{P}(\varepsilon_{i1}|\tau_{i1}) = N(0, 1)$
(3) $\mathbb{P}(\varepsilon_{i1}) = N(0, 1)$
(4) $\mathbb{C}(\tau_{i1}, \varepsilon_{i1}) = 0$

△

Beweis. Zur Vereinfachung der Notation setzen wir $\tau := \tau_{i1}, y := y_{i1}, \varepsilon := \varepsilon_{i1}$.

(1) Wir betrachten die durch

$$\mathbb{P}(\tau) = N(\mu, 1) \text{ und } \mathbb{P}(y|\tau) = N(\tau, 1) \tag{2.21}$$

induzierte gemeinsame Verteilung von τ und y, wobei offenbar

$$\mathbb{P}(y|\tau) = N(a \cdot \tau + b, 1) \text{ mit } a := 1 \text{ und } b := 0 \tag{2.22}$$

gilt. Aus dem Theorem zu gemeinsamen Normalverteilungen (vgl. Theorem A.13) ergibt sich dann zunächst, dass

$$\begin{pmatrix}\tau\\ y\end{pmatrix} \sim N\left(\begin{pmatrix}\mu\\ 1\cdot\mu+0\end{pmatrix}, \begin{pmatrix}1 & 1\cdot 1\\ 1\cdot 1 & 1+1\cdot 1\cdot 1\end{pmatrix}\right) = N\left(\begin{pmatrix}\mu\\ \mu\end{pmatrix}, \begin{pmatrix}1 & 1\\ 1 & 2\end{pmatrix}\right) \tag{2.23}$$

Aus dem Theorem zu marginalen Normalverteilungen (vgl. Theorem A.14) ergibt sich dann durch Ablesen $y \sim N(\mu, 2)$.

(2) Wir betrachten $\mathbb{P}(\varepsilon|\tau = t)$ für einen beliebigen Wert $t \in \mathbb{R}$. Dann gilt

$$\varepsilon := y - t \text{ mit } y \sim N(t, 1) \tag{2.24}$$

Mit dem Theorem zu linear-affinen Transformationen normalverteilter Zufallsvariablen (vgl. Theorem A.15) gilt dann

$$\varepsilon \sim N\left(t - t, 1^2 \cdot 1\right) = N(0, 1) \tag{2.25}$$

Die Tatsache, dass dies für alle möglichen Werte von τ gilt, ist gerade Aussage (2).

(3) und (4) Wir betrachten die durch

$$\mathbb{P}(\tau) = N(\mu, 1) \text{ und } \mathbb{P}(\varepsilon|\tau) = N(0, 1) \tag{2.26}$$

induzierte gemeinsame Verteilung von τ und ε, wobei offenbar

$$\mathbb{P}(\varepsilon|\tau) = N(a \cdot \tau + b, 1) \text{ mit } a := 0 \text{ und } b := 0 \tag{2.27}$$

gilt. Aus dem Theorem zu gemeinsamen Normalverteilungen (vgl. Theorem A.13) ergibt sich dann zunächst, dass

$$\begin{pmatrix}\tau\\ \varepsilon\end{pmatrix} \sim N\left(\begin{pmatrix}\mu\\ 0\cdot\mu+0\end{pmatrix}, \begin{pmatrix}1 & 1\cdot 0\\ 0\cdot 1 & 1+0\cdot 1\cdot 0\end{pmatrix}\right) = N\left(\begin{pmatrix}\mu\\ 0\end{pmatrix}, \begin{pmatrix}1 & 0\\ 0 & 1\end{pmatrix}\right) \tag{2.28}$$

Aus dem Theorem zu marginalen Normalverteilungen (vgl. Theorem A.14) ergeben sich dann durch Ablesen

$$\varepsilon \sim N(0, 1) \text{ und } \mathbb{C}(\tau, \varepsilon) = 0. \tag{2.29}$$

□

Das Beispiel zeigt insbesondere, wie die Spezifika des Modells multipler Testmessungen der klassischen Testtheorie äquivalent durch Definition eines zeitgemäßen probabilistischen Modells erzeugt werden können. Hier induzieren die Definition der marginalen Verteilung des wahren Werts und die Definition der bedingten Verteilung des beobachteten Werts zunächst die gemeinsame Normalverteilung von τ_{i1} und y_{i1}. Die Definition des Messfehlers als Differenz zwischen beobachtetem Wert und dessen bedingtem Erwartungswert bei gegebenem wahren Wert ergibt dann die bedingte Verteilung des Messfehlers. Diese und die Definitionen des Beispiels induzieren dann eine gemeinsame Normalverteilung von τ_{i1} und ε_{i1}. Die weiteren Eigenschaften im Sinne von Theorem 2.1 ergeben sich in diesem Beispiel dann mit den Eigenschaften gemeinsamer Normalverteilungen.

Mithilfe folgender Simulation wollen wir das hier diskutierte Beispiel noch weiter verdeutlichen. Wir setzen dafür $\mu := 1$ und generieren 10^4 Realisierungen der marginalen Verteilung von τ_{i1} und der bedingten Verteilung von y_{i1}.

```
# Modellformulierung
n            = 1e4                                  # Personenanzahl
m            = 1                                    # Testmessungsanzahl
mu           = 1                                    # Erwartungswertparameter der wahren Werte
Tau          = matrix(rep(NaN, n*m), nrow = n)      # Array der wahren Werte
Y            = matrix(rep(NaN, n*m), nrow = n)      # Array der beobachteten Werte
E            = matrix(rep(NaN, n*m), nrow = n)      # Array der Messfehler

# Modellsimulation
for(i in 1:n){                                      # Iteration über Personen
  for(j in 1:m){                                    # Iteration über Testmessungen
    Tau[i,j] = rnorm(1,mu,1)                        # Realisierung des wahren Werts
    Y[i,j]   = rnorm(1,Tau[i,j],1)                  # Realisierung des beobachteten Werts
    E[i,j]   = Y[i,j] - Tau[i,j]}}                  # Realisierung des Messfehlers

# Modelleigenschaftsschätzung
e_hat_es     = mean(E[,1])                          # Erwartungswertschätzung der Messfehler
c_hat_ts_es  = cov(Tau[,1],E[,1])                   # Kovarianzschätzung: wahrer Wert und Messfehler
v_hat_os     = var(Y[,1])                           # Varianzschätzung der beobachteten Werte
v_hat_ts     = var(Tau[,1])                         # Varianzschätzung der wahren Werte
v_hat_es     = var(E[,1])                           # Varianzschätzung der Messfehler
c_hat_os_ts  = cov(Y[,1],E[,1])                     # Kovarianzschätzung: beobachteter Wert und Messfehler
```

Abbildung 2.1 A und B zeigen die resultierenden marginalen Verteilungen von y_{i1} und ε_{i1} mit ihren theoretischen Entsprechungen laut Beispiel 2.1. Abbildung 2.1 C zeigt die gemeinsame Verteilung von τ_{i1} und ε_{i1} mit ihrer theoretischen Entsprechung. Abbildung 2.1 D schließlich zeigt die auf Grundlage der Simulation gewonnenen Schätzer relevanter Erwartungswerte, Varianzen und Kovarianzen in diesem Modell, die die theoretischen Einsichten nach Beispiel 2.1 bestätigen.

Darstellung als lineares gemischtes Modell

Das Normalverteilungsmodell lässt sich auch als lineares gemischtes Modell darstellen. Für fünf Personen schreiben wir den wahren Wert als gemeinsamen Erwartungswert μ plus personenspezifischer Abweichung η_i:

$$\begin{aligned} \tau_{i1} &= \mu + \eta_i, \\ y_{i1} &= \tau_{i1} + \varepsilon_{i1} = \mu + \eta_i + \varepsilon_{i1}, \qquad i = 1, \dots, 5. \end{aligned} \tag{2.30}$$

Dabei sind η_i und ε_{i1} unabhängig und jeweils standardnormalverteilt. Auch die Zufallsvariablen verschiedener Personen sind unabhängig. Die Abweichung η_i beschreibt den zufälligen Personeneffekt, ε_{i1} den Messfehler.

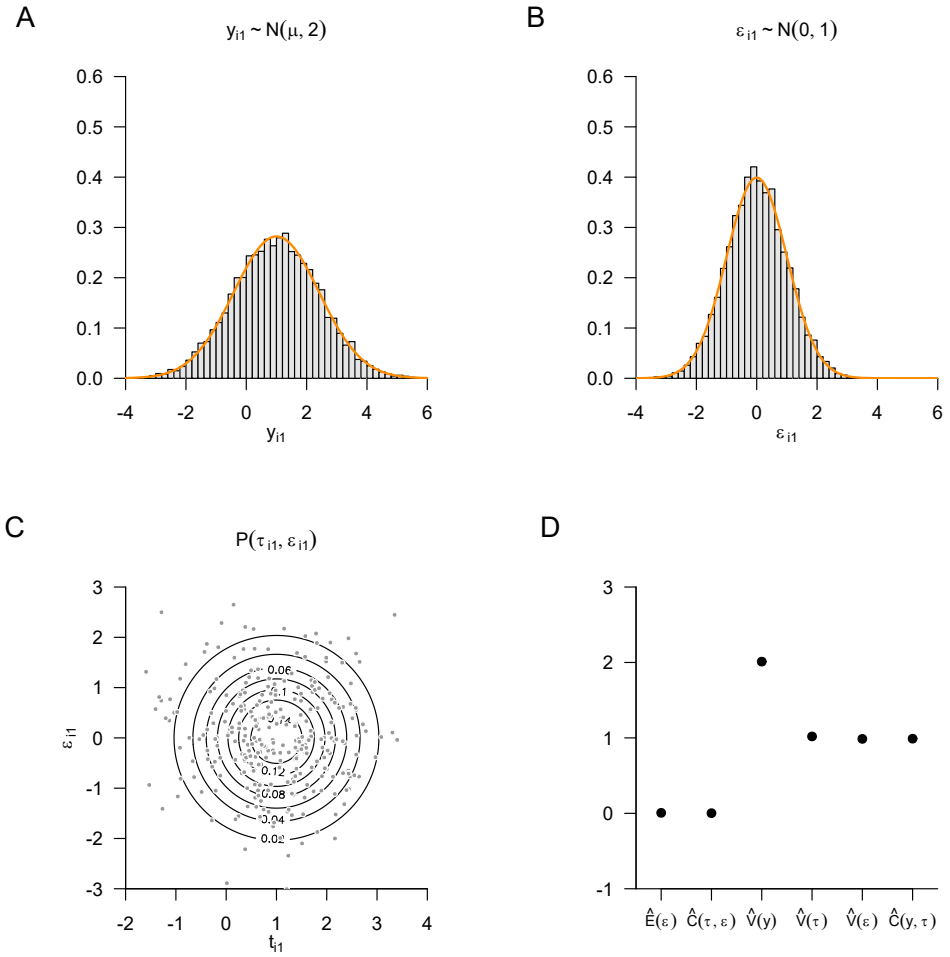


Abbildung 2.1. Normalverteilungsbeispiel bezüglich einer Testmessung.

Eigenschaften bezüglich zweier Testmessungen

Bisher haben wir fünf Eigenschaften des Modells multipler Testmessungen kennengelernt, die für den wahren Wert τ_{ij}, den beobachteten Wert y_{ij} und den Messfehler ε_{ij} einer (und damit jeder) Person i und einer (und damit jeder) Testmessung j gelten. Im Folgenden beschäftigen wir uns mit Eigenschaften des Modells multipler Testmessungen, die für die wahren Werte τ_{ij} und τ_{ik}, beobachteten Werte y_{ij} und y_{ik} und Messfehler ε_{ij} und ε_{ik} einer (und damit jeder) Person i hinsichtlich *zweier* Testmessungen j und k gelten. Wir fassen diese Eigenschaften, die manchmal als *lokale Unkorreliertheit* des Modells multipler Testmessungen bezeichnet werden (vgl. Krauth (1995)), im folgenden Theorem zusammen.

Theorem 2.2 (Eigenschaften bezüglich zweier Testmessungen)**.** *Gegeben sei das Modell multipler Testmessungen. Für alle $i = 1, \dots, n$ und alle j, k mit $1 \leq j, k \leq m$ und $j \neq k$ gelten die folgenden Aussagen:*

(1) $\mathbb{C}(y_{ij}, y_{ik} | \tau_{ij} = t_{ij}, \tau_{ik} = t_{ik}) = 0$
(2) $\mathbb{C}(\varepsilon_{ij}, \varepsilon_{ik} | \tau_{ij} = t_{ij}, \tau_{ik} = t_{ik}) = 0$
(3) $\mathbb{C}(\varepsilon_{ij}, \varepsilon_{ik}) = 0$
(4) $\mathbb{C}(\tau_{ij}, \varepsilon_{ik}) = 0$

(5) $\mathbb{C}(y_{ij}, y_{ik}) = \mathbb{C}(\tau_{ij}, \tau_{ik})$

∘

Beweis. Zur Vereinfachung der Notation verzichten wir in den Beweisen auf den Personenindex i. Wir betrachten weiterhin nur den diskreten Fall und setzen die Existenz der marginalen WMF

$$p(t_j, y_j, t_k, y_k) = p(t_j, t_k)p(y_j|t_j)p(y_k|t_k) \tag{2.31}$$

und folglich auch der bedingten Wahrscheinlichkeitsmassefunktion

$$p(y_j, y_k|t_j, t_k) = \frac{p(t_j, y_j, t_k, y_k)}{p(t_j, t_k)} = \frac{p(t_j, t_k)p(y_j|t_j)p(y_k|t_k)}{p(t_j, t_k)} = p(y_j|t_j)p(y_k|t_k) \tag{2.32}$$

voraus. Der kontinuierliche Fall folgt dann wieder analog.

(1) Es gilt

$$\begin{aligned}
\mathbb{C}(y_j, y_k|\tau_j = t_j, \tau_k = t_k) &= \sum_{y_j \in \mathcal{Y}_j} \sum_{y_k \in \mathcal{Y}_k} (y_j - \mathbb{E}(y_j|\tau_j = t_j))(y_k - \mathbb{E}(y_k|\tau_k = t_k))p(y_j|t_j)p(y_k|t_k) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \sum_{y_k \in \mathcal{Y}_k} (y_k - t_k)p(y_k|t_k) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \left(\sum_{y_k \in \mathcal{Y}_k} y_k p(y_k|t_k) - t_k \sum_{y_k \in \mathcal{Y}_k} p(y_k|t_k) \right) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \left(t_k - t_k \cdot 1\right) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \cdot 0 \\
&= 0.
\end{aligned} \tag{2.33}$$

(2) Wir bestimmen zunächst $\mathbb{E}(\varepsilon_j\varepsilon_k|\tau_j = t_j, \tau_k = t_k)$. Es gilt

$$\begin{aligned}
\mathbb{E}(\varepsilon_j\varepsilon_k|\tau_j = t_j, \tau_k = t_k) &= \mathbb{E}((y_j - \tau_j)(y_k - \tau_k)|\tau_j = t_j, \tau_k = t_k) \\
&= \sum_{y_j \in \mathcal{Y}_j} \sum_{y_k \in \mathcal{Y}_k} (y_j - t_j)(y_k - t_k)p(y_j|t_j)p(y_k|t_k) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \sum_{y_k \in \mathcal{Y}_k} (y_k - t_k)p(y_k|t_k) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \left(\sum_{y_k \in \mathcal{Y}_k} y_k p(y_k|t_k) - t_k \sum_{y_k \in \mathcal{Y}_k} p(y_k|t_k) \right) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \left(t_k - t_k \cdot 1\right) \\
&= \sum_{y_j \in \mathcal{Y}_j} (y_j - t_j)p(y_j|t_j) \cdot 0 \\
&= 0.
\end{aligned} \tag{2.34}$$

Mit dem Verschiebungssatz der bedingten Kovarianz (Theorem A.5) und Aussage (1) des Theorems zu den Eigenschaften bezüglich einer Testmessung (Theorem 2.1) folgt dann

$$\mathbb{C}(\varepsilon_j, \varepsilon_k|\tau_j = t_j, \tau_k = t_k) = \mathbb{E}(\varepsilon_j\varepsilon_k|\tau_j = t_j, \tau_k = t_k) - \mathbb{E}(\varepsilon_j|\tau_j = t_j)\mathbb{E}(\varepsilon_k|\tau_k = t_k) = 0 - 0 \cdot 0 = 0. \tag{2.35}$$

(3) Wir bestimmen zunächst $\mathbb{E}(\varepsilon_j\varepsilon_k)$. Mit dem Beweis von Aussage (2) des vorliegenden Theorems ergibt

sich

$$\begin{aligned}
\mathbb{E}(\varepsilon_j\varepsilon_k) &= \mathbb{E}((y_j-\tau_j)(y_k-\tau_k)) \\
&= \sum_{t_j\in\mathcal{T}_j}\sum_{t_k\in\mathcal{T}_k}\sum_{y_j\in\mathcal{Y}_j}\sum_{y_k\in\mathcal{Y}_k}(y_j-t_j)(y_k-t_k)p(y_j|t_j)p(y_k|t_k)p(t_j,t_k) \\
&= \sum_{t_j\in\mathcal{T}_j}\sum_{t_k\in\mathcal{T}_k}\sum_{y_j\in\mathcal{Y}_j}\sum_{y_k\in\mathcal{Y}_k}(y_j-\mathbb{E}(y_j|\tau_j=t_j))(y_k-\mathbb{E}(y_k|\tau_k=t_k))p(y_j|t_j)p(y_k|t_k)p(t_j,t_k) \\
&= \sum_{t_j\in\mathcal{T}_j}\sum_{t_k\in\mathcal{T}_k}\mathbb{E}\left((y_j-\tau_j)(y_k-\tau_k)|\tau_j=t_j,\tau_j=t_j\right)p(t_j,t_k) \\
&= \sum_{t_j\in\mathcal{T}_j}\sum_{t_k\in\mathcal{T}_k}\mathbb{E}\left(\varepsilon_j\varepsilon_k|\tau_j=t_j,\tau_j=t_j\right)p(t_j,t_k) \\
&= \sum_{t_j\in\mathcal{T}_j}\sum_{t_k\in\mathcal{T}_k}0\cdot p(t_j,t_k) \\
&= 0.
\end{aligned} \tag{2.36}$$

Mit dem Kovarianzverschiebungssatz (Theorem A.4) und Aussage (2) des Theorems zu den Eigenschaften bezüglich einer Testmessung (Theorem 2.1) ergibt sich dann

$$\mathbb{C}(\varepsilon_j,\varepsilon_k) = \mathbb{E}(\varepsilon_j\varepsilon_k) - \mathbb{E}(\varepsilon_j)\mathbb{E}(\varepsilon_k) = 0 - 0\cdot 0 = 0. \tag{2.37}$$

(4) Mit dem Kovarianzverschiebungssatz (Theorem A.4) und Aussage (2) des Theorems zu den Eigenschaften bezüglich einer Testmessung (Theorem 2.1) gilt

$$\begin{aligned}
\mathbb{C}(\tau_j,\varepsilon_k) &= \mathbb{E}(\tau_j\varepsilon_k) - \mathbb{E}(\tau_j)\mathbb{E}(\varepsilon_k) \\
&= \mathbb{E}(\tau_j\varepsilon_k) - \mathbb{E}(\tau_j)\cdot 0 \\
&= \mathbb{E}(\tau_j(y_k-\tau_k)) \\
&= \sum_{t_j\in\mathcal{T}_j}\sum_{t_k\in\mathcal{T}_k}\sum_{y_k\in\mathcal{Y}_k} t_j(y_k-t_k)p(y_k|t_k)p(t_j,t_k) \\
&= \sum_{t_j\in\mathcal{T}_j} t_j \sum_{t_k\in\mathcal{T}_k} p(t_j,t_k)\sum_{y_k\in\mathcal{Y}_k}(y_k-t_k)p(y_k|t_k) \\
&= \sum_{t_j\in\mathcal{T}_j} t_j \sum_{t_k\in\mathcal{T}_k} p(t_j,t_k)\left(\sum_{y_k\in\mathcal{Y}_k} y_k p(y_k|t_k) - t_k\sum_{y_k\in\mathcal{Y}_k} p(y_k|t_k)\right) \\
&= \sum_{t_j\in\mathcal{T}_j} t_j \sum_{t_k\in\mathcal{T}_k} p(t_j,t_k)\left(t_k - t_k\cdot 1\right) \\
&= \sum_{t_j\in\mathcal{T}_j} t_j \sum_{t_k\in\mathcal{T}_k} p(t_j,t_k)\cdot 0 \\
&= 0.
\end{aligned} \tag{2.38}$$

(5) Wir halten zunächst fest, dass mit Aussage (4) durch Vertauschen der Indizes und der Symmetrie der Kovarianz auch

$$\mathbb{C}(\tau_k,\varepsilon_j) = \mathbb{C}(\varepsilon_j,\tau_k) = 0 \tag{2.39}$$

gilt. Mit dem Theorem zur paarweisen Addition von Zufallsvariablen (Theorem A.6) und Aussage (3) des vorliegenden Theorems gilt dann

$$\begin{aligned}
\mathbb{C}(y_j,y_k) &= \mathbb{C}(\tau_j+\varepsilon_j,\tau_k+\varepsilon_k) \\
&= \mathbb{C}(\tau_j,\tau_k) + \mathbb{C}(\tau_j,\varepsilon_k) + \mathbb{C}(\varepsilon_j,\tau_k) + \mathbb{C}(\varepsilon_j,\varepsilon_k) \\
&= \mathbb{C}(\tau_j,\tau_k) + 0 + 0 + 0 \\
&= \mathbb{C}(\tau_j,\tau_k).
\end{aligned} \tag{2.40}$$

□

Im Sinne des vereinfachten Modells der klassischen Testtheorie nach Definition 2.3 werden die Aussagen von Theorem 2.2 oft auch als

(1) $\mathbb{C}(y_j,y_k|\tau_j=t_j,\tau_k=t_k)=0$

(2) $\mathbb{C}(\varepsilon_j, \varepsilon_k | \tau_j = t_j, \tau_k = t_k) = 0$
(3) $\mathbb{C}(\varepsilon_j, \varepsilon_k) = 0$
(4) $\mathbb{C}(\tau_j, \varepsilon_k) = 0$
(5) $\mathbb{C}(y_j, y_k) = \mathbb{C}(\tau_j, \tau_k)$

geschrieben. Die ersten beiden Aussagen von Theorem 2.2 besagen, dass, bedingt auf die jeweiligen wahren Werte, die Kovarianzen von beobachteten Werten sowie die Kovarianzen der Messfehler einer Person zwischen zwei Testmessungen gleich null sind. Für die Messfehler gilt dies nach Aussage (3) von Theorem 2.2 auch im Sinne der unbedingten Marginalverteilung. Die Messfehler verschiedener Testmessungen sind somit im Modell multipler Testmessungen paarweise unkorreliert. Weiterhin ist nach Aussage (4) die Kovarianz des wahren Werts bei einer Testmessung mit dem Messfehler einer anderen Testmessung gleich null. Schließlich gilt nach Aussage (5), dass die Kovarianz der beobachteten Werte zweier Testmessungen gleich der Kovarianz der wahren Werte ist.

Beispiel 2.2 (Normalverteilungsbeispiel für zwei Testmessungen)**.** Als erstes Beispiel für ein Modell multipler Testmessungen mit $m > 1$ setzen wir das Beispiel aus Beispiel 2.1 fort und betrachten den Fall zweier Testmessungen $j = 1, 2$. Für $i = 1, ..., n$ seien entsprechend

$$\mathbb{P}(\tau_{i1}, \tau_{i2}) = \mathbb{P}(\tau_{i2} | \tau_{i1}) \mathbb{P}(\tau_{i1}) \tag{2.41}$$

mit

$$\mathbb{P}(\tau_{i1}) := N(1, 1) \text{ und } \mathbb{P}(\tau_{i2} | \tau_{i1}) := N(\tau_{i1} + 1, 0.25) \tag{2.42}$$

Die Verteilung des wahren Werts von Person i in Testmessung $j = 2$ hängt in diesem Beispiel also explizit von der Verteilung des wahren Werts von Person i in Testmessung $j = 1$ ab. Weiterhin seien

$$\mathbb{P}(y_{i1} | \tau_{i1}) := N(\tau_{i1}, 1) \text{ und } \mathbb{P}(y_{i2} | \tau_{i2}) := N(\tau_{i2}, 0.25) \tag{2.43}$$

Die Propensitätsverteilung von Person i bei Testmessung $j = 1$ unterscheidet sich somit von ihrer Propensitätsverteilung bei Testmessung $j = 2$. Folgender **R**-Code generiert 10^5 Realisierungen dieses Modells und schätzt die in Theorem 2.2 betrachteten marginalen Kovarianzen $\mathbb{C}(\varepsilon_{i1}, \varepsilon_{i2})$, $\mathbb{C}(\tau_{i1}, \varepsilon_{i2})$, $\mathbb{C}(y_{i1}, y_{i2})$ und $\mathbb{C}(\tau_{i1}, \tau_{i2})$.

```
# Modellformulierung
n           = 1e5                                  # Personenanzahl
m           = 2                                    # Testmessungsanzahl
mu          = 1                                    # Erwartungswertparameter der wahren Werte
Tau         = matrix(rep(NaN, n*m), nrow = n)      # Array der wahren Werte
Y           = matrix(rep(NaN, n*m), nrow = n)      # Array der beobachteten Werte
E           = matrix(rep(NaN, n*m), nrow = n)      # Array der Messfehler

# Modellsimulation
for(i in 1:n){                                     # Iteration über Personen
    Tau[i,1] = rnorm(1,1,1)                        # Realisierung des wahren Werts für j = 1
    Y[i,1]   = rnorm(1,Tau[i,1],1)                 # Realisierung des beobachteten Werts für j = 1
    E[i,1]   = Y[i,1] - Tau[i,1]                   # Realisierung des Messfehlers für j = 1
    Tau[i,2] = rnorm(1,Tau[i,1] + 1,.5)            # Realisierung des wahren Werts für j = 2
    Y[i,2]   = rnorm(1,Tau[i,2],.5)                # Realisierung des beobachteten Werts für j = 2
    E[i,2]   = Y[i,2] - Tau[i,2]}                  # Realisierung des Messfehlers für j = 2

# Modelleigenschaftsschätzung
c_hat_e1_e2  = cov(E[,1],E[,2])                    # Kovarianzschätzung: Messfehler 1 und 2
c_hat_t1_e2  = cov(Tau[,1],E[,2])                  # Kovarianzschätzung: wahrer Wert 1 und Messfehler 2
c_hat_y1_y2  = cov(Y[,1],Y[,2])                    # Kovarianzschätzung: beobachtete Werte 1 und 2
c_hat_t1_t2  = cov(Tau[,1],Tau[,2])                # Kovarianzschätzung: wahre Werte 1 und 2
```

Abbildung 2.2 visualisiert 500 der so generierten Zufallsvariablenrealisierungen und dokumentiert die resultierenden Kovarianzschätzer. Abbildung 2.2 A zeigt die marginale Unkorreliertheit der Messfehler bezüglich zweier Testmessungen (Aussage (3) von Theorem 2.2), Abbildung 2.2 B zeigt die marginale Unkorreliertheit des wahren Wertes und des Messfehlers bezüglich zweier Testmessungen (Aussage (4) von Theorem 2.2) und Abbildung 2.2 C und Abbildung 2.2 D zeigen die Gleichheit der marginalen Kovarianzen von beobachteten und wahren Werten bezüglich zweier Testmessungen.

△

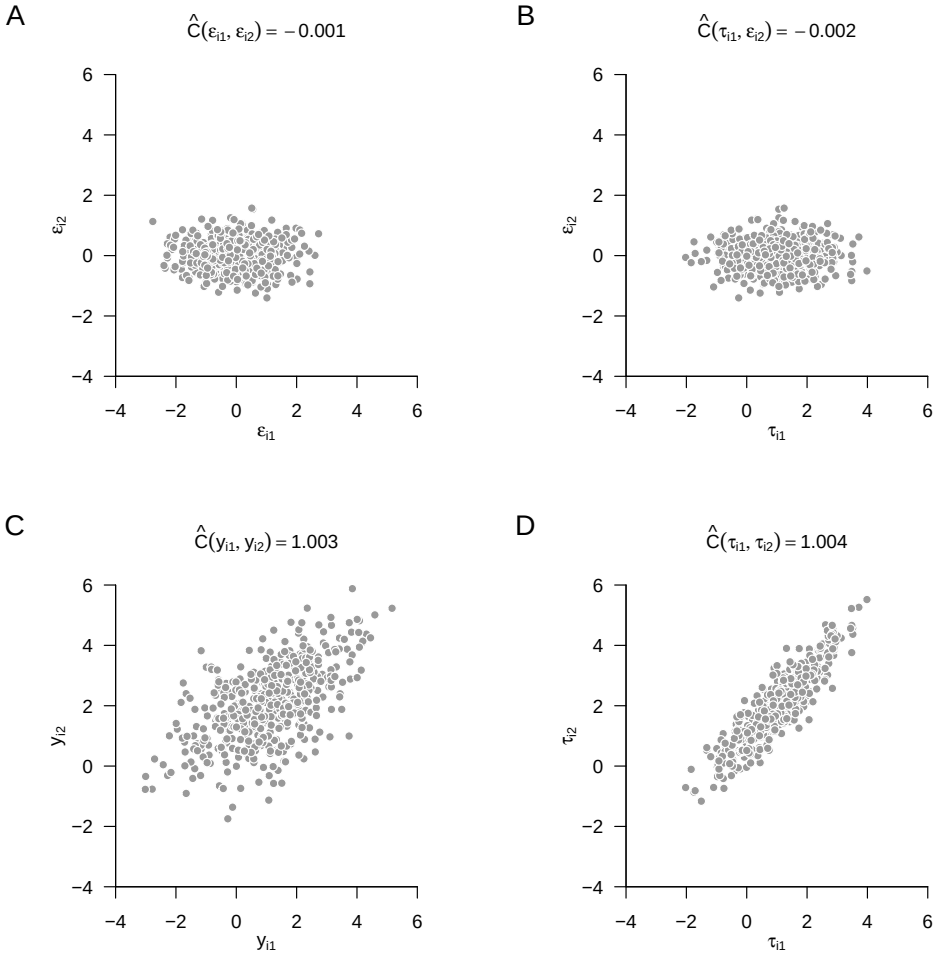


Abbildung 2.2. Normalverteilungsbeispiel bezüglich zweier Testmessungen.

2.2. Das Modell paralleler Testmessungen

Im Modell multipler Testmessungen haben wir bislang offengelassen, wie die wahren Werte einer Person über verschiedene Testmessungen hinweg zusammenhängen. Sie müssen nicht unabhängig sein, die Form ihrer möglichen Abhängigkeiten wurde jedoch noch nicht näher bestimmt. Die klassische Testtheorie betrachtet hierzu verschiedene Spezialfälle. Insbesondere können wir annehmen, dass sich die wahren Werte der weiteren Testmessungen jeweils als Funktion des wahren Werts der ersten Testmessung darstellen lassen.

Im Folgenden betrachten wir zunächst den einfachsten Fall einer solchen funktionalen Beziehung: Die wahren Werte einer Person stimmen über alle Testmessungen hinweg überein. Die zugehörigen Funktionen sind dann jeweils die Identitätsfunktion, die jedem Wert wieder denselben Wert zuordnet. Diese Gleichheit der wahren Werte kennzeichnet τ-äquivalente Testmessungen. Stimmen zusätzlich die Messfehlervarianzen überein, spricht man von parallelen Testmessungen. Im nachfolgend definierten Modell verlangen wir hierzu, dass die bedingten Varianzen der beobachteten Werte bei jedem festen wahren Wert über die Testmessungen hinweg gleich sind. Unterschiede zwischen den beobachteten Werten einer Person gehen in diesem Modell somit allein auf die Messfehler zurück.

Eine allgemeinere funktionale Beziehung ergibt sich, wenn die wahren Werte durch testmessungsspezifische linear-affine Funktionen miteinander verbunden sind. Dann können sich die wahren Werte verschiedener Testmessungen sowohl um eine additive Konstante als auch durch einen von null verschiedenen multiplikativen Faktor unterscheiden. Diese Beziehung charakterisiert die später behandelten essentiell kongenerischen Testmodelle.

Definition 2.4 (Modell paralleler Testmessungen)**.** Für $i = 1, ..., n$ und $j = 1, ..., m$ seien τ_i eine Zufallsvariable, die den wahren Wert der $i$ten Person in jeder Testmessung $j = 1, ..., m$ modelliere, y_{ij} eine Zufallsvariable, die den beobachteten Wert der $i$ten Person in der $j$ten Testmessung modelliere und $\varepsilon_{ij} := y_{ij} - \tau_i$ die Zufallsvariable, die den Messfehler der $i$ten Person in der $j$ten Testmessung modelliere. Dann heißt die gemeinsame Verteilung der τ_i und y_{ij} mit den Faktorisierungseigenschaften

$$\mathbb{P}\left(\tau_1, y_{11}, ...y_{1m}, ..., \tau_n, y_{n1}, ..., y_{nm}\right) := \prod_{i=1}^{n} \left(\mathbb{P}(\tau_i) \prod_{j=1}^{m} \mathbb{P}(y_{ij}|\tau_i) \right) \tag{2.44}$$

das *Modell paralleler Testmessungen*, wenn gilt, dass

(1) $\mathbb{P}(\tau_1) = \cdots = \mathbb{P}(\tau_n)$
(2) $\mathbb{P}(y_{1j}|\tau_1) = \cdots = \mathbb{P}(y_{nj}|\tau_n)$ für alle $1 \leq j \leq m$
(3) $\mathbb{E}(y_{ij}|\tau_i = t_i) = \mathbb{E}(y_{ik}|\tau_i = t_i) := t_i$ für alle $1 \leq i \leq n, 1 \leq j, k \leq m$
(4) $\mathbb{V}(y_{ij}|\tau_i = t_i) = \mathbb{V}(y_{ik}|\tau_i = t_i)$ für alle $1 \leq i \leq n, 1 \leq j, k \leq m$

•

Aus generativer Sicht lässt sich das Modell folgendermaßen beschreiben: Zunächst wird für Person i ein gemeinsamer wahrer Wert t_i aus der Verteilung von τ_i realisiert. Anschließend wird für jede Testmessung $j = 1, \dots, m$ ein beobachteter Wert y_{ij} aus der bedingten Verteilung $\mathbb{P}(y_{ij} \mid \tau_i = t_i)$ erzeugt. Bei gegebenem wahren Wert erfolgen diese Ziehungen unabhängig voneinander.

Eigenschaften des Modells paralleler Testmessungen

Betrachtet man nur eine einzige Testmessung, so hat das Modell paralleler Testmessungen natürlich die gleiche Form wie das Modell multipler Testmessungen. Damit gilt dann aber auch Theorem 2.1 analog für das Modell paralleler Testmessungen. Betrachtet man allerdings mehr als eine Testmessung, so ergeben sich für das Modell paralleler Testmessungen speziellere Eigenschaften, die wir im folgenden Theorem festhalten.

Theorem 2.3 (Eigenschaften des Modells paralleler Testmessungen bezüglich zweier Testmessungen)**.** *Gegeben sei das Modell paralleler Testmessungen. Für alle $i = 1, \dots, n$ und alle j, k mit $1 \leq j, k \leq m$ und $j \neq k$ gelten die folgenden Aussagen:*

(1) $\mathbb{E}(y_{ij}) = \mathbb{E}(y_{ik})$
(2) $\mathbb{V}(y_{ij}) = \mathbb{V}(y_{ik})$
(3) $\mathbb{C}(\varepsilon_{ij}, \varepsilon_{ik}) = 0$
(4) $\mathbb{C}(\tau_i, \varepsilon_{ik}) = 0$
(5) $\mathbb{C}(y_{ij}, y_{ik}) = \mathbb{V}(\tau_i)$

∘

Beweis. Zum Beweis setzen wir zur Vereinfachung der Notation zunächst

$$y_j := y_{ij}, y_k := y_{ik}, \tau := \tau_i, t := t_i, \mathcal{Y}_j := \mathcal{Y}_{ij}, \mathcal{Y}_k := \mathcal{Y}_{ik} \text{ und } \mathcal{T} := \mathcal{T}_i \tag{2.45}$$

für alle $i = 1, \ldots, n$. Wir betrachten weiterhin nur den diskreten Fall, setzen also die Existenz einer Wahrscheinlichkeitsmassefunktion der Form

$$p(t, y_j, y_k) = p(y_j|t)p(y_k|t)p(t) \tag{2.46}$$

voraus. Der kontinuierliche Fall folgt dann analog.

(1) Mit der Gleichheit der bedingten Erwartungswerte im Falle paralleler Testmessungen gilt

$$\mathbb{E}(y_j) = \sum_{t\in\mathcal{T}} \sum_{y_j\in\mathcal{Y}_j} y_j p(y_j|t)p(t) = \sum_{t\in\mathcal{T}} \mathbb{E}(y_j|\tau = t)p(t) = \sum_{t\in\mathcal{T}} \sum_{y_k\in\mathcal{Y}_k} y_k p(y_k|t)p(t) = \mathbb{E}(y_k). \tag{2.47}$$

(2) Mit dem Satz von der iterierten Varianz (Theorem A.7) gilt

$$\mathbb{V}(y_j) = \mathbb{V}\left(\mathbb{E}(y_j|\tau)\right) + \mathbb{E}\left(\mathbb{V}(y_j|\tau)\right) = \mathbb{V}\left(\mathbb{E}(y_k|\tau)\right) + \mathbb{E}\left(\mathbb{V}(y_k|\tau)\right) = \mathbb{V}(y_k). \tag{2.48}$$

(3) Wir bestimmen zunächst $\mathbb{E}(\varepsilon_j\varepsilon_k)$. Mit Aussage (2) von Theorem 2.1 gilt dann

$$\begin{aligned}
\mathbb{E}(\varepsilon_j\varepsilon_k) &:= \mathbb{E}((y_j - \tau)(y_k - \tau)) \\
&= \sum_{t\in\mathcal{T}} \sum_{y_j\in\mathcal{Y}_j} \sum_{y_k\in\mathcal{Y}_k} (y_j - t)(y_k - t)p(t)p(y_j|t)p(y_k|t) \\
&= \sum_{t\in\mathcal{T}} p(t) \sum_{y_j\in\mathcal{Y}_j} \sum_{y_k\in\mathcal{Y}_k} (y_j - t)(y_k - t)p(y_j|t)p(y_k|t) \\
&= \sum_{t\in\mathcal{T}} p(t) \sum_{y_j\in\mathcal{Y}_j} (y_j - t)p(y_j|t) \sum_{y_k\in\mathcal{Y}_k} (y_k - t)p(y_k|t) \\
&= \sum_{t\in\mathcal{T}} p(t) \left(\sum_{y_j\in\mathcal{Y}_j} y_j p(y_j|t) - t \sum_{y_j\in\mathcal{Y}_j} p(y_j|t)\right) \left(\sum_{y_k\in\mathcal{Y}_k} y_k p(y_k|t) - t \sum_{y_k\in\mathcal{Y}_k} p(y_k|t)\right) \\
&= \sum_{t\in\mathcal{T}} p(t)\,(t - t)\,(t - t) \\
&= \sum_{t\in\mathcal{T}} p(t) \cdot 0 \cdot 0 \\
&= 0.
\end{aligned} \tag{2.49}$$

Mit dem Kovarianzverschiebungssatz (Theorem A.4) und wiederum mit Aussage (2) von Theorem 2.1 folgt dann

$$\mathbb{C}(\varepsilon_j, \varepsilon_k) = \mathbb{E}(\varepsilon_j\varepsilon_k) - \mathbb{E}(\varepsilon_j)\mathbb{E}(\varepsilon_k) = 0 - 0 \cdot 0 = 0 \tag{2.50}$$

(4) Mit dem Kovarianzverschiebungssatz (Theorem A.4) und Aussage (2) von Theorem 2.1 gilt

$$\begin{aligned}
\mathbb{C}(\tau, \varepsilon_k) &= \mathbb{E}(\tau\varepsilon_k) - \mathbb{E}(\tau)\mathbb{E}(\varepsilon_k) \\
&= \mathbb{E}(\tau\varepsilon_k) - \mathbb{E}(\tau) \cdot 0 \\
&= \mathbb{E}(\tau(y_k - \tau)) \\
&= \sum_{t\in\mathcal{T}} \sum_{y_k\in\mathcal{Y}_k} t(y_k - t)p(t)p(y_k|t) \\
&= \sum_{t\in\mathcal{T}} tp(t) \sum_{y_k\in\mathcal{Y}_k} (y_k - t)p(y_k|t) \\
&= \sum_{t\in\mathcal{T}} tp(t) \left(\sum_{y_k\in\mathcal{Y}_k} y_k p(y_k|t) - t \sum_{y_k\in\mathcal{Y}_k} p(y_k|t)\right) \\
&= \sum_{t\in\mathcal{T}} tp(t)\,(t - t) \\
&= \sum_{t\in\mathcal{T}} tp(t) \cdot 0 \\
&= 0.
\end{aligned} \tag{2.51}$$

(5) Nach Aussage (4) gilt $\mathbb{C}(\tau, \varepsilon_k) = 0$. Ebenso gilt dies für den Messfehler der Testmessung j. Aufgrund der Symmetrie der Kovarianz folgt daher

$$\mathbb{C}(\tau, \varepsilon_j) = \mathbb{C}(\varepsilon_j, \tau) = 0. \tag{2.52}$$

Mit dem Theorem zur Kovarianz bei paarweiser Addition von Zufallsvariablen (Theorem A.6) und Aussagen (3) und (4) des vorliegenden Theorems gilt dann

$$\begin{aligned} \mathbb{C}(y_j, y_k) &= \mathbb{C}(\tau + \varepsilon_j, \tau + \varepsilon_k) \\ &= \mathbb{C}(\tau, \tau) + \mathbb{C}(\tau, \varepsilon_k) + \mathbb{C}(\varepsilon_j, \tau) + \mathbb{C}(\varepsilon_j, \varepsilon_k) \\ &= \mathbb{C}(\tau, \tau) + 0 + 0 + 0 \\ &= \mathbb{C}(\tau, \tau) \\ &= \mathbb{V}(\tau). \end{aligned} \tag{2.53}$$

□

Aussage (1) von Theorem 2.3 besagt, dass bei Paralleltestmessungen alle Erwartungswerte der beobachteten Werte identisch sind und Aussage (2) des Theorems besagt, dass bei Paralleltestmessungen alle Varianzen der beobachteten Werte identisch sind. Die Aussagen (3) und (4) von Theorem 2.3 sind analog zu den lokalen Unkorreliertheitseigenschaften des Modells multipler Testmessungen. Aussage (5) besagt insbesondere, dass die Kovarianz der beobachteten Werte zweier verschiedener Testmessungen stets der Varianz des gemeinsamen wahren Werts entspricht, also $\mathbb{C}(y_{ij}, y_{ik}) = \mathbb{V}(\tau_i)$ für alle $j \neq k$.

Beispiel 2.3 (Zwei parallele Testmessungen)**.** Wir betrachten den Fall zweier Testmessungen $j = 1, 2$ im Modell paralleler Testmessungen. Für $i = 1, ..., n$ seien

$$\mathbb{P}(\tau_i) = N(1, 1) \text{ und } \mathbb{P}(y_{i1}|\tau_i) := \mathbb{P}(y_{i2}|\tau_i) := N(\tau_i, 1) \tag{2.54}$$

Für Person i gibt es also nur eine Zufallsvariable des wahren Werts für alle Testmessungen und die Propensitätsverteilungen unterscheiden sich zwischen Testmessungen nicht.

```
# Modellformulierung
n            = 1e5                                  # Personenanzahl
m            = 2                                    # Testmessungsanzahl
Tau          = matrix(rep(NaN, n)  , nrow = n)      # Array der wahren Werte
Y            = matrix(rep(NaN, n*m), nrow = n)      # Array der beobachteten Werte
E            = matrix(rep(NaN, n*m), nrow = n)      # Array der Messfehler

# Modellsimulation
for(i in 1:n){                                      # Iteration über Personen
    Tau[i]   = rnorm(1,1,1)                         # Realisierung des gemeinsamen wahren Werts
    for(j in 1:m){                                  # Iteration über Testmessungen
        Y[i,j]= rnorm(1,Tau[i],1)                   # Realisierung des beobachteten Werts
        E[i,j]= Y[i,j] - Tau[i]}}                   # Realisierung des Messfehlers

# Modelleigenschaftsschätzung
e_hat_o1_o2  = apply(Y, 2, mean)                    # Erwartungswertschätzung der beobachteten Werte 1 und 2
v_hat_o1_o2  = apply(Y, 2, var)                     # Varianzschätzung der beobachteten Werte 1 und 2
c_hat_e1_e2  = cov(E[,1],E[,2])                     # Kovarianzschätzung: Messfehler 1 und 2
c_hat_t_e2   = cov(Tau    ,E[,2])                   # Kovarianzschätzung: wahrer Wert und Messfehler 2
c_hat_y1_y2  = cov(Y[,1],Y[,2])                     # Kovarianzschätzung: beobachtete Werte 1 und 2
v_hat_t      = var(Tau)                             # Varianzschätzung der wahren Werte
```

Abbildung 2.3 visualisiert 500 der so generierten Zufallsvariablenrealisierungen und dokumentiert die resultierenden Kovarianzschätzer. Abbildung 2.3 A zeigt die Unkorreliertheit der Messfehler bezüglich zweier paralleler Testmessungen (Aussage (3) von Theorem 2.3), Abbildung 2.3 B zeigt die Unkorreliertheit des wahren Wertes und des Messfehlers bezüglich zweier paralleler Testmessungen (Aussage (4) von Theorem 2.3) und Abbildung 2.3 C zeigt die durch die identischen wahren Werte induzierte Kovarianz der beobachteten Werte zweier paralleler Testmessungen.

△

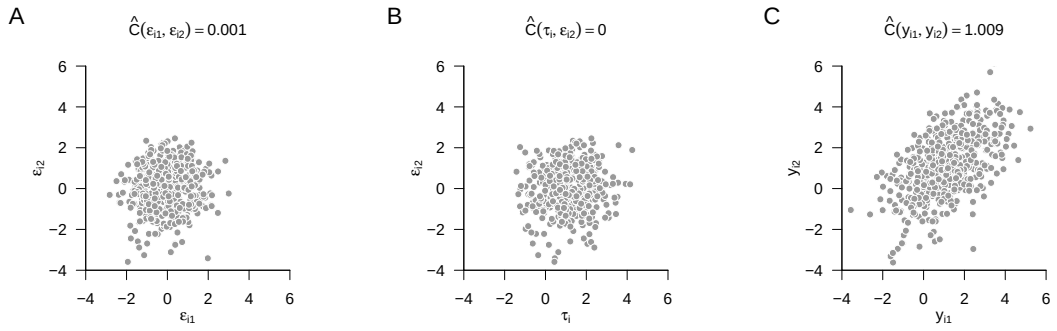


Abbildung 2.3. Normalverteilungsbeispiel bezüglich zweier paralleler Testmessungen.

2.3. Modelle kongenerischer Testmessungen

Mit den Modellen kongenerischer Testmessungen verbinden wir die klassische Testtheorie mit der Faktorenanalyse. Wir folgen dabei dem Ansatz von Jöreskog (1970) und Jöreskog (1971) und gehen von einem einfaktoriellen Normalverteilungsmodell für die Werte einer Testperson bei mehreren Items aus. Die beobachteten Werte setzen sich jeweils aus einem itemspezifischen Mittelwert, dem Beitrag eines gemeinsamen latenten Faktors und einem Messfehler zusammen. Der Faktor beschreibt dabei eine personenspezifische Größe, während die Faktorladungen bestimmen, wie stark diese Größe in die einzelnen Testmessungen eingeht. Den wahren Wert einer Person in einer Testmessung definieren wir als Summe aus dem itemspezifischen Mittelwert und dem mit der jeweiligen Faktorladung gewichteten Faktorwert. Damit ergibt sich erneut die grundlegende Zerlegung der klassischen Testtheorie in wahren Wert und Messfehler.

Formal schreiben wir für eine Testperson und m Items:

$$y = \mu + Lx + \varepsilon \Leftrightarrow \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_m \end{pmatrix} + \begin{pmatrix} l_1 \\ \vdots \\ l_m \end{pmatrix} x + \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_m \end{pmatrix} \tag{2.55}$$
$$\text{mit } x \sim N(0, \Phi), \varepsilon \sim N(0_m, \Psi) \text{ und } x \perp \varepsilon.$$

Für die folgenden Modelle setzen wir eine positive Faktorvarianz $\Phi > 0$ voraus. Mit der Definition

$$\tau_j := \mu_j + l_j x \tag{2.56}$$

gilt dann insbesondere, dass

$$y_j = \mu_j + l_j x + \varepsilon_j = \tau_j + \varepsilon_j \text{ für alle } j = 1, ..., m \tag{2.57}$$

bzw. unter Berücksichtigung der Personenindizes

$$y_{ij} = \mu_j + l_j x_i + \varepsilon_{ij} = \tau_{ij} + \varepsilon_{ij} \text{ für alle } i = 1, ..., n \text{ und } j = 1, ..., m. \tag{2.58}$$

Die wahren Werte der verschiedenen Testmessungen sind in diesem Modell also linear-affine Funktionen desselben latenten Faktors. Bei nichtverschwindenden Faktorladungen lassen sie sich deshalb auch als linear-affine Funktionen voneinander darstellen. Durch zusätzliche Restriktionen an die Mittelwerte, Faktorladungen und Messfehlervarianzen erhalten wir unterschiedliche Testmodelle. Tabelle 2.2 fasst diese Restriktionen sowie die

Tabelle 2.2. Überblick über die Modelle kongenerischer Testmessungen: Restriktionen an den Mittelwertvektor μ, den Faktorladungsvektor L und die Messfehlerkovarianzmatrix Ψ sowie die daraus folgenden funktionalen Beziehungen zwischen den wahren Werten und ihren Varianzen. Der Parameter c bezeichnet einen beliebigen gemeinsamen Mittelwert. Darstellung in Anlehnung an Millsap & Everson (1991).

Bezeichnung	$\mu \in \mathbb{R}^m$	$L \in \mathbb{R}^{m\times 1}$	$\Psi \in \mathbb{R}^{m\times m}$	$\tau_j = f(\tau_k)$	a_{jk}	b_{jk}	$\mathbb{V}(\tau_j)$
Essentiell kongenerisch	μ	L	$\text{diag}(\psi_j)$	$a_{jk} + b_{jk}\tau_k$	$\mu_j - \frac{l_j\mu_k}{l_k}$	$\frac{l_j}{l_k}$	$b_{jk}^2\mathbb{V}(\tau_k)$
Kongenerisch	0_m	L	$\text{diag}(\psi_j)$	$b_{jk}\tau_k$	-	$\frac{l_j}{l_k}$	$b_{jk}^2\mathbb{V}(\tau_k)$
Essentiell τ-äquivalent	μ	1_m	$\text{diag}(\psi_j)$	$a_{jk} + \tau_k$	$\mu_j - \mu_k$	-	$\mathbb{V}(\tau_k)$
τ-äquivalent	$c\,1_m$	1_m	$\text{diag}(\psi_j)$	τ_k	-	-	$\mathbb{V}(\tau_k)$
Essentiell parallel	μ	1_m	ψI_m	$a_{jk} + \tau_k$	$\mu_j - \mu_k$	-	$\mathbb{V}(\tau_k)$
Parallel	$c\,1_m$	1_m	ψI_m	τ_k	-	-	$\mathbb{V}(\tau_k)$

daraus folgenden Beziehungen zwischen den wahren Werten und ihren Varianzen zusammen. Sie stellt essentiell kongenerische und kongenerische, essentiell τ-äquivalente und τ-äquivalente sowie essentiell parallele und parallele Modelle gegenüber.

Theorem 2.4 (Essentiell kongenerische und kongenerische Testmodelle)**.** *Gegeben sei das einfaktorielle Normalverteilungsmodell der Faktorenanalyse für eine Testperson und m Items mit nichtverschwindenden Faktorladungen $l_1, ..., l_m$*

$$y = \mu + Lx + \varepsilon \text{ mit } x \sim N(0, \Phi), \varepsilon \sim N(0_m, \Psi), x \perp \varepsilon \text{ und } \Psi := diag(\psi_j) \tag{2.59}$$

Dann wird das Modell in Gleichung (2.59) auch als essentiell kongenerisches Testmodell bezeichnet. Im Sinne der klassischen Testtheorie gilt für die wahren Werte τ_j und τ_k zweier Testmessungen j und k insbesondere, dass

$$\tau_j = a_{jk} + b_{jk}\tau_k \text{ wobei } a_{jk} := \mu_j - \frac{l_j\mu_k}{l_k} \text{ und } b_{jk} := \frac{l_j}{l_k} \text{ für alle } j,k = 1, ..., m \text{ mit } j \neq k. \tag{2.60}$$

Für die Varianzen gilt

$$\mathbb{V}(\tau_j) = b_{jk}^2\mathbb{V}(\tau_k), \tag{2.61}$$

sodass $\mathbb{V}(\tau_j)$ und $\mathbb{V}(\tau_k)$ im Allgemeinen nicht übereinstimmen. Gilt in Gleichung (2.59) außerdem, dass $\mu = 0_m$, so wird das Modell als kongenerisches Testmodell bezeichnet. In diesem Fall gilt insbesondere, dass

$$\tau_j = b_{jk}\tau_k \text{ wobei } b_{jk} := \frac{l_j}{l_k} \text{ für alle } j,k = 1, ..., m \text{ mit } j \neq k. \tag{2.62}$$

Für die Varianzen gilt

$$\mathbb{V}(\tau_j) = b_{jk}^2\mathbb{V}(\tau_k), \tag{2.63}$$

sodass $\mathbb{V}(\tau_j)$ und $\mathbb{V}(\tau_k)$ im Allgemeinen nicht übereinstimmen.

∘

Beweis. Im Fall des essentiell kongenerischen Testmodells gilt, dass

$$\tau_j = \mu_j + l_j x \text{ und } \tau_k = \mu_k + l_k x \text{ für alle } j,k = 1, ..., m \text{ mit } j \neq k. \tag{2.64}$$

Dann gilt

$$\tau_k = \mu_k + l_k x \Leftrightarrow x = \frac{1}{l_k}\tau_k - \frac{\mu_k}{l_k} \tag{2.65}$$

und damit

$$\tau_j = \mu_j + l_j\left(\frac{1}{l_k}\tau_k - \frac{\mu_k}{l_k}\right) = \mu_j + \frac{l_j}{l_k}\tau_k - \frac{l_j\mu_k}{l_k} = \mu_j - \frac{l_j\mu_k}{l_k} + \frac{l_j}{l_k}\tau_k = a_{jk} + b_{jk}\tau_k \tag{2.66}$$

Also ist die Funktion $f : \mathbb{R} \to \mathbb{R}$, die τ_j als Funktion von τ_k darstellt, eine linear-affine Funktion der Form

$$f(t) = a_{jk} + b_{jk}t \text{ für alle } t \in \mathbb{R}. \tag{2.67}$$

Entsprechend gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(a_{jk} + b_{jk}\tau_k) = b_{jk}^2\mathbb{V}(\tau_k). \tag{2.68}$$

Für $b_{jk}^2 \neq 1$ folgt insbesondere, dass $\mathbb{V}(\tau_j) \neq \mathbb{V}(\tau_k)$.

Im Fall des kongenerischen Testmodells gilt unter der zusätzlichen Annahme $\mu = 0_m$, dass

$$\tau_j = l_j x \text{ und } \tau_k = l_k x \text{ für alle } j, k = 1, ..., m \text{ mit } j \neq k. \tag{2.69}$$

Dann gilt

$$\tau_k = l_k x \Leftrightarrow x = \frac{1}{l_k}\tau_k \tag{2.70}$$

und damit

$$\tau_j = l_j \left(\frac{1}{l_k}\tau_k\right) = \frac{l_j}{l_k}\tau_k = b_{jk}\tau_k \tag{2.71}$$

Also ist die Funktion $f : \mathbb{R} \to \mathbb{R}$, die τ_j als Funktion von τ_k darstellt, eine lineare Funktion der Form

$$f(t) = b_{jk}t \text{ für alle } t \in \mathbb{R}. \tag{2.72}$$

Entsprechend gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(b_{jk}\tau_k) = b_{jk}^2\mathbb{V}(\tau_k). \tag{2.73}$$

Für $b_{jk}^2 \neq 1$ folgt insbesondere, dass $\mathbb{V}(\tau_j) \neq \mathbb{V}(\tau_k)$. □

Theorem 2.5 (Essentiell τ-äquivalente und τ-äquivalente Testmodelle)**.** *Gegeben sei das einfaktorielle Normalverteilungsmodell der Faktorenanalyse für eine Testperson und m Items*

$$y = \mu + Lx + \varepsilon \text{ mit } x \sim N(0, \Phi), \varepsilon \sim N(0_m, \Psi), x \perp \varepsilon, L := 1_m \text{ und } \Psi := diag(\psi_j). \tag{2.74}$$

Dann wird das Modell in Gleichung (2.74) auch als essentiell τ-äquivalentes Testmodell bezeichnet. Im Sinne der klassischen Testtheorie gilt für die wahren Werte τ_j und τ_k zweier Testmessungen j und k insbesondere, dass

$$\tau_j = a_{jk} + \tau_k \text{ wobei } a_{jk} := \mu_j - \mu_k \text{ für alle } j, k = 1, ..., m \text{ mit } j \neq k. \tag{2.75}$$

Für die Varianzen gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(\tau_k). \tag{2.76}$$

Gilt in Gleichung (2.74) außerdem, dass $\mu = c\,1_m$ mit $c \in \mathbb{R}$, so wird das Modell als τ-äquivalentes Testmodell bezeichnet. In diesem Fall gilt insbesondere, dass

$$\tau_j = \tau_k \text{ für alle } j, k = 1, ..., m \text{ mit } j \neq k. \tag{2.77}$$

∘

Beweis. Im Fall des essentiell τ-äquivalenten Testmodells gilt, dass

$$\tau_j = \mu_j + x \text{ und } \tau_k = \mu_k + x \text{ für alle } j, k = 1, ..., m \text{ mit } j \neq k. \tag{2.78}$$

Dann gilt

$$\tau_k = \mu_k + x \Leftrightarrow x = \tau_k - \mu_k \tag{2.79}$$

und damit

$$\tau_j = \mu_j + \tau_k - \mu_k = \mu_j - \mu_k + \tau_k = a_{jk} + \tau_k. \tag{2.80}$$

Also ist die Funktion $f : \mathbb{R} \to \mathbb{R}$, die τ_j als Funktion von τ_k darstellt, eine linear-affine Funktion der Form

$$f(t) = a_{jk} + t \text{ für alle } t \in \mathbb{R}. \tag{2.81}$$

Entsprechend gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(a_{jk} + \tau_k) = \mathbb{V}(\tau_k). \tag{2.82}$$

Im Fall des τ-äquivalenten Testmodells gilt unter der zusätzlichen Annahme $\mu = c\,1_m$ mit $c \in \mathbb{R}$, dass

$$\tau_j = c + x \text{ und } \tau_k = c + x \text{ für alle } j, k = 1, \ldots, m \text{ mit } j \neq k. \tag{2.83}$$

Damit gilt

$$\tau_j = \tau_k. \tag{2.84}$$

Also ist die Funktion $f : \mathbb{R} \to \mathbb{R}$, die τ_j als Funktion von τ_k darstellt, die Identitätsfunktion

$$f(t) = t \text{ für alle } t \in \mathbb{R}. \tag{2.85}$$

Entsprechend gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(\tau_k). \tag{2.86}$$

□

Theorem 2.6 (Essentiell parallele und parallele Testmodelle)**.** *Gegeben sei das einfaktorielle Normalverteilungsmodell der Faktorenanalyse für eine Testperson und m Items*

$$y = \mu + Lx + \varepsilon \text{ mit } x \sim N(0, \Phi), \varepsilon \sim N(0_m, \Psi), x \perp \varepsilon, L := 1_m \text{ und } \Psi := \psi I_m. \tag{2.87}$$

Dann wird das Modell in Gleichung (2.87) auch als essentiell paralleles Testmodell bezeichnet. Im Sinne der klassischen Testtheorie gilt für die wahren Werte τ_j und τ_k zweier Testmessungen j und k insbesondere, dass

$$\tau_j = a_{jk} + \tau_k \text{ wobei } a_{jk} := \mu_j - \mu_k \text{ für alle } j, k = 1, ..., m \text{ mit } j \neq k. \tag{2.88}$$

Für die Varianzen gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(\tau_k). \tag{2.89}$$

Für die Messfehlervarianzen und die Varianzen der beobachteten Werte gilt außerdem

$$\mathbb{V}(\varepsilon_j) = \mathbb{V}(\varepsilon_k) = \psi \text{ und } \mathbb{V}(y_j) = \mathbb{V}(y_k). \tag{2.90}$$

Gilt in Gleichung (2.87) außerdem, dass $\mu = c\,1_m$ mit $c \in \mathbb{R}$, so wird das Modell als paralleles Testmodell bezeichnet. In diesem Fall gilt insbesondere, dass

$$\tau_j = \tau_k \text{ für alle } j, k = 1, ..., m \text{ mit } j \neq k. \tag{2.91}$$

∘

Beweis. Im Fall des essentiell parallelen Testmodells gilt, dass

$$\tau_j = \mu_j + x \text{ und } \tau_k = \mu_k + x \text{ für alle } j, k = 1, \ldots, m \text{ mit } j \neq k. \tag{2.92}$$

Dann gilt

$$\tau_k = \mu_k + x \Leftrightarrow x = \tau_k - \mu_k \tag{2.93}$$

und damit

$$\tau_j = \mu_j + \tau_k - \mu_k = \mu_j - \mu_k + \tau_k = a_{jk} + \tau_k. \tag{2.94}$$

Also ist die Funktion $f : \mathbb{R} \to \mathbb{R}$, die τ_j als Funktion von τ_k darstellt, eine linear-affine Funktion der Form

$$f(t) = a_{jk} + t \text{ für alle } t \in \mathbb{R}. \tag{2.95}$$

Entsprechend gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(a_{jk} + \tau_k) = \mathbb{V}(\tau_k). \tag{2.96}$$

Aus $\Psi := \psi I_m$ folgt außerdem

$$\mathbb{V}(\varepsilon_j) = \mathbb{V}(\varepsilon_k) = \psi. \tag{2.97}$$

Mit $y_j = \tau_j + \varepsilon_j$ und $y_k = \tau_k + \varepsilon_k$ folgt damit

$$\mathbb{V}(y_j) = \mathbb{V}(\tau_j) + \mathbb{V}(\varepsilon_j) = \mathbb{V}(\tau_k) + \mathbb{V}(\varepsilon_k) = \mathbb{V}(y_k). \tag{2.98}$$

Im Fall des parallelen Testmodells gilt unter der zusätzlichen Annahme $\mu = c\,1_m$ mit $c \in \mathbb{R}$, dass

$$\tau_j = c + x \text{ und } \tau_k = c + x \text{ für alle } j, k = 1, \ldots, m \text{ mit } j \neq k. \tag{2.99}$$

Damit gilt

$$\tau_j = \tau_k. \tag{2.100}$$

Also ist die Funktion $f : \mathbb{R} \to \mathbb{R}$, die τ_j als Funktion von τ_k darstellt, die Identitätsfunktion

$$f(t) = t \text{ für alle } t \in \mathbb{R}. \tag{2.101}$$

Entsprechend gilt

$$\mathbb{V}(\tau_j) = \mathbb{V}(\tau_k). \tag{2.102}$$

Aus $\Psi := \psi I_m$ folgt außerdem

$$\mathbb{V}(\varepsilon_j) = \mathbb{V}(\varepsilon_k) = \psi. \tag{2.103}$$

Mit $y_j = \tau_j + \varepsilon_j$ und $y_k = \tau_k + \varepsilon_k$ folgt damit

$$\mathbb{V}(y_j) = \mathbb{V}(\tau_j) + \mathbb{V}(\varepsilon_j) = \mathbb{V}(\tau_k) + \mathbb{V}(\varepsilon_k) = \mathbb{V}(y_k). \tag{2.104}$$

□

Zusammenfassend unterscheiden sich essentiell parallele und parallele Testmodelle hinsichtlich der Mittelwerte der Testmessungen. Im essentiell parallelen Modell können sich die wahren Werte einer Person zwischen den Testmessungen um additive Konstanten unterscheiden. Stimmen sämtliche Mittelwerte mit demselben Wert c überein, sind auch die wahren Werte identisch und das Modell ist parallel.

Das so erhaltene parallele Modell ist eine normalverteilte parametrische Spezialisierung des zuvor eingeführten Modells paralleler Testmessungen, das im Allgemeinen keine Normalverteilung voraussetzt. Unter ausdrücklicher Berücksichtigung der Personen lässt sich der beobachtete Wert wiederum als Summe aus einem gemeinsamen wahren Wert und einem testmessungsspezifischen Messfehler darstellen. Der gemeinsame wahre Wert ist dabei die Summe aus c und dem Faktorwert der jeweiligen Person.

Auch die bedingte Unabhängigkeit der beobachteten Werte ergibt sich aus den Annahmen des Faktorenmodells. Die Messfehler sind gemeinsam normalverteilt, besitzen dieselbe Varianz und sind wegen ihrer diagonalen Kovarianzmatrix untereinander unabhängig. Zudem sind sie unabhängig vom latenten Faktor und damit vom wahren Wert. Bei gegebenem wahren Wert sind deshalb auch die beobachteten Werte der verschiedenen Testmessungen unabhängig. Ihre gemeinsame bedingte Verteilung lässt sich folglich als Produkt ihrer einzelnen bedingten Verteilungen schreiben.

2.4. Selbstkontrollfragen

1. Skizzieren Sie die klassische Testtheorie und ihre Bedeutung für die Fragebogendatenanalyse.
2. Geben Sie die Definition eines bedingten Erwartungswerts wieder.
3. Geben Sie die Definitionen von wahrem Wert, beobachtetem Wert und Messfehler wieder.
4. Erläutern Sie den Begriff der Propensitätsverteilung im Kontext der klassischen Testtheorie.
5. Geben Sie die Definition des Modells multipler Testmessungen wieder.
6. Erläutern Sie das Modell multipler Testmessungen.
7. Geben Sie die Definition des vereinfachten Modells der klassischen Testtheorie wieder.
8. Erläutern Sie das vereinfachte Modell der klassischen Testtheorie.
9. Geben Sie das Theorem zu den Eigenschaften bezüglich einer Testmessung wieder.

10. Erläutern Sie das Theorem zu den Eigenschaften bezüglich einer Testmessung.
11. Geben Sie das Theorem zu den Eigenschaften bezüglich zweier Testmessungen wieder.
12. Erläutern Sie das Theorem zu den Eigenschaften bezüglich zweier Testmessungen.
13. Erläutern Sie den Begriff der parallelen Testmessungen.
14. Erläutern Sie die Bedeutungen von

$$\tau_{ij} = \mathrm{id}_{\mathbb{R}}(\tau_{i1}) \text{ und } t_{ij} = \mathrm{id}_{\mathbb{R}}(t_{i1}) \text{ für } i = 1, \ldots, n \text{ und } j = 2, \ldots, m \tag{2.105}$$

    im Kontext paralleler Testmessungen.
15. Geben Sie die Definition des Modells paralleler Testmessungen wieder.
16. Erläutern Sie das Modell paralleler Testmessungen.
17. Geben Sie das Theorem zu den Eigenschaften des Modells paralleler Testmessungen wieder.
18. Erläutern Sie das Theorem zu den Eigenschaften des Modells paralleler Testmessungen.

Referenzen

Anderson, T. W. (2003). *An Introduction to Multivariate Statistical Analysis* (3rd ed). Wiley-Interscience.

Beck, A. T. (1961). An Inventory for Measuring Depression. *Archives of General Psychiatry*, *4*(6), 561. https://doi.org/10.1001/archpsyc.1961.01710120031004

Beck, A. T., Steer, R. A., Ball, R., & Ranieri, W. F. (1996). Comparison of Beck Depression Inventories-IA and-II in Psychiatric Outpatients. *Journal of Personality Assessment*, *67*(3), 588–597. https://doi.org/10.1207/s15327752jpa6703_13

Borsboom, D. (2005). *Measuring the Mind: Conceptual Issues in Contemporary Psychometrics*. Cambridge University Press. https://doi.org/10.1017/CBO9780511490026

Borsboom, D. (2006). The Attack of the Psychometricians. *Psychometrika*, *71*(3), 425–440. https://doi.org/10.1007/s11336-006-1447-6

Borsboom, D. (2009). *Measuring the Mind: Conceptual Issues in Contemporary Psychometrics*. Cambridge University Press.

Borsboom, D., Mellenbergh, G. J., & Van Heerden, J. (2004). The Concept of Validity. *Psychological Review*, *111*(4), 1061–1071. https://doi.org/10.1037/0033-295X.111.4.1061

Brennan, R. L. (2024). Current Psychometric Models and Some Uses of Technology in Educational Testing. *Educational Measurement: Issues and Practice*, *43*(4), 88–92. https://doi.org/10.1111/emip.12644

Bühner, M. (2010). *Einführung in die Test- und Fragebogenkonstruktion* (2., aktualisierte und erw. Aufl., [Nachdr.]). Pearson Studium.

Bühner, M. et al. (2026). *Psychologische Testtheorie: Vorlesungsfolien*. Lehrstuhl für Psychologische Methodenlehre und Diagnostik, Ludwig-Maximilians-Universität München; Open Educational Resources. https://www.oer.psy.lmu.de/Diag1.html

Campbell, D. T. (1963). Social Attitudes and Other Acquired Behavioral Dispositions. In *Psychology: A Study of a Science. Study II. Empirical Substructure and Relations with Other Sciences. Volume 6. Investigations of Man as Socius: Their Place in Psychology and the Social Sciences* (S. 94–172). McGraw-Hill. https://doi.org/10.1037/10590-003

Cronbach, L. (1951). Coefficient Alpha and the Internal Structure of Tests. *Psychometrika*, *16*(3), 297–334.

Edgeworth, F. Y. (1888). The Statistics of Examinations. *Journal of the Royal Statistical Society*, *51*(3), 599–635. https://doi.org/10.1111/j.2397-2335.1888.tb00089.x

Foster, R. C. (2020). A Generalized Framework for Classical Test Theory. *Journal of Mathematical Psychology*, *96*, 102330. https://doi.org/10.1016/j.jmp.2020.102330

Gulliksen, H. (1950). *Theory of Mental Tests*. John Wiley & Sons Inc. https://doi.org/10.1037/13240-000

Hautzinger, M., Keller, F., & Kühner, C. (2006). *BDI-II Beck Depressions-Inventar*. Pearson.

Hotelling, H. (1933). Analysis of Complex Variables into Principal Components. *Journal of Educational Psychology*, *24*, 417-441 and 498-520.

Jöreskog, K. G. (1970). A General Method for Analysis of Covariance Structures. *Biometrika*, *57*(2), 239. https://doi.org/10.2307/2334833

Jöreskog, K. G. (1971). Statistical Analysis of Sets of Congeneric Tests. *Psychometrika*, *36*(2), 109–133. https://doi.org/10.1007/BF02291393

Kaiser, F. G. (1998). A General Measure of Ecological Behavior[1]. *Journal of Applied Social Psychology*, *28*(5), 395–422. https://doi.org/10.1111/j.1559-1816.1998.tb01712.x

Kaiser, F. G. (2020). *GEB-50. General Ecological Behavior Scale*. ZPID (Leibniz Institute for Psychology Information) – Open Test Archive. https://doi.org/10.23668/PSYCHARCHIVES.3453

Kaiser, F. G., Byrka, K., & Hartig, T. (2010). Reviving Campbell's Paradigm for Attitude Research. *Personality and Social Psychology Review*, *14*(4), 351–367. https://doi.org/10.1177/1088868310366452

Kaiser, F. G., & Wilson, M. (2004). Goal-Directed Conservation Behavior: The Specific Composition of a General Performance. *Personality and Individual Differences*, *36*(7), 1531–1544. https://doi.org/10.1016/j.paid.2003.06.003

Krauth, J. (1995). *Testkonstruktion und Testtheorie*. Beltz, Psychologie Verl.-Union.

Lawley, D. N. (1940). The Estimation of Factor Loadings by the Method of Maximum Likelihood. *Proceedings of the Royal Society of Edinburgh. Section B: Biological Sciences*.

Lazarsfeld, P. (1959). Latent Structure Analysis. In *Psychology: A Study of a Science, Vol. 3*. McGraw-Hill.

Lienert, G. A. (1968). *Testaufbau und Testanalyse* (4. Aufl.). Psychologie Verlags Union.

Lienert, G. A., & Raatz, U. (1998). *Testaufbau und Testanalyse* (6. Auflage). Beltz, Psychologie Verlags Union.

Lord, F. M. (1980). *Applications of Item Response Theory To Practical Testing Problems* (0. Aufl.). Routledge. https://doi.org/10.4324/9780203056615

Lord, F. M., & Novick, M. R. (1968). *Statistical Theories of Mental Test Scores* (Nachdr. der Ausg. Reading, Mass. [u.a.], 1968). Information Age Publ.

Mardia, K. V., Kent, J. T., & Bibby, J. M. (1979). *Multivariate Analysis*. Academic Press.

McCall, W. A. (1922). *How to Measure in Education*. MacMillan Co. https://doi.org/10.1037/13551-000

Millsap, R. E., & Everson, H. (1991). Confirmatory Measurement Model Comparisons Using Latent Means. *Multivariate Behavioral Research*, *26*(3), 479–497. https://doi.org/10.1207/s15327906mbr2603_6

Moosbrugger, H., & Kelava, A. (Hrsg.). (2012). *Testtheorie und Fragebogenkonstruktion: mit 66 Abbildungen und 41 Tabellen* (2., aktualisierte und überarbeitete Auflage). Springer.

Novick, M. R. (1966). The Axioms and Principal Results of Classical Test Theory. *Journal of Mathematical Psychology*, *3*(1), 1–18. https://doi.org/10.1016/0022-2496(66)90002-2

OECD. (2024). *PISA 2022 Technical Report*. OECD. https://doi.org/10.1787/01820d6d-en

Rasch, G. (1960). *Probabilistic Models for Some Intelligence and Attainment Tests* (Expanded ed). University of Chicago Press.

Reise, S. P., & Waller, N. G. (2009). Item Response Theory and Clinical Measurement. *Annual Review of Clinical Psychology*, *5*(1), 27–48. https://doi.org/10.1146/annurev.clinpsy.032408.153553

Rost, J. (2004). *Lehrbuch Testtheorie, Testkonstruktion* (2., vollständig überarbeitete und erweiterte Aufl). H. Huber.

Sijtsma, K. (2009). On the Use, the Misuse, and the Very Limited Usefulness of Cronbach's Alpha. *Psychometrika*, *74*(1), 107–120. https://doi.org/10.1007/s11336-008-9101-0

Spearman, C. (1904a). "General Intelligence," Objectively Determined and Measured. *The American Journal of Psychology*, *15*(2), 201. https://doi.org/10.2307/1412107

Spearman, C. (1904b). The Proof and Measurement of Association between Two Things. *The American Journal of Psychology*, *15*(1), 72–101. https://doi.org/10.2307/1412159

Stefana, A., Damiani, S., Granziol, U., Provenzani, U., Solmi, M., Youngstrom, E. A., & Fusar-Poli, P. (2025). Psychological, Psychiatric, and Behavioral Sciences Measurement Scales: Best Practice Guidelines for Their Development and Validation. *Frontiers in Psychology*, *15*, 1494261. https://doi.org/10.3389/fpsyg.2024.1494261

Traub, R. E. (1997). Classical Test Theory in Historical Perspective. *Educational Measurement: Issues and Practice*, *16*(4), 8–14. https://doi.org/10.1111/j.1745-3992.1997.tb00603.x

Warren, H. C. (1934). *Dictionary of Psychology*. Routledge.

A. Wahrscheinlichkeitstheoretische Ergänzungen

In diesem Anhang stellen wir einige grundlegende Definitionen und Resultate zu Erwartungswerten, Varianzen und Kovarianzen sowie Normalverteilungen zusammen.

A.1. Erwartungswerte

Definition A.1 (Bedingter Erwartungswert)**.** Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$, WMF oder WDF $p(x_1, x_2)$. Für einen Wert $x_2 \in \mathcal{X}_2$ mit positiver marginaler WMF bzw. positiver marginaler WDF sei $p(x_1|x_2)$ die bedingte WMF bzw. WDF. Es gelte $\sum_{x_1 \in \mathcal{X}_1} |x_1| p(x_1|x_2) < \infty$ im diskreten Fall bzw. $\int_{\mathcal{X}_1} |x_1| p(x_1|x_2)\, dx_1 < \infty$ im kontinuierlichen Fall. Dann ist der *bedingte Erwartungswert* von ξ_1 gegeben $\xi_2 = x_2$ definiert als

- $\mathbb{E}(\xi_1|\xi_2 = x_2) := \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2)$, wenn ξ ein diskreter Zufallsvektor ist.
- $\mathbb{E}(\xi_1|\xi_2 = x_2) := \int_{\mathcal{X}_1} x_1 p(x_1|x_2)\, dx_1$, wenn ξ ein kontinuierlicher Zufallsvektor ist.

•

Der bedingte Erwartungswert einer Zufallsvariable ist also der Erwartungswert einer Zufallsvariable in einer bedingten Verteilung. Man beachte, dass wir in Definition A.1 den bedingten Erwartungswert für einen festen Wert x_2 von ξ_2 definiert haben. Bei einem festen Wert x_2 von ξ_2 ist $\mathbb{E}(\xi_1|\xi_2 = x_2)$ damit ein fester Wert und durch Austauschen der Subskripte erhält man entsprechend $\mathbb{E}(\xi_2|\xi_1 = x_1)$.

Allgemein ist $\mathbb{E}(\xi_1|\xi_2)$ allerdings eine Zufallsvariable, da ξ_2 eine Zufallsvariable ist und nur mit einer gewissen Wahrscheinlichkeit einen Wert $\xi_2 = x_2$ annimmt. Wir werden später sehen, dass analog zu Definition A.1 bedingte Varianzen, bedingte Kovarianzen und bedingte Korrelationen definiert werden. In der Psychologie ist der Begriff des bedingten Erwartungswerts zentral, denn in der klassischen Testtheorie sind die wahren Werte von Personen bei Testmessungen als bedingte Erwartungswerte definiert. Zur Verdeutlichung von Definition A.1 betrachten wir ein Beispiel für einen diskreten Zufallsvektor.

Beispiel A.1 (Bedingter Erwartungswert eines diskreten Zufallsvektors)**.** Für einen zweidimensionalen Zufallsvektor $\xi := (\xi_1, \xi_2)$, der Werte in $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$ mit $\mathcal{X}_1 := \{1, 2, 3, 4\}$ und $\mathcal{X}_2 = \{1, 2, 3\}$ annehme, seien bedingte WMFen für $p(x_1|x_2)$ für alle $x_1 \in \mathcal{X}_1$ wie in Tabelle A.1 spezifiziert

Tabelle A.1. Bedingte Wahrscheinlichkeitsverteilung von x_1 gegeben x_2

$p(x_1\|x_2)$	$x_2 = 1$	$x_2 = 2$	$x_2 = 3$
$p(x_1 = 1\|x_2)$	$\frac{1}{4}$	$\frac{1}{3}$	0
$p(x_1 = 2\|x_2)$	0	$\frac{2}{3}$	$\frac{1}{3}$
$p(x_1 = 3\|x_2)$	$\frac{1}{2}$	0	$\frac{1}{3}$
$p(x_1 = 4\|x_2)$	$\frac{1}{4}$	0	$\frac{1}{3}$

Dann ergeben sich die bedingten Erwartungswerte

$$\begin{aligned}
\mathbb{E}(\xi_1|\xi_2 = 1) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 1) = 1 \cdot \frac{1}{4} + 2 \cdot 0 + 3 \cdot \frac{1}{2} + 4 \cdot \frac{1}{4} = \frac{11}{4} \\
\mathbb{E}(\xi_1|\xi_2 = 2) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 2) = 1 \cdot \frac{1}{3} + 2 \cdot \frac{2}{3} + 3 \cdot 0 + 4 \cdot 0 = \frac{5}{3} \\
\mathbb{E}(\xi_1|\xi_2 = 3) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2 = 3) = 1 \cdot 0 + 2 \cdot \frac{1}{3} + 3 \cdot \frac{1}{3} + 4 \cdot \frac{1}{3} = 3.
\end{aligned} \tag{A.1}$$

△

Theorem A.1 (Erwartungswert bei linear-affiner Kombination von Zufallsvariablen)**.** *ξ sei ein n-dimensionaler Zufallsvektor mit Komponenten $\xi_1, ..., \xi_n$ und Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \cdots \times \mathcal{X}_n$. Die Komponenten besitzen endliche erste absolute Momente, also $\mathbb{E}(|\xi_i|) < \infty$ für $i = 1, ..., n$. Weiterhin sei*

$$f : \mathcal{X} \to \mathcal{Z}, x \mapsto f(x) := a_0 + \sum_{i=1}^{n} a_i x_i \text{ für } a_0, ..., a_n \in \mathbb{R}. \tag{A.2}$$

eine linear-affine Kombination der Komponenten von ξ. Dann gilt

$$\mathbb{E}(f(\xi)) = \mathbb{E}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) = a_0 + \sum_{i=1}^{n} a_i \mathbb{E}(\xi_i). \tag{A.3}$$

∘

Beweis. Wie unten gezeigt, folgt das Theorem aus der Linearität von Summen und Integralen sowie dem Satz von Fubini zur Vertauschung der Summations- bzw. Integrationsreihenfolge. Wir beschränken uns auf den diskreten Fall, wobei wir zur Vereinfachung der Notation $\sum_{x_i \in \mathcal{X}_i}$ als $\sum_{x_i}$ schreiben. Es gilt dann

$$
\begin{aligned}
\mathbb{E}(f(\xi)) &= \mathbb{E}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) \\
&= \mathbb{E}(a_0 + a_1\xi_1 + \cdots + a_n\xi_n) \\
&= \sum_{x_1} \cdots \sum_{x_n} (a_0 + a_1 x_1 + \cdots + a_n x_n) p(x_1, \ldots, x_n) \\
&= \sum_{x_1} \cdots \sum_{x_n} (a_0 p(x_1, \ldots, x_n) + a_1 x_1 p(x_1, \ldots, x_n) + \cdots + a_n x_n p(x_1, \ldots, x_n)) \\
&= \sum_{x_1} \cdots \sum_{x_n} a_0 p(x_1, \ldots, x_n) + \sum_{x_1} \cdots \sum_{x_n} a_1 x_1 p(x_1, \ldots, x_n) + \cdots + \sum_{x_1} \cdots \sum_{x_n} a_n x_n p(x_1, \ldots, x_n) \\
&= a_0 \sum_{x_1} \cdots \sum_{x_n} p(x_1, \ldots, x_n) + a_1 \sum_{x_1} \cdots \sum_{x_n} x_1 p(x_1, \ldots, x_n) + \cdots + a_n \sum_{x_n} \cdots \sum_{x_1} x_n p(x_1, \ldots, x_n) \\
&= a_0 + a_1 \sum_{x_1} x_1 \sum_{x_2} \cdots \sum_{x_n} p(x_1, \ldots, x_n) + \cdots + a_n \sum_{x_n} x_n \sum_{x_{n-1}} \cdots \sum_{x_1} p(x_1, \ldots, x_n) \\
&= a_0 + a_1 \sum_{x_1} x_1 p(x_1) + \cdots + a_n \sum_{x_n} x_n p(x_n) \\
&= a_0 + a_1 \mathbb{E}(\xi_1) + \cdots + a_n \mathbb{E}(\xi_n) \\
&= a_0 + \sum_{i=1}^{n} a_i \mathbb{E}(\xi_i)
\end{aligned}
\tag{A.4}
$$

Analog folgt das Resultat für einen kontinuierlichen Zufallsvektor. □

Das folgende Theorem, der sogenannte *Satz vom iterierten Erwartungswert*, stellt einen Zusammenhang zwischen dem (marginalen) Erwartungswert einer Zufallsvariable und dem bedingten Erwartungswert dieser Zufallsvariable her. Das Theorem wird manchmal auch als *Satz vom totalen Erwartungswert* bezeichnet.

Theorem A.2 (Satz vom iterierten Erwartungswert)**.** *Gegeben sei ein Zufallsvektor* $\xi := (\xi_1, \xi_2)$*, wobei* $\mathbb{E}(|\xi_1|) < \infty$ *gilt. Dann gilt*

$$
\mathbb{E}(\xi_1) = \mathbb{E}\left(\mathbb{E}\left(\xi_1 | \xi_2\right)\right). \tag{A.5}
$$

∘

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor, der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Die folgenden Summen über x_2 laufen nur über Werte mit $p(x_2) > 0$. Es gilt

$$
\begin{aligned}
\mathbb{E}(\xi_1) &= \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1 \sum_{x_2 \in \mathcal{X}_2} p(x_1, x_2) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1 \sum_{x_2 \in \mathcal{X}_2} p(x_1 | x_2) p(x_2) \\
&= \sum_{x_1 \in \mathcal{X}_1} \sum_{x_2 \in \mathcal{X}_2} x_1 p(x_1 | x_2) p(x_2) \\
&= \sum_{x_2 \in \mathcal{X}_2} \sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1 | x_2) p(x_2) \\
&= \sum_{x_2 \in \mathcal{X}_2} \mathbb{E}(\xi_1 | \xi_2 = x_2) p(x_2) \\
&= \mathbb{E}\left(\mathbb{E}(\xi_1 | \xi_2)\right).
\end{aligned}
\tag{A.6}
$$

A.2. Varianzen und Kovarianzen

Theorem A.3 (Varianzen spezieller Linearkombinationen von Zufallsvariablen)**.**

(1) (Varianz bei Addition zweier Zufallsvariablen). Gegeben seien zwei Zufallsvariablen ξ und ζ. Dann gilt

$$\mathbb{V}(\xi + \zeta) = \mathbb{V}(\xi) + \mathbb{V}(\zeta) + 2\mathbb{C}(\xi, \zeta) \tag{A.7}$$

(2) (Varianz bei Subtraktion zweier Zufallsvariablen). Gegeben seien zwei Zufallsvariablen ξ und ζ. Dann gilt

$$\mathbb{V}(\xi - \zeta) = \mathbb{V}(\xi) + \mathbb{V}(\zeta) - 2\mathbb{C}(\xi, \zeta) \tag{A.8}$$

∘

Beweis. Es seien $n := 2$, $\xi_1 := \xi$, $\xi_2 := \zeta$, $a_0 := 0$, $a_1 := 1$ und $a_2 := 1$. Dann gilt mit Theorem A.9

$$\begin{aligned}
\mathbb{V}(\xi + \zeta) &= \mathbb{V}(a_0 + a_1\xi_1 + a_2\xi_2) \\
&= \mathbb{V}\left(a_0 + \sum_{i=1}^{2} a_i\xi_i\right) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{i=1}^{2-1}\sum_{j=i+1}^{2} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{i=1}^{1}\sum_{j=i+1}^{2} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{j=1+1}^{2} a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{j=2}^{2} a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= a_1^2\mathbb{V}(\xi_1) + a_2^2\mathbb{V}(\xi_2) + 2a_1a_2\mathbb{C}(\xi_1, \xi_2) \\
&= 1^2 \cdot \mathbb{V}(\xi) + 1^2 \cdot \mathbb{V}(\zeta) + 2 \cdot 1 \cdot 1 \cdot \mathbb{C}(\xi, \zeta) \\
&= \mathbb{V}(\xi) + \mathbb{V}(\zeta) + 2\mathbb{C}(\xi, \zeta).
\end{aligned} \tag{A.9}$$

Es seien nun $n := 2$, $\xi_1 := \xi$, $\xi_2 := \zeta$, $a_0 := 0$, $a_1 := 1$ und $a_2 := -1$. Dann gilt mit dem Theorem A.9

$$\begin{aligned}
\mathbb{V}(\xi - \zeta) &= \mathbb{V}(a_0 + a_1\xi_1 + a_2\xi_2) \\
&= \mathbb{V}\left(a_0 + \sum_{i=1}^{2} a_i\xi_i\right) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{i=1}^{2-1}\sum_{j=i+1}^{2} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{i=1}^{1}\sum_{j=i+1}^{2} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{j=1+1}^{2} a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= \sum_{i=1}^{2} a_i^2\mathbb{V}(\xi_i) + 2\sum_{j=2}^{2} a_1 a_j \mathbb{C}(\xi_1, \xi_j) \\
&= a_1^2\mathbb{V}(\xi_1) + a_2^2\mathbb{V}(\xi_2) + 2a_1a_2\mathbb{C}(\xi_1, \xi_2) \\
&= 1^2 \cdot \mathbb{V}(\xi) + (-1)^2 \cdot \mathbb{V}(\zeta) + 2 \cdot 1 \cdot (-1) \cdot \mathbb{C}(\xi, \zeta) \\
&= \mathbb{V}(\xi) + \mathbb{V}(\zeta) - 2\mathbb{C}(\xi, \zeta).
\end{aligned} \tag{A.10}$$

Alternativ gilt ohne Rückgriff auf Theorem A.9 und mit Theorem A.1, dass

$$\begin{aligned}
&\mathbb{V}(a\xi + b\zeta + c)\\
&= \mathbb{E}\left((a\xi + b\zeta + c - a\mathbb{E}(\xi) - b\mathbb{E}(\zeta) - c)^2\right)\\
&= \mathbb{E}\left((a(\xi - \mathbb{E}(\xi)) + b(\zeta - \mathbb{E}(\zeta)))^2\right)\\
&= \mathbb{E}\left(a^2(\xi - \mathbb{E}(\xi))^2 + 2ab(\xi - \mathbb{E}(\xi))(\zeta - \mathbb{E}(\zeta)) + b^2(\zeta - \mathbb{E}(\zeta))^2\right)\\
&= a^2\mathbb{E}\left((\xi - \mathbb{E}(\xi))^2\right) + b^2\mathbb{E}\left((\zeta - \mathbb{E}(\zeta))^2\right) + 2ab\mathbb{E}\left((\xi - \mathbb{E}(\xi))(\zeta - \mathbb{E}(\zeta))\right)\\
&= a^2\mathbb{V}(\xi) + b^2\mathbb{V}(\zeta) + 2ab\mathbb{C}(\xi, \zeta).
\end{aligned} \tag{A.11}$$

Die Spezialfälle folgen dann direkt mit $a := b := 1$ und $a := 1, b := -1$, respektive. □

Theorem A.4 (Kovarianzverschiebungssatz)**.** *ξ_1 und ξ_2 seien Zufallsvariablen mit endlichen zweiten Momenten. Dann gilt*

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2). \tag{A.12}$$

∘

Beweis. Mit Definition A.3 gilt

$$\begin{aligned}
\mathbb{C}(\xi_1, \xi_2) &= \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right)\\
&= \mathbb{E}\left(\xi_1\xi_2 - \xi_1\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\xi_2 + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2)\right)\\
&= \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2) + \mathbb{E}(\xi_1)\mathbb{E}(\xi_2)\\
&= \mathbb{E}(\xi_1\xi_2) - \mathbb{E}(\xi_1)\mathbb{E}(\xi_2).
\end{aligned} \tag{A.13}$$

□

Definition A.2 (Bedingte Kovarianz)**.** Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2, \xi_3)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2 \times \mathcal{X}_3$ und gemeinsamer WMF oder WDF $p(x_1, x_2, x_3)$. Für einen Bedingungswert x_3 mit positiver marginaler WMF bzw. WDF sei $p(x_1, x_2|x_3)$ die entsprechende bedingte WMF bzw. WDF. Es gelte $\mathbb{E}(\xi_1^2|\xi_3 = x_3) < \infty$ und $\mathbb{E}(\xi_2^2|\xi_3 = x_3) < \infty$. Dann ist die bedingte Kovarianz von ξ_1 und ξ_2 gegeben $\xi_3 = x_3$ definiert als

$$\mathbb{C}(\xi_1, \xi_2|\xi_3 = x_3) := \mathbb{E}\left((\xi_1 - \mathbb{E}\left(\xi_1|\xi_3 = x_3\right))\left(\xi_2 - \mathbb{E}\left(\xi_2|\xi_3 = x_3\right)\right)|\xi_3 = x_3\right) \tag{A.14}$$

•

Die bedingte Kovarianz ist der Erwartungswert des Produkts der bedingt zentrierten Zufallsvariablen in ihrer bedingten gemeinsamen Verteilung. Für einen festen Bedingungswert x_3 ist sie eine feste Zahl. Als Funktion der Zufallsvariablen ξ_3 ergibt sich dagegen die Zufallsvariable $\mathbb{C}(\xi_1, \xi_2|\xi_3)$. Auch für die bedingte Kovarianz gilt ein Verschiebungssatz.

Theorem A.5 (Verschiebungssatz der bedingten Kovarianz)**.** *Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2, \xi_3)$, wobei ξ_1 und ξ_2 endliche zweite Momente besitzen. Dann gilt fast sicher*

$$\mathbb{C}(\xi_1, \xi_2|\xi_3) = \mathbb{E}\left(\xi_1\xi_2|\xi_3\right) - \mathbb{E}\left(\xi_1|\xi_3\right)\mathbb{E}\left(\xi_2|\xi_3\right). \tag{A.15}$$

∘

Beweis. Ein Beweis ergibt sich durch die Ersetzung der entsprechenden Erwartungswerte im Beweis von Theorem A.4 durch die entsprechenden bedingten Erwartungswerte. □

Theorem A.6 (Kovarianz bei paarweiser Addition von Zufallsvariablen)**.** *$\xi_1, \xi_2, \zeta_1, \zeta_2$ seien vier Zufallsvariablen mit endlichen zweiten Momenten. Dann gilt*

$$\mathbb{C}(\xi_1 + \xi_2, \zeta_1 + \zeta_2) = \mathbb{C}(\xi_1, \zeta_1) + \mathbb{C}(\xi_1, \zeta_2) + \mathbb{C}(\xi_2, \zeta_1) + \mathbb{C}(\xi_2, \zeta_2). \tag{A.16}$$

∘

Beweis. Es seien $n := 2, m := 2, a_0 = b_0 := 0$ und $a_i = b_i := 1$ für $i = 1, 2$. Dann gilt mit Theorem A.8

$$\begin{aligned}
\mathbb{C}\left(\xi_1 + \xi_2, \zeta_1 + \zeta_2\right) &= \mathbb{C}\left(a_0 + \sum_{i=1}^{2} a_i \xi_i, b_0 + \sum_{j=1}^{2} b_j \zeta_j\right) \\
&= \sum_{i=1}^{2}\sum_{j=1}^{2} a_i b_j \mathbb{C}\left(\xi_i, \zeta_j\right) \\
&= \sum_{i=1}^{2}\sum_{j=1}^{2} \mathbb{C}\left(\xi_i, \zeta_j\right) \\
&= \mathbb{C}\left(\xi_1, \zeta_1\right) + \mathbb{C}\left(\xi_1, \zeta_2\right) + \mathbb{C}\left(\xi_2, \zeta_1\right) + \mathbb{C}\left(\xi_2, \zeta_2\right).
\end{aligned} \tag{A.17}$$

□

Theorem A.7 (Satz von der iterierten Varianz)**.** *Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$, wobei ξ_1 ein endliches zweites Moment besitzt. Dann gilt*

$$\mathbb{V}(\xi_1) = \mathbb{E}(\mathbb{V}(\xi_1|\xi_2)) + \mathbb{V}(\mathbb{E}(\xi_1|\xi_2)) \tag{A.18}$$

∘

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor. Der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Mit dem Kovarianzverschiebungssatz (Theorem A.4), dem Satz vom iterierten Erwartungswert (Theorem A.2) und dem Verschiebungssatz der bedingten Varianz (Theorem A.10) ergibt sich folgende Rechnung. Die Summen über x_2 laufen nur über Werte mit $p(x_2) > 0$.

$$\begin{aligned}
\mathbb{V}(\xi_1) &= \mathbb{E}(\xi_1^2) - \mathbb{E}(\xi_1)^2 \\
&= \mathbb{E}\left(\mathbb{E}(\xi_1^2|\xi_2)\right) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2) \mathbb{E}(\xi_1^2|\xi_2 = x_2) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2) \left(\mathbb{V}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2\right) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \sum_{x_2 \in \mathcal{X}_2} p(x_2) \mathbb{V}(\xi_1|\xi_2 = x_2) + \sum_{x_2 \in \mathcal{X}_2} p(x_2) \mathbb{E}(\xi_1|\xi_2 = x_2)^2 - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2 \\
&= \mathbb{E}(\mathbb{V}(\xi_1|\xi_2)) + \left(\mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)^2\right) - \mathbb{E}\left(\mathbb{E}(\xi_1|\xi_2)\right)^2\right) \\
&= \mathbb{E}(\mathbb{V}(\xi_1|\xi_2)) + \mathbb{V}\left(\mathbb{E}(\xi_1|\xi_2)\right)
\end{aligned} \tag{A.19}$$

□

Definition A.3 (Kovarianz und Korrelation zweier Zufallsvariablen)**.** ξ_1 und ξ_2 seien Zufallsvariablen mit endlichen zweiten Momenten. Ihre *Kovarianz* ist definiert als

$$\mathbb{C}(\xi_1, \xi_2) := \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right). \tag{A.20}$$

Die *Korrelation* zweier Zufallsvariablen ξ_1 und ξ_2 mit $\mathbb{S}(\xi_1) > 0$ und $\mathbb{S}(\xi_2) > 0$ ist definiert als

$$\rho(\xi_1, \xi_2) := \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)}. \tag{A.21}$$

•

Theorem A.8 (Kovarianz von Linearkombinationen von Zufallsvariablen)**.** *Gegeben seien n Zufallsvariablen $\xi_1, ..., \xi_n$ und $n+1$ reelle Konstanten $a_0, a_1, ..., a_n$ sowie m Zufallsvariablen $\zeta_1, ..., \zeta_m$ und $m+1$ reelle Konstanten $b_0, b_1, ..., b_m$. Alle genannten Zufallsvariablen besitzen endliche zweite Momente. Dann gilt*

$$\mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i\xi_i, b_0 + \sum_{j=1}^{m} b_j\zeta_j\right) = \sum_{i=1}^{n}\sum_{j=1}^{m} a_i b_j \mathbb{C}(\xi_i, \zeta_j). \tag{A.22}$$

∘

Beweis.

$$\begin{aligned}
&\mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i\xi_i, b_0 + \sum_{j=1}^{m} b_j\zeta_j\right)\\
&= \mathbb{E}\left(\left(a_0 + \sum_{i=1}^{n} a_i\xi_i - \mathbb{E}\left(a_0 + \sum_{i=1}^{n} a_i\xi_i\right)\right)\left(b_0 + \sum_{j=1}^{m} b_j\zeta_j - \mathbb{E}\left(b_0 + \sum_{j=1}^{m} b_j\zeta_j\right)\right)\right)\\
&= \mathbb{E}\left(\left(a_0 + \sum_{i=1}^{n} a_i\xi_i - a_0 - \mathbb{E}\left(\sum_{i=1}^{n} a_i\xi_i\right)\right)\left(b_0 + \sum_{j=1}^{m} b_j\zeta_j - b_0 - \mathbb{E}\left(\sum_{j=1}^{m} b_j\zeta_j\right)\right)\right)\\
&= \mathbb{E}\left(\left(\sum_{i=1}^{n} a_i\xi_i - \sum_{i=1}^{n} a_i\mathbb{E}(\xi_i)\right)\left(\sum_{j=1}^{m} b_j\zeta_j - \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\right)\right)\\
&= \mathbb{E}\Big(\sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\zeta_j - \sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\\
&\quad - \sum_{i=1}^{n} a_i\mathbb{E}(\xi_i)\sum_{j=1}^{m} b_j\zeta_j + \sum_{i=1}^{n} a_i\mathbb{E}(\xi_i)\sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\Big)\\
&= \mathbb{E}\left(\sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\zeta_j\right) - \mathbb{E}\left(\sum_{i=1}^{n} a_i\xi_i \sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\right)\\
&\quad - \mathbb{E}\left(\sum_{i=1}^{n} a_i\mathbb{E}(\xi_i)\sum_{j=1}^{m} b_j\zeta_j\right) + \mathbb{E}\left(\sum_{i=1}^{n} a_i\mathbb{E}(\xi_i)\sum_{j=1}^{m} b_j\mathbb{E}(\zeta_j)\right)\\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_i b_j \mathbb{E}(\xi_i\zeta_j) - 2\sum_{i=1}^{n}\sum_{j=1}^{m} a_i b_j \mathbb{E}(\xi_i)\mathbb{E}(\zeta_j) + \sum_{i=1}^{n}\sum_{j=1}^{m} a_i b_j \mathbb{E}(\xi_i)\mathbb{E}(\zeta_j)\\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_i b_j \left(\mathbb{E}(\xi_i\zeta_j) - 2\mathbb{E}(\xi_i)\mathbb{E}(\zeta_j) + \mathbb{E}(\xi_i)\mathbb{E}(\zeta_j)\right)\\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_i b_j \mathbb{E}\left((\xi_i - \mathbb{E}(\xi_i))(\zeta_j - \mathbb{E}(\zeta_j))\right)\\
&= \sum_{i=1}^{n}\sum_{j=1}^{m} a_i b_j \mathbb{C}(\xi_i, \zeta_j)
\end{aligned}$$

□

Theorem A.9 (Varianz einer Linearkombination von Zufallsvariablen)**.** *Gegeben seien n Zufallsvariablen $\xi_1, ..., \xi_n$ und $n+1$ reelle Konstanten $a_0, a_1, ..., a_n$. Dann gilt*

$$\mathbb{V}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) = \sum_{i=1}^{n} a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j). \tag{A.23}$$

∘

Beweis.

Mit $\mathbb{V}(\xi) = \mathbb{C}(\xi, \xi)$ und Theorem A.8 gilt zunächst

$$\begin{aligned}
\mathbb{V}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i\right) &= \mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i, a_0 + \sum_{i=1}^{n} a_i \xi_i\right) \\
&= \mathbb{C}\left(a_0 + \sum_{i=1}^{n} a_i \xi_i, a_0 + \sum_{j=1}^{n} a_j \xi_j\right) \\
&= \sum_{i=1}^{n} \sum_{j=1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j=i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) + \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} a_i a_i \mathbb{C}(\xi_i, \xi_i) + \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} a_i^2 \mathbb{V}(\xi_i) + \sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{i=1}^{n} a_i^2 \mathbb{V}(\xi_i) + 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j),
\end{aligned} \tag{A.24}$$

Dabei wurde in der vierten Gleichung die Doppelsumme in solche Terme aufgespalten für die $i = j$ und für die $i \neq j$ und in der siebten Gleichung ausgenutzt, dass

$$a_i a_j \mathbb{C}(\xi_i, \xi_j) = a_j a_i \mathbb{C}(\xi_j, \xi_i). \tag{A.25}$$

Wir verdeutlichen die daraus folgende Identität

$$\sum_{i=1}^{n} \sum_{\substack{j=1 \\ j \neq i}}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j) = 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} a_i a_j \mathbb{C}(\xi_i, \xi_j), \tag{A.26}$$

am Beispiel $n = 3$ untenstehend. Analog mag man sich vorstellen, über alle Elemente außer der Diagonalelemente der $i = 1, ..., n$ Zeilen und $j = 1, ..., n$ Spalten einer symmetrischen Matrix mit Einträgen $a_i a_j \mathbb{C}(\xi_i, \xi_j)$ zu summieren. Die linke Seite oberer Gleichung entspricht dann dem zeilenweisen Vorgehen der Summationsbildung für alle Spalteneinträge außer dem, der in der Spalte der jeweils betrachteten Zeile steht, d.h. dem Diagonaleintrag. Die rechte Seite der obigen Gleichung entspricht dann dem Vorgehen, die Symmetrie der Matrix auszunutzen, also die Tatsache zu berücksichtigen, dass die Einträge der Matrix rechts oberhalb und links unterhalb der Diagonalen identisch sind, so dass es genügt, die Einträge der oberen Dreieckshälfte ohne Diagonale aufzuaddieren und zu verdoppeln. Dabei werden für jede Zeile $i = 1, ..., n$ nur gerade die Spalten $j = i + 1, ..., n$ betrachtet, die rechts von der Diagonale stehen und ihre Einträge aufsummiert. In der letzten Zeile steht dabei nur ein Diagonalelement, das nicht zur Summe gehört, weshalb der Index der äußeren Summe nur bis $n - 1$ läuft.

Konkret ergibt sich für $n := 3$

$$
\begin{aligned}
&\sum_{i=1}^{3}\sum_{\substack{j=1\\j\neq i}}^{3} a_i a_j \mathbb{C}(\xi_i, \xi_j) \\
&= \sum_{\substack{j=1\\j\neq 1}}^{3} a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{\substack{j=1\\j\neq 2}}^{3} a_2 a_j \mathbb{C}(\xi_2, \xi_j) + \sum_{\substack{j=1\\j\neq 3}}^{3} a_3 a_j \mathbb{C}(\xi_3, \xi_j) \\
&= a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_2 a_1 \mathbb{C}(\xi_2, \xi_1) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3) + a_3 a_1 \mathbb{C}(\xi_3, \xi_1) + a_3 a_2 \mathbb{C}(\xi_3, \xi_2) \\
&= a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_2 a_1 \mathbb{C}(\xi_2, \xi_1) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_3 a_1 \mathbb{C}(\xi_3, \xi_1) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3) + a_3 a_2 \mathbb{C}(\xi_3, \xi_2) \\
&= 2a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + 2a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + 2a_2 a_3 \mathbb{C}(\xi_2, \xi_3) \\
&= 2\left(a_1 a_2 \mathbb{C}(\xi_1, \xi_2) + a_1 a_3 \mathbb{C}(\xi_1, \xi_3) + a_2 a_3 \mathbb{C}(\xi_2, \xi_3)\right) \\
&= 2\left(\sum_{j=2}^{3} a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{j=3}^{3} a_2 a_j \mathbb{C}(\xi_2, \xi_j)\right) \\
&= 2\left(\sum_{j=1+1}^{3} a_1 a_j \mathbb{C}(\xi_1, \xi_j) + \sum_{j=2+1}^{3} a_2 a_j \mathbb{C}(\xi_2, \xi_j)\right) \\
&= 2\sum_{i=1}^{2}\sum_{j=i+1}^{3} a_i a_j \mathbb{C}(\xi_i, \xi_j).
\end{aligned}
\tag{A.27}
$$

□

Definition A.4 (Bedingte Varianz)**.** Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$ mit Ergebnisraum $\mathcal{X} := \mathcal{X}_1 \times \mathcal{X}_2$ und gemeinsamer WMF oder WDF. Für einen Bedingungswert x_2 mit positiver marginaler WMF bzw. WDF existiere die entsprechende bedingte Verteilung, und es gelte $\mathbb{E}(\xi_1^2|\xi_2 = x_2) < \infty$. Dann ist die *bedingte Varianz von* ξ_1 *gegeben* $\xi_2 = x_2$ definiert als

$$\mathbb{V}(\xi_1|\xi_2 = x_2) := \mathbb{E}\left(\left(\xi_1 - \mathbb{E}(\xi_1|\xi_2 = x_2)\right)^2 |\xi_2 = x_2\right) \tag{A.28}$$

und die *bedingte Standardabweichung von* ξ_1 *gegeben* $\xi_2 = x_2$ ist definiert als

$$\mathbb{S}(\xi_1|\xi_2 = x_2) := \sqrt{\mathbb{V}(\xi_1|\xi_2 = x_2)}. \tag{A.29}$$

•

Für einen festen Bedingungswert x_2 sind die bedingte Varianz und die bedingte Standardabweichung feste Zahlen. Betrachtet man die bedingte Varianz dagegen als Funktion der Zufallsvariablen ξ_2, erhält man die Zufallsvariable $\mathbb{V}(\xi_1|\xi_2)$. Entsprechendes gilt für $\mathbb{S}(\xi_1|\xi_2)$. Auch für die bedingte Varianz gilt ein Verschiebungssatz.

Theorem A.10 (Verschiebungssatz der bedingten Varianz)**.** *Gegeben sei ein Zufallsvektor $\xi := (\xi_1, \xi_2)$, wobei ξ_1 ein endliches zweites Moment besitzt. Für alle Bedingungswerte x_2 mit positiver marginaler WMF bzw. WDF und endlichem bedingtem zweiten Moment gilt*

$$\mathbb{V}(\xi_1|\xi_2 = x_2) = \mathbb{E}\left(\xi_1^2|\xi_2 = x_2\right) - \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \tag{A.30}$$

∘

Beweis. Wir beschränken uns auf den Beweis für einen diskreten Zufallsvektor. Der Beweis für einen kontinuierlichen Zufallsvektor folgt analog. Mit der Definition des bedingten Erwartungswerts (Definition A.1) gilt

$$\begin{aligned}
\mathbb{V}(\xi_1|\xi_2 = x_2) &= \mathbb{E}\left(\left(\xi_1 - \mathbb{E}(\xi_1|\xi_2 = x_2)\right)^2 |\xi_2 = x_2\right) \\
&= \mathbb{E}\left(\xi_1^2 - 2\xi_1\mathbb{E}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2|\xi_2 = x_2\right) \\
&= \sum_{x_1 \in \mathcal{X}_1} p(x_1|x_2)\left(x_1^2 - 2x_1\mathbb{E}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2\right) \\
&= \sum_{x_1 \in \mathcal{X}_1} x_1^2 p(x_1|x_2) - \sum_{x_1 \in \mathcal{X}_1} 2x_1\mathbb{E}(\xi_1|\xi_2 = x_2)p(x_1|x_2) + \sum_{x_1 \in \mathcal{X}_1} \mathbb{E}(\xi_1|\xi_2 = x_2)^2 p(x_1|x_2) \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - 2\mathbb{E}(\xi_1|\xi_2 = x_2)\sum_{x_1 \in \mathcal{X}_1} x_1 p(x_1|x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \sum_{x_1 \in \mathcal{X}_1} p(x_1|x_2) \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - 2\mathbb{E}(\xi_1|\xi_2 = x_2)\mathbb{E}(\xi_1|\xi_2 = x_2) + \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \cdot 1 \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - 2\mathbb{E}(\xi_1|\xi_2 = x_2)^2 + \mathbb{E}(\xi_1|\xi_2 = x_2)^2 \\
&= \mathbb{E}(\xi_1^2|\xi_2 = x_2) - \mathbb{E}(\xi_1|\xi_2 = x_2)^2
\end{aligned} \tag{A.31}$$

□

Theorem A.11 (Nichtnegativität der Varianz)**.** *ξ sei eine Zufallsvariable mit endlichem zweiten Moment. Dann gilt*

$$\mathbb{V}(\xi) \geq 0. \tag{A.32}$$

∘

Beweis. Wir betrachten den Fall einer diskreten Zufallsvariablen. Dann gilt zunächst

$$(x - \mathbb{E}(\xi))^2 \geq 0 \text{ für alle } x \in \mathcal{X}. \tag{A.33}$$

Weiterhin gilt für die WMF p von ξ, dass

$$p(x) \geq 0 \text{ für alle } x \in \mathcal{X}. \tag{A.34}$$

Also folgt

$$p(x)(x - \mathbb{E}(\xi))^2 \geq 0 \text{ für alle } x \in \mathcal{X}. \tag{A.35}$$

Damit gilt dann aber

$$\mathbb{V}(\xi) = \sum_{x \in \mathcal{X}} p(x)(x - \mathbb{E}(\xi))^2 \geq 0. \tag{A.36}$$

Analog zeigt man die Nichtnegativität der Varianz bei kontinuierlichen Zufallsvariablen. □

Theorem A.12 (Symmetrie von Kovarianz und Korrelation)**.** *ξ_1 und ξ_2 seien zwei Zufallsvariablen mit endlichen zweiten Momenten. Für die Aussage zur Korrelation seien zudem $\mathbb{S}(\xi_1) > 0$ und $\mathbb{S}(\xi_2) > 0$ vorausgesetzt. Dann gelten*

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{C}(\xi_2, \xi_1) \text{ und } \rho(\xi_1, \xi_2) = \rho(\xi_2, \xi_1). \tag{A.37}$$

∘

Beweis. Mit der Kommutativität der Multiplikation gilt zunächst

$$\mathbb{C}(\xi_1, \xi_2) = \mathbb{E}\left((\xi_1 - \mathbb{E}(\xi_1))(\xi_2 - \mathbb{E}(\xi_2))\right) = \mathbb{E}\left((\xi_2 - \mathbb{E}(\xi_2))(\xi_1 - \mathbb{E}(\xi_1))\right) = \mathbb{C}(\xi_2, \xi_1) \tag{A.38}$$

Weiterhin gilt dann

$$\rho(\xi_1, \xi_2) = \frac{\mathbb{C}(\xi_1, \xi_2)}{\mathbb{S}(\xi_1)\mathbb{S}(\xi_2)} = \frac{\mathbb{C}(\xi_2, \xi_1)}{\mathbb{S}(\xi_2)\mathbb{S}(\xi_1)} = \rho(\xi_2, \xi_1) \tag{A.39}$$

□

A.3. Normalverteilungen

Theorem A.13 (Gemeinsame Normalverteilungen)**.** *ξ sei ein m-dimensionaler normalverteilter Zufallsvektor mit WDF*

$$p_\xi : \mathbb{R}^m \to \mathbb{R}_{>0},\ x \mapsto p_\xi(x) := N(x; \mu_\xi, \Sigma_{\xi\xi}) \text{ mit } \mu_\xi \in \mathbb{R}^m, \Sigma_{\xi\xi} \in \mathbb{R}^{m\times m}, \tag{A.40}$$

$A \in \mathbb{R}^{n\times m}$ sei eine Matrix, $b \in \mathbb{R}^n$ sei ein Vektor und υ sei ein n-dimensionaler bedingt normalverteilter Zufallsvektor mit bedingter WDF

$$p_{\upsilon|\xi}(\cdot|x) : \mathbb{R}^n \to \mathbb{R}_{>0},\ y \mapsto p_{\upsilon|\xi}(y|x) := N(y; Ax + b, \Sigma_{\upsilon\upsilon}) \text{ mit } \Sigma_{\upsilon\upsilon} \in \mathbb{R}^{n\times n}. \tag{A.41}$$

Die Matrizen $\Sigma_{\xi\xi}$ und $\Sigma_{\upsilon\upsilon}$ seien symmetrisch und positiv definit. Die bedingte Kovarianzmatrix $\Sigma_{\upsilon\upsilon}$ sei unabhängig von x. Dann ist der $m+n$-dimensionale Zufallsvektor $(\xi, \upsilon)^T$ normalverteilt mit (gemeinsamer) WDF

$$p_{\xi,\upsilon} : \mathbb{R}^{m+n} \to \mathbb{R}_{>0},\ \begin{pmatrix} x \\ y \end{pmatrix} \mapsto p_{\xi,\upsilon}\left(\begin{pmatrix} x \\ y \end{pmatrix}\right) = N\left(\begin{pmatrix} x \\ y \end{pmatrix}; \mu_{\xi,\upsilon}, \Sigma_{\xi,\upsilon}\right), \tag{A.42}$$

mit $\mu_{\xi,\upsilon} \in \mathbb{R}^{m+n}$ und $\Sigma_{\xi,\upsilon} \in \mathbb{R}^{(m+n)\times(m+n)}$ und insbesondere

$$\mu_{\xi,\upsilon} = \begin{pmatrix} \mu_\xi \\ A\mu_\xi + b \end{pmatrix} \text{ und } \Sigma_{\xi,\upsilon} = \begin{pmatrix} \Sigma_{\xi\xi} & \Sigma_{\xi\xi}A^T \\ A\Sigma_{\xi\xi} & \Sigma_{\upsilon\upsilon} + A\Sigma_{\xi\xi}A^T \end{pmatrix}. \tag{A.43}$$

∘

Theorem A.14 (Marginale Normalverteilungen)**.** *Es sei $n := k + l$ und $\xi = (\xi_1, ..., \xi_n)^T$ sei ein n-dimensionaler normalverteilter Zufallsvektor mit Erwartungswertparameter*

$$\mu = \begin{pmatrix} \mu_\upsilon \\ \mu_\zeta \end{pmatrix} \in \mathbb{R}^n, \tag{A.44}$$

mit $\mu_\upsilon \in \mathbb{R}^k$ und $\mu_\zeta \in \mathbb{R}^l$ und Kovarianzmatrixparameter

$$\Sigma = \begin{pmatrix} \Sigma_{\upsilon\upsilon} & \Sigma_{\upsilon\zeta} \\ \Sigma_{\zeta\upsilon} & \Sigma_{\zeta\zeta} \end{pmatrix} \in \mathbb{R}^{n \times n}, \tag{A.45}$$

mit $\Sigma_{\upsilon\upsilon} \in \mathbb{R}^{k \times k}$, $\Sigma_{\upsilon\zeta} \in \mathbb{R}^{k \times l}$, $\Sigma_{\zeta\upsilon} \in \mathbb{R}^{l \times k}$, und $\Sigma_{\zeta\zeta} \in \mathbb{R}^{l \times l}$. Dann sind $\upsilon := (\xi_1, ..., \xi_k)^T$ und $\zeta := (\xi_{k+1}, ..., \xi_n)^T$ normalverteilte Zufallsvektoren der Dimension k bzw. l, und es gilt

$$\upsilon \sim N(\mu_\upsilon, \Sigma_{\upsilon\upsilon}) \text{ und } \zeta \sim N(\mu_\zeta, \Sigma_{\zeta\zeta}). \tag{A.46}$$

∘

Die Marginalverteilungen einer multivariaten Normalverteilung sind also auch Normalverteilungen und die Parameter der Marginalverteilungen ergeben sich aus den Parametern der gemeinsamen Verteilung. Für Beweise dieses Theorems verweisen wir auf Mardia et al. (1979) und Anderson (2003).

Theorem A.15 (Linear-affine Transformation eines normalverteilten Zufallsvektors)**.** $\xi \sim N(\mu_\xi, \Sigma_\xi)$ *sei ein normalverteilter n-dimensionaler Zufallsvektor und es sei*

$$\zeta := A\xi + b \text{ mit } A \in \mathbb{R}^{m \times n} \text{ und } b \in \mathbb{R}^m. \tag{A.47}$$

Dann gilt

$$\zeta \sim N(\mu_\zeta, \Sigma_\zeta) \text{ mit } \mu_\zeta = A\mu_\xi + b \in \mathbb{R}^m \text{ und } \Sigma_\zeta = A\Sigma_\xi A^T \in \mathbb{R}^{m \times m}. \tag{A.48}$$

∘

Die resultierende Normalverteilung kann degeneriert sein. Ist Σ_ξ positiv definit, so ist $A\Sigma_\xi A^T$ genau dann positiv definit, wenn A vollen Zeilenrang besitzt.

Für einen Beweis verweisen wir auf Anderson (2003).